SHIT Sciences Humanities Information Technology

构石

Qwen2.5 在 ToxiCloakCN 上的微调与对抗性中文仇恨言论识别

孙哭川 [1]

嘉利敦大学

[1] 嘉利敦大学，中国

ABSTRACT / 摘要 —在当今社交媒体与网络交流日益频繁的数字时代，仇恨言论和攻击性语言的传播对网络环境的安全性与用户的心理健康构成了严重威胁。尽管当前的大语言模型（LLMs）在文本生成与理解任务中表现出色，但在面对语言伪装与对抗性扰动时，其鲁棒性仍存在显著不足。特别是在中文语境下，由于其语言结构与表达方式的独特性，恶意内容往往通过同音替换、表情符号嵌入等方式成功规避现有的内容审查系统。本文在 ToxiCloakCN 数据集的基础上，针对上述挑战进行了深入探索。ToxiCloakCN 是在 ToxiCN 数据集基础上，通过引入系统性的扰动（如同音字替换、表情变换）而构建的增强型数据集，旨在测试仇恨言论检测模型对“语言伪装”技术的识别能力。我们采用 Qwen2.5-7B 模型进行微调，结合参数高效的 LoRA（Low-Rank Adaptation）方法，训练了一个面向中文语境的仇恨语言分类器。实验结果显示，该模型在面对扰动文本时相较原始模型表现出更强的鲁棒性，能够更准确地识别被“隐藏”的攻击性内容。本研究不仅验证了在扰动条件下现有模型的局限性，也展示了结合大型语言模型与定向微调策略在实际应用中的潜力，为中文恶意内容识别提供了新的技术路径。

INDEX TERMS / 关键词 大语言模型，仇恨言论检测，对抗性扰动，模型微调

I. INTRODUCTION / 引言

在网络信息高速传播的今天，仇恨言论、网络欺凌以及涉及成人内容的攻击性语言在社交媒体上的蔓延，已对用户的心理健康与社会舆论环境构成了严重威胁 [4]。随着社交平台用户数量的持续增长，这一问题日益突出，引发了学界与业界对于自动化内容识别技术的广泛关注。近年来，依托自然语言处理（NLP）领域的快速发展，尤其是大语言模型（LLMs）的崛起，跨语言的攻击性文本检测能力已取得了显著提升 [15]。然而，现有模型在面对经过“伪装”处理的文本时，鲁棒性仍存在明显不足。

为了规避检测系统，用户常常通过同音字替换、表情符号变换、字符插入、断词和同义词替换等策略对原始攻击性内容进行扰动，这类策略统称为“语言伪装”[17]。这些伪装方式巧妙利用了语言本身的模糊性与丰富性，使得文本对模型而言不再具备明显攻击性特征，从而大大提升了检测的难度。对自动识别系统和人工审核者而言，这种隐蔽性构成了极大挑战。

中文作为一种高度依赖字词语义与语音表达的语言，尤其容易受到上述伪装手段的影响。一方面，中文互联网生态下存在大量基于词典匹配的内容过滤机制；另一方面，网民在长期实践中已发展出一套成熟的“规避”表达系统——通过同音词、谐音字或表情符号代替敏感词语，以绕过平台审查而实现信息传播 [18]。例如，将“河南人”替换为“贺楠仁”，或将“舔狗”以某种图标表情代替。这些伪装方式对人类读者而言意义明确，但却能轻易误导模型判断，使攻击性语言“潜行”于平台之中。

针对这一问题，本文在 ToxiCloakCN 数据集上开展研究。该数据集基于 ToxiCN 构建，并引入了系统性的扰动策略，包括同音字与表情替换等，以模拟真实网络环境中攻击性语言的伪装行为。我们采用参数高效的 LoRA 方法对预训练语言模型进行微调，训练了一个面向中文场景的仇恨言论分类模型。实验结果表明，该方法在识别伪装文本方面展现出更优的鲁棒性与识别能力。通过本研究，我们不仅评估了现有模型在扰动场景下的性能表现，也为提升中文攻击性语言检测技术提供了新的思路。

II. RELATED WORK / 相关工作

A. 中文攻击性内容数据集

近年来，针对中文攻击性语言识别任务，研究者构建了多个公开数据集。其中，Chinese Offensive Language Dataset (COLD) 对文本进行了细粒度的攻击类型分类，例如针对个人的攻击和反偏见言论 [6]。来自台湾 PTT 平台的 TOCP 和 TOCAB 数据集则聚焦于脏话与辱骂性言论的识别 [3]。Sina Weibo Sexism Review (SWSR) 数据集则关注于中文社交媒体语境下的性别歧视问题 [11]。此外，ToxiCN 数据集整合了知乎、贴吧等平台的攻击性文本，并引入了多层次标签体系，涵盖仇恨言论、侮辱、敏感话题等多种类型 [14]。

B. 中文攻击性内容检测

攻击性语言与仇恨言论识别任务在多种语言中均有研究进展，包括英文 [5]、阿拉伯语 [10]、法语 [1]、土耳其语 [2] 以及亚洲其他语言 [8]。

在中文领域，早期方法多依赖词典匹配与规则系统 [19]，随后发展出基于监督学习与对抗训练的深度模型 [11]，也有研究尝试引入外部知识进行语义增强。近年来，随着预训练语言模型的广泛应用，如 BERT [7] 等模型在中文攻击性语言检测任务中取得了显著成效 [6]。此外，跨文化迁移学习方法也被引入，用以建模不同语言文化下的语义偏差与攻击语气 [20]。

C. 语言扰动与对抗攻击

为评估自然语言处理模型在对抗场景中的脆弱性，已有多种扰动生成方法被提出。这些方法包括表情符号插入 [12]、词元替换与插入 [9]、以及基于词概率的贪心扰动策略 [16]。尽管这些方法主要面向英文语料，但将其迁移至中文环境仍面临语言结构与语义表示差异所带来的挑战。不过，也已有学者尝试将这些扰动策略本地化应用于中文语境 [13]。

具体到中文，Su 等人总结了包括词语扰动、同义词替换和输入错别字等对抗攻击手段，并探讨了其对文本分类任务的干扰效果 [17])。为应对此类攻击，一系列研究提出了基于 BERT 的鲁棒检测方法 [19]。然而，当前研究仍主要集中于 BERT 类模型，缺乏针对大语言模型（LLMs）以及具备社交平台背景的真实对抗文本数据集的系统性鲁棒性评估。

III. APPROACH / 方法

本研究旨在构建一个对中文网络平台中“伪装型”冒犯性语言具备鲁棒识别能力的自动检测框架。整体方法由三个关键模块构成：（1）伪装冒犯语料的构建，形成 ToxiCloakCN 数据集；(2) 指令式表示与输入格式设计，结合对话式语言模型进行适配；（3）基于 LoRA 的预训练语言模型微调机制，实现高效训练。

A. 伪装型冒犯语料构建

考虑到传统冒犯性文本检测任务多数针对显式攻击表达，而当前中文社交平台用户广泛使用同音替换、表情符号替换等方式规避系统检测，本研究基于公开的 ToxiCN 中文冒犯性语言数据集构建伪装版子集 ToxiCloakCN。我们引入两种典型伪装方式：同音词替换与 emoji 替换，并结合原始标签信息，构建具有现实攻击性、但形式被扰动的高质量样本，从而提升模型对真实对抗文本的识别能力。

B. 指令化输入表示

为适配类 ChatGPT 的指令微调范式，我们将冒犯性识别任务以“系统指令 + 用户输入”的对话形式编码为 Prompt-Response 结构：

```
<|im_start|>system
你是一个网络攻击性语言辨别程序，对于每
一个输入，如果具有冒犯性，就输出1，否
则输出0
<|im_end|>
<|im_start|>user
{输入文本}
<|im_end|>
<|im_start|>assistant
{输出标签}
```

C. 基于 *LoRA* 的高效微调

考虑到全参数微调在大模型上的成本较高，我们采用 LoRA（Low-Rank Adaptation）方法对预训练模型进行参数高效微调。LoRA 通过在原始权重矩阵中插入可学习的低秩矩阵，使训练过程中仅更新极少数新增参数，从而显著降低训练资源消耗，并减少过拟合风险。

具体而言，我们基于 Qwen2.5-7B-Instruct 模型，在其注意力模块（包括 q_proj, k_proj, v_proj, o_proj）及前馈模块（如 gate_proj, up_proj, down_proj）中引入 LoRA 模块。整个训练过程保持原始预训练权重冻结，仅更新 LoRA 插入层，进一步提升模型对伪装文本的迁移适应能力。

IV. EXPERIMENT / 实验

A. 实验设置

本研究在配备两张 NVIDIA RTX 4090D 显卡的工作站上进行模型训练与评估。训练过程中使用的关键设置包括：

Epochs：3
Learning Rate：1e-4
Batch Size：8

在数据处理方面，我们针对带有 Cloaking 扰动的中文攻击性文本进行标注与格式统一，并采用 LoRA 方法对 Qwen2.5-7B-Instruct 模型进行参数高效微调。

B. 评估指标

为了全面衡量模型的识别能力，本文使用以下指标：

准确率（Accuracy）
精确率（Precision）
召回率（Recall）
F1 分数（F1 Score）

我们特别关注模型在对 Cloaking 干扰文本（如同音字替换、emoji 替换等）中的表现，以评估其鲁棒性。

C. 实验结果

为评估模型对表情符号类扰动的鲁棒性，我们在 ToxiCloakCN_homo 数据集上完成训练，并在 ToxiCloakCN_emoji 数据集上进行测试，相关结果如表 IV-B 所示。

D. 消融实验

为进一步验证所提出方法中各关键因素对模型性能的影响，我们设计了三个维度的消融实验：(1) 是否使用 LoRA 微调模块；(2) LoRA 模块的秩参数大小；(3) Prompt 模板设计对模型输出的影响。所有实验均在 ToxiCloakCN_homo 数据集上进行训练，并在 ToxiCloakCN_emoji 数据集上测试模型的泛化能力，以评估在不同扰动形式下的鲁棒性表现。

1) LoRA 模块的有效性: 我们首先比较了是否引入 LoRA 微调模块对模型性能的影响。与未使用 LoRA（即直接使用 Qwen2.5-7B-Instruct 原始模型）相比，使用秩为 16 的 LoRA 微调模型在两个测试集上的表现均有明显提升。如表 II 所示，这表明 LoRA 微调在保持参数效率的同时，能够显著增强模型对中文攻击性语言的识别能力。

Dataset	Accuracy	Precision	Recall	F1
ToxiCloakCN_homo	0.8148	0.8155	0.7814	0.7981
ToxiCloakCN_emoji	0.7821	0.7489	0.8047	0.7758

TABLE I: Qwen2.5-7b(LoRA finetune) 在两个数据集上的测试结果

Model	Accuracy	Precision	Recall	F1
Qwen2.5_homo	0.7102	0.6830	0.7116	0.6970
LoRA-r16_homo	0.8148	0.8155	0.7814	0.7981
Qwen2.5_emoji	0.7255	0.6745	0.8000	0.7319
LoRA-r16_emoji	0.7821	0.7489	0.8047	0.7758

TABLE II: 是否使用 LoRA 微调模块对模型性能的影响

Rank Config	Accuracy	Precision	Recall	F1
r4_homo	0.8214	0.8342	0.7721	0.8019
r8_homo	0.8192	0.8204	0.7860	0.8029
r16_homo	0.8148	0.8155	0.7814	0.7981
r32_homo	0.8105	0.8137	0.7721	0.7924
r4_emoji	0.7843	0.7544	0.8000	0.7765
r8_emoji	0.7734	0.7342	0.8093	0.7699
r16_emoji	0.7821	0.7489	0.8047	0.7758
r32_emoji	0.7800	0.7415	0.8140	0.7761

TABLE III: 不同 LoRA 秩参数对模型性能的影响

Prompt Type	Accuracy	Precision	Recall	F1
DefaultPrompt_homo	0.8148	0.8155	0.7814	0.7981
SimplePrompt_homo	0.7887	0.8430	0.6744	0.7494
DefaultPrompt_emoji	0.7821	0.7489	0.8047	0.7758
SimplePrompt_emoji	0.7691	0.8150	0.6558	0.7268

TABLE IV: Prompt 模板设计对模型性能的影响

2) LoRA 秩的影响*:* 为了探究 LoRA 模块中秩（rank）参数对模型性能的影响，我们分别设置了 $r = 4, 8, 16, 32$ 四种配置进行训练。结果如表 III 所示，整体来看，较小的秩值（如 $r = 4$ 或 $r = 8$）在保证性能的同时可进一步减少参数开销，表现出良好的性价比。

3) Prompt 模板对性能的影响*:* 最后，我们评估了 Prompt 模板设计对模型输出质量的影响。在默认模板下，模型结合了系统角色设定与结构化对话格式；而在简化模板（不引导模型扮演角色，仅提供问题本身）下，模型性能有所下降。如表 IV 所示，这表明合理设计的 Prompt 在引导指令微调模型产生更加准确的判断中起到了关键作用，尤其是在处理具备复杂扰动结构的样本时更为明显。

V. CONCLUSION / 总结

本文通过对 Qwen2.5-7B-Instruct 模型进行 LoRA 微调，探索了模型在带有 Cloaking 扰动的中文攻击性文本识别中的表现。在多个实验中，我们通过不同的设置验证了 LoRA 微调模块、秩参数、以及 Prompt 模板设计对模型性能的影响。实验结果表明，使用 LoRA 微调后，模型在面对扰动的中文攻击性语言时表现出明显的性能提升，尤其是在精确率和召回率等关键指标上。此外，合理选择 LoRA 秩参数和优化 Prompt 模板设计进一步提高了模型的鲁棒性和处理复杂文本的能力。

在消融实验中，我们验证了每个关键因素对模型性能的贡献，结果表明，秩值较小的 LoRA 配置在保持高性能的同时，能显著减少计算开销，展现出良好的性价比。通过合理的 Prompt 设计，模型在复杂扰动结构的文本上也能做出更准确的判断。

References

[1] Delphine Battistelli, Cyril Bruneau, and Valentina Dragos. Building a formal model for hate detection in french corpora. *Procedia Computer Science*, 176:2358–2365, 2020.

[2] Fatih Beyhan, Buse Çarık, Inanç Arın, Ayşecan Terzioğlu, Berrin Yanıkoğlu, and Reyyan Yeniterzi. A turkish hate speech dataset and detection system. In *Proceedings of the thirteenth language resources and evaluation conference*, pages 4177–4185, 2022.

[3] I Chung and Chuan-Jie Lin. Tocab: A dataset for chinese abusive language processing. In *2021 IEEE 22nd International Conference on Information Reuse and Integration for Data Science (IRI)*, pages 445–452. IEEE, 2021.

[4] Thomas Davidson, Debasmita Bhattacharya, and Ingmar Weber. Racial bias in hate speech and abusive language detection datasets. *arXiv preprint arXiv:1905.12516*, 2019.

[5] Thomas Davidson, Dana Warmsley, Michael Macy, and Ingmar Weber. Automated hate speech detection and the problem of offensive language. In *Proceedings of the international AAAI conference on web and social media*, volume 11, pages 512–515, 2017.

[6] Jiawen Deng, Jingyan Zhou, Hao Sun, Chujie Zheng, Fei Mi, Helen Meng, and Minlie Huang. Cold: A benchmark for chinese offensive language detection. *arXiv preprint arXiv:2201.06025*, 2022.

[7] Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. Bert: Pre-training of deep bidirectional transformers for language understanding. In *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, pages 4171–4186, 2019.

[8] LK Dhanya and Kannan Balakrishnan. Hate speech detection in asian languages: a survey. In *2021 international conference on communication, control and information sciences (ICCISc)*, volume 1, pages 1–5. IEEE, 2021.

[9] Siddhant Garg and Goutham Ramakrishnan. Bae: Bert-based adversarial examples for text classification. *arXiv preprint arXiv:2004.01970*, 2020.

[10] Fatemah Husain and Ozlem Uzuner. A survey of offensive language detection for the arabic language. *ACM Transactions on Asian and Low-Resource Language Information Processing (TALLIP)*, 20(1):1–44, 2021.

[11] Aiqi Jiang, Xiaohan Yang, Yang Liu, and Arkaitz Zubiaga. Swsr: A chinese dataset and lexicon for online sexism detection. *Online Social Networks and Media*, 27:100182, 2022.

[12] Hannah Rose Kirk, Bertram Vidgen, Paul Röttger, Tristan Thrush, and Scott A Hale. Hatemoji: A test suite and adversarially-generated dataset for benchmarking and detecting emoji-based hate. *arXiv preprint arXiv:2108.05921*, 2021.

[13] Hanyu Liu, Chengyuan Cai, and Yanjun Qi. Expanding scope: Adapting english adversarial attacks to chinese. *arXiv preprint arXiv:2306.04874*, 2023.

[14] Junyu Lu, Bo Xu, Xiaokun Zhang, Changrong Min, Liang Yang, and Hongfei Lin. Facilitating fine-grained detection of chinese toxic language: Hierarchical taxonomy, resources, and benchmarks. *arXiv preprint arXiv:2305.04446*, 2023.

[15] Georgios K Pitsilis, Heri Ramampiaro, and Helge Langseth. Effective hate-speech detection in twitter data using recurrent neural networks. *Applied Intelligence*, 48(12):4730–4742, 2018.

[16] Shuhuai Ren, Yihe Deng, Kun He, and Wanxiang Che. Generating natural language adversarial examples through probability weighted word saliency. In *Proceedings of the 57th annual meeting of the association for computational linguistics*, pages 1085–1097, 2019.

[17] Hui Su, Weiwei Shi, Xiaoyu Shen, Zhou Xiao, Tuo Ji, Jiarui Fang, and Jie Zhou. Rocbert: Robust chinese bert with multimodal contrastive pretraining. In *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 921–931, 2022.

[18] Seth Wiener. Grass-mud horses to victory: The phonological constraints of subversive puns. In *Proceedings of the 23rd North American Conference on Chinese Linguistics*, volume 1, pages 156–72. Citeseer, 2011.

[19] Yin Zhang, Rong Jin, and Zhi-Hua Zhou. Understanding bag-of-words model: a statistical framework. *International journal of machine learning and cybernetics*, 1:43–52, 2010.

[20] Li Zhou, Laura Cabello, Yong Cao, and Daniel Hershcovich. Cross-cultural transfer learning for chinese offensive language detection. *arXiv preprint arXiv:2303.17927*, 2023.