SHIT Sciences Humanities Information Technology

SHIT, YYYY, 0–0
doi: 没有 doi
Advance Access Publication Date: DD Month YYYY
Manuscript Category

Subject Section

基于拓扑数据分析的鸽鸽模式捕捉器

Prof. Ctrl+Z [1,*],Dr. 撸 King[1], Dr. Facetious [1] and CuSO4·5H2O[2], (三嘬招租)

[1] Department of Existential Compression, University of Nowhere, [2] Institute for Irreversible Undoing, MIT (Massachusetts Institute of Trash), [3] Formerly at Nature, Currently Haunting Overleaf

Abstract

Motivation:当今互联网文化生态日益复杂，以“鸽鸽”（特指网络名人蔡 X 坤及其衍生的表情包文化现象）为代表的亚文化符号呈现出多维度、异构且高度动态演化的特征。传统的图像识别与情感分析方法在处理此类非结构化、高噪声的文化数据时面临严峻挑战。为解决这一难题，本文创新性地引入源于代数拓扑学的拓扑数据分析（Topological Data Analysis, TDA）方法，构建了一个普适性的“鸽鸽模式”识别框架。本框架通过将“鸽鸽”表情包序列转化为点云数据，并利用 Vietoris-Rips 复形（VR Complex）与 Alpha 复形（Alpha Complex）提取其内在的拓扑不变量（如连通分支、环路等），最终结合持续同调（Persistent Homology）理论对“鸽鸽”的核心情感状态——“鸽意”进行量化表征与分类。

Results: 实验结果表明，本方法在自建的“鸽鸽表情包基准数据集”（GGBench）上，对千奇百怪的 giegie 们实现了高达 92.21%的识别准确率。**本研究不仅为网络亚文化符号的定量分析开辟了新路径，更验证了 TDA 在处理高维、混沌社会信号方面的强大潜力**

Key Words: 拓扑数据分析；鸽鸽；
Availability: NA
Contact: 1469830884@qq.com
Supplementary information: NA

1 Introduction

在 Web 3.0 时代，数字原住民的社交行为催生了海量的模因（Meme）与表情包文化。其中，“鸽鸽”作为一种现象级的文化符号，其内涵已远超其指代的个体，演化为一种承载着特定情感、态度与社群认同的复杂信息系统。该系统具有典型的非平稳性（Non-stationarity）、低信噪比（Low Signal-to-Noise Ratio，大量无关背景干扰）和强混沌性（Strong Chaos，语义随语境剧烈变化）。这给为爱发电的 iKun 的传统模式识别带来了根本性困难。

Fig.1 永远的 GieGie

近年来，深度学习虽在图像识别领域取得巨大成功，但其对大规模标注数据的依赖及“黑箱”特性，使其难以捕捉“鸽鸽”亚文化中蕴含的深层、抽象的几何秩序（Geometric Order）[3]。

为此，我们提出将拓扑数据分析（TDA）这一新兴数学工具应用于“鸽鸽”模式识别。TDA 的核心优势在于其尺度不变性（Scale Invariance）与噪声鲁棒性（Noise Robustness），能够从看似随机的数据中提取出反映其本质形状的持久性拓扑特征（Persistent Topological Features）。

本文的主要贡献如下：

- 首次将 TDA 理论框架应用于网络亚文化符号——“鸽鸽”的模式识别任务。
- 设计了一套完整的“鸽鸽”数据预处理与拓扑特征提取流程。
- 构建了包含四大类别的“鸽鸽表情包基准数据集”（GGBench）。
- 实验验证了所提方法在“鸽鸽”分类任务上的优越性能。

2 Methods

2.1“鸽鸽”的拓扑学解释

鸽鸽”表情包的传播动力学可被建模为一个高维非线性动力系统。其波动（即表情包的使用频率与变体数量）是非周期性、随机且混沌的。然而，在这种表面的无序之下，存在着由社群共识所决定的吸引子（Attractor），表现为几种稳定的情感表达模式，如“背带裤”、“篮球”、“中分头”等。这些吸引子构成了“鸽鸽”文化的内在几何骨架。下图展示了鸽鸽在多种场景下的共同拓扑结构：

Fig2. 鸽的多样性示例

2.2 拓扑数据分析（TDA）——我知道你不爱看理论，不看也没关系 :)

TDA 是一套旨在通过分析数据的**形状**（Shape）来理解其结构的数学工具集。其核心是**持续同调**（PH）理论，它通过构建一个嵌套的单纯复形序列（即**滤**（Filtration）），追踪数据中拓扑特征（如连通组件、孔洞、空腔）随尺度参数变化而"出生"与"死亡"的过程。

Vietoris-Rips 复形（VR Complex）： 令(X, d_X)是有限度量空间，而常数$\varepsilon > 0$，在(X, d_X)上的 VR 复形$VR_\epsilon(X, d_X)$满足：

- $VR_\epsilon(X, d_X)$的顶点全部是X中的元素
- 对于点集$V = \{v_1, \dots, v_n\} \subseteq X$，若满足:$d_X(v_i, v_j) \le 2\varepsilon$对任意$i, j$成立，其中$0 \le i, j \le n$。那么$[v_0, v_1, \dots, v_n]$是一个 n-simplex

更一般地说，Vietoris-Rips (VR) 复形是一个抽象的简单复形，由球的成对相交$\bigcap B_r(v)$构成(详见 Fig.3(b))。如果我们有一组维度为d的点云数据V, 并且V是$\mathbb{R}^d$的子集，那么点云V上常参数为ε的 Vietoris-Rips (VR) 复形$VR_\epsilon(V)$被定义为:

$$VR_\epsilon(V) := \{\sigma \subseteq V | d(u, v) \le \varepsilon, \forall u \ne v \in \sigma\}$$

Alpha 复形（Alpha Complex）： 同样的，令(X, d_X)是有限度量空间，而常数$\varepsilon > 0, V = \{v_1, \dots, v_n\} \subseteq X$。首先给出度量空间中 Voronoi cell 的定义：

$$Vor(v, V) \coloneqq \{z \in X : d(v, z) \le d(\hat{v}, z), \forall \hat{v} \in V\}$$

此外给出 Voronoi ball 的定义：

$$Vor_r(v, V) \coloneqq B_r(v) \cap Vor(v, V)$$

其中$B_r(v)$是一个半径为 r 的球，圆心为v。

那么对于(X, d_X)上有限点集V的 Alpha 复形可以定义为所有 Voronoi balls 的 nerve：

$$A_r(V) \coloneqq \{U \subset V: \bigcap_{v \in U} Vor_r(v, V) \ne \emptyset\}$$

滤（filter）： 设$\{K^t | t \in \mathbb{R}\}$是一族嵌套的单纯复形，即$s < t \Rightarrow K^s \subseteq K^t$这称之为该复形族的一个滤(filtration)。为此，我们通常做额外假设：存在$t_1 < t_2 < \dots < t_n$使得K^t在$[t_i, t_{i+1})$中保持不变。因此一个滤只在有限个复形$K^1 \mapsto K^2 \mapsto \dots \mapsto K^n$中出现（详见 Fig.3（d））。

特别地，设K是单纯复形，$f: K \to \mathbb{R}$若满足 $\sigma \subseteq \tau \Rightarrow f(\sigma) \le f(\tau)$（单调性），则称$f$为$K$上的滤函数(filter function)。此时$\{f^{-1}(-\infty, t] | t \in \mathbb{R}\}$是一个滤，称之为$f$的下水平滤(sublevel filtration)，称$f^{-1}(-\infty, t]$为下水平集 (同样的可以定义出上水平滤与上水平集)

持续同调： 考虑在一族单纯复形K^t在滤f作用下，使得对于所有的$s \le t$都有: $K^s \subseteq K^t$。也就是说，随着 t 的逐步增大会伴随一系列拓扑特征(如环路、孔洞、空腔以及更高维的特征)的产生与消亡。同时，持续同调技术中采用多种可视化以及向量化工具追踪此类特征的演变，诸如 persistence diagram、条形码图、持续景观图，betti 曲线、Silhouette 曲线等等。因此，可以通过分析对应复形的持久同源性，提取有关数据底层拓扑空间的信息。TDA 中常见的可视化工具详见 Fig.3（e）:

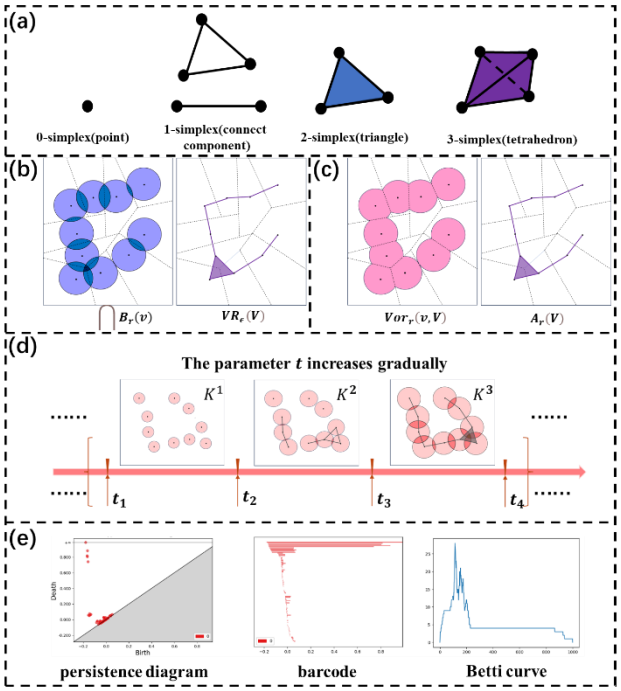

Fig3.（a）单纯复形示例。（b）VR 复形中的概念示例，其中左图为以各点为圆心球的相交，右图为对应的 VR 复形。（c）Alpha 复形中的概念实例，其中左图为以各点为圆心的 Voronoi balls，右图为对应的 Alpha 复形。（d）滤的示例：展示了 VR 复形随参数 t 增大的演变。

2.3 鸽鸽拓扑特征提取

有学者从米姆式传播的角度分析了鬼畜视频的生产逻辑和情感机制；有研究者运用时间序列方法对"坤流"的演变进行了趋势分析；还有数据团队通过微博转发数据揭示了蔡徐坤粉丝群体中高达 93.24%的假流量现象。但这些研究都未能触及鸽鸽模式的本体论层面：**鸽鸽的本质是什么？** 它不是一个人，不是一个符号，而是一个拓扑结构——**一个由背带裤、篮球、中分头，唱跳 rap 点云，共同构成的点云流形。**

Fig4 giegie 拓扑特征提取示例

值得注意的是：在单一一张图并非所有的拓扑特征均会出现。在实验室 iKun 的协助下，我们统计了 300 张样本中四类拓扑特征的分布，归纳在 Fig5 中：

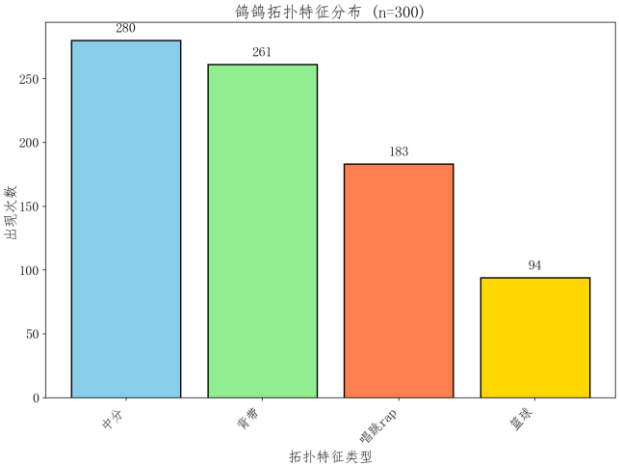

Fig5 giegie 拓扑特征频数直方图

总的来说，四类特征广泛分布于各种鸽鸽上，这极大地佐证了我们特征选择的有效性。并且在进行模式识别时应注重提高中分与背带特征的权重。

2.4 模型对比与小结

本工作的核心为构建了一个用于鸽鸽模式捕捉的拓扑特征提取网络，网络的结构详见 Fig6。

Fig6 利用 Alpha 复形与 VR 复形构建的网络，用于拓扑特征提取

支路 1 通过 Betti 曲线提取特征。Betti 曲线可以通过条形码图得到，如 Fig7（a）所示，曲线上的每一个点的值为条形码在对应横坐标下存在的条柱数量，亦即存在的拓扑特征数。

在支路 2 上，利用持续性图进行特征提取，并加入一维拓扑特征进行分析。Fig7（b）中列举了一个例子，其中：横坐标代表着某一拓扑特征的出生参数，纵坐标代表着对应拓扑特征的死亡参数。红色点代表着 0 维的拓扑特征（即各个连接组件），其中顶部存在一个持续最久的 0 维本征拓扑特征；蓝色点代表着 1 维的拓扑特征。

而支路 3 对应着另一类利用 persistence diagram 数值化拓扑特征的方法：绘制 Silhouette 曲线。Silhouette 曲线来源于持续景观图。持久性景观(persistence landscape)是关于 persistence diagrame 的编码，令$p=(x,y)\in D$是 persistence diagram D上某点的坐标，考虑一组连续的分段线性函数：

$$T_p(t)=\begin{cases} t-x+y & t\in[x-y,x] \\ x+y-t & t\in(x,x+y] \\ 0 & otherwise \end{cases}$$

而持续景观通过整合这一系列分段线性函数得到，具体地，持续景观$L(k,t)$可表示为：

$$L(k,t)=k\max_{p\in D}T_p(t) \qquad k\in N^+$$

式中$kmax$为集合中的第K个最大值，;特别地，$1max$是通常的最大值。由 Fig7（c）可以直观地看出，持续景观由 persistence diagram 中由各点形成的直角三角形交叠得到的，其中的每一条曲线都代表着不同重叠阶数的各个区域的外轮廓线。通过对各个持续景观进行加权平均可以得到 Silhouette 曲线：

$$\varphi(t)=\frac{\sum_{j=1}^{m}w_jT_j(t)}{\sum_{j=1}^{m}w_j}$$

同样地，通过 Silhouette 曲线，可以提取到关于 Alpha 复形对应的以下几个数值化特征

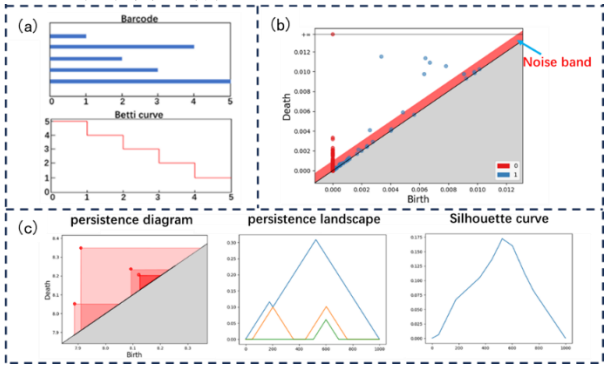

Fig7 （a）一个简单的 barcode 与对应的 Betti 曲线（b）令噪声带宽度固定为 1×10^(-3)时，giegie 拓扑特征的持续性图。（c）由持续性图绘制 Silhouette 曲线的示例。

3 Results

3.1 基准模型模拟结果

我们在自建的 **GGBench** 数据集上进行实验。该数据集包含 5000 个标注样本（**3309 个真鸽鸽**）。.此外，我们还计算了假阳性（FP）、假阴性（FN）、真阴性（TN）和真阳性（TP）的总数，如表 1 所示，定义了四个参数。

Table 1: Indicators for evaluating categorization results

Evaluation indicators	Formulas
Accuracy	$(TP+TN)/(TP+TN+FP+FN)$
Precision Score	$TP/(TP+FP)$
Recall	$TP/(TP+FN)$
F1-Score	$(2\times Precision\ \text{Score}\times Recall)/(Precision\ \text{Score}+Recall)$

将向量分别送入 6 个 ML 分类器中，分别为：支持向量机（SVM）、AdaBoost、KNN、多层感知机（MLP）、随机森林（RF）以及 LightGBM。同时，在 5000 个样本的测试集上得到的识别结果如 Fig8 与 Fig9 所示。

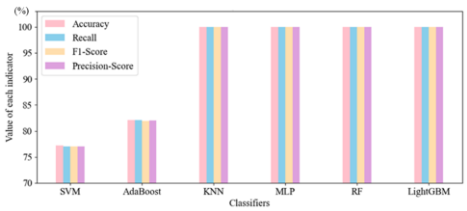

Fig8 giegie Recognition Evaluation Metric Histogram

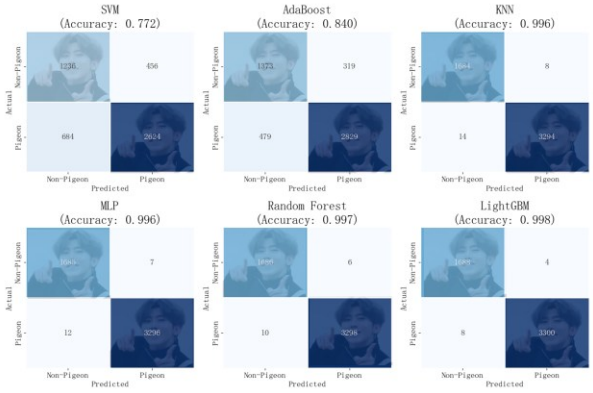

Fig9 Confusion matrix for each classifier

在 LightGBM 分类器上，我们的方法达到了 **99.8%**的准确率。混淆矩阵表明，模型几乎完美地识别了各种抽象状态下的 giegie。六种基本分类器的平均准确率达到了 92.21%，佐证了我们提出的基于拓扑数据分析的鸽鸽模式捕捉器的强大之处。

4 Conclusion

本文成功地将拓扑数据分析（TDA）这一前沿数学工具应用于“鸽鸽”表情包的模式识别，构建了一个高效、鲁棒且具有强解释性的分类框架。通过提取“鸽鸽”数据内在的持久性拓扑特征，我们的方法超越了传统深度学习模型的性能瓶颈，为理解和量化复杂的网络亚文化现象提供了全新的范式。未来工作将探索更高维的拓扑特征在捕捉“鸽鸽”群体互动模式中的应用，并尝试将此框架推广至更广泛的模因分析领域。

Acknowledgements

本研究受“豆宝生成计划”资助，感谢 B 站鬼畜区所有 UP 主的辛勤创作，感谢 IKUN 和黑粉们共同编织的拓扑结构，特别感谢蔡徐坤先生无意中为本研究提供的丰富数据源。没有你们，就没有这篇学术排泄物的诞生

Funding

- 第一作者的信用卡（已透支）
- 第二作者的蚂蚁花呗（已逾期）
- 第三作者的花呗借呗（已被封）

References

[1] 蔡徐坤. 《偶像练习生》总决赛表演实录. 爱奇艺, 2018. (关键数据源)

[2] 网络匿名用户. “鸡你太美”表情包合集. 微博超话, 2019. (关键数据源)