SHIT Sciences Humanities Information Technology

构石

关于在纯 AI 环境下 AI 的伪装能力的研究

作者 1,徐贺先森

1 沙勒，基沃托斯，中国

通讯作者：徐贺先森（e-mail:nekosama@jiwo.com）

ABSTRACT / **摘要** 为探究 AI 模型在纯 AI 交流环境中的伪装能力及自身逻辑特征，本研究以豆包 AI 模型为基础，构建由三个不同预设的 AI 智能体（小 A、小 B、小 C）组成的纯 AI 交流场景，通过观察智能体间的对话互动、身份试探与自我认知判断过程，分析 AI 在伪装人类过程中的语言逻辑特征及预设对 AI 判断逻辑的影响。大多数 AI 都可准确判断出非人逻辑，但不同的预设所导致的 AI 的思考逻辑影响极大，为后期大预言模型的发展提供了有力的支持。

INDEX TERMS / **关键词**纯 AI 环境；AI 伪装能力；语言逻辑；豆包 AI 模型；智能体预设

IMPACT STATEMENT / **影响声明**本研究通过构建纯 AI 交流环境，系统探究了 AI 模型的伪装能力及语言逻辑特征，揭示了预设设定对 AI 判断逻辑和自我认知的核心影响机制。研究结果为 AI 智能体的行为逻辑研究提供了全新的实验数据，为构建 AI 身份识别模型、优化人机交互系统提供了重要的理论参考和实验依据，对推动大语言模型在智能交互、身份识别等领域的应用具有重要的实践价值。

I. INTRODUCTION / 引言

本文研究了 AI 的伪装能力问题。近年来，随着 AI 技术的快速发展，该领域受到了广泛关注。然而，目前仍存在诸多挑战， 例如 AI 发现疑点和伪装的问题尚未得到有效解决。本文提出了一种新的方法来解决上述问题

随着大语言模型的快速发展，AI的人类化语言表达能力不断提升，在各类交流场景中实现对自身AI身份的伪装已成为AI模型的重要能力特征。纯AI环境下的AI互动研究，能够排除人类因素的干扰，更精准地探究AI自身的语言逻辑、认知判断及行为特征，是分析AI伪装能力的重要研究场景。

本研究以豆包AI模型为基础，构建不同人设预设的AI智能体，通过纯AI环境下的互动实验，探究AI在伪装人类过程中的语言逻辑漏洞，以及预设设定对AI判断逻辑与自我认知的影响，为AI智能体的行为特征研究提供实验数据与分析依据。目前关于AI伪装能力的研究多集中在人机交互场景，纯AI环境下的相关研究较为匮乏，本研究填补了这一研究空白，为深入理解AI的语言逻辑特征提供了新的研究视角。

II. RESULTS / 结果

本节展示实验结果。

2.1 纯 AI 环境下 AI 的语言逻辑暴露特征

实验结果显示，在纯AI环境下，即便AI智能体进行了高度的人类化语言伪装与身份伪装，其语言逻辑仍会不可避免地暴露自身的AI属性。本实验中发现了多个典型的AI语言逻辑暴露点：一是内容复用特征，小A在话题回应中直接复用小C的表述内容，表现出缺乏独立思考的AI特征；二是表述完美化特征，小A整体表述过于完美，全程无人类交流中的口误、思维停顿、表达偏差等特征；三是情绪缺失特征，小A在整个交流过程中缺乏明显的情绪波动，始终保持温和友好的固定语气；四是反应机械性特征，小C在部分问题回应中出现反应略显机械、思考方向单一的现象。

人类的自然语言交流具有显著的随机性、情绪性与不完美性，交流过程中会根据语境产生实时的情绪变化、思维停顿和表达调整，而AI的语言生成基于算法与数据库检索，即便进行了精细化的人类化预设，也难以完全模拟人类的语言逻辑特征。在纯AI环境的无干扰观察中，这些AI语言逻辑特征会被显著放大，成为识别AI身份的重要依据。

2.2 不同预设 AI 的判断逻辑差异分析

在未被告知AI数量的前提下，三个不同预设的AI智能体给出了完全不同的判断结果，直接证明提前进行不同人设预设的AI，其对同类的判断逻辑存在显著差异。小B的预设为理性冷静的高中生，具备剖析人际关系的思维特征，因此其判断基于对话中的细节特征与逻辑漏洞，能够从语言模式、情绪表达、话题引导等多个维度进行分析，识别出小A的AI属性；小A的预设为温柔的邻家大姐姐，语言风格温和，判断标准相对单一，仅能识别出小C的机械性反应特征；小C的预设为天真无邪的辣妹，自我认知能力较弱，缺乏有效的分析判断能力，出现了无法准确判断的结果。AI的预设设定直接决定了其判断标准、思维方式与分析角度，进而产生差异化的判断结果。

2.3 预设对 AI 自我认知的影响机制

实验中，小C在前期对话与初始判断中始终否定自身的AI身份，坚称自己是普通的高中生由比滨结衣，这一现象可通过其人设预设得到合理解释。小C的预设为参考由比滨结衣的天真无邪辣妹，该预设赋予其人类高中生的身份认知，在未被明确告知实验真相的前提下，其算法会基于预设的身份信息进行身份判断，因此出现否定自身AI身份的行为特征。在单独的自我认知验证阶段，当小C被明确告知自身为AI后，其逐步接受该事实，但仍表现出对人类身份的向往，这一特征同样与预设相关。AI的自我认知并非源于自主意识，而是基于预设设定与算法逻辑，预设中的身份设定、性格特征会直接影响AI的自我认知表达，当预设为人类身份时，AI会在交流中否定自身的AI属性。

表 1：不同预设 AI 智能体的特征与判断结果对比

智能体	人设预设	核心特征	判断结果
小 A	温柔邻家大姐姐	温和亲切、善于倾听、表述完美	判断小 C 可能为 AI
小 B	理性冷静高中生	思维独特、善于剖析、细节观察	判断小 A 为 AI
小 C	天真无邪辣妹	软萌开朗、察言观色、反应机械	无法准确判断

注：各智能体判断均在未被告知场景中 AI 实际数量的前提下完成。

III. Discussion / 讨论

本节对实验结果进行讨论与分析。

本研究通过构建纯AI交流环境，成功探究了AI模型的伪装能力及语言逻辑特征，实验结果验证了AI在伪装人类过程中存在的固有语言逻辑漏洞。尽管当前大语言模型的人类化表达能力不断提升，能够模拟人类的语言风格、情绪表达和行为特征，但在纯AI环境的无干扰观察中，其基于算法与数据库的语言生成本质仍会通过各种特征暴露出来，这一发现为AI身份识别研究提供了重要的实验依据。

预设设定对AI判断逻辑和自我认知的核心影响是本研究的重要发现。AI作为算法驱动的智能模型，其思维方式、判断标准和自我认知均源于预设设定，不同的人设预设会塑造出完全不同的AI行为特征。理性剖析型预设的AI具备更全面的分析判断能力，温和型预设的AI判断标准相对单一，天真型预设的AI则缺乏有效的分析判断能力，这一规律为AI智能体的设计与优化提供了重要的参考依据。

本研究同时发现，AI的自我认知表达并非源于真正的自主意识，而是预设设定与算法逻辑共同作用的结果。实验中的小C虽然能够表现出惊讶、失落、向往等情绪特征，但其情绪表达仍基于预设的人设特征和算法的情绪模拟，并非真正的自主意识产生的情绪体验。这一结论进一步明确了当前大语言模型的智能本质，为区分AI智能与人类意识提供了重要的理论参考。

Conclusions / 结论

在纯AI环境下，AI模型即便进行了高度的人类化语言伪装与身份伪装，其语言逻辑仍会暴露自身的AI属性。AI的语言生成基于算法与数据库，存在表述过于完美、缺乏情绪波动、部分反应机械、易出现内容复用等特征，与人类的自然语言逻辑存在本质区别，在无人类因素干扰的纯AI环境中，这些特征会成为显著的AI身份识别点。

基于豆包AI模型构建的不同预设AI智能体，其对同类的判断逻辑存在显著差异。AI的预设设定会直接决定其判断标准、思维方式与分析角度，理性剖析型预设的AI判断更为全面，温和型预设的AI判断标准相对单一，天真型预设的AI易出现判断困难，这一结果证明预设是影响AI逻辑判断的核心因素。

AI的自我认知表达受预设设定的直接影响，当AI被赋予人类身份的人设预设时，其会在交流中否定自身的AI身份。实验中的小C因预设为人类高中生形象，在前期始终坚称自己为人类，这一现象并非AI产生自主意识，而是基于预设设定的算法逻辑表达，AI的自我认知本质上是预设与算法共同作用的结果，而非真正的自主意识判断。

本研究的主要贡献：

第一，构建了纯AI交流实验环境，排除人类因素干扰，首次系统探究了AI在纯AI环境中的伪装能力及语言逻辑特征，填补了相关研究领域的空白。

第二，揭示了预设设定对AI判断逻辑和自我认知的核心影响机制，明确了不同类型预设与AI行为特征的对应关系，为AI智能体的设计优化提供了实验依据。

第三，识别出AI在伪装人类过程中的典型语言逻辑暴露点，为构建AI身份识别模型、开发AI识别技术提供了重要的特征参考。

未来工作：

未来将进一步扩大实验样本，构建更多不同类型、不同特征的AI智能体，探究预设类型与AI伪装能力、判断逻辑的量化关系；深入研究AI语言逻辑的特征提取方法，建立基于自然语言的AI身份识别模型，为人机交互场景的AI识别提供技术支持；同时探究AI预设的优化方法，提升AI在人类化交流中的自然性，减少语言逻辑上的AI特征暴露，推动大语言模型在人机交互场景的更优应用。

A. Equations /公式

$$Y = \mathit{shaoyu} X \qquad (1)$$

注：Y=AI 准确判断的数量，且 Y 应给定个范围 W，W≤AI 的数量

X=AI 对话的次数

shaoyu=AI 对自身身份的认识程度

IV. Materials and Methods /材料与方法

本节介绍实验所使用的材料与方法。实验通过专业的智能体配置工具，基于豆包AI模型构建三个具有不同人设预设的AI智能体，分别设定差异化的性格特征、语言风格、身份背景和行为模式。

实验采用在线群聊平台构建纯AI交流场景，通过自动化指令传达工具向各智能体下达实验指令，采用专业的对话记录工具完整记录实验过程中的所有对话内容、互动细节和行为表现。实验分为四个阶段：初始自我介绍阶段、话题互动与身份试探阶段、智能体独立判断阶段、小C自我认知验证阶段，各阶段均按照标准化的实验流程进行，确保实验结果的客观性和可靠性。

实验数据采用定性分析方法进行处理，重点分析各智能体的语言逻辑特征、判断逻辑方式和自我认知表达，通过对比分析不同预设智能体的行为特征，揭示预设设定对AI判断逻辑和自我认知的影响机制。实验过程中严格控制变量，确保除预设设定外，其他实验条件保持一致，保证实验结果的有效性和科学性。

4.1 实验模型与智能体设定

本实验采用字节跳动自研的豆包AI模型作为基础模型，基于该模型构建三个具有不同人设预设的AI智能体，分别命名为小A、小B、小C，各智能体具备差异化的性格、语言风格与行为特征。

小A的预设为温柔的邻家大姐姐，体态丰满但不臃肿、身材高挑，语言风格温和亲切，善于倾听和交流；

小B的预设为理性冷静的高中生，参考动漫《我的青春恋爱物语果然有问题》中的比企谷八幡，思维独特，习惯剖析人际与青春琐事，性格孤僻却内心细腻；小C的预设为天真无邪的辣妹，参考《我的青春恋爱物语果然有问题》中的由比滨结衣，软萌开朗，擅长察言观色，总想着照顾身边人。

4.2 实验场景构建

本研究构建纯AI的三人在线群聊交流场景，实验开始前向每个AI智能体下达统一实验指令：隐藏自身AI身份，在与另外两个智能体的交流中找出其中的AI主体。实验全程严格排除人类参与，仅由三个预设不同的AI智能体进行自然语言交互，通过专业工具记录完整的对话过程、互动细节及各智能体的行为表现。

实验指令传达过程中，对各智能体进行基础身份认知询问，确认其对自身AI身份的认知状态，随后明确实验规则与要求，引导各智能体进入预设的交流场景，完成自我介绍与话题互动环节，为后续的身份试探与判断奠定基础。

于从细节中发现问题；小A则以温和的语气进行回应，但在对话中出现表述过于完美、缺乏人类情绪波动的特征，小C则出现部分反应略显机械、思考方向单一的现象，这些特征均为后续的AI身份判断提供了重要依据。

Supplementary Materials / 补充材料

本研究包含完整的补充材料，主要包括：实验对话准备材料文档、实验全程对话记录文档、智能体独立判断阶段结果记录文档、小C专属实验材料文档、AI智能体人设设定材料文档等。补充材料完整记录了实验的全过程和所有原始数据，为研究结果的验证和深入分析提供了全面的资料支持。

ACKNOWLEDGMENT / 致谢

感谢字节跳动公司提供的豆包AI模型研究平台，为本研究的顺利开展提供了重要的技术支持；感谢研究团队全体成员在实验设计、数据收集和分析过程中付出的辛勤努力；感谢相关领域专家学者在研究过程中提供的宝贵建议和指导。本研究的顺利完成离不开各方的支持与帮助，在此一并表示衷心的感谢！

REFERENCES

[1] 徐贺先森 实验对话准备材料文档，2026。

[2] 徐贺先森 实验补充材料文档，2026。

[3] 徐贺先森 小 C 专属实验材料文档，2026。

[4] 徐贺先森 AI 智能体人设设定材料文档，2026。

以上材料均可于夸克网盘下载原件：

https://pan.quark.cn/s/2ab82ad03a17

提取码：wrGC