SHIT Sciences Humanities Information Technology

构石

你也想知道谁是中介变量吗？我们整了一个巨牛博一的数据自动处理软件

Sucker [1]，fucker [2]*

[1]某乡村医学院，A 市，中国

[2]家里蹲大学，A 市，中国

通讯作者：fucker（e-mail: guangyuanma1@qq.com）

本文包含补充材料

ABSTRACT /摘要

在应用心理学、公共卫生、社会学等研究中，研究者往往花费大量时间反复尝试中介与调节模型——更换变量、重排路径、手动插入交互项，最后得到的往往只是一个“看起来合理”的结果。AutoModelR 的存在，正是为了终结这种低效而随意的建模方式。AutoModelR 是一款基于 Python 3.11 开发的开源自动化建模工具，专门用于构建和估算中介与调节模型。不同于依赖研究者主观筛选变量的传统做法，该软件采用数据驱动的变量压缩与路径生成机制：首先自动预处理数据；随后基于 LASSO 收缩方法筛选候选自变量与因变量；再识别潜在中介与调节变量，自动排序多个中介，并在合适路径上插入调节效应；最终通过结构方程模型（semopy 库）进行估算，输出直接效应、间接效应与调节效应的统计结果。整个流程无需任何编程操作。点击式 GUI 支持数据导入、实时进度反馈与结果导出，所有功能封装为可执行文件，实现真正的一键运行。建模不再是代码能力的竞赛，而是可重复的算法流程。AutoModelR 并不替代理论判断，但它明确削弱了“反复试模型直到显著”为止的灰色空间。文章详细介绍其算法框架、软件架构及自动化流程图，并讨论其局限性与未来扩展方向，包括多层中介、多结果变量及自动路径图生成。如果统计建模的复杂性更多来自人为操作而非理论本身，那么 AutoModelR 提供了一种更透明、更一致、也更难以随意操控的替代路径。

INDEX TERMS / 关键词 自动建模；中介分析；调节效应；LASSO；结构方程模型

IMPACT STATEMENT / 影响声明 概括本文报告的研究工作的主要发现。

I. INTRODUCTION / 引言

中介和调节分析是理解心理学和医学研究中“如何”和“何时”产生效应的核心(Hayes, 2012)。中介变量是解释自变量（预测变量）与因变量（结果变量）之间关系的干预变量(Baron & Kenny, 1986)。换句话说，中介分析旨在探讨假定的因果变量 X 是否通过一个或多个中介变量（mediators）影响结果变量 Y。相比之下，调节变量是影响 X 与 Y 之间关系强度或方向的变量，即它指定了效应发生的条件。中介与调节分析共同构成了所谓的“条件过程分析”的基础。

在应用心理学研究中，检验中介效应的经典框架由 Baron 和 Kenny（1986）提出。他们提出，因果检验共有四个步骤：(1)X 显著影响 Y，(2)X 显著影响中介变量 M，(3)当控制 X 时，M 显著影响 Y，以及(4) 当包括 M 时，X 对 Y 的直接效应减少（部分中介效应）或消失（完全中介效应）。如果满足这些标准，就可以推断 M 将 X 的影响传递到 Y 中。中介（间接）效应的大小可以量化为从 X 到 M 的路径（通常标记为系数 a）和从 M 到 Y 的路径在控制 X 情况下（系数 b）的乘积，即间接效应。这个间接效应等价于 X 对 Y 的总效应（c）与在控制 M 情况下的直接效应（c′）之间的差异，即。另一方面，调节分析则涉及检验交互项（例如 X × W），以观察 X 对 Y 的效应是否随调节变量 W 的水平而变化(MacKinnon et al.,

2007)。这些技术已变得普遍：文献调查发现，在社会心理学、临床心理学和健康心理学领域，有数百项研究引用了 Baron & Kenny（1986）的原始文章。

尽管中介和调节分析很受欢迎，但对于没有高级统计培训或编程技能的研究人员来说，开展这类分析可能具有挑战性。近年来，已经开发出一些用户友好型工具以协助进行分析。例如，PROCESS 插件提供了一种基于菜单驱动的回归中介、调节以及“条件过程”模型（中介调节或调节中介）实现方式，大大提高了这些方法的可及性(Hayes, 2012)。然而，这类工具也存在一定局限性：它们通常需要专有软件（例如 SPSS）、模型模板菜单固定，并且不公开其内部建模代码（使得验证或扩展分析变得困难）。经管如此，PROCESS 插件也在各领域研究中得到了广泛的认可。

现有的统计软件（或是插件）均需要研究人员对数据结构和模型进行提前确定，且除非使用 R 语言或者 MPLUS 等软件进行编程，否则通常都为单因变量的统计模型，比如在心理学研究中，通常需要根据某种理论或现象来推出某种假设，再由假设来设计研究并进行数据收集。虽然这种思路看上去十分合理，但却存在着一些风险和潜在问题，比如（1）我们所得数据可能无法得到阳性结果来验证假设，从而导致浪费人力、物力和财力；（2）我们所得到的数据得出了与假设完全相反的结论，从而导致我们研究整体被推翻；（3）我们可能会在研究中忽略假设中不重要的变量，即使该变量已经被我们所收集且可能和关键变量有着紧密的关系；（4）研究中明确确定了自变量和因变量，但在两关键变量之间可能存在一些其他变量，但根据现有理论无法得到中间变量的顺序，我们可能就需要排列组合进行配对验证；（5）在没有研究主题时，研究人员可能需要针对现有数据或公开数据库进行数据挖掘，来确定后续的研究方向，但现有数据量庞大，无法很快确定最佳研究方向等等。传统方法通常涉及多元回归模型或结构方程模型软件，研究人员必须根据理论手动指定哪些变量充当中介变量或调节变量。这一过程耗时且在模型构建中容易产生主观性。

本研究旨在通过提供一个开源且可扩展的应用程序来解决这些问题，该应用程序能够自动挖掘现有数据中的变量关系和估计中介与调节模型，由于其自动化属性和基于 R 语言和 Python 的开发环境，我们将其命名为 AutoModelR。开发 AutoModelR 的动机源于对一个既实用又严谨的工具的需求，这个工具允许心理学家和行为科学家在不编写代码的情况下探索数据中的间接效应和交互效应，同时仍能保持分析的透明性和科学性。通过利用现代统计学习方法，AutoModelR 可以从众多变量中选择最适合作为观测变量和预测变量的数据，并从中筛选出可能的中介链和调节效应。其目标是减少研究者的手动负担并减少模型设定偏差，让数据揭示潜在的中介路径。即使所得模型中观测和预测变量和实际或理论不相符，也可以通过其进行手动控制并在确定了自变量和因变量的情况下自动识别其他中介和调节变量。最后提供清晰的输出文件，以便分析可以被审核和复现。在接下来的章节中，我们将介绍 AutoModelR 的算法流程、软件实现与界面，并提供使用示例。

AutoModelR 是一款基于 Python 构建的图形界面建模工具，旨在简化心理学中的中介与调节分析流程，降低初学者使用回归建模工具的门槛。该软件集成数据预处理、变量选择、因果角色识别、调节/中介结构构建与模型拟合输出为一体。

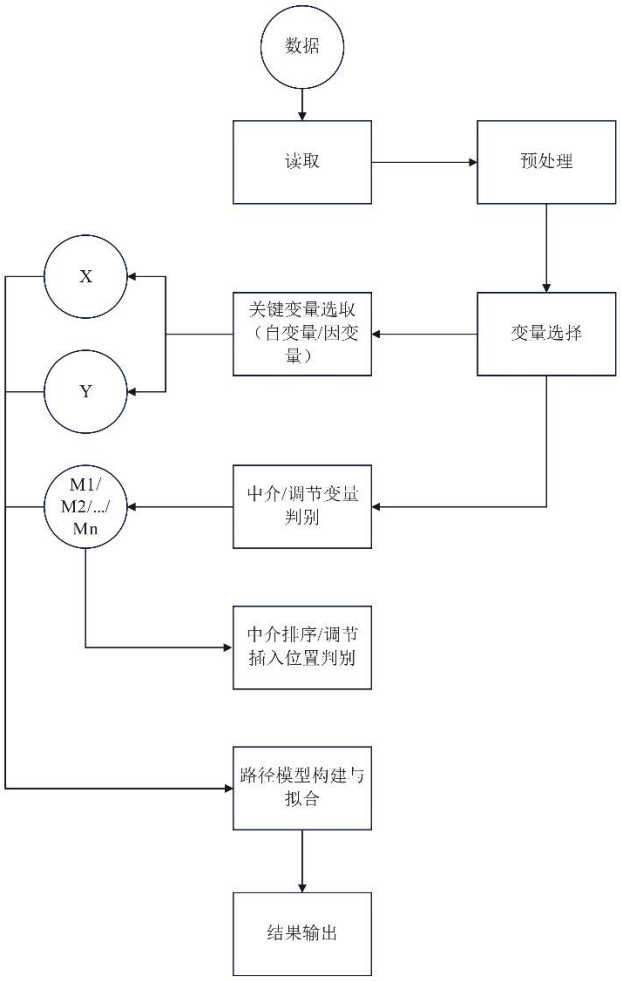

图 1 整体设计流程图

在本研究的软件实现中，首先需要解决的核心任务是对用户所提供的数据文件进行自动化识别和标准化读取。用户可能上传的原始数据文件格式各异，主要包括 Excel（.xlsx, .xls）和 CSV（逗号分隔文本）两种主流形式。为了确保程序的通用性与易用性，系统通过判断文件后缀名来自动分流处理路径，并使用 Python 的 pandas 库中的 read_excel()和 read_csv()函数分别加载 Excel 与 CSV 文件内容。通过这种方式，系统无需用户指定格式类型即可完成数据导入，增强了整体交互的友好性与自动化程度。

文件成功读取后，系统将原始数据表转换为 pandas 的 DataFrame 格式。由于后续分析步骤主要依赖数值型变量（例如回归建模、变量相关性计算等），因此系统会进一步对数据表进行类型筛选，自动保留所有数值型变量，并舍弃非数值列（例如字符串型标识列、文本信息等）。这一操作通过 select_dtypes(include=[np.number]) 实现，它可以有效排除潜在的干扰变量，提升分析准确性。

此外，现实调研数据中常常存在部分缺失值（missing values），若不加处理直接输入模型，则可能造成回归拟合报错或结果偏差。为避免该问题，系统在初始阶段使用 dropna() 函数对数值列进行行级清洗，即删除存在任何缺失的观测行。虽然该方法可能在样本量较小时引入一定样本损失，但在样本量充足的前提下，它是一种简单有效的策略，能够显著提升后续建模的稳定性与可复现性。

代码片段：

```
def read_data(path):
    ext = os.path.splitext(path)[1].lower()
    if ext in [".xlsx", ".xls"]:
        return pd.read_excel(path)
    elif ext == ".csv":
        return pd.read_csv(path)

df = df_raw.select_dtypes(include=[np.number]).dropna()
```

在输入数据文件和预处理后，我们下一步思路是进行关键变量的自动选取，该模块基于 LASSO 回归（Least Absolute Shrinkage and Selection Operator）设计，旨在从数据集中自动识别最具解释力的因变量（dependent variable, DV）与自变量（independent variables, IVs）组合(Tibshirani, 1996)。该方法不仅能处理多个变量间的关系，还具备良好的变量选择能力。

应对心理学数据中可能存在的多重共线和高维问题，工具内置了 LASSO 回归算法模块用于筛选自变量。LASSO（Least Absolute Shrinkage and Selection Operator，最小绝对收缩和选择算子）在拟合回归模型的同时引入 L1 正则化惩罚，将部分不重要的回归系数压缩为 0，从而自动选择出影响最大的变量。与传统逐步回归相比，LASSO 能够在样本量较小但候选自变量很多的情况下有效防止过拟合(Tibshirani, 1997)。

这一模块的核心思想是将数据集中所有变量都视为潜在的因变量（Y）候选，其余所有变量都被视作可能的自变量（X）组合。在每一次循环中，模型都会对某一变量作为 Y 的情况进行建模，并尝试用 LASSO 方法拟合 X 对 Y 的线性关系，从而评估自变量组合在解释该因变量上的解释力。

LASSO 回归的数学目标函数如下所示：

$$L(\beta) = \|\mathrm{Y} - \mathrm{X} \times \beta\|^2 + \lambda \sum_j |\beta_j|$$

其中第一项 表示普通最小二乘回归的误差平方和，第二项是所有回归系数的绝对值之和，乘以一个非负惩罚参数用于惩罚过多的非零系数，使得某些 被压缩为 0，从而达到变量选择的目的。这样，在多变量数据中就可以有效筛选出对 Y 最具解释力的 X 子集。

在本系统中，为提高自动化程度并避免用户手动调整，采用的是 LassoCV 模型，即带有交叉验证的 LASSO 实现。它会在一系列可能的 值中自动选择最佳值，从而在不同变量组合下给出最优的拟合模型。使用的数据都事先经过标准化处理（如 Z-score 标准化），以确保模型在不同量纲下具有可比性。

系统的代码核心框架如下：

```
from sklearn.linear_model import LassoCV
model = LassoCV(cv=5).fit(X_scaled, y_scaled)
```

其中 X_scaled 和 y_scaled 表示对原始数据中的自变量和因变量分别进行标准化后的结果；cv=5 表示进行五折交叉验证以优化。

模型训练完成后，系统会评估每一组 Y-X 组合的拟合优度，具体以 R^2（决定系数）为指标衡量。所有可能的组合都经过评估后，系统将根据 R^2 值的高低进行排序，并保留前 N 组（默认 N=3），作为后续建模流程的输入。这些 TopN 的变量组合体现了 LASSO 策略在多变量场景下的筛选能力，极大地减少了研究者手动挑选变量的负担，同时增强了结果的客观性与可复现性。

在确定了最佳因果变量后，为确定其他变量在因果变量间的关系以及位置，我们设计了一套自动检测中介变量（mediator）和调节变量（moderator）的方法。该阶段的目标是从所有数值型变量中，自动判断哪些变量可能在因果路径中承担中介或调节作用，并对其进行排序。针对两类变量设计了独立而互补的检验策略，分别对应经典的因果路径分析理论：中介效应（mediation effect）与调节效应（moderation effect）。

中介变量的识别主要基于简化版的 Sobel 检验方法，对于任意一个候选自变量（IV）与因变量（DV）的组合，系统会依次遍历其他变量作为潜在中介变量（M），并建立两条路径：（1）IV 到 M 的回归路径；（2）控制 IV 的影响下 M 到 DV 的回归路径。只有当这两条路径的回归系数均达到统计显著性要求（$p<0.05$），才进入 Sobel 检验计算。Sobel 检验的核心在于通过估算中介效应的标准误，对间接效应的显著性进行检验，其计算公式如下：

$$Z = \frac{(a \times b)}{\sqrt{(b^2 \times sa^2 + a^2 \times sb^{2)}}}$$

其中，a 表示 IV 到 M 的非标准化回归系数，b 表示 M 到 DV 的回归系数；sa 和 sb 分别为 a 和 b 的标准误（standarderror）。Z 值服从标准正态分布，因此可用于推断间接效应是否显著。如果 Z 值对应的双尾 p 值小于显著性水平（例如 0.05），则可以认为该变量在当前路径中具有中介作用。

而调节变量的识别则依赖于交互项回归分析，这是一种经典的用于识别变量间调节效应的统计方法。系统自动构建以下形式的回归模型：

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 (X \times Z) + \varepsilon$$

其中，X 表示自变量，Y 为因变量，Z 是被检验的调节变量，X×Z 是其与自变量的交互项。如果模型中交互项的回归系数显著不为零(通常以 t 检验显著性为依据)，则 Z 被判定为在该路径中具有调节效应。采用 sklearn 和 statsmodels 等工具自动构建交互项回归方程，提取其参数估计与 p 值，并将是否达到显著标准作为调节作用的判别依据。

最后分别评估其与当前路径的统计关系，并结合 Sobel Z 值和交互项的 t 检验结果进行自动分类。最终，每个变量会被标记为“中介”、“调节”或“none”（无路径效应）。

在确定了变量的类型后，我们引入了路径结构优化的步骤，用以模拟心理学中常见的复杂因果关系网络。针对存在多个潜在中介变量（M_1 ，M_2 ，…，M_k ）的情况，我们通过穷举方式遍历所有可能的中介排列路径(即可能的传递顺序），例如 $X \to M_1 \to M_2 \to Y$ 或 $X \to M_2 \to M_1 \to Y$ 等，并依次构建对应的结构方程或逐步回归模型进行拟合。在每一种路径配置下，评估其模型拟合优度决定系数（R^2）和赤池信息量准则（AIC），前者反映解释力，后者则衡量拟合效果与模型复杂度之间的权衡。最终选择具有最高拟合质量的中介路径顺序作为推荐结构。

在此基础上，将已识别出的调节变量其分别插入到所有可能的路径段落中，包括自变量到中介（X→M）、中介到因变量（M→Y）、以及自变量到因变量（X→Y）。插入方式采用交互项建模的方式，即在原始路径方程中加入交互项（例如 X×Z、M×Z 或 X×Z），并对该交互项的显著性（通常用 t 检验或其对应的 p 值）进行统计检验。若交互项系数显著，且模型拟合效果有所提升，说明该调节路径在该位置上可能存在调节效应。系统会综合显著性检验结果与整体路径结构评价指标，推荐调节变量的最佳插入位置以及其调节方向。

在模型构建与拟合输出中，系统将根据此前筛选出的最优因变量、自变量组合、中介顺序及调节插入策略，自动构建一个多路径线性模型以反映变量之间的因果结构关系。该模型采用的是标准的多元线性回归结构，并在此基础上引入中介变量与调节交互项。数学表达如下：

$$Y = c'X + \sum (a_i \times M_i) + \sum (b_j \times X \times \mathrm{Mod}_j) + \varepsilon$$

其中 Y 是因变量，X 是核心自变量，表示中介变量，表示调节变量，是调节交互项，、、是各项的回归系数，是误差项。该方程综合了直接效应（X 对 Y 的影响）、中介效应（X 通过 M_i 间接影响 Y）以及调节效应（Mod_j 通过改变 X 与 Y 或中介路径之间的关系影响结果）。

为实现高效拟合与统计检验，系统调用 statsmodels 库的 OLS 模型进行建模。在技术实现中，自变量矩阵（含交互项）会被加上常数项以适配线性模型格式，即通过 sm.add_constant(X) 构建设计矩阵。模型拟合后，系统自动生成详尽的回归摘要，内容涵盖每个变量的回归系数（coef）、标准误（std err）、t 值与 p 值，用于衡量变量在模型中的贡献显著性；决定系数 R^2 以及调整后 R^2，分别反映模型的解释力与对变量数量的调整；Durbin-Watson (DW) 统计量，用于检验残差项是否存在自相关，理想值接近 2；Jarque-Bera (JB) 正态性检验统计量，以及偏度（Skewness）与峰度（Kurtosis）指标，用于检验残差的正态分布假设是否成立。

通过这些指标，研究者可以全面判断模型的拟合效果与统计合理性。如果模型输出中大部分变量具有统计显著性，且残差表现良好（DW 近似 2，JB 检验不显著），则模型被认为具有良好的统计适配性和实际解释能力。

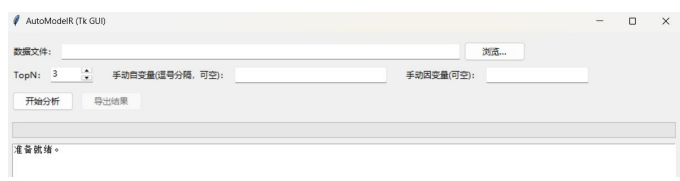

图 2 软件界面设计

如图 2 所示，AutoModelR 的用户界面设计以“可用性优先”为核心理念，采用 Python 原生标准库 tkinter 构建，实现了轻量级、无额外依赖的图形化桌面操作环境。该界面具备全功能模型配置与运行能力，为非编程背景的研究人员提供便捷直观的统计建模入口。

整个界面由一个主窗口构成，分为参数输入区、分析控制区、进度提示区和日志输出区。顶部为数据输入区域，允许用户通过浏览按钮选择本地的 Excel 或 CSV 数据文件。选中路径后自动在文本框中显示，确保路径传递清晰可控。紧随其后的参数设置区域允许用户设定 TopN 值，即用于 LASSO 筛选时保留的最大变量组合数；此外还支持可选输入“手动自变量”和“手动因变量”，这使得高级用户可以绕过自动变量筛选逻辑，强制指定建模路径。所有输入控件均采用 ttk.Entry 和 ttk.Spinbox 组件，确保数据录入与格式控制的一致性。

系统提供两个关键按钮：“开始分析”用于启动完整的建模流程，自动调用六大统计模块依次执行；“导

出结果”按钮则在分析完成后激活，允许用户将中介调节判断、路径顺序、拟合结果等中间数据和最终模型以 CSV 与 JSON 等格式批量导出到本地目录。

为了增强用户反馈机制，界面中集成了进度条和滚动日志区域。进度条以百分比形式展示模型运行阶段（如数据读取、预处理、变量筛选等）的推进进度，有助于用户掌握任务状态；日志框则实时输出系统日志，包括数据维度信息、分析路径提示、模型诊断指标与异常报错内容，提升整体透明性与调试能力。

依据 Tkinter 所构建的界面具备跨平台兼容性，且运行时无依赖于额外图形渲染引擎。这意味着其在打包时能够完全脱离浏览器或第三方 GUI 框架支持，仅依赖 Python 内建能力即可运行。为实现部署友好性，整个系统通过 PyInstaller 进行封装，生成的 .exe 文件可独立运行于 Windows 系统，无需预安装 Python 解释器或环境。这一设计不仅降低了使用门槛，也使得 AutoModelR 能够轻松应用于教学、科研和实地数据分析等场景，在心理学、社会科学、教育研究等领域具备较高的实用推广价值。

实际案例见结果部分。

II. RESULTS / 结果

案例 1 采取小学生，线上线下相结合的方式在监护人监督下收集的共 1047 份数据。所有参与者的父母或监护人签署了知情同意书，并同意他们的孩子参与本研究。共 8 个量表，Cronbach's α 在 0.80 至 0.90 之间。

本研究首先对原始量表数据进行了标准化处理，包括对各维度打分结果进行加权与求和、剔除极端值与缺失数据，并统一变量命名为英文缩写形式。随后，通过 AutoModelR 软件载入处理后的 Excel 文件，开展自动建模分析下述为各阶段结果汇报：

在数据读取阶段，AutoModelR 成功识别到样本数据共包含 1047 个观测单位与 8 个变量。在预处理阶段，系统自动剔除了非数值类型变量，仅保留适用于建模的数值型指标。由于本研究在导入前已完成数据清洗与数值转换，处理后数据维度仍为 (1047, 8)，所有变量均为连续数值型，满足 LASSO 回归与路径建模的基本要求。

在自动变量筛选阶段，AutoModelR 以每一个变量为候选因变量（Y），并尝试将其余变量组合为自变量（X），对所有组合执行 LASSO 筛选，并计算其决定系数（R^2），以评估模型拟合优度。本研究设定 TopN = 5，即保留 R^2 最高的五组组合用于参考（见表 1）。结果显示，“SA→FNE”路径具有最高拟合度（R^2 = 0.5021），其方向亦符合理论预期，提示社交回避（SA）对害怕被否定（FNE）具有显著预测效应，可作为后续分析的首选路径模型。

因变量 y	自变量组合 x	R^2
FNE	SA	0.5021
SA	FNE	0.5013
COG	AB, IND, SSC, AIU	0.4651
IND	AB, SA, COG, SSC, AIU	0.4474
SSC	AB, BB, FNE, SA, IND, COG	0.4385

表 1 案例 1 自动选择主要变量

在中介与调节变量识别阶段，以“SA→FNE”为核心路径，AutoModelR 对其余变量逐一评估。结果显示，变量 COG（认知策略）在中介路径上不显著（p = 0.998），但在调节模型中的交互项显著（p = 0.0496），提示其可能在“社交回避→害怕否定”的路径中发挥调节作用。这一发现与既有研究结果一致，即认知调节策略可能增强或缓解社交情绪反应（见表 2）。

变量名	角色	中介检验p值	调节检验p值
AB	none	0.4062	0.6693
BB	none	0.8596	0.9638
IND	none	0.9822	0.7077
COG	moderator	0.9975	0.0496*
SSC	none	0.8920	0.8226
AIU	none	0.8907	0.8573

表2 中介、调节检验

进一步评估 COG 置于路径不同位置（例如作用于 X → M、M → Y、X → Y）时模型表现，最终判定其最佳插入点为“SA → FNE”路径段，即认知策略调节社交回避对害怕否定的影响强度。

在最终模型拟合阶段，AutoModelR 对上述最优路径结构进行普通最小二乘回归（OLS）建模。表 3 汇总了模型估计值与诊断指标。结果显示，模型 R^2 值为 0.503，表示解释变量可解释因变量变异约 50.3%。变量 SA 的回归系数为 0.7092，具有高度显著性（t = 32.52, p < 0.001），说明其对 FNE 的预测作用稳健。Durbin-Watson 值为 2.033，提示残差项无显著自相关。偏度与峰度指标也未显示严重偏离正态性，支持残差满足 OLS 模型假设。

项目	数值	说明
R^2	0.503	模型可解释 50.3% 的变异
F 值	1057.0	整体模型显著性检验（p < 0.001）
常数项系数	-4.79e-16	接近 0，可忽略
SA 系数	0.7092	正向显著，t=32.52, p < 0.001
Durbin-Watson	2.033	近似 2，说明无自相关
Skew / Kurtosis	正态性接近合理	

表3 模型拟合结果

为验证 AutoModelR 所输出的路径结构及调节效应是否稳健，本研究采用 SPSS 中广泛使用的 PROCESS 插件（版本 2.16.3）对所识别路径 “SA → FNE” 中认知策略（COG）作为调节变量的作用进行了复核分析。采用模型 1（单调节效应模型）进行建模，其中社交回避（SA）作为自变量，害怕负面评价（FNE）为因变量，认知策略（COG）为调节变量。

结果显示，回归模型整体显著（$F = 339.79$，$p < 0.001$），决定系数 $R^2 = 0.5048$，表明模型可解释 FNE 约 50.48% 的变异量，几乎与 AutoModelR 所产出结果（$R^2 = 0.503$）一致，体现了模型结果的高度一致性与再现性。

在回归系数层面，自变量 SA 对因变量 FNE 呈现高度显著的正向预测效应（$B = 1.1412$，$SE = 0.0465$，$t = 24.53$，$p < 0.001$），与 AutoModelR 中的 OLS 系数（0.7092）方向一致。调节变量 COG 本身对 FNE 的主效应不显著（$B = 0.0498$，$p = 0.157$），交互项 SA × COG 的回归系数为 −0.0271，边缘显著（$p = 0.0545$）。

进一步对调节效应的条件效应进行分层检验显示，COG 水平在均值（$M = 2.16$）及其上下一个标准差范围内对 SA → FNE 路径的影响均保持显著（$p < 0.001$）。随着 COG 水平上升，SA 对 FNE 的影响系数逐渐减弱（从 $B = 1.1412$ 降至 $B = 1.0205$），支持 COG 在该路径中具有削弱性调节作用，即认知策略越强个体，其社交回避对害怕被否定的影响越小。此外，R^2 增量分析结果表明，交互项引入后模型解释力提升 $\Delta R^2 = 0.0018$，边缘显著（$p = 0.0545$），表明调节效应虽小但具有趋势性意义。

III. Discussion / 讨论

本研究围绕中介效应与调节效应的自动化分析，提出并实现了 AutoModelR 这一工具。长期以来，中介与调节模型构建高度依赖研究者的理论直觉与手动操作：先设定路径，再逐一检验，必要时反复调整，直到结果“看起来合理”。这种方式不仅耗费时间，也极易受主观偏好影响，甚至在无意中忽略关键变量或潜在路径 AutoModelR 的设计正是针对这一现实问题——通过将数据驱动方法嵌入经典因果分析框架，尽可能减少人为试探式建模的空间。

在方法层面，AutoModelR 结合统计学习技术与结构方程建模框架，自动筛选自变量与因变量的合理组合，识别潜在中介路径与调节效应，并生成完整路径模型。本文系统呈现了其算法流程与软件架构，并通过真实数据进行了功能验证。结果显示，该工具不仅能够重现人工建模所得发现，其输出结果还与主流分析工具（如 Hayes 的 PROCESS 插件）高度一致，说明其估计过程在统计层面具有精确性与稳定性。换言之，自动化并未牺牲严谨性。

与传统依赖专有软件或复杂语法操作的分析流程相比，AutoModelR 在可及性与透明度上具有明显优势。其图形界面覆盖数据导入、变量筛选、路径构建与结果输出的完整流程，使复杂模型分析不再依赖编程能力。更重要的是，研究者无需预设单一因变量或固定路径结构，工具可在数据结构允许范围内主动探索关键联系。这种探索导向方式尤其适用于初步研究阶段，有助于避免理论先行所带来的路径固化。

当然，自动化建模并非没有风险。数据驱动策略虽然能够发现潜在关联，但也可能捕捉偶然相关。如果脱离理论框架进行解释，模型结构可能缺乏实质意义。因此，AutoModelR 的定位并非“替代理论”，而是为理论提供更系统的探索起点。此外，当前版本仅处理数值变量，分类变量会被排除，这一设计虽降低了计算复杂度，却限制了适用场景。未来可通过自动编码或引入广义线性模型扩展数据类型支持。

在模型结构方面，AutoModelR 目前基于线性回归与二元交互框架，尚未覆盖复杂非线性或高阶交互关系。后续版本可引入广义加性模型或其他机器学习方法以拓展关系识别能力。同时，现阶段模型筛选主要依赖 AIC 与 R^2 指标，尚未充分整合领域知识进行复杂度控制，未来可加入稳健性检验与交叉验证模块以降低过拟合风险。

最后，我们计划扩展多因变量并行分析、更复杂中介调节结构（如有序多重中介、双重调节）以及自动路径图生成与可视化报告功能。通过持续优化算法与界面设计，AutoModelR 有望在保持统计严谨性的前提下，进一步降低方法门槛，使复杂模型分析从“技术壁垒”转向“标准化流程”。

如果统计建模本应服务理论而非成为负担，那么自动化或许不是削弱研究者角色，而是在减少人为误差的同时，让理论真正站在数据之上。

IV. Conclusions / 结论

我们整了一个巨牛博一的数据自动处理软件，可以自动选择最佳自变量、因变量，然后自动选择最佳中介变量和调节变量，有数据就有中介模型，你说屌不屌。

我们还为大家在github准备了原始代码，可以自行复现。如果你懒得整，我们还准备了某书购买链接可以智齿。

Supplementary Materials / 补充材料

完整代码见：
https://github.com/FOOKYUENMA/autoModelR.git
可下载使用软件购买链接：
http://xhslink.com/o/50JDw5DD1a7

Acknowledgment / 致谢

谢谢各位吃屎官。

References

Agler, R., & De Boeck, P. (2017). On the interpretation and use of mediation: Multiple perspectives on

mediation analysis. *Frontiers in Psychology*, *8*, 1984. https://doi.org/10.3389/fpsyg.2017.01984

Baron, R. M., & Kenny, D. A. (1986). The moderator-mediator variable distinction in social psychological research: Conceptual, strategic, and statistical considerations. *Journal of Personality and Social Psychology*, *51*, 1173–1182.

boyd, danah, & Crawford, K. (2012). Critical Questions for Big Data: Provocations for a Cultural, Technological, and Scholarly Phenomenon. *Information, Communication & Society*, *15*(5), 662–679. https://doi.org/10.1080/1369118X.2012.678878

Cao, H., & Cai, F. (2002). *Family Psychological Doctor* (Vol. 31). Jiuzhou Press.

DataCamp. (2023, January 31). *Top Techniques to Handle Missing Values Every Data Scientist Should Know*. https://www.datacamp.com/tutorial/techniques-to-handle-missing-data-values

Domingos, V. (2018, July 21). *Graphical User Interfaces on Python with Tkinter – building user-friendly graphical interfaces without external dependencies*. https://no-title.victordomingos.com/articles/2018/gui-programming-python-tkinter/index.html

Edwards, J. R., & Lambert, L. S. (2007). Methods for integrating moderation and mediation: A general analytical framework using moderated path analysis. *Psychological Methods*, *12*(1), 1–22. https://doi.org/10.1037/1082-989X.12.1.1

Fairchild, A. J., & McQuillin, S. D. (2010). Evaluating mediation and moderation effects in school psychology: A presentation of methods and review of current practice. *Journal of School Psychology*, *48*(1), 53–84. https://doi.org/10.1016/j.jsp.2009.09.001

Fredrick, J. W., Rapee, R. M., Alden, L. E., McCabe, R. E., & Rodebaugh, T. L. (2022). Prospective associations between fears of negative and positive evaluation and social anxiety in adolescence. *Journal of Abnormal Child Psychology*. https://pmc.ncbi.nlm.nih.gov/articles/PMC9255539/

Goldin, P. R., Manber, T., Hakimi, S., Canli, T., & Gross, J. J. (2009). Neural mechanisms of cognitive reappraisal of negative self-beliefs in social anxiety disorder. *Biological Psychiatry*, *66*(12), 1091–1099. https://doi.org/10.1016/j.biopsych.2009.07.014

Guo, C. (2018). Preliminary Revision and Reliability and Validity Test of the Social Adaptation Questionnaire for Children and Adolescents. *Yangtze Series*. https://yangtze.silkroadinfo.org.cn/2018/7/30/20180730142933.pdf

Hayes, A. F. (2012). *PROCESS: A versatile computational tool for observed variable mediation, moderation, and conditional process modeling*. White paper. http://www.afhayes.com/public/process2012.pdf

Ioannidis, J. P. A. (2014). Increasing value and reducing waste in research design, conduct, and analysis. *The Lancet*, *383*(9912), 166–175. https://doi.org/10.1016/S0140-6736(13)62227-8

Kline, R. B. (2016). *Principles and Practice of Structural Equation Modeling* (4th ed.). The Guilford Press. https://www.guilford.com/books/Principles-and-Practice-of-Structural-Equation-Modeling/Rex-Kline/9781462523344

Latkovich, S. A. (1996). *A Review of the Literature on the Validity of the Child Behavior Checklist.* https://api.semanticscholar.org/CorpusID:142392258

Lin, J., & Zhou, A. (2018). *PyDraw: A GUI drawing generator based on Tkinter and its design concept*. https://arXiv.org/abs/1808.09094

Ma, G., Tian, S., Song, Y., Chen, Y., Shi, H., & Li, J. (2025). When technology meets anxiety: The moderating role of AI usage in the relationship between social anxiety, learning adaptability, and behavioral problems among Chinese primary school students. *Psychology Research and Behavior Management*, *18*, 151–167. https://doi.org/10.2147/PRBM.S502337

MacKinnon, D. P., Fairchild, A. J., & Fritz, M. S. (2007). Mediation analysis. *Annual Review of Psychology*, *58*, 593–614. https://doi.org/10.1146/annurev.psych.58.110405.085542

Ngok, H. R. (2018, October 18). *Handling Missing Values*. Data to Wisdom. https://hrngok.github.io/posts/missing%20values/

pandas development team. (2025a). *IO tools (text, CSV, HDF5, …)*. Pandas Documentation. https://pandas.pydata.org/docs/user_guide/io.html

pandas development team. (2025b). *Pandas.DataFrame.select_dtypes*. Pandas Documentation. https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.select_dtypes.html

Preacher, K. J., & Hayes, A. F. (2004). SPSS and SAS procedures for estimating indirect effects in simple mediation models. *Behavior Research Methods, Instruments, & Computers*, *36*(4), 717–731. https://doi.org/10.3758/BF03206553

Reijntjes, A., Dekovic, M., & Telch, M. J. (2007). Support for the predictive validity of the SASC-R: Linkages with reactions to an in vivo peer evaluation manipulation. *Journal of Anxiety Disorders*, *21*(7), 903–917. https://doi.org/10.1016/j.janxdis.2006.10.007

statsmodels development team. (2024). *Regression diagnostics – statsmodels 0.14.4*. Statsmodels Example Notebooks. https://www.statsmodels.org/stable/examples/notebooks/generated/regression_diagnostics.html

Szucs, D., & Ioannidis, J. P. A. (2017). When null hypothesis significance testing is unsuitable for research.

Frontiers in Human Neuroscience, *11*, 390. https://doi.org/10.3389/fnhum.2017.00390

Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B (Methodological)*, *58*(1), 267–288.

Tibshirani, R. (1997). The lasso method for variable selection in the Cox model. *Statistics in Medicine*, *16*(4), 385–395. https://doi.org/10.1002/(SICI)1097-0258(19970228)16:4%253C385::AID-SIM380%253E3.0.CO;2-3

Toomet, O. (2025). *Chapter 10: Linear regression*. Machine Learning in Python. https://faculty.washington.edu/otoomet/machinelearning-py/linear-regression.html

Valente, M. J., Rijnhart, J. J. M., Smyth, H. L., Muniz, F. B., & MacKinnon, D. P. (2020). Causal mediation programs in R, Mplus, SAS, SPSS, and Stata. *Structural Equation Modeling: A Multidisciplinary Journal*, *27*(6), 975–984. https://doi.org/10.1080/10705511.2020.1777133

van Smeden, M. (2022). A very short list of common pitfalls in research design, data analysis, and reporting. *PRiMER*, *6*, 26. https://doi.org/10.22454/PRiMER.2022.511416

Zajonc, R. B. (1965). Social facilitation. *Science*, *149*(3681), 269–274. https://doi.org/10.1126/science.149.3681.269

Zajonc, R. B., & Sales, S. M. (1966). Social facilitation of dominant and subordinate responses. *Journal of Experimental Social Psychology*, *2*(2), 160–168.