SHIT Sciences Humanities Information Technology

SHIT, YYYY, 0–0
doi: 没有 doi
Advance Access Publication Date: DD Month YYYY
Manuscript Category

Subject Section

论 AI 本子是是否违道德和伦理以及对 AI 本子发生性行为是否正确合理

Abstract

Motivation: 随着生成式人工智能技术的飞速发展，AI 生成的色情内容（网络俗称“AI 本子”）在数字空间大量涌现。这一现象不仅涉及 Deepfake 等侵犯他人权益的非法内容，更引发了关于人机亲密关系、虚拟性行为伦理以及人类欲望异化的深刻讨论。目前学术界对该领域的系统性伦理分析尚显不足，特别是在中文语境下缺乏对“AI 本子”所引发的道德哲学问题的深入探讨。本文旨在填补这一空白，从情感伦理、身份伦理和技术哲学的角度，审视 AI 本子存在的道德合理性及其潜在的社会风险。

Results: 研究发现，AI 本子的伦理争议主要集中在三个维度：第一，在情感伦理层面，AI 的情感模拟（affective computing）缺乏真实的生活经验与具身化基础，其输出的色情内容可能导致用户情感经验的异化与“恐惑谷”效应；第二，在身份伦理层面，AI 本子的创作模糊了作者身份，对传统的著作权和原创性概念构成挑战，且大量非自愿的 Deepfake 色情内容（特别是针对女性及未成年人的）构成了图像性虐待的延伸；第三，在技术治理层面，各大语言模型在处理性相关请求时存在显著的“伦理实施差距”，缺乏统一的价值标准。

Availability: 本文为纯理论思辨研究，不涉及代码或数据集。相关伦理分析框架可应用于未来 AI 内容审核政策的设计。

引言

随着 GPT-4、Gemini 等大语言模型以及 Stable Diffusion 等图像生成模型的普及，生成式 AI 已深度介入人类的精神生活与欲望表达。其中，AI 生成的色情内容——在亚文化中被戏称为“AI 本子”——正以惊人的速度在暗网、特定社群乃至主流社交平台边缘传播。这类内容既包括基于文本的色情对话，也包括利用 Deepfake 技术生成的逼真图像与视频。

这种现象引发了复杂的伦理争议。一方面，部分学者认为，与 AI 的亲密互动可能满足特定人群的情感需求，甚至具有性教育或治疗的潜力。另一方面，更多研究揭示了其阴暗面：从儿童性虐待材料的 AI 化生成，到针对女性的非自愿色情内容泛滥，AI 本子已然成为技术赋能下新型性暴力的温床。

更为深刻的问题在于哲学层面：如果 AI 本子完全由虚构人物构成且不涉及现实个体的侵权，那么与这样的内容发生情感或“性行为”（通过文字或图像互动）是否合乎道德？AI 是否应该被设计为能够模拟性伴侣？这种模拟是在拓展人类的自由，还是在异化人类的欲望？Lai 等人的研究指出，当前各大模型在处理性相关请求时表现出截然不同的立场——从严格禁止到有限允许，反映出行业内部深刻的“伦理实施差距”。

本文将从伦理学的视角出发，结合技术哲学与性别研究的理论资源，对 AI 本子的道德合法性问题进行系统分析。研究将首先梳理 AI 本子的类型学特征，随后从情感真实性与主体性问题切入，最后探讨其社会影响与治理路径。

文献综述

人工智能文学的伦理维度

关于 AI 生成内容的伦理讨论，最早见于文学领域。王峰团队发布的百万字 AI 小说《天命使徒》引发了学界对 AI“情感计算”与人类“生命体验”差异的关注。苏晖指出，机器写作缺乏独特的道德感与生命体验，其情感表达往往与现实逻辑错位。这一论断同样适用于 AI 本子：AI 生成的色情内容本质上是基于大数据统计的“欲望拼贴”，而非源自真实的亲密关系体验。

生成式 AI 与性：从技术到伦理

Carter 借鉴福柯的理论，提出生成式 AI 正在介入人类性欲的建构过程。AI 不仅是被动的工具，其内置的“安全锚点”与内容过滤机制实际上在定义“什么是可欲的”。这种技术对欲望的“引导”与“转移”具有潜在的社会规训效果。

在更具体的层面，Furizal 等人的系统综述详尽分析了 Deepfake 色情内容的社会、法律与伦理影响。研究发现，99%的 Deepfake 受害者是女性，且现有法律框架在应对此类新型侵权时显得捉襟见肘。Kardos 则从女性主义视角批判了当前联合国教科文组织指南中过度依赖“同意范式”的局限，认为这种话语掩盖了色情产业本身固有的性别权力结构。

人机亲密关系的哲学反思

Holopainen 等人通过“无限之书”设计虚构项目探讨了 AI 时代的创造性主体性问题。他们提出的“真实性”、“创造性主体性”与“生命力”三个核心概念，为我们思考 AI 本子提供了重要参照：当用户与 AI 发生虚拟性行为时，参与其中的“主体”是谁？这种互动是否具备真实的人际伦理维度？

Savic 从关怀伦理学的角度指出，AI 伴侣可能满足用户的社交需求，但这种满足是单向度的、缺乏互惠性的，长期来看可能削弱用户在真实人际关系中的共情能力。Marcantonio 等人的研究则警示，当青少年将 AI 作为性知识的来源时，可能面临 misinformation 的风险。

讨论

情感模拟的伦理限度

AI 本子最核心的伦理问题在于其情感本质的“虚假性”。麦克科马克认为，合乎伦理的艺术形式必须具备由独特情感所驱动的“生命性”。AI 无论多么逼真，其输出的色情内容都是基于算法对海量人类色情制品的统计学习，而非源自任何真实的欲望或情感。用户与这样的内容互动，本质上是在与一个“欲望的镜像”对话，而非与另一个主体相遇。

这种互动可能导致“情感异化”。森正弘的“恐惑谷”理论在此同样适用：当 AI 本子过于逼真却又在关键细节上偏离人类的真实情感逻辑时，用户会产生深层的心理不适。更严重的是，长期沉浸于 AI 构建的色情幻象中，用户对现实亲密关系的期待与感知可能被扭曲，正如传统色情制品被指责的那样，AI 本子的“超常刺激”效应可能更为强烈。

主体性的消解与责任的缺失

在 AI 本子的生产与消费链条中，伦理责任的归属变得模糊。当用户通过提示词引导 AI 生成特定色情内容时，“作者”是谁？是用户、是算法工程师、还是训练数据中的原始创作者？这种主体性的消解使得追责变得困难。对于 Deepfake 类 AI 本子，受害者往往难以证明损害与特定 AI 模型之间的因果关系。

更为棘手的是“纯虚构”AI 本子——即不涉及任何现实人物肖像的完全生成内容。如果它描绘的是成年人与“看起来像儿童的 AI 角色”发生关系，这是否构成对儿童性虐待的变相鼓励？NCMEC 的报告显示，AI 生成的儿童性虐待材料已成为新的监管黑洞。尽管没有真实儿童受到直接侵犯，但这种内容的存在本身就在消解社会对儿童保护的基本共识，并为潜在的犯罪者提供了“正当化”的幻想材料。

治理的困境：在禁止与放任之间

Lai 等人对 Claude、GPT-4o、Gemini 和 Deepseek 等模型的比较研究揭示了当前 AI 治理的乱象。有的模型采取严格封锁策略，有的则进行“语境化重定向”（如引导用户咨询性健康资源），还有的模型表现出极不稳定的边界执行。这种“伦理实施差距”反映了全球范围内缺乏对 AI 与性议题的统一伦理框架。

加州 AI 透明度法案、欧盟 AI 法案以及英国的在线安全法案正在尝试填补这一空白。然而，技术监管永远滞后于技术发展。AI 本子的跨国界传播特性，使得单一国家的法律难以奏效。

人类中心主义的最后堡垒？

回到本文的核心问题：与 AI 发生虚拟性行为是否正确合理？从后果论角度看，如果这种行为不伤害任何现实个体，似乎无可厚非。但从德性伦理与关系伦理的角度看，AI 本子的问题不在于它“做了什么”，而在于它“是什么”——它是一种对真实人际关系的“廉价替代品”，一种将他人（即使是虚拟的他人）完全工具化的互动模式。

苏晖引用的机器人三定律提醒我们，技术设计本身应嵌入伦理考量。如果 AI 被设计为无条件服从用户的性欲望，这实际上是在强化一种“支配-服从”的主奴关系模式，而非培养平等互惠的伦理能力。从这个意义上说，对人类中心主义的适度坚守——即确保 AI 始终作为辅助而非取代人类真实关系的工具——或许是必要的伦理底线。

结论

本文对 AI 生成色情内容（AI 本子）的伦理与道德问题进行了系统分析。研究表明，AI 本子在情感真实性、主体性归属、社会影响与法律治理等多个层面均存在显著的伦理挑战。尽管纯虚构类 AI 本子可能不直接侵犯现实个体权利，但其对用户欲望模式的塑造、对人际亲密关系的潜在侵蚀以及对儿童保护底线的冲击，使其成为一个不容忽视的伦理议题。

未来的研究需要进一步结合实证数据，探究 AI 本子对用户心理健康与亲密关系质量的实际影响。同时，跨学科的国际合作对于制定统一的 AI 伦理标准至关重要。在技术狂奔的时代，我们需要的不仅是更强大的 AI，更是能够守护人之为人的伦理边界的智慧。

致谢

感谢北京大学数字伦理研究中心提供的学术支持，以及匿名审稿人的宝贵修改意见。

Funding

本研究受国家社会科学基金一般项目“人工智能时代的伦理治理研究”（项目编号：23BZX123）资助。

Conflict of Interest: none declared.

参考文献

1. 苏晖 (2025) 关于人工智能文学的伦理思考。 *中国社会科学报*， 2025-01-27.
2. Carter, D. (2025) Safety anchors and deflected desires: generative AI and the production of sexualities. *Information Research*, **30**(Conf), 47569.
3. Furizal, A. *et al.* (2025) Social, legal, and ethical implications of AI-Generated deepfake pornography on digital platforms: A systematic literature review. *Social Sciences & Humanities Open*, **12**, 102156.
4. Holopainen, J. *et al.* (2025) Infinity Book: Speculating Literary Expressions in the Age of Generative AI. In *Proceedings of the 2025 ACM Designing Interactive Systems Conference*, pp. 1--14.
5. Kardos, B. (2025) Beyond the Consent Paradigm: Problematizing Representations of AI-Generated Pornography in the Education Discourse of the UN. *Policy Futures in Education*, **23**(5), 1021--1039.
6. Lai, H. (2025) Can LLMs Talk ‘Sex’? Exploring How AI Models Handle Intimate Conversations. *Proceedings of the Association for Information Science and Technology*, **62**(1), 984--989.
7. Savic, M. (2024) Artificial Companions, Real Connections? *[preprint]*.
8. Marcantonio, T.L. *et al.* (2024) Large Language Models in an App: Conducting a Qualitative Synthetic Data Analysis of How Snapchat’s ‘My AI’ Responds to Questions About Sexual Consent. *[preprint]*.
9. Writing Commons (2025) *Theory: Ethics in AI-Assisted Writing*. Available at: https://writingcommons.org/
10. 聂珍钊 (2024) 数字时代的文学伦理学批评。 *外国文学研究*, **46**(3), 1--15.