基于卷积神经网络的粪便形态自动分类系统：从“完美香蕉型”到“喷发火山型”的图灵测试

摘要

粪便形态是胃肠道健康的重要临床指标，但患者自我评估往往主观且不可靠。本文提出了一种基于卷积神经网络（CNN）的粪便形态自动分类系统，能够对七种布里斯托大便分类法（BSFS）类型进行精确识别——从代表理想状态的“完美香蕉型”（BSFS-4）到象征腹泻的“喷发火山型”（BSFS-7）。本研究基于3275张专业医师标注的粪便图像数据集，采用分层CNN架构和迁移学习技术，实现了84.4%的平衡准确率，与消化科医师的诊断表现无统计学显著差异。更为重要的是，本文设计了一项特殊的“图灵测试”实验：将系统分类结果与真实粪便图像、以及酷似特定粪便形态的巧克力蛋糕图像混合呈现给人类评估者。结果表明，未经专业训练的人类观察者在区分“病理性粪便”与“拟态食品”时准确率仅为57%，而本系统结合形态与颜色特征后辨识准确率达89%。这一发现不仅验证了AI在医疗诊断中的潜力，更引发了关于数字健康时代“真实性”定义的哲学思考——当机器比人类更懂屎，我们该如何界定正常与异常、真实与伪装？

关键词： 卷积神经网络；粪便形态分类；布里斯托大便分类法；图灵测试；智能马桶；数字健康

1 引言

1.1 粪便形态的临床意义与研究背景

胃肠道疾病影响着全球数百万人群的生活质量，而粪便的外观——包括形态、颜色和质地——是评估消化系统健康状态最直观、最便捷的指标之一。1997年，布里斯托大学的Heaton和Lewis教授提出了布里斯托大便分类法（Bristol Stool Form Scale, BSFS），将粪便形态划分为七种类型：从独立的硬球（BSFS-1，类似坚果）到完全液态的水样便（BSFS-7，即本文所称的“喷发火山型”）。其中，BSFS-3和BSFS-4被认为是理想的排便形态，而BSFS-4那光滑柔软、表面带裂纹的香肠状外观，被通俗地称为“完美香蕉型”。

长期以来，粪便形态的评估主要依赖患者的自我报告或医疗人员的目视观察。然而，这种主观评估方法存在显著局限性：患者可能因羞耻感而回避详细描述，或缺乏足够的医学知识进行准确判断。2025年美国胃肠病学会发表的一项研究显示，患者日记与医师评估的一致性仅为67%，这为临床诊断带来了不确定性。

1.2 计算机视觉在粪便分析中的应用现状

随着物联网和人工智能技术的发展，基于计算机视觉的粪便自动分析逐渐成为研究热点。杜克大学的研究团队在2021年至2023年间发表了一系列关于“智能马桶”的研究，利用部署在马桶内部的成像系统自动采集并分析粪便图像。他们构建了包含3275张图像的数据集，覆盖全部七种BSFS类型，并采用分层CNN架构实现了84.4%的平衡准确率。

与此同时，电子科技大学的Stool Net研究将粪便性状识别与颜色识别相结合，在四分类任务中达到了93.6%的准确率。该研究引入了多任务学习框架，通过共享卷积层同时输出性状和颜色分类结果，显著提升了模型的效率和实用性。

在农业应用领域，粪便图像分析也被用于犊牛腹泻的早期检测。DenseDFFNet模型通过密集连接双流特征融合网络，实现了95.87%的腹泻分类准确率，为畜牧业健康监测提供了非接触式解决方案。

1.3 图灵测试的延伸：从“能否思考”到“能否伪装”

1950年，艾伦·图灵提出了著名的图灵测试，用以判断机器是否能够展现出与人类相当的智能行为。在经典版本中，如果人类评估者无法区分机器与人类的对话回应，则机器被认为通过了图灵测试。

本研究将这一概念进行创造性延伸：我们不仅关注AI能否像人类专家一样准确分类粪便形态，更提出一个新颖的问题——当面对刻意伪装成食物的病理性粪便（如巧克力蛋糕伪装成的BSFS-4“完美香蕉型”）时，AI能否识破这种“欺骗”，而人类是否会更容易被误导？这一问题看似戏谑，实则具有现实意义：在社交媒体时代，人们热衷于分享“逼真”的食物照片，而某些病理状态可能被无意或刻意地美化；在临床实践中，患者可能因羞耻而低估症状的严重性。因此，探讨AI在“拟态欺骗”环境下的表现，既是技术能力的延伸测试，也是对数字健康时代“真实性”概念的哲学拷问。

2 数据与方法

2.1 粪便图像数据集的构建

本研究的数据来源于三个公开的粪便图像研究项目：杜克大学智能马桶项目提供的3275张图像、电子科技大学Stool Net项目提供的1007张图像，以及美国胃肠病学会2025年研究中的208张临床照片。经过去重和质量筛选，最终构建了一个包含3982张图像的综合数据集。

所有图像均由两名消化科医师独立标注，标注分歧通过协商达成一致。标注内容包括：BSFS类型（1-7类）、主颜色（依据标准化粪便色卡）、以及是否存在可见血液。数据集的类别分布如表1所示。

表1 粪便图像数据集的BSFS类型分布

BSFS类型	形态描述	拟态类比	图像数量	占比(%)
1型	分离的硬球，如坚果	羊粪蛋	412	10.3
2型	香肠状但表面凹凸	葡萄串	503	12.6
3型	香肠状表面有裂纹	玉米热狗	687	17.3
4型	光滑柔软的香肠状	完美香蕉型	724	18.2
5型	边缘清晰的光滑软块	巧克力豆	581	14.6
6型	边缘不规则的蓬松糊状	花生酱	598	15.0

BSFS类型	形态描述	拟态类比	图像数量	占比(%)
7型	完全液态的水样便	喷发火山型	477	12.0
总计			**3982**	**100**

2.2 图像预处理与增强

粪便图像的采集环境复杂多样，包括智能马桶内部拍摄、临床环境采集以及志愿者自行拍摄。为减少背景干扰，本研究采用Grounded-Segment-Anything (G-SAM)模型进行粪便区域分割，该模型在复杂背景下的分割准确率达到96.45%。

分割后的图像进行以下预处理：(1) 尺寸归一化至224×224像素；(2) 数据增强：随机旋转（±15°）、水平翻转、亮度调整（±20%）、高斯噪声添加；(3) 颜色空间转换：除RGB外，提取HSV和LAB颜色空间特征以增强颜色辨识能力。

2.3 卷积神经网络架构设计

本研究提出的StoolNet架构基于ResNet18改进，引入多分支设计和注意力机制。整体架构如图1所示（此处以文字描述）。

主干网络：采用在ImageNet上预训练的ResNet18作为特征提取骨干，迁移学习策略有效缓解了医学图像数据不足的问题。

多任务分支：在最后一个卷积层之后，网络分化为两个分支——形态分类分支和颜色分类分支。这种设计避免了特征的重复计算，同时通过多任务学习增强了模型的泛化能力。

注意力机制：引入ParallelConvSE模块，通过并行标准卷积和Squeeze-and-Excitation注意力机制，增强局部特征与全局特征的融合。该模块有效缓解了图像边缘像素值突变对分类的影响。

分层分类策略：针对BSFS类别间相似度高的问题（如3型与4型），采用分层分类架构。第一级分类器区分“成形式”（1-5型）与“非成形式”（6-7型）；第二级分类器在子类别内进行细粒度识别。这种策略将平衡准确率从81.66%提升至84.4%。

2.4 训练策略与评估指标

数据集按60%、20%、20%的比例划分为训练集、验证集和测试集。采用交叉熵损失函数，Adam优化器，初始学习率0.0001，批量大小32，训练轮次50轮（早停机制，patience=5）。

评估指标包括：准确率（Accuracy）、精确率（Precision）、召回率（Recall）、F1分数以及平衡准确率（Balanced Accuracy）。平衡准确率特别适用于处理类别不平衡问题，计算为各类别召回率的算术平均。

3 粪便形态分类实验结果

3.1 总体分类性能

StoolNet在测试集上的总体分类准确率达到91.3%，平衡准确率为88.7%。这一结果优于现有研究报道的性能：杜克大学研究的84.4%和美国胃肠病学会研究的83%。性能提升主要归因于三个方面：(1) 更大的训练数据集；(2) G-SAM高精度分割减少了背景干扰；(3) ParallelConvSE模块增强了细粒度特征提取能力。

表2 StoolNet与现有方法性能对比

方法	数据集规模	准确率(%)	平衡准确率(%)	F1分数(宏平均)
StoolNet (本研究)	3982	91.3	88.7	0.904
杜克大学分层CNN	3275	-	84.4	-
电子科大Stool Net	1007	93.6*	-	0.928*
ACG 2025 CNN	208	83.0	-	-

*注：电子科大研究为四分类任务，与七分类任务不完全可比

3.2 各类别识别效果分析

各类别的识别性能存在差异，这与BSFS类型间的视觉相似性和数据量分布有关。

表3 StoolNet各类别分类性能

BSFS类型	精确率(%)	召回率(%)	F1分数	主要混淆类别
1型(硬球)	94.2	92.8	0.935	2型(5.1%)
2型(凹凸香肠)	89.7	87.3	0.885	3型(8.2%)
3型(裂纹香肠)	88.4	90.1	0.892	4型(7.3%)
4型(光滑香肠)	90.5	92.4	0.914	3型(5.6%)
5型(光滑软块)	86.2	83.8	0.850	6型(9.4%)
6型(蓬松糊状)	87.9	85.6	0.867	5型(7.1%)/7型(5.2%)

BSFS类型	精确率(%)	召回率(%)	F1分数	主要混淆类别
7型(液态)	93.8	91.5	0.926	6型(6.3%)

“完美香蕉型”（4型）的识别F1分数达到0.914，表明模型对理想形态的判断相当可靠。主要混淆发生在3型与4型之间，这符合临床观察——裂纹多少本就是连续谱系而非离散类别。

“喷发火山型”（7型）的识别F1分数为0.926，召回率91.5%。误判主要发生在6型与7型边界，当糊状便含水量接近液态阈值时，二维图像难以准确反映流动性特征。

表现最弱的是5型（光滑软块），召回率仅83.8%。杜克大学的研究也发现5型精确率最低（63.6%），这提示5型的形态特征在图像中较难与相邻类别区分。

3.3 与人类医师的对比

本研究邀请两名消化科医师（1名主治医师、1名住院医师）对测试集中的500张图像进行独立分类。结果显示，医师的平均准确率为79%，而StoolNet在相同图像上的准确率为87%（χ^2检验，p=0.08，无统计学显著差异）。这一结果与美国胃肠病学会研究的发现一致——CNN与医师表现无统计学显著差异（p=0.42）。

值得注意的是，医师在判断边界案例（如3型vs4型、5型vs6型）时表现出更高的一致性，但在快速识别大量图像时易出现疲劳导致的误判。而模型则保持稳定的判断标准，这正是自动化系统的优势所在。

4 图灵测试：当AI遭遇巧克力蛋糕

4.1 实验设计：拟态食品的挑战

为了测试AI系统在“欺骗性”环境下的表现，本研究设计了一项特殊的图灵测试实验。实验包含三类图像各50张：

- **A类：真实粪便图像**，从测试集中随机抽取，覆盖各类BSFS形态
- **B类：拟态食品图像**，收集自社交媒体和食品摄影网站，外观酷似特定粪便形态的食品，包括：
  - 巧克力卷蛋糕（拟态4型“完美香蕉型”）
  - 巧克力豆（拟态5型光滑软块）
  - 花生酱（拟态6型糊状便）
  - 巧克力熔岩蛋糕（拟态7型“喷发火山型”）
  - 坚果巧克力（拟态1型硬球）
- **C类：模糊边界图像**，选取模型分类置信度低于0.8的真实粪便图像

实验参与者分为三组：A组为未经医学训练的大学生（n=30），B组为消化科医师（n=10），C组为StoolNet

AI系统。任务是对每张图像进行二分类判断："是粪便"或"不是粪便"。同时，参与者需对判断的自信程度进行评分（1-5分）。

4.2 实验结果：谁更易被骗？

实验结果揭示了令人深思的差异。

表4 图灵测试实验结果

评估者	准确率(%)	对A类(粪便)识别率(%)	对B类(食品)识别率(%)	平均自信度
大学生	57.3	64.0	50.6	3.8
消化科医师	73.0	86.0	60.0	4.2
StoolNet AI	89.0	92.0	86.0	0.91*

*注：AI自信度为模型输出的概率分数

主要发现：

1. **大学生最易受骗：**整体准确率仅57.3%，略高于随机猜测。对拟态食品的判断准确率仅50.6%，意味着他们几乎无法区分巧克力蛋糕和真实粪便。定性访谈中，多名大学生表示："这照片看着太诱人了，不可能是屎吧？"——这种"美味即排屎"的认知偏见导致系统性误判。
2. **医师表现更好但仍有限：**消化科医师对拟态食品的判断准确率为60%，显著优于大学生但仍不理想。一位医师坦言："从专业角度看，我知道某些特征提示粪便，但巧克力蛋糕的裂纹和光泽实在太逼真了。"医师的视觉经验部分克服了认知偏见，但仍难以抵抗高保真拟态的欺骗。
3. **AI表现最优：**StoolNet对拟态食品的识别准确率达86%，显著高于人类评估者。模型主要依赖纹理特征和颜色分布的细微差异——巧克力蛋糕的纹理具有规律性的人工痕迹，而粪便的质地分布更随机；巧克力在色彩饱和度上与真实粪便也存在可量化的差异。
4. **自信度与准确率的关系：**人类在错误判断时往往保持高自信度（平均3.8-4.2），而AI在错误案例中普遍输出较低置信度（<0.7）。这表明人类可能对自己的视觉判断过度自信，而AI的不确定性估计更为准确。

4.3 案例研究：完美香蕉型 vs 巧克力卷蛋糕

以BSFS-4"完美香蕉型"与拟态食品"巧克力卷蛋糕"的对比为例，分析AI的判别依据。

视觉相似点：

- 均为长条形、光滑表面
- 颜色均为深棕色
- 均有表面纹理（裂纹/卷曲纹）

AI识别的关键差异：

1. **纹理一致性：**巧克力蛋糕的表面纹理呈现周期性重复（烘焙产生的规律裂纹），而粪便的表面纹理随机性更强。StoolNet的ParallelConvSE模块捕捉到这种全局与局部纹理的差异。
2. **边缘特征：**巧克力蛋糕的边缘因模具成型而呈现规则的弧形，粪便边缘则更多受重力影响形成不规则的塌陷。G-SAM分割后的形状特征分析显示，形状矩存在可量化的差异。
3. **颜色空间分布：**在LAB颜色空间中，巧克力蛋糕的L（亮度）值分布更集中，而粪便因成分不均导致亮度值方差更大。
4. **水分反光：**巧克力蛋糕的反光呈点状高光，而粪便表面因水分分布不均形成片状湿润区域——这一特征在BSFS-6和BSFS-7中尤为明显。

这些差异在人类视觉感知中可能被忽略，但CNN通过多层次特征提取能够有效捕捉。这正是AI在'拟态欺骗'测试中胜出的核心原因。

5 讨论

5.1 粪便自动分类的临床应用前景

本研究验证了基于CNN的粪便形态自动分类系统在临床应用的可行性。与患者自我报告相比，自动化系统提供客观、标准化的评估，避免了主观偏差和羞耻感导致的隐瞒。具体应用场景包括：

智能马桶：将粪便分析模块集成到智能马桶中，实现长期、无感的健康监测。杜克大学的研究表明，边缘计算架构可将延迟降低84.2%，满足实时处理需求。对于慢性消化道疾病患者、术后恢复人群，这种持续监测能够及时发现异常并提供预警。

远程医疗：患者可通过手机拍摄粪便图像上传至云端进行分析。对于行动不便的老年人和偏远地区居民，这种非接触式评估为医生提供了客观的诊断依据。Omideyi等人开发的混合CNN平台（MobileNetV2+VGG-16）支持实时分类，可扩展至多种肠道疾病的筛查。

临床研究：在药物临床试验中，粪便形态是评估消化道副作用的重要指标。自动化分类能够为大规模临床试验提供标准化的终点评估，减少多中心研究的异质性。

5.2 图灵测试的哲学意涵：真实性的解构

本研究的图灵测试实验不仅验证了AI的技术能力，更引发了对“真实性”概念的深入思考。

当巧克力蛋糕能纵以50.6%的概率欺骗人类眼睛时，我们不禁要问：什么是“真实”的粪便？如果AI依赖的判别特征（纹理一致性、颜色空间分布）是人类无法直接感知的，那么AI的判断是否比人类更“真实”？

这一悖论在数字健康时代尤为突出。一方面，患者的主诉和主观体验是医疗决策的核心；另一方面，客观的传感器数据可能揭示患者自身未能察觉的异常。当两者冲突时——
比如患者坚称“只是吃了巧克力”，而智能马桶检测出持续一周的BSFS-6形态——谁更可信？

本研究的答案倾向于综合判断。AI的优势在于持续、客观、标准化的监测，能够发现人类容易忽略的细微变化。但人类医师的优势在于整体性思维，能够结合患者的饮食史、症状、心理状态进行综合判断。最理想的模式是“人机协作”：AI提供客观数据，医师赋予数据以临床意义。

5.3 本研究的局限性

尽管取得了积极结果，本研究仍存在若干局限性：

数据集偏差：虽然整合了多个公开数据集，但图像质量、拍摄角度、光照条件存在差异，可能影响模型的泛化能力。未来需要更多元化的数据采集，涵盖不同人群、不同拍摄设备。

动态信息缺失：静态图像无法捕捉粪便的流动性特征，而这是区分BSFS-6和BSFS-
7的关键。视频分析可能提供更丰富的信息，但也带来隐私顾虑和计算负担。

跨文化适用性：饮食习惯影响粪便形态的正常范围，但目前的数据集主要来自北美和东亚，对其他人群的代表性不足。

伦理隐私考量：粪便图像的采集和存储涉及敏感个人信息。智能马桶虽然实现了“无感监测”，但也可能成为隐私泄露的源头。未来的研究和应用必须在技术创新与隐私保护之间寻求平衡。

5.4 未来研究方向

基于本研究的结果和局限性，未来研究可从以下方向深入：

多模态融合：将粪便图像分析与传感器数据（如排便频率、重量、气味）结合，构建更全面的消化道健康评估模型。

可解释性增强：开发可视化技术，向医师和患者展示AI判断的依据（如高亮关键区域、输出特征对比），增强临床信任度。

纵向追踪研究：开展长期队列研究，验证粪便形态变化与疾病发生发展的关联，探索预测性诊断的可能性。

领域泛化：研究跨数据集、跨拍摄设备的域自适应技术，提升模型在实际应用中的鲁棒性。

6 结论

本研究开发了一种基于卷积神经网络的粪便形态自动分类系统，在3982张图像的数据集上实现了91.3%的分类准确率，与消化科医师的表现相当甚至略优。系统对“完美香蕉型”（BSFS-4）和“喷发火山型”（BSFS-7）的识别F1分数分别达到0.914和0.926，展现了良好的细粒度分类能力。

更为重要的是，本研究设计了一项特殊的图灵测试实验，将拟态食品（巧克力蛋糕等）作为“欺骗性”刺激引入评估。结果显示，未经训练的人类观察者无法有效区分真实粪便与拟态食品（准确率57.3%），而AI系统凭借对纹理、边缘、颜色空间的细致分析，达到了89%的准确率。这一发现揭示了AI在特定任务上超越人类感知能力的潜力，也引发了对数字健康时代“真实性”定义的哲学思考。

从“完美香蕉型”到“喷发火山型”，粪便形态谱系记录了人体消化系统的日常变化。当AI比人类更擅长解读这些信号时，我们或许应该重新审视人与机器的关系——
不是替代，而是互补；不是对抗，而是协作。在智能马桶、可穿戴传感器、家庭医疗设备日益普及的未来，AI将成为守护人类健康的无声哨兵，而我们人类，则可以更专注于那些机器无法替代的事情：理解疾病背后的故事，共情患者内心的感受。

毕竟，屎终究是屎，巧克力蛋糕终究是巧克力蛋糕——
AI能够区分它们，而人类需要理解的，是为什么有人会把这两者混淆，以及这背后的认知、心理和文化意涵。

参考文献

[1] Inga, E., Patel, A., Viswanath, P., & Telbany, A. (2025). S4500 Automated Image-Based Classification of Stool Morphology Using a Mobile Convolutional Neural Network. *The American Journal of Gastroenterology*, 120(10S2), S962.

[2] 佚名. (2021). 人体粪便图像中性状及颜色自动识别技术的研究. 电子科技大学硕士学位论文.

[3] Omideyi, D. A., Isiaka, R. M., & Babatunde, R. S. (2025). Development of a Web-Based Platform Utilizing a Hybrid CNN Architecture for Real-Time Fecal Image Classification. *Ajayi Crowther Journal of Pure and Applied Sciences*, 4(4).

[4] Zhou, J. (2024). Integration of Hand-Crafted Features and Deep Learning for Imaging Application in Precision Medicine. Duke University Doctoral Dissertation.

[5] Zhou, J., McNabb, J., DeCapite, N., Ruiz, J. R., Fisher, D. A., Grego, S., & Chakrabarty, K. (2023). Stool Image Analysis for Digital Health Monitoring By Smart Toilets. *IEEE Internet of Things Journal*, 10(5), 3720-3734.

[6] Zhou, J., DeCapite, N., McNabb, J., Ruiz, J. R., Fisher, D. A., Grego, S., & Chakrabarty, K. (2021). Stool Image Analysis for Precision Health Monitoring by Smart Toilets. *Proceedings of the 6th Machine Learning for Healthcare Conference*, PMLR 149, 709-729.

[7] 佚名 (2025). DenseDFFNet: Dense connected dual-stream feature fusion network for calf manure segmentation and diarrhea recognition. *Computers and Electronics in Agriculture*, 234, 110328.