从影像特征到食疗菜谱的端到端生成：基于生成式 AI 的“厨房级”医学报告研究

摘要 医学影像报告生成是人工智能在医疗领域的重要应用，然而现有模型输出的报告充斥着专业术语，患者“看不懂、记不住、用不上”。受中国传统“药食同源”理念启发，本文提出了一种颠覆性的“厨房级”医学报告生成框架——Med2Recipe。该框架首次将影像特征提取与食疗知识图谱相结合，实现从 CT、X 光等医学影像到个性化食疗菜谱的端到端生成。模型采用多模态融合架构，包含影像编码器、疾病-食材注意力机制和食谱解码器三个核心模块。在构建的“医学影像-食疗菜谱”配对数据集上的实验表明，模型在食材预测 F1 分数达到 42.3%，食谱生成的 BLEU-4 得分为 7.8%，且初步临床实验显示，患者对“可食用报告”的依从性提升了 63%。本文工作为医学报告的可解释性和患者参与度提供了全新范式，也引发了对“报告到底写给谁看”这一根本问题的反思。

关键词 医学报告生成；食疗推荐；多模态学习；Transformer；可解释性 AI

Abstract The generation of medical imaging reports is a significant application of artificial intelligence in the healthcare sector. However, existing models often produce reports filled with technical jargon, making them difficult for patients to "understand, remember, and utilize." Inspired by the traditional Chinese philosophy of "medicine and food homology," this paper proposes a groundbreaking "kitchen-level" medical report generation framework—Med2Recipe. This framework, for the first time, integrates image feature extraction with a food therapy knowledge graph, enabling end-to-end generation of personalized dietary recipes directly from medical images such as CT scans and X-rays. The model employs a multi-modal fusion architecture, consisting of three core modules: an image encoder, a disease-ingredient attention mechanism, and a recipe decoder. Experiments conducted on a constructed "medical image-dietary recipe" paired dataset demonstrate that the model achieves a 42.3% F1-score for ingredient prediction and a BLEU-4 score of 7.8% for recipe generation. Preliminary clinical trials indicate a 63% increase in patient adherence to these "edible reports."

This work provides a novel paradigm for the interpretability of medical reports and patient engagement, prompting a fundamental rethinking of the question: "For whom are medical reports ultimately intended?"

Keywords Medical report generation; Food therapy recommendation; Multi-modal learning; Transformer; Explainable AI

1.引言

“医生，我这个报告到底什么意思？”“那我该吃什么？”——这是医院影像科外最常听到的两句话。

医学影像报告是医生与患者沟通的桥梁，然而长期以来，这座桥梁更像是一座“单行道”。现有的自动医学报告生成研究大多聚焦于如何生成更准确、更专业的影像学描述，其输出结果往往连患者自己都难以理解。更关键的是，即便患者看懂了“右肺下叶磨玻璃结节”这样的描述，下一步行动——尤其是“吃什么”——仍然是一片空白。

在中国传统文化中，“药食同源”的理念深入人心。《黄帝内经》有云：“毒药攻邪，五谷为养，五果为助，五畜为益，五菜为充”。食疗作为疾病辅助治疗和康复的重要手段，却长期被排除在现代医学报告体系之外。这种“诊断-治疗”链条中的“吃什么”环节的缺失，造成了患者获得报告后的“行动焦虑”。

与此同时，深度学习领域近期涌现出一批有趣的跨域研究工作。有学者尝试将“逆烹饪”问题形式化为从食物图像生成食谱的任务，其模型能够根据一张

美食照片预测食材列表并生成烹饪步骤。这启发了我们：既然可以从图像生成“入口之物”的做法，为何不能从医学影像生成“入口之物”本身？

基于上述思考，本文提出一个看似“逆天”实则颇具深度的研究问题：能否构建一个从医学影像端到端生成个性化食疗菜谱的 AI 模型？我们的核心贡献如下：

1 任务创新：首次提出“厨房级医学报告”的概念，将传统影像报告的功能从“告知病情”延伸至“指导饮食”。

2 方法创新：构建了融合影像特征与食疗知识的“药膳知识图谱”，设计了疾病-食材注意力机制，实现基于病理特征的个性化菜谱生成。

3 数据集创新：通过爬取中医古籍、现代营养学数据库和食谱社区，构建了首个“医学影像-食疗菜谱”多模态配对数据集。

4 评估创新：提出包括“可食用性”“疗效置信度”“患者依从性”在内的多维评估指标体系。

本文试图论证一个观点：最好的报告，是患者看完后知道晚上做什么吃的报告。

2. 相关工作

2.1 医学报告生成

医学报告生成任务旨在将医学影像（如 X 光、CT、MRI）自动转化为自然语言描述。早期的研究主要采用模板填充和检索方法，近年来基于深度学习的

图像描述模型逐渐成为主流。代表性工作包括基于多任务学习的影像报告生成框架，以及引入知识图谱增强的医学报告生成模型。然而，现有研究普遍存在两大局限：一是输出结果专业性强，普通患者难以理解；二是止步于影像描述，未能为患者提供可操作的后续建议。这为本文的研究提供了切入空间。

2.2 从图像到食谱的“逆烹饪”模型

与医学报告生成并行发展的另一条研究线索是“逆烹饪”（Inverse Cooking）任务。研究者利用大规模食谱-图像配对数据，训练能够从食物图像反向预测食材并生成烹饪步骤的模型。典型的架构包括 VGG-16 图像编码器和 Transformer 解码器，在食材预测任务上 F1 分数可达 38.62%，食谱生成 BLEU-4 得分为 6.15%。这一研究证明了“图像→入口之物”的生成路径是可行的，为本文从医学影像到食疗菜谱的迁移提供了方法论基础。

2.3 药膳推荐系统

现有的饮食推荐系统主要分为两类：一类基于用户口味偏好进行菜品推荐，另一类基于营养需求进行膳食规划。真正结合中医辨证论治理念的药膳推荐系统研究尚属空白。少数工作尝试构建“症状-食材”关联规则，但缺乏从医学影像等客观检查结果到食疗方案的端到端映射。

3. 方法

3.1 问题定义与总体框架

本文将“厨房级医学报告生成”任务形式化如下：给定医学影像 I（如胸部CT、腹部B超等），模型生成三部分输出：(1) 影像学发现F（如“右肺结节”）；(2) 推荐食材列表 $I_g=\{i_1,i_2,\ldots,i_n\}$；(3) 结构化食谱 R，包含菜谱名称、烹饪步骤和每日建议食用量。

模型整体架构包含三个核心模块：

1 影像编码器：提取影像的病理特征表示

2 疾病-食材注意力模块：将影像特征映射到食材空间

3 食谱解码器：生成结构化的食疗菜谱

3.2 影像编码器

采用预训练的3D ResNet-50作为骨干网络，输入为CT影像序列（尺寸：224×224×32），输出为影像特征张量 $X \in R^{d \times h \times w}$。为捕捉病灶区域的局部特征，引入空间注意力机制，使模型聚焦于异常区域。模型在NIH ChestX-ray14数据集上进行预训练。

3.3 药膳知识图谱构建

这是本文方法的核心创新。我们从三方面构建了“药膳知识图谱”：

1 中医古籍数字化：从《本草纲目》、《食疗本草》等古籍中抽取“食材-性味-归经-主治”三元组

2 现代营养学数据库：整合USDA国家营养数据库，补充食材的营养成分信

息

3 烹饪社区数据：从下厨房、豆果美食等平台爬取大量菜谱，构建“食材-菜谱-烹饪方法”关联

最终知识图谱包含食材节点 3,742 个、疾病节点 1,286 个、关系类型 28 种。特别地，我们定义了“相克”“相须”“相使”等中医配伍关系，为菜谱生成提供先验约束。

3.4 疾病-食材注意力机制

传统的图像描述模型仅建立“影像→文本”的映射，无法显式建模疾病与食材的关联。为此，本文提出疾病-食材注意力模块，将影像特征X 与知识图谱中的疾病节点嵌入进行交互，计算食材预测概率：

$$P(i|I)=Softmax(W_i\cdot(A(X)\odot E_d))$$

其中$A(X)$ 是影像特征经过注意力加权后的表示，E_d 是预测疾病类别的嵌入，$\odot$ 表示按元素乘，W_i是食材分类层的权重。这一设计确保食材推荐既基于影像特征，又受疾病类型约束。

3.5 食谱解码器

食材列表生成后，需进一步生成结构化食谱。我们采用两阶段解码策略：

第一阶段：菜谱标题生成:

利用 Transformer 解码器，输入为食材列表的嵌入序列，输出为菜谱标题。

标题需包含疾病信息和主要食材，如“山药枸杞乌鸡汤（肺结节调理版）”。

第二阶段：烹饪步骤生成：

考虑烹饪步骤的时序性和逻辑性，引入层级 LSTM 结构，先生成步骤大纲（备料→预处理→烹饪→调味），再为每一步生成具体描述。生成过程中需保证步骤间的连贯性和可操作性。

3.6 训练目标

模型采用多任务联合训练，总损失函数为：

$$L = \lambda_1 L_{cls} + \lambda_2 L_{ing} + \lambda_3 L_{title} + \lambda_4 L_{step} + \lambda_5 ¿kg❑$$

其中L 为影像分类损失（疾病诊断），L_{ing}为食材预测的二分类损失，L_{title}和 L_{step}为标题和步骤生成的交叉熵损失，$¿kg❑$为知识图谱嵌入的链接预测损失超参数 λ_1-λ_5 通过网格搜索确定。

4. 实验

4.1 数据集构建

由于“医学影像-食疗菜谱”配对数据在公开领域完全不存在，我们自行构建了 MedRecipe-1.0 数据集，构建流程如下：

1 医学影像采集：从合作医院获取脱敏的 CT 影像 10,234 例，涵盖肺结节、脂肪肝、胃溃疡等 8 类常见疾病。影像格式参照 MIMIC-CXR-JPG 标准进行预处理。

2 疾病标注：由 3 名放射科医师对影像进行标注，包括病灶位置、大小、形态特征

3 食疗方案收集：邀请 5 名中医师为每类疾病设计 3-5 套标准化食疗方案，每套方案包含食材列表和菜谱

4 菜谱扩充：基于知识图谱和规则，将标准化方案扩展为多个具体菜谱变体

5 质量控制：由营养师审核菜谱的营养均衡性，剔除明显不合理的组合

最终数据集包含影像-菜谱对 9,876 组，按 8:1:1 划分为训练集、验证集和测试集。

4.2 评估指标

除传统指标外，本文提出以下评估维度：

1 食材预测准确率：采用 Precision、Recall、F1 分数

2 菜谱质量：BLEU、ROUGE、METEOR（与中医师设计的参考菜谱对比）

3 可食用性：邀请志愿者尝试生成的菜谱，评分（1-5 分）

4 疗效置信度：中医师对菜谱“对症程度”的打分

5 患者依从性：在模拟实验中，对比患者对传统报告和“厨房级报告”的遵从意愿

4.3 基线模型与实现细节

由于本文任务为首次提出，没有直接可比的基线模型。我们设计了两种对

比方案：

- Baseline 1：传统影像报告生成模型 + 规则映射（将疾病名映射到预定义食谱库）

- Baseline 2：移除知识图谱的 Med2Recipe 变体（仅从影像直接生成菜谱）

模型实现采用 PyTorch 框架，影像编码器在 NIH ChestX-ray14 上预训练，Transformer 解码器包含 6 层，隐藏层维度 512，参考 GPT-3 的架构设计。训练使用 Adam 优化器，初始学习率 1e-4，batch size 32，在 4 张 NVIDIA V100 上训练 50 轮。

4.4 实验结果

表 1：食材预测性能对比

模型	Precision	Recall	F1
Baseline 1	0.324	0.287	0.304
Baseline 2	0.386	0.351	0.368
Med2Recipe（ours）	0.442	0.406	0.423

表 2：食谱生成质量

模型	BLEU-1	BLEU-4	ROUGE-L	可食用性(1-5)
Baseline 1	0.186	0.043	0.201	2.8
Baseline 2	0.243	0.067	0.254	3.5

Med2Recipe（ours）	0.287	0.078	0.293	4.2

表 3：患者依从性模拟实验（N=50）

报告类型	理解难度(1-5，越低越好)	依从意愿(1-5)	实际行动率
传统影像报告	4.6	1.8	12%
“厨房级”报告	2.1	4.3	68%

4.5 案例分析

输入：胸部 CT，显示右肺下叶 8mm 磨玻璃结节

输出菜谱：

【山药薏米百合汤——适合肺结节调理】

食材：鲜山药 200g，薏米 50g，百合 30g，枸杞 10g，瘦肉 100g

步骤：

1 薏米提前浸泡 2 小时，山药去皮切段，百合掰开洗净

2 瘦肉焯水去浮沫

3 所有食材入锅，加清水 1500ml

4 大火煮沸后转小火煲 1 小时

5 关火前 5 分钟加入枸杞，加盐调味

建议：每周食用 3-4 次，连续 4 周后复查

中医师评价：山药补脾益肺，薏米健脾祛湿，百合润肺止咳，枸杞滋补肝肾，组合合理，符合肺结节“气虚痰瘀”病机的调理原则。

5. 讨论

5.1 为什么是“逆天”但合理？

本文选题看似“搞怪”，实则回应了医学人工智能领域一个被长期忽视的根本问题：医学报告到底写给谁看？

如果报告是写给医生看的，那么现有的专业术语体系无可厚非。但如果承认患者也是报告的核心受众，那么报告的“可理解性”和“可操作性”就必须被纳入评估体系。“厨房级报告”的提出，正是对这一问题的极端化回应——既然患者最关心“吃什么”，那就直接把“吃什么”给他们。

5.2 从“诊断工具”到“健康伴侣”

传统医学影像 AI 定位为医生的辅助诊断工具，其输出终点是“诊断结论”。本文提出的框架将输出终点延伸到“患者行动”，使 AI 从一个“旁观者”变成患者健康管理的“参与者”。这种角色的转变，可能重新定义医学 AI 的价值边界。

5.3 中医与现代医学的融合路径

本文工作也展示了中医知识融入现代医学 AI 系统的可行路径。药膳知识图谱的构建、疾病-食材注意力机制的设计，为传统医学的现代化提供了一个可计算、可验证的方法论框架。

5.4 局限性与未来工作

本研究存在以下局限：

1 疗效验证不足：目前仅完成菜谱生成，尚未开展长期的临床疗效观察

2 个性化程度有限：未充分考虑患者体质差异（如寒热虚实）、过敏史等因素

3 食材地域性缺失：推荐菜谱未考虑食材的地域可获得性

4 法律伦理风险："食疗推荐"若被误读为"治疗方案"，可能引发医疗纠纷

未来工作将围绕以下方向展开：

1. 引入患者个体特征（舌象、脉象、体质问卷）实现个性化推荐
2. 构建"疗效反馈闭环"，通过患者随访数据优化推荐模型
3. 开展随机对照试验，验证食疗方案对疾病康复的实际效果

6. 结论

本文提出了一种从医学影像到食疗菜谱的端到端生成框架 Med2Recipe，首次将"厨房级报告"引入医学影像分析领域。实验结果表明，模型能够基于影像特征预测推荐食材并生成可操作、可食用的菜谱，患者对这类报告的依从性显著高于传统报告。本文工作不仅拓展了医学报告生成的任务边界，也为中医食疗知识的现代化应用提供了新思路。正如一位参与实验的患者所言："看了这么多年报告，第一次知道看完报告该吃什么。"

或许，这才是医学报告该有的样子。

参考文献

[1] Bravin, M. (2020). Deep Inverse Cooking. arXiv preprint.

[2] Wang, X., Peng, Y., Lu, L., Lu, Z., Bagheri, M., & Summers, R. M. (2017). ChestX-ray8: Hospital-scale Chest X-ray Database and Benchmarks on Weakly-Supervised Classification and Localization of Common Thorax Diseases. IEEE CVPR.

[3] Li, M., Cai, W., Verspoor, K., Pan, S., Liang, X., & Chang, X. (2022). Cross-modal Clinical Graph Transformer for Ophthalmic Report Generation. IEEE/CVF CVPR.

[4] 李时珍. (1596). 本草纲目.

[5] 佚名. (战国至西汉). 黄帝内经素问.

[6] Salvador, A., Drozdzal, M., Giro-i-Nieto, X., & Romero, A. (2019). Inverse Cooking: Recipe Generation from Food Images. IEEE/CVF CVPR.

[7] Jiang, G., Yao, Y., Mu, H., Shen, Q., & Zhou, S. (2025). A Knowledge-Enhanced Multi-Task Learning Model for Domain-Specific Question Answering. IEEE ISEAE.

[8] Pennington, J. A., Stumbo, P. J., Murphy, S. P., McNutt, S. W., Eldridge, A. L., McCabe-Sellers, B. J., & Chenard, C. A. (2007). Food Composition Data: The Foundation of Dietetic Practice and Research. Journal of the American Dietetic Association, 107(12), 2105-2113.

[9] Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., & Amodei, D. (2020). Language Models are Few-Shot Learners. arXiv preprint arXiv:2005.14165.

[10] Johnson, A., Lungren, M., Peng, Y., Lu, Z., Mark, R., Berkowitz, S., & Horng, S. (2024). MIMIC-CXR-JPG - chest radiographs with structured labels (version 2.1.0). PhysioNet.

[11] Huang, Z., Zhang, X., & Zhang, S. (2023). KiUT: Knowledge-injected U-Transformer for Radiology Report Generation.

[12] Liu, C., Cao, Y., Luo, Y., Chen, G., Vokkarane, V., & Ma, Y. (2016). DeepFood: Deep Learning-Based Food Image Recognition for Computer-Aided Dietary Assessment. Inclusive Smart Cities and Digital Health.

[13] Schick, T., & Schütze, H. (2021). Exploiting Cloze-Questions for Few-Shot Text Classification and Natural Language Inference.

[14] Radford, A., & Narasimhan, K. (2018). Improving Language Understanding by Generative Pre-Training.

[15] Howard, J., & Ruder, S. (2018). Universal Language Model Fine-tuning for Text Classification.

[16] Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL.

[17] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., & Polosukhin, I. (2017). Attention Is All You Need. NeurIPS.

[18] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. IEEE CVPR.

[19] Deng, J., Dong, W., Socher, R., Li, L. J., Li, K., & Fei-Fei, L. (2009). ImageNet: A Large-Scale Hierarchical Image Database. IEEE CVPR.

[20] Kingma, D. P., & Ba, J. (2015). Adam: A Method for Stochastic Optimization. ICLR.

[21] Johnson, A., Pollard, T., & Mark, R. (2019). MIMIC-CXR Database. PhysioNet.

[22] Irvin, J., Rajpurkar, P., Ko, M., Yu, Y., Ciurea-Ilcus, S., Chute, C., & Ng, A. Y. (2019). CheXpert: A Large Chest Radiograph Dataset with Uncertainty Labels and Expert Comparison. AAAI.

[23] Rajpurkar, P., Irvin, J., Ball, R. L., Zhu, K., Yang, B., Mehta, H., & Ng, A. Y. (2017). Deep learning for chest radiograph diagnosis: A retrospective comparison of the CheXNeXt algorithm to practicing radiologists. PLoS Medicine.

[24] Peng, Y., Wang, X., Lu, L., Bagheri, M., Summers, R., & Lu, Z. (2018). NegBio: a high-performance tool for negation and uncertainty detection in radiology reports. AMIA Joint Summits.

[25] Jing, B., Xie, P., & Xing, E. (2018). On the Automatic Generation of Medical Imaging Reports. ACL.

[26] Chen, Z., Song, Y., Chang, T. H., & Wan, X. (2020). Generating Radiology Reports via Memory-driven Transformer. EMNLP.

[27] Liu, F., Yin, C., Wu, X., Ge, S., Zhang, P., & Sun, X. (2021). Contrastive Attention for Automatic Chest X-ray Report Generation. ACL Findings.

[28] Yang, X., Ye, M., You, Q., & Ma, F. (2021). Writing by Memorizing: Hierarchical Retrieval-based Medical Report Generation. ACL.

[29] Zhang, Y., Wang, X., Xu, Z., Yu, Q., Yuille, A., & Xu, D. (2020). When Radiology Report Generation Meets Knowledge Graph. AAAI.

[30] Liu, G., Hsu, T. M. H., McDermott, M., Boag, W., Weng, W. H., Szolovits, P., & Ghassemi, M. (2019). Clinically Accurate Chest X-Ray Report Generation. MLHC.

[31] Kisilev, P., Sason, E., Barkan, E., & Hashoul, S. (2016). Medical image captioning: learning to describe medical findings with deep neural networks. ISBI.

[32] Shin, H. C., Roberts, K., Lu, L., Demner-Fushman, D., Yao, J., & Summers, R. M. (2016). Learning to Read Chest X-Rays: Recurrent Neural Cascade Model for Image Sentence Labeling. MICCAI.

[33] Wang, X., Peng, Y., Lu, L., Lu, Z., & Summers, R. M. (2018). TieNet: Text-Image Embedding Network for Common Thorax Disease Classification and Reporting in Chest X-Rays. IEEE CVPR.

[34] Li, Y., Liang, X., Hu, Z., & Xing, E. P. (2018). Hybrid Retrieval-Generation Reinforced Agent for Medical Image Report Generation. NeurIPS.

[35] Xue, Y., Xu, T., Long, L. R., Xue, Z., Antani, S., Thoma, G. R., & Huang, X. (2018). Multimodal Recurrent Model with Attention for Automated Radiology Report Generation. MICCAI.

[36] Gale, W., Oakden-Rayner, L., Carneiro, G., Bradley, A. P., & Palmer, L. J. (2017). Detecting hip fractures with radiologist-level performance using deep neural networks. arXiv.

[37] Lakhani, P., & Sundaram, B. (2017). Deep Learning at Chest Radiography: Automated Classification of

Pulmonary Tuberculosis by Using Convolutional Neural Networks. Radiology.

[38] Prevedello, L. M., Erdal, B. S., Ryu, J. L., Little, K. J., Demirer, M., Qian, S., & White, R. D. (2017). Automated Critical Test Findings Identification and Online Notification System Using Artificial Intelligence in Imaging. Radiology.

[39] Titano, J. J., Badgeley, M., Schefflein, J., Pain, M., Su, A., Cai, M., & Oermann, E. K. (2018). Automated deep-neural-network surveillance of cranial images for acute neurologic events. Nature Medicine.

[40] Esteva, A., Kuprel, B., Novoa, R. A., Ko, J., Swetter, S. M., Blau, H. M., & Thrun, S. (2017). Dermatologist-level classification of skin cancer with deep neural networks. Nature.

[41] Gulshan, V., Peng, L., Coram, M., Stumpe, M. C., Wu, D., Narayanaswamy, A., ... & Webster, D. R. (2016). Development and Validation of a Deep Learning Algorithm for Detection of Diabetic Retinopathy in Retinal Fundus Photographs. JAMA.

[42] McKinney, S. M., Sieniek, M., Godbole, V., Godwin, J., Antropova, N., Ashrafian, H., & Shetty, S. (2020). International evaluation of an AI system for breast cancer screening. Nature.

[43] Ardila, D., Kiraly, A. P., Bharadwaj, S., Choi, B., Reicher, J. J., Peng, L., ... & Shetty, S. (2019). End-to-end lung cancer screening with three-dimensional deep learning on low-dose chest computed tomography. Nature Medicine.

[44] Hannun, A. Y., Rajpurkar, P., Haghpanahi, M., Tison, G. H., Bourn, C., Turakhia, M. P., & Ng, A. Y. (2019). Cardiologist-level arrhythmia detection and classification in ambulatory electrocardiograms using a deep neural network. Nature Medicine.

[45] Poplin, R., Varadarajan, A. V., Blumer, K., Liu, Y., McConnell, M. V., Corrado, G. S., ... & Webster, D. R. (2018). Prediction of cardiovascular risk factors from retinal fundus photographs via deep learning. Nature Biomedical Engineering.

[46] Attia, Z. I., Kapa, S., Lopez-Jimenez, F., McKie, P. M., Ladewig, D. J., Satam, G., ... & Friedman, P. A. (2019). Screening for cardiac contractile dysfunction using an artificial intelligence-enabled electrocardiogram. Nature Medicine.

[47] Tomašev, N., Glorot, X., Rae, J. W., Zielinski, M., Askham, H., Saraiva, A., ... & Mohamed, S. (2019). A clinically applicable approach to continuous prediction of future acute kidney injury. Nature.

[48] Liang, H., Tsui, B. Y., Ni, H., Valentim, C. C., Baxter, S. L., Liu, G., ... & Xia, H. (2019). Evaluation and accurate diagnoses of pediatric diseases using artificial intelligence. Nature Medicine.

[49] Ramesh, A., Kambhampati, C., Monson, J. R., & Drew, P. J. (2004). Artificial intelligence in medicine. Annals of The Royal College of Surgeons of England.

[50] Topol, E. J. (2019). High-performance medicine: the convergence of human and artificial intelligence. Nature Medicine.

[51] Yu, K. H., Beam, A. L., & Kohane, I. S. (2018). Artificial intelligence in healthcare. Nature Biomedical Engineering.

[52] Obermeyer, Z., & Emanuel, E. J. (2016). Predicting the Future - Big Data, Machine Learning, and Clinical Medicine. New England Journal of Medicine.

[53] Rajkomar, A., Dean, J., & Kohane, I. (2019). Machine Learning in Medicine. New England Journal of Medicine.

[54] Chen, J. H., & Asch, S. M. (2017). Machine Learning and Prediction in Medicine - Beyond the Peak of Inflated Expectations. New England Journal of Medicine.

[55] Beam, A. L., & Kohane, I. S. (2018). Big Data and Machine Learning in Health Care. JAMA.

附录 A：部分生成菜谱示例

本附录展示了 Med2Recipe 模型针对不同疾病类型生成的 10 个代表性食疗菜谱。每个菜谱均由模型端到端生成，未经人工修改，仅对格式进行了统一整理。菜谱中包含疾病适应症、食材清单、详细烹饪步骤以及食用建议，以体现模型从影像特征到“可

食用报告”的完整生成能力。

菜谱 1：肺结节调理

菜名：山药薏米百合汤（肺结节调理版）

适应症：右肺下叶磨玻璃结节（直径 8mm），证属气虚痰瘀

食材：

鲜山药 200g

薏米 50g

百合 30g

枸杞 10g

瘦肉 100g

生姜 3 片

盐 适量

步骤：

薏米提前用清水浸泡 2 小时，山药去皮切成段，百合掰开洗净，瘦肉切块焯水备用。

将所有食材（除枸杞和盐外）放入汤锅，加入 1500ml 清水。

大火煮沸后转小火慢炖 1 小时。

关火前 5 分钟加入枸杞，调入适量盐即可。

食用建议：每周食用 3-4 次，连续 4 周后复查。此汤健脾润肺、化痰散结，适合肺结节患者日常调理。

菜谱 2：脂肪肝

菜名：决明子山楂鲫鱼汤

适应症：中度脂肪肝，肝郁脾虚型

食材：

鲫鱼 1 条（约 300g）

山楂 15g

决明子 10g

陈皮 5g

冬瓜 200g

生姜 3 片

盐 适量

步骤：

鲫鱼去鳞、内脏，洗净后两面煎至微黄。

决明子、山楂、陈皮用纱布袋装好，冬瓜切块。

将煎好的鲫鱼、药袋、冬瓜、姜片一同放入锅中，加清水 2000ml。

大火煮沸后转小火煲 1.5 小时，取出药袋，加盐调味。

食用建议：每周 2-3 次，坚持饮用 2 个月。具有疏肝理气、降脂化浊的功效，配合低脂饮食效果更佳。

菜谱 3：胃溃疡

菜名：猴头菇猪肚养胃汤

适应症：胃溃疡（活动期），脾胃虚寒证

食材：

新鲜猴头菇 1 朵

猪肚 1 个

红枣 5 颗

生姜 5 片

白胡椒粒 10 粒

盐 适量

步骤：

猴头菇用温水泡发，反复挤压洗净去苦味，切片。

猪肚用面粉和盐反复搓洗，冲净后焯水，切条。

将猪肚、猴头菇、红枣、姜片、白胡椒粒放入砂锅，加足量水。

大火烧开撇去浮沫，转小火煲 2 小时至猪肚软烂，加盐调味。

食用建议：每周 1-2 次，空腹温热服用。猴头菇可促进胃黏膜修复，猪肚以形补形，温中和胃。

菜谱 4：高血压

菜名：芹菜决明子降压粥

适应症：原发性高血压（1 级），肝阳上亢证

食材：

芹菜 100g

决明子 10g

粳米 100g

枸杞 5g

生姜丝 少许

步骤：

决明子放入锅中炒香（不用加油），加水煎煮 20 分钟，去渣留汁。

粳米淘净，加入决明子汁和适量水煮粥。

芹菜洗净切碎，待粥将熟时加入，再煮 5 分钟。

撒入枸杞和姜丝，稍煮片刻即可。

食用建议：每日早餐食用，连续 2 周。芹菜与决明子协同降压，适合肝火旺盛型高血压患者。

菜谱 5：糖尿病（气阴两虚型）

菜名：苦瓜山药炖排骨

适应症：2 型糖尿病，气阴两虚证

食材：

苦瓜 1 根

山药 150g

猪排骨 300g

黄芪 10g

麦冬 10g

生姜 3 片

盐 少许

步骤：

排骨焯水去血沫，苦瓜去瓤切块，山药去皮切段。

黄芪、麦冬用清水稍冲洗。

将所有材料（盐除外）放入炖盅，加开水至八分满。

隔水炖 2 小时，取出加盐调味。

食用建议：每周 2-3 次，可作正餐汤品。苦瓜降糖，山药益气养阴，黄芪麦冬增强气阴双补之效。

菜谱 6：失眠（心脾两虚型）

菜名：酸枣仁莲子桂圆汤

适应症：慢性失眠，心脾两虚证

食材：

酸枣仁 15g

莲子 30g

桂圆肉 10g

百合 20g

红枣 5 颗

冰糖 适量

步骤：

酸枣仁捣碎，装入纱布袋。

莲子、百合提前浸泡 1 小时。

将药袋、莲子、百合、桂圆、红枣放入锅中，加 1000ml 水。

大火煮开后转小火煮 40 分钟，取出药袋，加入冰糖溶化。

食用建议：每晚睡前 1 小时温热服用。连续服用 2 周，可显著改善睡眠质量。

菜谱 7：慢性支气管炎（痰湿蕴肺型）

菜名：陈皮杏仁炖鹧鸪

适应症：慢性支气管炎，痰多咳嗽

食材：

鹧鸪 1 只

陈皮 5g

杏仁 10g

茯苓 15g

生姜 3片

盐 适量

步骤：

鹧鸪宰杀洗净，斩块焯水。

陈皮、杏仁、茯苓洗净。

所有材料放入炖盅，加清水800ml，加盖。

隔水炖2小时，加盐调味。

食用建议：每周2次，连服3周。陈皮燥湿化痰，杏仁降气止咳，鹧鸪补虚，尤宜老年慢性支气管炎。

菜谱 8：痛经（寒凝血瘀型）

菜名：当归生姜羊肉汤

适应症：原发性痛经，经期小腹冷痛

食材：

羊肉 300g

当归 15g

生姜 30g

红枣 5 颗

红糖 适量

步骤：

羊肉切块，冷水下锅煮沸撇沫，捞出。

生姜切片，当归、红枣洗净。

将羊肉、当归、生姜、红枣放入砂锅，加水 2000ml。

大火烧开转小火炖 1.5 小时，至羊肉酥烂，加红糖调味。

食用建议：经前 3-5 天开始服用，每日 1 碗，连服 5 天。此汤为张仲景名方化裁，温经散寒、养血止痛。

菜谱 9：骨质疏松（肾虚型）

菜名：杜仲牛骨壮骨汤

适应症：老年性骨质疏松，腰膝酸软

食材

牛骨 500g

杜仲 15g

巴戟天 10g

黑豆 50g

核桃仁 30g

生姜 5片

盐 适量

步骤：

牛骨敲断，焯水去血水。

黑豆提前浸泡2小时。

杜仲、巴戟天装入纱布袋。

将所有材料（盐除外）放入汤锅，加水2500ml，大火煮沸转小火煲2小时。

取出药袋，加盐调味。

食用建议：每周1-2次，可作家庭滋补汤品。补肾强骨，适合中老年人及骨折恢复期患者。

菜谱 10：湿疹（湿热型）

菜名：土茯苓薏米绿豆汤

适应症：急性湿疹，皮肤红斑、渗液

食材：

鲜土茯苓 100g（或干品 30g）

薏米 50g

绿豆 50g

陈皮 5g

冰糖 适量

步骤：

土茯苓洗净切片，薏米、绿豆、陈皮分别洗净。

所有材料放入锅中，加水 2000ml。

大火煮沸后转小火煮 1 小时，至绿豆开花。

加入冰糖煮化即可（可滤渣取汤饮用）。

食用建议：每日 1-2 次，连服 5-7 天。此汤清热解毒、利湿止痒，忌辛辣发物。

附录 B：患者知情同意书

研究题目：基于生成式 AI 的“厨房级”医学报告系统患者接受度模拟实验

研究机构：[技术大学] 医学人工智能实验室

伦理审批号：IRB-2025-0189

1. 研究目的

您被邀请参与一项关于新型医学报告系统的模拟实验。本研究旨在评估一种由人工智能生成的“厨房级”医学报告（即包含食疗菜谱的影像报告）在患者中的理解度、接受度及依从性。该报告将基于您的医学影像（如 CT、X 光）自动生成诊断描述及个性化的食疗菜谱，以探索更贴近患者需求的报告形式。

2. 研究过程

参与内容：您将看到一份由 AI 生成的模拟医学影像报告（非真实诊断），包含影像发现和对应的食疗菜谱。随后，您需要填写一份简短的问卷，评估报告的可理解性、可操作性以及您尝试菜谱的意愿。

时间投入：全程约 20 分钟。

菜谱尝试（可选）：如果您愿意，可以在家中尝试制作报告中的菜谱，并在 1 周后通过在线问卷反馈您的体验（如口感、制作难度等）。注意：所有菜谱仅供食疗参考，不能替代正规医疗治疗。

3. 风险与不适

本研究不涉及任何侵入性操作或药物干预，无生理风险。

菜谱中的食材均为常见食物，一般无不良反应。但如果您对某些食材过敏，请勿尝试。如食用后出现不适，应立即停止并咨询医生。

由于菜谱由 AI 生成，可能存在不完全适合您个人体质的情况，建议在中医师指导下参考使用。

4. 获益

您将免费获得一份个性化的食疗菜谱，并可能从中获得健康饮食的启发。您的反馈将帮助改进未来的医学报告系统，使其更贴近患者需求。

5. 隐私保密

所有数据将以匿名形式收集和处理，您的姓名、身份证号等个人信息不会出现在任何研究报告中。研究结果可能发表在学术期刊或会议上，但不会泄露您的个人身份。

6. 自愿参与

您的参与完全自愿，可以随时退出而不受任何惩罚，也不会影响您后续的医疗服务。如果您决定退出，已收集的数据将被销毁。

7. 联系人

如有任何问题或疑虑，请联系本研究负责人：[姓名]，电话：[虚构电话]，邮箱：[虚构邮箱]。

知情同意签名

我，_____（姓名），已阅读并理解上述信息。我知晓本研究为模拟实验，所有菜谱仅供参考。我自愿参与本研究，并同意我的匿名数据用于科学研究。

参与者签名：_____

日期：_____年____月____日

研究者签名：_____

日期：_____年____月____日