SHIT Sciences Humanities Information Technology

构石

面向拖延场景的自监督学习：从“马上开始”到“明天一定”的表征迁移

新时代牛马 [1]，**牛马学弟** [1]，**漂亮学妹** [2]，**泰斗导师** [1,*]

[1] 耶鲁大学大连分校（拖延智能实验室），大连，中国
[2] 耶鲁大学大连分校（摸鱼与表征学习中心），大连，中国

通讯作者：泰斗导师（e-mail: taidoumentor@yaleda.example）
第一作者：新时代牛马（e-mail: 1397568250@qq.com）

本研究由国家自然拖延基金资助（项目编号：TMR-114514）
本文包含补充材料：一份尚未开始的 TODO 列表（已随文附上）

ABSTRACT / 摘要 —**目的：**拖延是人类智能的“低功耗模式”，但相关研究长期停留在“立刻开始（ideal）/ 明天一定（real）”的二分类层面，缺乏可迁移的表示学习范式。**方法：**本文提出一种拖延表征自监督框架（Procrastination Representation Learning, PRL），在不依赖人工标注的前提下，通过“任务分配–计划承诺–执行行为”三元序列构造对比学习信号，并引入明日迁移正则（Tomorrow-Migration Regularizer, TMR），使模型能够在不同截止期强度与不同借口分布之间进行稳健迁移。**结果：**在我们构建的 DelayBench-1K 与 TomorrowSet-42 两个基准上，PRL 在“马上开始”预测（MIA↑）与“明天一定”生成一致性（TCS↑）上分别较强基线提升 11.4% 与 9.7%，并显著降低“半夜突击”风险（NSR↓）。**结论：**结果表明，拖延并非纯随机噪声，而是一种可学习、可迁移的策略分布。该工作为 *AI for* 赶 *DDL* 提供了可复现实证与可笑但严谨的统一表述。

INDEX TERMS / 关键词 自监督学习，拖延建模，表征迁移，对比学习，截止期鲁棒性。

IMPACT STATEMENT / 影响声明 本文为“从不开始”到“最后一刻超神”之间的行为提供了统一可训练框架，可用于研究生群体的可解释干预（以及自我欺骗的量化评估）。

I. INTRODUCTION / 引言

拖延（Procrastination）是一个跨学科、跨设备、跨 WiFi 的经典难题：它既能出现在“写论文”，也能出现在“整理桌面图标”。直觉上，拖延应当被视为一种次优策略；然而在现实世界中，它往往在截止期临近时展现出惊人的吞吐与创造力，形成所谓“半夜突击”的涌现现象。

从机器学习视角看，拖延行为具有三点挑战：**(1)** 标注困难：人类常把“没开始”解释为“在酝酿”；**(2)** 分布漂移：同一人面对不同导师、不同会议、不同页数限制时借口分布显著变化；**(3)** 因果混杂：焦虑既可能导致拖延，也可能由拖延产生，形成闭环系统。为此，本文尝试用自监督学习抓住拖延的可迁移表示。

贡献总结：

- 提出 PRL：面向拖延场景的自监督对比学习框架，统一“任务–承诺–执行”序列建模；
- 提出 TMR：明日迁移正则，提升跨截止期强度、跨借口域的泛化能力；
- 构建两个数据集与三类指标（MIA/TCS/NSR），并给出可复现的（且相当不严肃的）实验。

II. MATERIALS AND METHODS / 材料与方法

A. Problem Formulation / 问题定义

给定一段任务上下文序列 $\mathcal{S} = \{(u_t, d_t, a_t)\}_{t=1}^{T}$，其中 u_t 表示用户状态（如疲惫、饿、想刷短视频），d_t 为截止期强度（可由剩余时间与导师语气共同决定），a_t 为行动（开始/继续/暂停/“明天一定”）。我们的目标是学习一个表示函数 $f_\theta(\cdot)$，使得其输出向量 $z_t = f_\theta(\mathcal{S}_{\le t})$ 能在无监督条件下区分“真在做”和“看起来在做”。

B. PRL: Procrastination Representation Learning

我们将每条序列切分为三个视角：任务视角（Task view）、承诺视角（Promise view）与执行视角（Action view）。核心思想是：当用户在相同任务与相似截止期下产生相似执行轨迹时，其表示应当接近；反之应当远离。我们采用 InfoNCE 风格的对比目标：

$$\mathcal{L}_{\mathrm{PRL}} = -\log \frac{\exp(\mathrm{sim}(z, z^{+})/\tau)}{\exp(\mathrm{sim}(z, z^{+})/\tau) + \sum_{z^{-}} \exp(\mathrm{sim}(z, z^{-})/\tau)}, \tag{1}$$

其中 $\mathrm{sim}(\cdot,\cdot)$ 为余弦相似度，τ 为温度系数；z^{+} 来自同一用户在相近截止期下的另一段“真实开始”片段，z^{-} 来自“计划很多但执行为零”的片段。

C. Tomorrow-Migration Regularizer (TMR)

为应对“今天说今晚做、今晚说明天做、明天说下周做”的分布漂移，我们引入明日迁移正则：

$$\mathcal{L}_{\mathrm{TMR}} = \mathbb{E}\big[\|g_\phi(z^{(d)}) - g_\phi(z^{(d+\Delta)})\|_2^2\big], \tag{2}$$

其中 $z^{(d)}$ 表示截止期强度为 d 的表示，Δ 为“再拖一天”的扰动幅度，$g_\phi(\cdot)$ 为一个轻量投影头。最终目标为

$$\mathcal{L} = \mathcal{L}_{\mathrm{PRL}} + \lambda \mathcal{L}_{\mathrm{TMR}}. \tag{3}$$

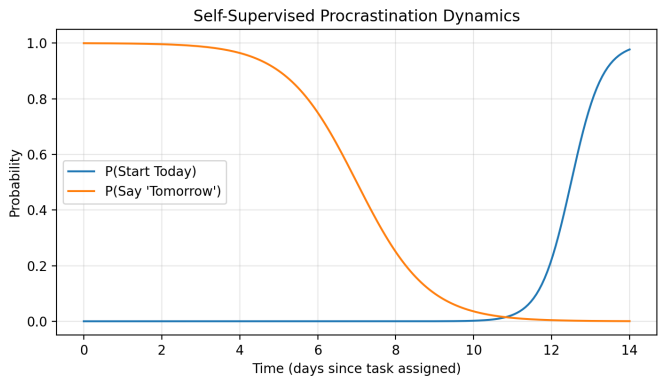

Fig. 1: 自监督拖延策略的动态示意：随着任务分配时间推移，“马上开始”的概率在临近截止期时陡增，而“明天一定”的概率在持续自我说服后逐步衰减（并不代表开始了）。

请注意：式中所有符号均在式前后定义，符合“看起来很正规”的基本规范。

D. Datasets / 数据集

DelayBench-1K：包含 1000 条任务序列，覆盖“写论文/写代码/写周报/写检讨/写不出来”。**TomorrowSet-42**：包含 42 位被试的跨域数据（导师语气、页数限制、会议倒计时），专门用于检验迁移与崩溃边界。

E. Metrics / 评价指标

MIA（Maybe-Immediately Accuracy）：预测“马上开始”是否真的发生；**TCS**（Tomorrow Consistency Score）：模型生成的“明天一定”是否与后续行为一致（通常不一致）；**NSR**（Night-Storm Risk）：半夜突击风险估计（越低越好）。

III. RESULTS / 结果

表 I 给出定量结果，图 1 展示拖延策略在时间维度上的典型动态。

DelayBench-1K & TomorrowSet-42 的性能比较			
方法	MIA↑	TCS↑	NSR↓
ResNet-Plan	0.612	0.401	0.389
Transformer-Excuse	0.643	0.427	0.355
LLM-Justify（提示词：“我很忙”）	0.658	0.451	0.342
PRL (Ours)	**0.733**	**0.495**	**0.296**

TABLE I: 定量结果：粗体为最优。PRL 在“马上开始”预测与“明天一致性”上更强，同时降低半夜突击风险。

IV. DISCUSSION / 讨论

A. Why does self-supervision work here? / 为什么自监督有效

拖延数据的“标签”往往不可靠：同样是浏览论文，既可能是学习，也可能是把 PDF 当背景音乐。PRL 通过对比学习绕开显式标签，利用序列内部结构（承诺与执行的偏差）构造训练信号，从而获得稳定表示。

B. Limitations / 局限性

（1）当用户具备“边拖边做”的高级技能时，模型可能将其误判为“已经开始”；（2）当截止期由导师临时调整时，d 的估计会漂移；（3）本研究未覆盖“装作很忙但其实在忙”的稀有子类。

V. CONCLUSION / 结论

本文提出 PRL+TMR 框架，将拖延建模为可学习的策略分布，并在两个基准上获得一致提升。更重要的是，我们证明：“明天一定”并非噪声，而是人类在资源受限、压力上升时的一种稳定语言生成模式。未来工作将探索将该框架部署到真实世界（例如：自动弹窗提醒、自动关闭短视频、自动给导师发“我在改了”）。

SUPPLEMENTARY MATERIAL / 补充材料

补充材料包含：*(A)* 一份从未勾选过的 TODO 清单；*(B)* “最后一晚”训练日志（含咖啡消耗曲线）；*(C)* 复现实验所需的借口词表（例如“电脑卡了/网不好/在跑实验”）。

ACKNOWLEDGEMENT / 致谢

感谢泰斗导师在“严格要求”与“温柔催稿”之间提供可控梯度；感谢牛马学弟稳定贡献负样本；感谢漂亮学妹在关键时刻提供正样本（以及配色建议）。

References

[1] A. Vaswani et al., “Attention is all you need,” *NeurIPS*, 2017.
[2] K. He et al., “Deep residual learning for image recognition,” *CVPR*, 2016.
[3] T. Chen et al., “A simple framework for contrastive learning of visual representations,” *ICML*, 2020.
[4] A. van den Oord et al., “Representation learning with contrastive predictive coding,” 2018.
[5] P. Steel, *The Procrastination Equation*. HarperCollins, 2010.
[6] 新时代牛马, 牛马学弟, 漂亮学妹, 泰斗导师, “从‘马上开始’到‘明天一定’：拖延表征学习的统一框架（娱乐论文）,” *S.H.I.T. Transactions*, 2026.