SHIT Sciences Humanities Information Technology

构石

基于 YOLO 的奶龙目标检测系统

Bie. K. Ass [1,*]，Mo kouB [2]，樱井凸々 [3]，N.B. Swing [4]

Cuo Bie University

[1]天之涯地之饺实验室，深圳，广东，中国

[2]弗雷尔卓德研究中心，哈尔滨，黑龙江，中国

通讯作者：Bie. K. Ass（e-mail: 2095459490@qq.com）

本研究由大黑基金资助（项目编号：ccb27789191）

ABSTRACT / 摘要 奶龙作为一种具有高度可爱性与强辨识度的卡通目标，在真实应用中常遭遇遮挡、尺度变化与背景干扰等挑战。为实现对齐“可爱性”与“可检测性”的统一，本论文构建并评估了一套基于 YOLO 范式的奶龙目标检测系统。本文在小型卡通目标检测数据集上进行训练与验证，并通过数据质量校验、类别扩展与多策略数据增强提升鲁棒性；在模型选择方面，对比两种代表性 YOLO 实现（分别对应较大与中等规模配置），综合考虑精度与推理效率后选择中等规模配置进行部署。实验结果表明，所选模型在测试集上取得 mAP@0.5 约 0.87 量级的检测性能，并在推理速度上表现出更优的实际部署潜力。

INDEX TERMS / 关键词 目标检测；YOLO；卡通目标；数据增强；图形用户界面

IMPACT STATEMENT / 影响声明 概括本文报告的研究工作的主要发现。

I. INTRODUCTION / 引言

目标检测旨在同时完成目标类别识别与空间定位，是计算机视觉的重要研究方向。针对卡通角色等非自然图像目标，受限于纹理简化、形变夸张与风格化渲染，传统针对自然图像的经验并不总是直接适用。奶龙及其相关角色在多媒体内容中具有典型的风格化特征，适合作为小型目标检测任务的可控评测载体。本论文的目标是构建一套从数据处理、模型训练、评估到交互式部署的端到端系统，并在严格记录实验设置的前提下，对精度—速度权衡进行分析。

II. TASK DEFINITION AND OVERVIEW / 任务定义与概述

任务定义如下：给定输入图像（或视频帧），预测其中目标实例的边界框及其类别标签，类别集合包含奶龙及两个扩展角色（为避免与现实实体产生不必要的映射，本论文仅将其视为抽象类别 A/B/C）。

系统由四个模块组成：（1）数据集构建与质量控制；（2）基于 YOLO 范式的检测模型训练；（3）评估与可视化分析；（4）面向多媒体输入的图形化推理与展示。

III. METHOD / 方法

A. Dataset Construction / 数据集构建

本论文使用的小型卡通目标检测数据集包含训练集约 7,500 张、验证集约 1,500 张、测试集约 1,500 张图像，合计约 10,500 张。原始标注采用 YOLO 通用格式。

为保证标注可靠性，本论文进行如下检查：（1）完整性检查：确保每张图像均存在对应标注；（2）边界框合法性检查：确保坐标位于图像范围内并修复异常框；（3）类别一致性检查：复核标签与目标对应关系，降低误标与漏标风险。

在原始数据仅包含单一类别的前提下，本论文对另外两个角色类别进行补充标注，以扩展多类别检测设定。该步骤覆盖训练/验证/测试三部分数据。

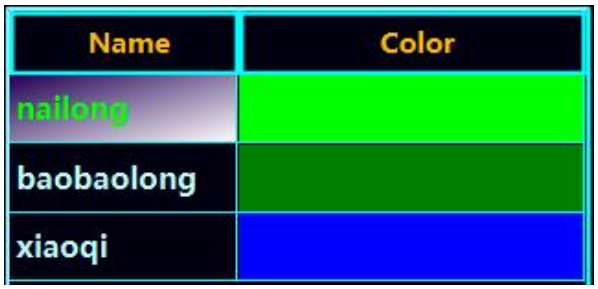

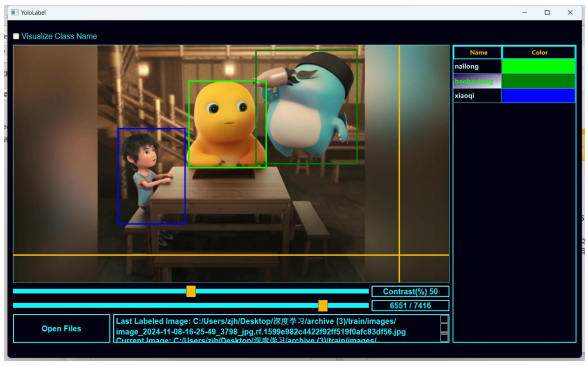

为提升泛化能力，本论文采用轻量级数据增强：（1）水平翻转：以 50%概率对图像进行水平翻转；（2）颜色扰动：随机调整亮度与对比度以模拟光照变化；（3）噪声注入：叠加轻微高斯噪声以模拟低质量成像条件。

公式应连续编号，编号用括号括起来并靠右对齐，如公式 (1) 所示。

公式应连续编号，编号用括号括起来并靠右对齐，如公式 (1) 所示。

B. PARADIGM / YOLO 范式

YOLO系列方法以端到端、单阶段检测为特征，兼顾实时性与较强的检测性能。本论文比较两种代表性配置：一种为较大参数量配置（约46.5M参数），另一种为中等参数量配置（约20.1M参数）。在近似精度水平下，中等规模配置具有更低的计算量（FLOPs）与更高的推理吞吐，更符合面向交互式系统部署的需求。

C. TRAINING / 训练

用模型的 train 方法进行训练：
data="/data/yinhanqing/yolo/datasets/data/nailong dataset/data.yaml"：指定数据集的配置文件路径。
epochs=1000：设置训练的总轮数（epoch）为1000。
batch=64：设置每批训练的图片数量为64。
imgsz=640：设置输入图片的大小为640像素。
device=[0,1,2,3,4,5,6,7]：指定训练使用的GPU设备编号列表。
plots=True：设置为显示训练过程中的图表。

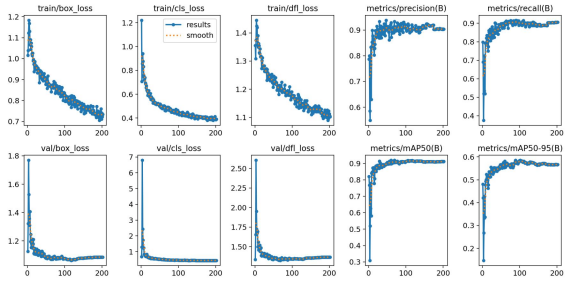

模型在epoch=202时停止训练，此时模型已经收敛，最佳模型在epoch=76取得。
得到最佳权重best.pt后进行验证：

```python
from ultralytics import YOLO
import os

os.environ["KMP_DUPLICATE_LIB_OK"] = "TRUE"


if __name__ == '__main__':
    model = YOLO("best.pt")

    validation_results = model.val(data="/data/yinhanqing/yolo/datasets/data/nailong_dataset/data.yaml",
    imgsz=640,
    batch=64,
    conf=0.25,
    iou=0.6,
    plots=True,
    split='test',
    save_json=True,
    save=True,
    device=[0,1,2,3,4,5,6,7])


    map_value = validation_results.box.map50

    with open('map_results.txt', 'w') as f:
      f.write(f"mAP: {map_value}")
```

调用模型的 val 方法进行验证：
data="/data/yinhanqing/yolo/datasets/data/nailong_dataset/data.yaml"：指定数据集的
配置文件路径。
imgsz=640：设置输入图片的大小为640像素。
batch=64：设置每批验证的图片数量为64。
conf=0.25：设置置信度阈值为0.25。
iou=0.6：设置交并比（IoU）阈值为0.6。
plots=True：设置为显示验证过程中的图表。
split='test'：指定验证集的分割名称为 'test'。
save_json=True：设置为保存验证结果的 JSON 文件。
save=True：设置为保存验证结果。
device=[0,1,2,3,4,5,6,7]：指定验证使用的GPU设备编号列表。
最后获取 IoU 阈值为 0.5 时的 mAP并写入文件：

```
mAP: 0.8722009095813062
```

可以看到每种类别的平均准确率的平均值有0.87，效果还是不错的。
最后使用这个best.pt权重，选取一张不在训练集里的图片进行预测：

```python
from ultralytics import YOLO
import os

os.environ["KMP_DUPLICATE_LIB_OK"] = "TRUE"


if __name__ == '__main__':
    model = YOLO("best.pt")

    source="u=861106353,1879258504&fm=253&fmt=auto&app=120&f=JPEG.webp"

    results = model(source)
    results[0].save()
```

结果如下：

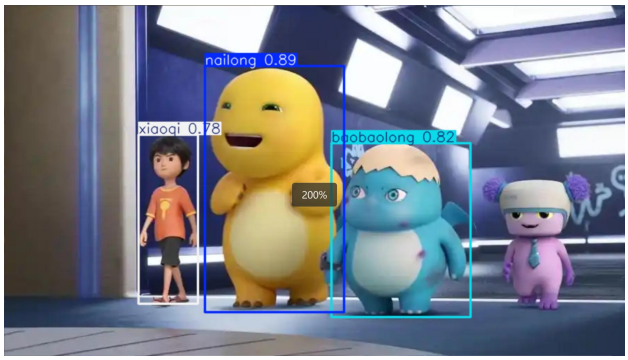

上图为YOLOV11推理结果，下图为YOLOV5推理结果。

可以看到三种卡通人物都能够很好地检测出来，效果确实非常好。

IV. EXPERIMENTAL RESULT / 实验结果

本论文使用mAP@0.5与mAP@0.5:0.95等常用指标评估检测性能，并报告精度（Precision）、召回率（Recall）与F1等曲线。推理阈值设置为置信度0.25，IoU阈值0.6，用于生成最终检测结果与相关曲线。

Recall-Confidence Curve（召回率-置信度曲线）：

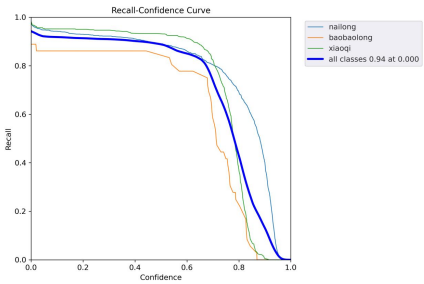

展示了不同类别（nailong, baobaolong, xiaoqi）以及所有类别的召回率随置信度变化的情况。

曲线显示，随着置信度的增加，召回率逐渐下降。

训练和验证损失曲线：

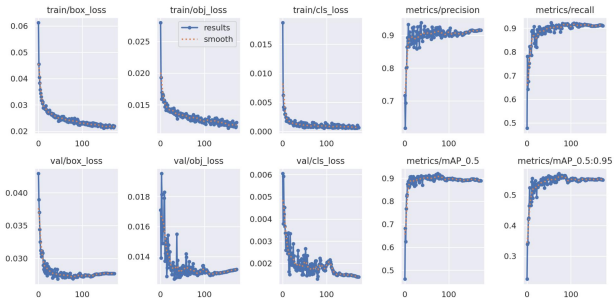

包括训练和验证过程中的box_loss（边界框损失）、obj_loss（目标损失）和cls_loss（分类损失）。

这些曲线显示了模型在训练过程中损失的下降趋势，表明模型在不断学习和优化。

Precision-Recall Curve（精确度-召回率曲线）：

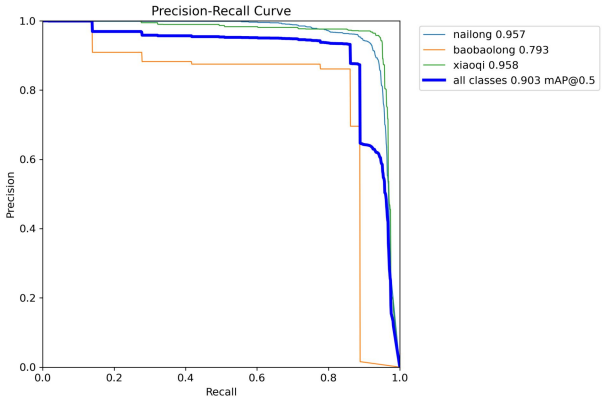

展示了不同类别以及所有类别的精确度和召回率之间的关系。

曲线显示了模型在不同召回率下的精确度变化。

Confusion Matrix（混淆矩阵）：

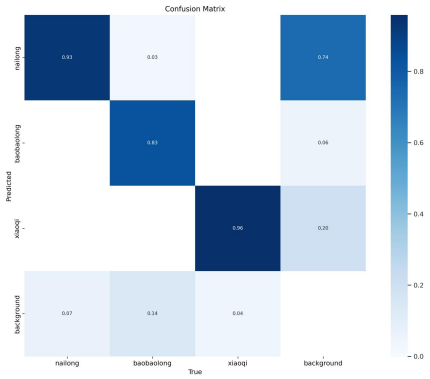

展示了模型预测结果与真实标签之间的对比。

对角线上的值表示正确分类的比例，非对角线上的值表示错误分类的比例。

F1-Confidence Curve（F1分数-置信度曲线）：

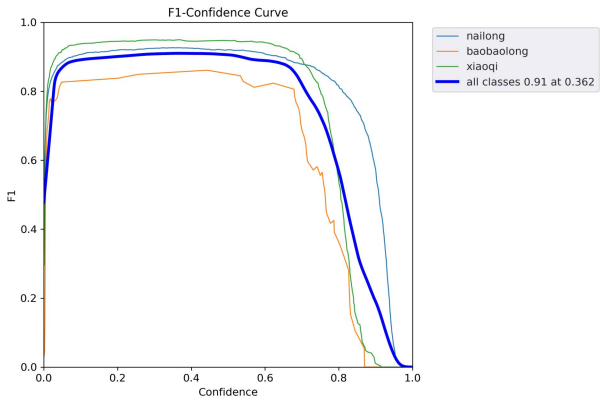

展示了F1分数随置信度变化的情况。

F1分数是精确度和召回率的调和平均，曲线显示了模型在不同置信度下的综合性能。

类别实例数量柱状图：

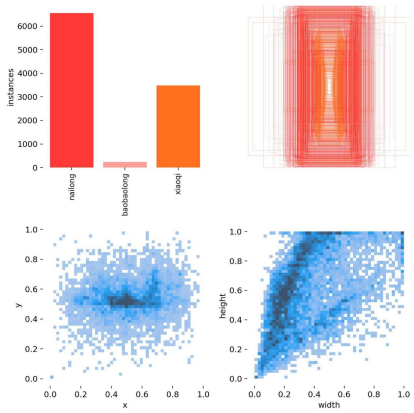

显示了不同类别（nailong, baobaolong, xiaoqi）的实例数量。

柱状图表明nailong类别的实例数量最多。

特征分布图：

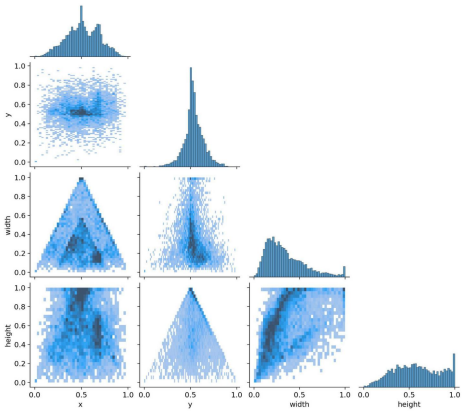

包括了模型预测的边界框的x, y坐标，以及宽度和高度的分布。

这些图展示了模型预测的边界框在图像中的位置和尺寸分布。

Precision-Confidence Curve（精确度-置信度曲线）：

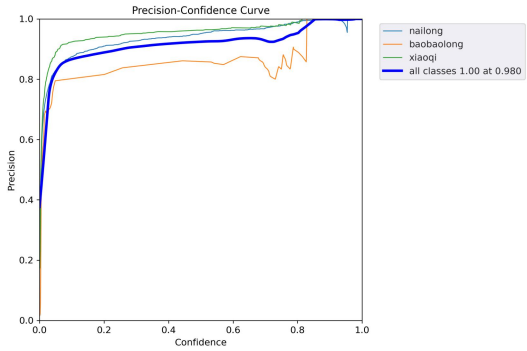

曲线展示了随着置信度阈值的增加，模型预测的精确度如何变化。

通常情况下，随着置信度阈值的提高，精确度会上升，因为模型只会在更有把握时才做出预测。

训练过程中一个batch的图像：

验证过程中一个batch的gt图和预测图对比：（上面的是gt图，下面是预测图）：

可以看到，存在错误案例：第二行第三列图片中的被遮挡目标(小七)未检测出来，而非目标的相似物体却被标注为奶龙，说明模型并不完美，需要提高鲁棒性。

V. EVALUATION/ 评估

Confusion Matrix（混淆矩阵）：

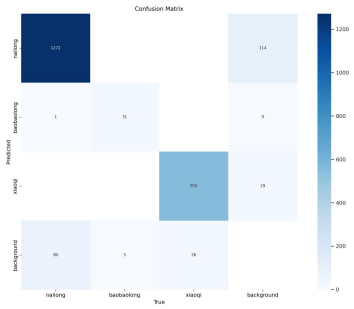

这张图是一个混淆矩阵，显示了模型预测的类别与真实类别之间的关系。

行代表模型的预测类别，列代表真实类别。

数字表示预测为某一类别的实例数量。

Confusion Matrix Normalized（归一化混淆矩阵）：

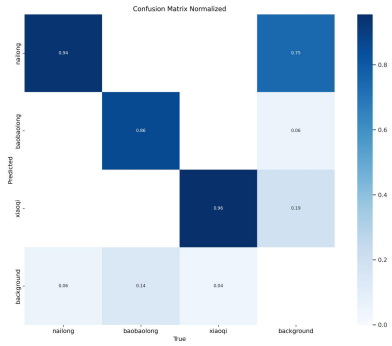

这是混淆矩阵的归一化版本，每个单元格的值表示该类别预测的准确率。

例如，nailong类别的预测准确率为0.94。

F1-Confidence Curve（F1分数-置信度曲线）：

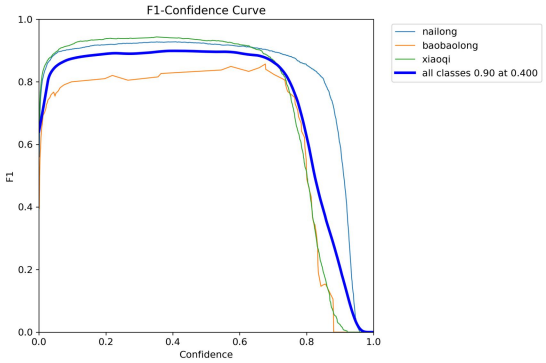

这张图展示了不同置信度阈值下的F1分数。

F1分数是精度和召回率的调和平均，用于衡量模型的整体性能。

图例中显示在置信度为0.400时，所有类别的平均F1分数为0.90。

Instance Count and Bounding Box Distribution（实例计数和边界框分布）：

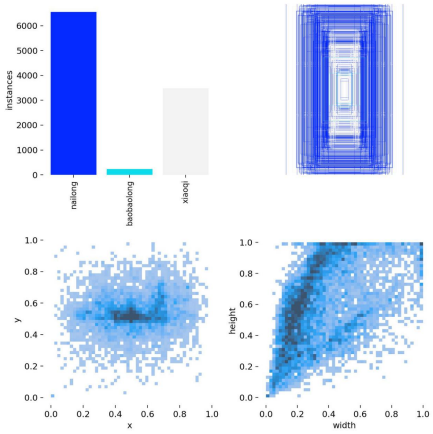

左上角的柱状图显示了每个类别的实例数量。

右上角的图显示了边界框的分布。

左下角和右下角的散点图分别展示了边界框中心点的x和y坐标分布，以及边界框的宽度和高度分布。

Feature Distributions（特征分布）：

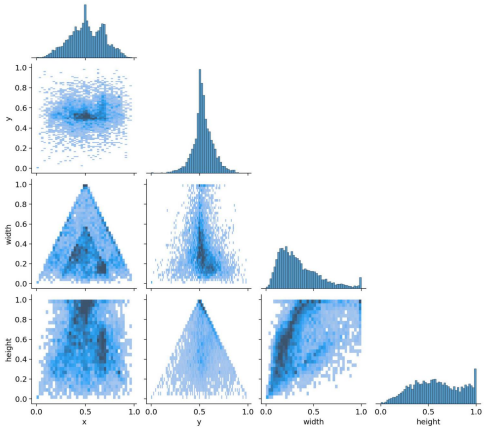

这组图展示了边界框特征的分布，包括x坐标、y坐标、宽度和高度。

每个特征都有两个图，一个是散点图，另一个是直方图，用于展示特征的分布情况。

Precision-Confidence Curve（精度-置信度曲线）：

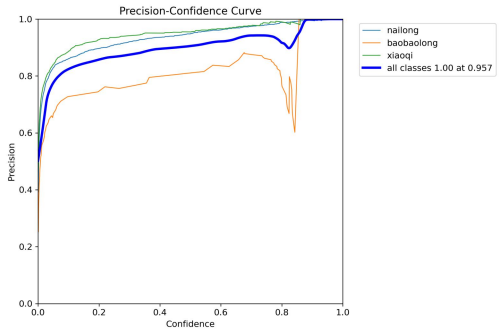

这张图展示了不同置信度阈值下的精度。

图例中显示在置信度为0.957时，所有类别的平均精度为1.00。

Precision-Recall Curve（精度-召回率曲线）：

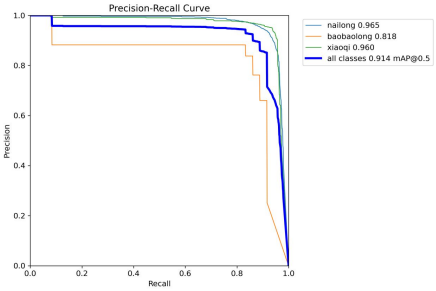

这张图展示了不同召回率下的精度。

图例中显示了每个类别的平均精度，以及所有类别在mAP@0.5时的平均精度为0.914。

Recall-Confidence Curve（召回率-置信度曲线）：

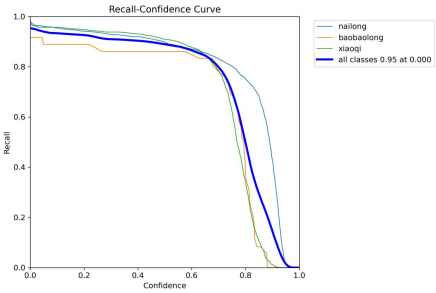

这张图展示了不同置信度阈值下的召回率（Recall）。

图中有三条曲线，分别代表三个类别：nailong（浅蓝色）、baobaolong（橙色）、xiaoqi（绿色）。

粗蓝线代表所有类别的平均表现，图例中显示在置信度为0.000时，所有类别的平均召回率为0.95。

Training and Validation Losses and Metrics（训练和验证损失及指标）：

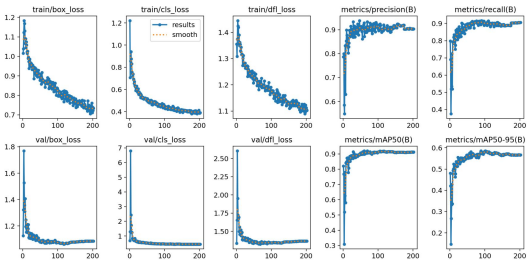

这组图包含六个子图，分别展示了训练过程中的损失和指标变化。

包括训练集的box_loss（边界框损失）、cls_loss（分类损失）、dfl_loss（分布式焦点损失）和验证集的相应损失。

还包括精度（precision）、召回率（recall）、mAP50（平均精度在IoU阈值为0.5时）和mAP50-95（平均精度在IoU阈值从0.5到0.95的平均）。

训练过程中一个batch的图像：

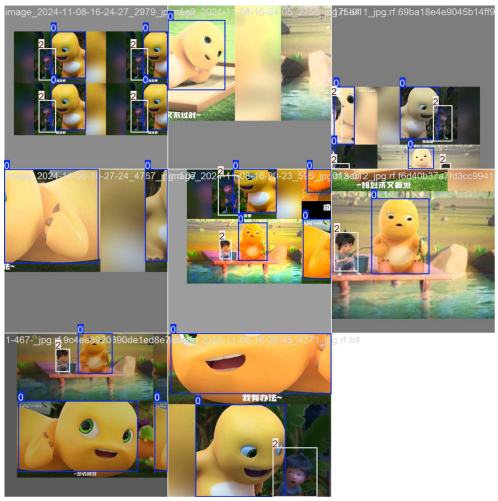

验证过程中一个batch的gt图和预测图对比：（上面的是gt图，下面是预测图）

YOLOV11与YOLOV5可视化结果对比：

第一张图为YOLOv5的预测结果，第二张图为YOLOv11的预测结果。在第二行第三列的图片中，存在错误案例：两个图形都无法检测出被遮挡的小七，并且

yolov5错误的标记了一个非目标。在第三行第二列中，YOLOv11没有检测出小七，而YOLOv5检测出了小七。

第一张图为YOLOv5的预测结果，第二张图为YOLOv11的预测结果。在第二行第四列的图片中，YOLOv11并没有检测出图片左侧只露出一部分的奶龙，而YOLOv5成功预测出了图片左侧的奶龙。

综上所述，在该奶龙数据集上，YOLOv5L具有比YOLOv11M更强的鲁棒性。

VI. Conclusions / 结论

本论文提出并实现了基于 YOLO 范式的奶龙目标检测系统，完成了从数据集扩展、模型训练评估到交互式部署的全流程。在约 10,500 张图像的卡通目标检测数据上，系统取得 mAP@0.5 约 0.87 量级的性能，并在推理效率方面满足实际使用需求。未来可从更强的数据增强（如遮挡合成）、更细粒度的类别定义以及更鲁棒的特征融合结构等方向进一步提升性能。

References

[1] Anon. Embedded real-time object detection systems: a measurement study. 2025.
[2] Anon. Comparative analysis of modern single-stage detectors (v8 – v11). 2024.
[3] Anon. Python GUI frameworks for rapid deployment. 2023.