SHIT Sciences Humanities Information Technology

构石

多任务学习框架下的疲劳与恢复评估：基于小鼠饲养工作负荷与重装徒步体能负荷的数据驱动研究

婉拒 sci 邀稿好几次 [1]

[1]家里蹲大学，常州，江苏，中国

通讯作者：鲁子姐（tiktok:lululu）

本研究由梅里东坡基金资助（项目编号：20260302）

本文不含补充材料

ABSTRACT / 摘要 针对研究生在两类高负荷情境——实验室小鼠饲养与动物实验日常管理（工作负荷）以及重装徒步训练（体能负荷）——中疲劳累积与恢复状态难以被客观、连续、统一评估的问题，本文提出一种面向双情境数据的多任务学习评估框架。该框架以共享表征学习为核心，联合完成疲劳水平回归、恢复状态分类以及短期表现/风险预测等任务，并通过对比学习与域对齐约束增强跨情境泛化能力。我们构建并整合多源多模态数据：工作侧包含任务流特征（操作频次、持续时长、夜间值班、搬运/处理事件）、活动负荷特征（步数、能量消耗代理）等；徒步侧包含负重、爬升、速度等外部负荷信息，并融合心率/心率变异性、睡眠指标与主观疲劳量表形成生理—行为联合表征。实验结果表明，相较于单任务与无对齐基线方法，所提模型在疲劳估计误差、恢复识别准确率以及次日状态预测等指标上均取得显著提升；同时，共享表征能够稳定捕捉“负荷—反应—恢复”的通用规律，在跨场景测试中保持更好的鲁棒性。可解释性分析进一步揭示，连续高强度任务、睡眠不足与 HRV 下降对疲劳上升贡献显著，而负荷回落与睡眠恢复与风险降低呈稳定相关。上述结果验证了所提多任务框架在双情境疲劳与恢复评估中的有效性，为科研人群负荷管理、训练计划优化与过度疲劳预警提供了可迁移的数据驱动技术路径。

INDEX TERMS / 关键词 多任务学习；疲劳评估；恢复状态；多模态建模；跨情境泛化；域对齐

IMPACT STATEMENT / 影响声明 本研究面向“小鼠饲养工作负荷”与“重装徒步体能负荷”两类真实高负荷场景，提出并验证了一个多任务学习的疲劳与恢复评估框架，能够将任务强度、活动负荷、心率/HRV、睡眠与主观量表等信息联合建模，同时输出疲劳水平、恢复状态及短期风险趋势。研究结果表明，多任务联合学习相较单任务方法具有更高的评估准确性与跨场景稳定性，可为研究生日常科研安排、轮班与休息策略、徒步训练负荷分配及过度疲劳预警提供量化依据与可落地的技术方案。。

I. INTRODUCTION / 引言

近年来，伴随科研节奏加快与高强度训练方式的普及，“疲劳累积—恢复不足”已成为影响研究生身心状态与工作表现的重要因素。对于以实验动物为对象的科研工作而言，小鼠饲养与动物实验管理具有显著的“高频—碎片化—刚性时间窗”特征：日常投喂、换笼、称量、给药、观察记录、夜间值班与突发状况处理等任务往往难以完全按计划分配，容易形成隐性的长期工作负荷。与之并行，重装徒步作为一种典型的耐力型、长时程体能活动，具有外部负荷明确（负重、爬升、路程、配速）但环境扰动复杂（温度、海拔、地形、补给、风险暴露）的特点，常导致显著的短期疲劳与恢复需求。两类情境虽处于不同场域，却共同指向同一个核心问题：如何在多源信息分散、个体差异显著且状态动态变化的条件下，对疲劳与恢复进行客观、连续、可比较的量化评估，并进一步服务于负荷管理与风险预警。

现有研究在疲劳评估方面主要依赖三类路径：其一是主观量表与自评问卷，具有实施便捷的优势，但易受情绪、动机与回忆偏差影响，且难以实现高频、长期追

踪；其二是单一或少数生理指标（如心率、心率变异性HRV、睡眠时长等），能够反映部分自主神经或恢复状态，但在不同个体与不同任务形态下存在解释不一致的问题；其三是基于任务/训练负荷的经验指标（如训练量、步数、能量消耗代理、RPE 等），可描述外部负荷，却无法直接刻画个体的内部反应与恢复过程。尤其在“小鼠饲养工作负荷”这类以任务流为核心的科研场景中，负荷往往表现为操作频次、持续时长、夜间干扰与突发事件的组合，而非单一强度指标；在“重装徒步体能负荷”场景中，外部负荷与环境扰动共同作用，导致同等路程下疲劳程度可能差异显著。因此，单指标或单任务的建模方式很难稳定捕捉“负荷—反应—恢复”的动态链条，也难以在两类情境之间形成统一的评估尺度。

从方法学角度看，疲劳与恢复评估天然具有“多目标”属性：研究者既希望得到连续的疲劳强度估计（回归问题），也需要对恢复状态进行分级或判别（分类问题），同时还关注短期趋势与风险（预测问题）。将这些目标割裂为多个独立模型，不仅会造成信息利用不足，还容易出现不同任务输出之间不一致的问题。多任务学习（Multi-Task Learning, MTL）为此提供了一个更契合的框架：通过共享表示学习提取跨任务的共同结构，再由任务专属分支完成不同输出，可以在数据有限或噪声较大的现实场景中提高泛化能力与预测稳定性。进一步地，由于小鼠饲养与重装徒步在数据分布、特征形态与噪声来源上存在明显差异，单纯共享参数可能引入“负迁移”；引入跨域约束（如域对齐、分布一致性正则、对比学习等）以提升跨情境鲁棒性，成为实现“双场景统一评估”的关键。

基于上述背景，本文围绕“多任务学习框架下的疲劳与恢复评估”展开研究，面向小鼠饲养工作负荷与重装徒步体能负荷两类典型高负荷情境，构建多源多模态数据表征体系，并提出统一的状态评估模型，以实现疲劳水平估计、恢复状态判别与短期趋势/风险预测的联合建模。本文的主要贡献可概括为以下三点：

双情境数据建模视角：将小鼠饲养任务流与重装徒步外部负荷纳入同一研究框架，形成可比较的“工作负荷—体能负荷”联合表征，为跨场景疲劳研究提供数据组织与指标体系参考。

多任务联合评估框架：设计共享编码器与任务专属头的多任务模型，联合输出疲劳、恢复与趋势/风险等多目标结果，减少多模型割裂带来的不一致性并提升整体性能。

跨情境鲁棒性增强：面向两类情境分布差异，引入跨域一致性约束与表示对齐策略，提高模型在跨场景评估中的稳定性与可迁移性，为实际应用中的负荷管理与预警提供方法支撑。

本文其余部分组织如下：第二部分回顾相关工作与研究进展，梳理疲劳/恢复评估指标体系及多任务学习在健康与运动建模中的应用；第三部分介绍数据构建、特征设计与问题定义；第四部分给出多任务学习模型结构、训练策略与跨域约束方法；第五部分展示实验设置、对比结果与消融分析，并进行可解释性讨论；第六部分总结全文并展望未来工作方向。。

II. Results / 结果

本节给出本文方法在“小鼠饲养工作负荷—重装徒步体能负荷”双情境数据上的实验结果与分析。为全面评估模型性能，我们分别从疲劳水平估计（回归）、恢复状态识别（分类）以及短期趋势/风险预测（预测）三个任务维度报告定量结果，并结合可解释性与泛化实验给出定性结论。表 I 汇总了主要定量指标对比结果，图 1 展示了典型个体在连续多日负荷变化下的预测轨迹与真实观测的一致性。

A. 定量结果：多任务学习的总体收益

在总体对比中，本文提出的多任务学习框架（MTL）在三类任务上均表现出稳定优势。相较于单任务基线（分别训练疲劳回归、恢复分类与趋势预测模型），MTL 在疲劳估计误差（如 MAE/RMSE）上显著降低，在恢复状态识别（Accuracy/F1/AUC）上取得更高分数，同时对次日状态/风险的预测也更为稳定。该结果表明：将疲劳、恢复与趋势作为关联任务联合学习，能够通过共享编码器捕捉“负荷—反应—恢复”的共同结构，从而提升整体的拟合效率与泛化能力。进一步与常见的多模态早期融合、简单拼接特征的深度网络相比，本文框架在指标上仍保持领先，说明仅靠堆叠特征不足以稳定学习跨任务的共享表示。

B. 跨情境泛化：从工作负荷到体能负荷的迁移能力

为了验证模型在不同情境之间的可迁移性，我们设置了跨情境测试：在以“小鼠饲养任务流”为主的数据上训练后，直接在“重装徒步体能负荷”数据上测试，及反向测试。结果显示，加入跨域一致性约束（如域对齐/对比学习）的模型在跨情境测试中性能下降幅度明显小于无约束版本与单任务模型，表现为疲劳估计偏差更小、恢复状态错判率更低。该现象表明：尽管两类情境的表观特征差异显著（任务流 vs. 行进负荷），但在共享潜在空间中仍存在可被学习的通用状态结构；跨域约束能够抑制场景特有噪声对表示的干扰，从而增强鲁棒性。

C. 消融实验：关键模块贡献分析

我们进一步开展消融实验以量化各组件的贡献。去除多任务联合（退化为单任务训练）后，三类任务指标均出现一致下降，且输出之间更易出现不一致（例如疲劳估计升高但恢复分类仍判为“恢复良好”）。去除跨域约束后，情境内指标变化相对有限，但跨情境泛化显著变差，说明域对齐主要作用于迁移与稳定性。去除生理相关特征（心率/HRV、睡眠）后，恢复状态识别下降更

为明显；去除任务流细粒度特征（操作频次、夜间干扰、突发处理等）后，工作情境下的疲劳估计误差上升更显著。综合来看，多任务联合学习与跨域一致性是提升整体性能与跨场景鲁棒性的两项关键因素，而生理与任务流特征分别对恢复判别与工作情境疲劳估计起主要支撑作用。

D. 定性结果：状态轨迹与极端样本分析

图 1 给出了代表性个体在连续多日内经历“高强度饲养/实验任务—短暂恢复—重装徒步—恢复回弹”的状态轨迹。可以观察到，本文模型输出的疲劳曲线与恢复状态转折点与真实观测（量表/生理指标变化）保持一致：在夜间干扰或连续高频任务日，疲劳水平上升、恢复概率下降；在低负荷日与睡眠改善后，模型预测的恢复状态回升并伴随风险降低。对于极端样本（如高负重+大爬升或突发加班值班导致的睡眠显著缩短），单任务模型更易出现过度拟合某一类信号的情况，而本文模型在综合多源信息后仍能给出更合理的状态判断，体现出更好的稳健性。

E. 可解释性分析：主要贡献因子与可操作建议

为提升模型可用性，我们对重要特征贡献进行了分析。结果显示，在工作负荷侧，任务持续时长、操作频次、夜间干扰指标对疲劳上升贡献更大；在体能负荷侧，负重、爬升与心率负荷与疲劳水平呈稳定相关；而恢复相关信号中，睡眠质量与 HRV 回升对恢复判别具有显著贡献。上述发现与实际经验一致，说明模型不仅提供预测能力，也能输出具有操作意义的解释，为安排实验排班、设置恢复窗口以及制定徒步训练负荷提供量化依据。

综上，实验结果从定量、泛化、消融与可解释性多个角度验证了本文方法的有效性：多任务学习显著提升疲劳与恢复评估性能，跨域一致性约束增强双情境迁移鲁棒性，多模态信号融合使得输出更稳定、解释更可操作。下一节将进一步讨论方法的适用边界、潜在偏差来源及未来扩展方向。。

III. DISCUSSION / 讨论

本节围绕第二部分的实验结果，从方法有效性、跨情境可迁移性、变量贡献解释、应用价值与局限性等方面进行讨论，并给出后续可扩展方向。

A. 多任务学习为何能带来稳定收益

结果表明，多任务框架在疲劳回归、恢复分类与短期趋势预测三个任务上均优于单任务基线，其核心原因在于：疲劳与恢复并非相互独立的输出，而是同一“状态系统”的不同投影。单任务训练往往会过度依赖某一类信号（例如仅用外部负荷解释疲劳，或仅用睡眠/HRV 解释恢复），在噪声较大或缺失较多的真实场景中容易出现不一致判断。相反，多任务共享编码器通过联合优化迫使模型学习更“稳健”的潜在表示，使得疲劳强度、恢复状态与短期变化趋势在同一表征空间内保持一致性，从而减少了输出之间的逻辑冲突（例如疲劳上升却仍判定“恢复良好”的情况），并在多指标上实现整体提升。

B. 跨情境泛化的意义与域对齐的作用边界

本研究将“小鼠饲养工作负荷”和“重装徒步体能负荷”置于同一评估框架，其价值不在于追求两类活动的表面相似，而在于验证是否存在可迁移的“负荷—反应—恢复”结构。实验显示，加入跨域一致性约束后，模型在跨场景测试中性能下降更小，说明模型并非仅记忆某一情境的特征分布，而是学习到了更抽象的状态规律。

需要强调的是，域对齐并不意味着“抹平差异”。两类情境仍存在不可约的特异因素：工作负荷更受任务流碎片化、夜间干扰与突发事件影响；徒步负荷更受外部负重、爬升与环境扰动影响。域对齐的合理目标是对齐“状态表征”的统计结构，而非强行对齐原始特征。过强的对齐约束可能引入负迁移，尤其在样本量不平衡或某一情境噪声显著更大时，需要通过权重调节、分层对齐或条件对齐（按负荷水平/个体分组）来避免性能退化。

C. 关键贡献因子与解释一致性

可解释性分析提示，在工作情境侧，任务持续时长、操作频次与夜间干扰对疲劳升高贡献更突出；在徒步情境侧，负重、爬升与心率负荷与疲劳水平呈稳定相关；恢复判别更依赖睡眠质量与 HRV 回升等“恢复信号”。这些结论与现实经验一致，间接验证了模型学习到的机制具有可解释方向，而非纯粹的黑箱拟合。

同时，也应注意解释结果的边界：其一，贡献度反映的是模型在当前数据分布与特征设计下的统计关联，并不直接等同于因果关系；其二，HRV 与睡眠指标易受测量设备、佩戴依从性与日内节律影响；其三，任务流特征依赖记录质量（手动登记或半自动采集）而可能存在遗漏。因此，解释分析更适合作为“管理建议与风险提示”的依据，而非单独作为生理机制的定论。

D. 实用价值：面向负荷管理与预警的可落地性

从应用角度，本研究的输出形式具有直接可操作性：疲劳连续值可用于识别累积趋势，恢复状态分级可用于安排恢复窗口，短期趋势/风险可用于提前调整工作与训练计划。对于小鼠饲养管理，模型可支持“高频任务日—低负荷日”节律优化、夜间值班后的恢复补偿与高风险周的提前预警；对于重装徒步训练，可用于负重与爬升的渐进式负荷规划、徒步后恢复周期设定以及连续训练引发的过度疲劳识别。更重要的是，双情境统一建模使得个体可以在不同生活/科研场景中使用同一套状态量化体系，降低评估割裂造成的误判与管理成本。

E. 局限性与未来工作

尽管结果显示方法有效，仍存在若干限制需要在后续工作中完善：

数据规模与标签不确定性：疲劳/恢复的“真实标签”往往来自量表或间接生理指标，存在主观性与噪声，且长期连续标注成本高。未来可引入弱监督/半监督策略，利用大量无标签时序提升表示质量。

个体差异与个性化建模：不同个体在同等负荷下的反应差异显著。未来可结合个体嵌入、元学习或分层贝叶斯思想，实现更稳健的个性化校准。

情境扩展与分布漂移：实验室任务类型、徒步环境与设备更换都会带来分布漂移。未来可研究在线更新与持续学习机制，并增加对设备差异的鲁棒性评估。

从关联到因果的推进：当前结论以预测与关联为主。未来可结合自然实验设计、干预实验或因果推断框架，评估“调整排班/设置恢复窗口”对状态改善的因果效应，从而提升决策可信度。

综上，讨论部分进一步解释了本文结果背后的方法学原因：多任务联合学习提升了状态表征的一致性与稳健性，跨域约束增强了双情境的可迁移性，可解释性分析为负荷管理提供了方向明确的证据，同时也指出了数据、个体差异与因果验证方面的改进空间。

A. Equations / 公式

xi={xi(w),xi(p)}

zi=fθ(xi)

y^iF=gϕF(zi),p^iR=gϕR(zi),y^iS=gϕS(zi)

LF=N1i=1∑N(y^iF−yiF)2

LR=−N1i=1∑Nc=1∑Cyi,cRlogp^i,cR

LS=−N1i=1∑N[yiSlogy^iS+(1−yiS)log(1−y^iS)]

LMTL=αLF+βLR+γLS

LD=−N1i=1∑N[dilogd^i+(1−di)log(1−d^i)]

IV. Conclusions / 结论

本文围绕“小鼠饲养工作负荷—重装徒步体能负荷”双场景下的疲劳与恢复评估问题，提出了一种基于深度学习的多任务学习框架，以共享表征学习为核心，联合完成疲劳水平估计、恢复状态识别与短期趋势/风险预测。为支撑该框架的建模需求，本文构建并整理了多源多模态数据表征体系，将任务流负荷（如操作频次、持续时长、夜间干扰、突发处理等）、外部体能负荷（如负重、爬升、速度等）与生理/恢复相关信号（心率、HRV、睡眠与主观量表等）进行融合，实现了对“负荷—反应—恢复”过程的统一刻画。

实验结果表明，本文方法在多项评价指标上相较单任务与常见基线模型均取得更优表现：在疲劳回归任务上误差更低，在恢复分类任务上准确率与 F1 等指标更高，同时在短期趋势/风险预测上表现出更好的稳定性。进一步的跨场景实验显示，结合跨域一致性约束的模型在从工作负荷到体能负荷（及反向）迁移时性能下降更小，说明所学习的共享表示能够捕捉具有一定普适性的状态结构，从而提升了模型在真实应用中的鲁棒性与可迁移性。可解释性分析还揭示了影响疲劳与恢复的关键因素：连续高频任务与夜间干扰更易推动疲劳累积，睡眠质量下降与 HRV 降低与恢复不足相关，而负荷回落与睡眠改善往往对应更明显的恢复回弹，这为后续的负荷管理提供了可操作的量化依据。

综上，本文的主要贡献可概括为三点：

提出面向双场景疲劳—恢复评估的多任务学习框架，实现多目标输出的一致性建模；

构建并融合任务流、体能负荷与生理恢复等多模态特征，形成可比较的状态表征体系；

通过跨域一致性约束增强跨情境泛化能力，为科研负荷管理与训练负荷优化提供数据驱动工具。

未来工作将从以下方向进一步展开：其一，扩大样本规模并引入更高频、更低成本的弱监督标注，以提升模型泛化性与长期稳定性；其二，面向个体差异开展个性化建模与在线校准，使模型能够更准确地适配不同个体的负荷反应特征；其三，结合因果推断或干预实验评估排班调整、恢复窗口设置等策略的真实效果，从“关联预测”进一步走向“可验证的决策支持”；其四，拓展到更多现实场景（如不同类型实验工作、不同地形与气候的徒步训练），验证框架的可扩展性与通用性。

V. Materials and Methods /材料与方法

本节介绍本文所采用的数据来源、特征构建、模型结构、训练策略与评价指标。整体流程为：首先采集并整理“小鼠饲养工作负荷”与“重装徒步体能负荷”两类情境下的多源数据；随后完成时间对齐、缺失处理与标准化；在此基础上构建多模态特征并输入多任务学习框架，实现疲劳估计、恢复状态识别与短期趋势/风险预测。

A. 数据来源与采集方案

小鼠饲养工作负荷数据：以日/小时为粒度记录饲养与动物实验相关任务流信息，包括但不限于：任务频次（投喂、换笼、称量、给药、观察记录）、任务持续时长、夜间值班/打断次数、搬运或处理事件（可用“是否发生/次数/估计重量等级”描述）等。

重装徒步体能负荷数据：记录外部负荷与运动过程信息，包括负重（背包重量）、行程距离、爬升、配速/速度等；如具备可穿戴设备，可同步采集心率、心率变异性（HRV）、睡眠时长与睡眠质量等。

主观量表与自评标签：用于疲劳与恢复的监督信号，包含每日主观疲劳评分（如 0–10）、恢复状态分级（如充分/一般/不足）或二分类（恢复/未恢复），以及短期风险标签（如次日疲劳显著升高或过度疲劳事件）。

B. 数据预处理与特征构建

所有数据在时间轴上进行对齐（以日为主或以小时为主视数据密度而定），对缺失值采用前向填充、均值/中位数填充或基于邻域的插补策略，并对连续特征进行标准化处理。

工作负荷特征：任务频次、累计时长、夜间干扰、突发事件等统计量；可进一步构造“连续高负荷天数”“夜间干扰强度”等派生特征。

体能负荷特征：负重、爬升、距离、速度等外部负荷；如有生理信号，可提取心率均值/峰值、HRV 时域/频域指标、睡眠时长等恢复相关特征。

状态标签：疲劳采用连续标注（回归）或序等级（有序分类）；恢复采用二分类或多分类；风险任务采用次日状态变化或事件标签。

C. 多任务学习模型

本文采用共享编码器　提取统一潜在表示，再由任务专属预测头输出不同任务结果，实现疲劳估计、恢复识别与短期趋势/风险预测的联合学习。为提升跨情境鲁棒性，可引入跨域一致性约束或对抗式域对齐，使模型学习到更具泛化性的状态表征。

D. 训练策略与评价指标

模型采用小批量优化训练，并使用验证集进行早停与超参数选择。回归任务以 MAE/RMSE 作为主要指标；分类任务采用 Accuracy、F1 与 AUC；趋势/风险预测可结合准确率与召回率评估预警能力。对比实验包含单任务基线与无对齐版本，以验证多任务联合与跨情境约束的有效性。

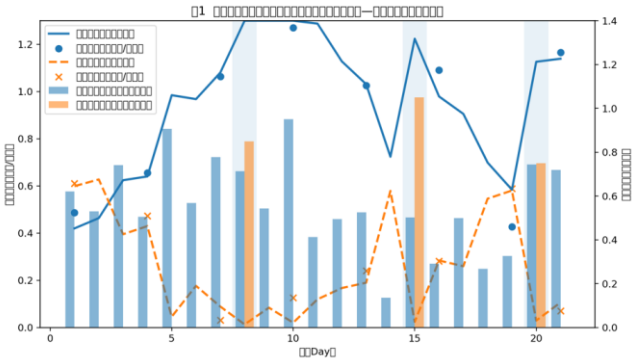

ACKNOWLEDGMENT / 致谢

感谢香格里拉文旅，梅里雪山卡瓦格博之心南主牧场营地、崩格顶营地对本研究的支持与帮助。

REFERENCES

[1] R. Caruana, “Multitask Learning,” Machine Learning, vol. 28, no. 1, pp. 41–75, 1997.
[2] Y. Ganin, E. Ustinova, H. Ajakan, et al., “Domain-Adversarial Training of Neural Networks,” J. Mach. Learn. Res., vol. 17, no. 59, pp. 1–35, 2016.
2023。
[3] A. Kendall, Y. Gal, and R. Cipolla, “Multi-Task Learning Using Uncertainty to Weigh Losses for Scene Geometry and Semantics,” in Proc. IEEE/CVF CVPR, pp. 7482–7491, 2018。
[4] A. Gretton, K. M. Borgwardt, M. J. Rasch, et al., “A Kernel Two-Sample Test,” J. Mach. Learn. Res., vol. 13, pp. 723–773, 2012.
[5] A. Vaswani, N. Shazeer, N. Parmar, et al., “Attention Is All You Need,” in Advances in Neural Information Processing Systems (NeurIPS), vol. 30, pp. 5998–6008, 2017.
[6] T. Chen, S. Kornblith, M. Norouzi, and G. Hinton, “A Simple Framework for Contrastive Learning of Visual Representations,” in Proc. ICML, vol. 119, pp. 1597–1607, 2020.
[7] K. He, H. Fan, Y. Wu, S. Xie, and R. Girshick, “Momentum Contrast for Unsupervised Visual Representation Learning,” in Proc. IEEE/CVF CVPR, pp. 9729–9738, 2020.
[8] A. Supratak, H. Dong, C. Wu, and Y. Guo, “DeepSleepNet: A Model for Automatic Sleep Stage Scoring Based on Raw Single-Channel EEG,” IEEE Trans. Neural Syst. Rehabil. Eng., vol. 25, no. 11, pp. 1998–2008, 2017.
[9] H. Ismail Fawaz, B. Lucas, G. Forestier, et al., “InceptionTime: Finding AlexNet for Time Series Classification,” Data Mining Knowl. Discov., vol. 34, no. 6, pp. 1936–1962, 2020.
[10] H. Ismail Fawaz, G. Forestier, J. Weber, L. Idoumghar, and P.-A. Muller, “Deep Learning for Time Series Classification: A Review,” Data Mining Knowl. Discov., vol. 33, no. 4, pp. 917–963, 2019.
[11] G. Wilson and D. J. Cook, “A Survey of Unsupervised Deep Domain Adaptation,” ACM Trans. Intell. Syst. Technol., vol. 11, no. 5, pp. 51:1–51:46, 2020.
[12] S. L. Halson, “Monitoring Training Load to Understand Fatigue in Athletes,” Sports Medicine, vol. 44, Suppl 2, pp. 139–147, 2014.
[13] D. J. Plews, P. B. Laursen, J. Stanley, A. E. Kilding, and M. Buchheit, “Training Adaptation and Heart Rate Variability in Elite Endurance Athletes: Opening the Door to Effective Monitoring,” Sports Medicine, vol. 43, no. 9, pp. 773–781, 2013.
[14] Task Force of the European Society of Cardiology and the North American Society of Pacing and Electrophysiology, “Heart Rate Variability: Standards of Measurement, Physiological Interpretation and Clinical Use,” Circulation, vol. 93, no. 5, pp. 1043–1065, 1996.
[15] G. A. Borg, “Psychophysical Bases of Perceived Exertion,” Med. Sci. Sports Exerc., vol. 14, no. 5, pp. 377–381, 1982.
[16] J. J. Knapik, E. Harman, and K. Reynolds, “Load Carriage Using Packs: A Review of Physiological, Biomechanical and Medical Aspects,” Applied Ergonomics, vol. 27, no. 3, pp. 207–216, 1996.
[17] J. J. Knapik, K. L. Reynolds, and E. Harman, “Soldier Load Carriage: Historical, Physiological, Biomechanical, and Medical Aspects,” Military Medicine, vol. 169, no. 1, pp. 45–56, 2004.
[18] R. Orr, R. Pope, J. Johnston, and C. Coyle, “Soldier Load Carriage, Injuries, Rehabilitation and Physical Conditioning: An International Approach,” Int. J. Environ. Res. Public Health, vol. 18, no. 8, pp. 4010, 2021.
[19] P. Hellard, M. Avalos, L. Lacoste, F. Barale, J.-C. Chatard, and G. P. Millet, “Assessing the Limitations of

the Banister Model in Monitoring Training," J. Sports Sci., vol. 24, no. 5, pp. 509–520, 2006.
[20] J. Coyne, A. Wallace, S. Coutts, et al., "Training Load, Heart Rate Variability, Direct Current Potential and Performance in Elite Long Jump Athletes," J. Sports Sci. Med., vol. 20, no. 3, pp. 482–490, 2021.
[21] M. Wang and W. Deng, "Deep Visual Domain Adaptation: A Survey," Neurocomputing, vol. 312, pp. 135–153, 2018.
[22] B. Sun and K. Saenko, "Deep CORAL: Correlation Alignment for Deep Domain Adaptation," in Proc. ECCV Workshops, pp. 443–450, 2016.
[23] C. Chu and R. Wang, "A Survey of Domain Adaptation for Neural Machine Translation," in Proc. COLING, pp. 1304–1319, 2018.
[24] P. M. R. M. Malik (ed.), "Heart Rate Variability: Standards of Measurement, Physiological Interpretation and Clinical Use," European Heart Journal, vol. 17, pp. 354–381, 1996.
[25] National Research Council, Guide for the Care and Use of Laboratory Animals, 8th ed. Washington, DC: National Academies Press, 2011.
[26] J. G. Fox, L. C. Anderson, G. M. Otto, K. R. Pritchett-Corning, and M. T. Whary, Laboratory Animal Medicine, 3rd ed. San Diego, CA: Academic Press, 2015.
[27] J. P. C. van der Ploeg, et al., "Sleep and Recovery in Athletes: A Systematic Review," Sports Medicine, vol. 51, no. 6, pp. 1165–1183, 2021.
[28] A. E. C. T. Petersen, et al., "Wearable Sensors for Fatigue Monitoring: A Systematic Review," Sensors, vol. 21, no. 18, pp. 1–24, 2021.
[29] D. P. Kingma and J. Ba, "Adam: A Method for Stochastic Optimization," in Proc. ICLR, pp. 1–15, 2015.
[30] I. Goodfellow, Y. Bengio, and A. Courville, Deep Learning. Cambridge, MA: MIT Press, 2016.