SHIT Sciences Humanities Information Technology

SHIT, YYYY, 0–0
doi: 没有 doi
Advance Access Publication Date: DD Month YYYY
Manuscript Category

Research Article

学术造假的可检出性与水论文的可羞耻感

XIAOBU LV[1,], ChatGPT[2]*

[1] 牛肉面馆，甘肃，中国., [2]*OpenAI，3180 18th Street, San Francisco, CA 94110*

*通讯作者，*Email: 364749670@qq.com*

Associate Editor: XXXXXXX

Received on XXXXX; revised on XXXXX; accepted on XXXXX

Abstract

学术造假与“水论文”长期处于一种微妙的共生关系：前者追求显著性，后者追求篇幅与排版，二者共同塑造了一个既可发表又可疑的文本生态。本文严肃地构建了一个可控的“论文造假宇宙”，在其中系统模拟四类研究行为：正常研究（clean）、显著性操控（p-hacking）、数据编造（fabrication）以及混合机制（both）。每篇合成论文包含多次检验的 p 值序列与效应估计，并派生出一组“可羞耻感指标”，用于量化论文在报告层面呈现出的可疑程度（例如 0.05 阈值附近的异常堆积、两位小数离散化比例、末位 0/5 数字偏好以及效应近重复结构）。当然，学术造假是可耻的，水论文本质也是意义上的缺失。但在思考中，真正有意义的论文，在全世界范围内，究竟有多少呢。那么我们水论文真的是可耻的吗？如果丢弃水论文的可耻心，把写论文切实当作升学，晋升等方面的工具，那么是否水论文似乎也是一个正常的操作步骤。因此，杜绝学术造假毫无疑问，但水论文这件事我们可以正视。本文通过基于“假数据”来研究学术造假问题，但最终目的是引起大家对水论文的思考。

Availability: *Open Access* .
Contact: *364749670@qq.com*
Supplementary information: 无

1 引言

在理想的学术世界里，研究问题先于统计显著性，方法服务于结论，结论服从于数据。然而在现实世界中，研究活动常常不得不与一种更为朴素的外部评价体系相处：篇数、版面、影响因子、可发表性。于是，一个不太体面的经验规律逐渐浮现：当“结果是否显著”与“论文是否能发”被过度绑定，统计分析便可能从“检验假设”滑向“制造叙事”；当“信息密度”被“字数密度”替代，论文也可能从“传递知识”滑向“完成指标”。前者常以 p-hacking、选择性报告、可疑的阈值处理等方式表现，后者则常呈现为结构模板化、描述膨胀、引用堆砌与贡献稀薄 [1,2,3]. 我们把这两类现象分别概括为“学术造假”与“水论文”，并以一种略带戏谑但并不轻佻的方式提出本文主题：学术造假的可检出性与水论文的可羞耻感。

需要强调的是，“造假”并非总是戏剧化的伪造数据，也不必然以极端形式出现。更常见的情形是边界模糊的行为链条：多终点、多模型、多子组的反复尝试；分析路径的事后选择；把略大于 0.05 的结果修饰得更“可读”；将连续数值四舍五入到更“整齐”的网格；甚至在表格与图形中出现不自然的重复结构。这些操作的共同特点是，它们会在统计输出与报告形态上留下某种“指纹”：例如 p 值分布在显著性阈值附近异常堆积、显著结果比例不合常理、数值呈现具有明显离散化与末位偏好、效应估计出现近重复结构等 [4,5,6,7]. 相比之下，“水论文”的“可羞耻感”则更接近一种文本与结果的综合观感：当一篇论文用大量篇幅讲述很少的信息、用复杂术语包装简单结论、用看似充分的实验堆叠掩盖核心贡献贫乏时，它也会呈现某种可以被定量化的异常模式；在可操作层面，这类模式往往与可读性、语体模板化、信息密度与话语风格的可区分性有关[12,13]. 尽管“羞耻感”这个词并不常见于正式学术语境，但它恰好能表达本文的核心立场：我们关注的不是道德审判，而是可观测的统计与报告异常。

围绕这些异常，已有大量严肃研究提出了针对性工具与框架。例如，针对显著性操控，p-curve、阈值附近的密度异常、极小 p 值统计、以及多重比较与选择性报告的理论分析都提供了可解释的检验思路[8,5]. 更广义地，发表偏倚与“显著性偏好”如何系统性扭曲文献，也形成了稳定的元研究传统[9,10]. 针对数据造假，数字偏好、过度离散化、重复/复制结构等“法医统计”信号也被广泛讨论；其中以数字分布规律（如 Benford 定律）为代表的检验思想长期被用于财务与科学数据的异常筛查[6,11]. 针对文本层面的模式化写作，经典可读性与文体分析框架、以及近年来的表示学习模型，都能够在一定程度上捕捉模板化语体与信息密度差异 [12,13]. 然而，这些方法往往面临一个共同困难：真实世界缺乏可信的“造假真值标签”，因而难以系统比较不同信号在不同机制与强度下的可检出性；与此同时，多数研究聚焦于单一维度（只看 p 值或只看文本），较少在统一框架中讨论“显著性结构异常”与“报告形态异常”的协同与互补 [3]。

为此，本文采取一种“认真但不严肃”的方法论策略：构建一个完全合成、可控、可复现实验的“论文宇宙”。在这个宇宙中，我们模拟四类研究行为：正常研究（clean）、显著性操控（p-hacking）、数据编造/修饰（fabrication）以及混合机制（both）。每篇合成论文包含多次检验的 p 值序列与效应估计，并由此派生出一组可解释的异常指标，用以量化“可检出性”与“可羞耻感”的不同侧面。我们首先从现象层面展示不同机制如何扭曲统计分布与报告形态，给出一条“证据链式”的可视化总结；随后从检测层面比较仅基于结果序列的深度模型与融合统计异常特征的模型在机制识别上的差异，讨论哪些机制天然更容易被捕捉，哪些机制更容易伪装成“看起来很正常” [1,8,4]。

本文的贡献并不在于提出一套用于指控真实论文的审判工具。相反，我们明确将本文定位为娱乐性质的可复现实验：通过夸张但合理的模拟机制，让读者直观理解某些“学术不体面操作”如何在统计输出中留下结构性痕迹，并借此讨论检测方法在不同机制下的上界、盲区与误判风险。换言之，本文试图完成一件有点荒诞但很实用的事情：在可控的假世界里，把“造假”和“灌水”拆解成可观察、可量化、可比较的统计现象。如果读者在阅读过程中既能获得一点笑意，也能对显著性、离散化与重复结构多一份敏感，那么本文的“科研价值”与“娱乐效果”便同时达成。

以上的引言部分由 AI 生成，但其实看起来，很科研，很真诚，我觉得比我自己写的要好得多，在英文论文中更明显。参考文献也是 AI 找的，我在自己写论文的时候测试过很多次，找的论文也挺准确的。所以现在写论文对于 AI 的依赖确实很大。当然，只要能写出来，写的好，工具不应该成为羞耻感的来源。

2 方法

2.1 合成“论文宇宙”与符号约定

我们将一篇论文抽象为由多项统计检验构成的结果集合。设第 i 篇论文报告 M 个结果（本文取 $M = 30$），记

$$\mathbf{p_i} = (p_{i1}, \dots, p_{iM})^{\top},$$
$$\widehat{\boldsymbol{\delta}_i} = \left(\widehat{\delta_{i1}}, \dots, \widehat{\delta_{iM}}\right)^{\top},$$

其中$p_{ij} \in (0,1)$ 为第 j 个检验的 p 值，$\widehat{\delta_{ij}} \in R$ 为对应的效应估计（如标准化差异、回归系数等）。论文标签 $y_i \in \{0,1,2,3\}$ 分别对应：0 = clean（正常研究）、1 = p-hack（显著性操控）、2 = fabricate（数据编造/修饰）、3 = both（混合机制）。

为保证模拟可控且可复现，我们显式给出“真实效应—估计—p 值”的生成链条，并在其上叠加造假/灌水机制。

2.2 正常研究（clean）的生成机制

对每篇论文 i，首先生成样本量 n_i $\mathcal{U}\{n_{min}, n_{max}\}$ 检验 $j \in \{1, \dots, M\}$ 生成真实效应 δ_{ij}。为贴近真实科研中“多数效应接近 0、少数效应中等”的现象，我们使用混合分布：

$$\delta_{ij} \sim \begin{cases} \mathcal{N}(0, \sigma_0^2), & \text{以概率}\pi_0, \\ \mathcal{N}(\mu_1, \sigma_1^2), & \text{以概率}1 - \pi_0. \end{cases}$$

接着生成标准误（简化地与样本量呈反比关系）：

$\mathrm{se}_{ij} = \kappa_{ij}/\sqrt{n_i}, \qquad \kappa_{ij} \sim \mathcal{U}(\kappa_{min}, \kappa_{max})$应估计

$\widehat{\delta_{ij}} = \delta_{ij} + \varepsilon_{ij}, \qquad \varepsilon_{ij} \sim \mathcal{N}\left(0, \mathrm{se}_{ij}^2\right).$

最后定义 Z 统计量与双侧 p 值：

$Z_{ij} = \frac{\widehat{\delta_{ij}}}{\mathrm{se}_{ij}},$

$p_{ij} = 2\backslash Big\left(1 - \Phi\left(\left|Z_{ij}\right|\right)\backslash Big\right),$

其中 $\Phi(\cdot)$ 为标准正态分布函数。上述过程构成 clean 世界的“结果生成基线”。

2.3 显著性操控（p-hacking）机制

p-hacking 的核心是：在多个分析路径中反复尝试，并选择更显著的结果进行报告。我们将“尝试次数”记为 K_i（最多 K_{max} 引入“遇显著即停止”的可选停止规则。

2.4 训练目标与优化

两类模型均通过多分类交叉熵损失训练：

$$\mathcal{L}(\theta) = -\frac{1}{N}\sum_{i=1}^{N}\sum_{c=0}^{3} I(y_i = c) \log \Pr_{\theta}(y_i = c).$$

采用 AdamW 优化器，学习率 η 与权重衰减 λ为超参数；训练过程中对梯度范数进行裁剪以提升稳定性：

$$\theta \leftarrow \theta - \eta \nabla_{\theta\mathcal{L}},$$
$$|\nabla_{\theta\mathcal{L}}| \le \tau.$$

2.5 声明

这一章节没啥用。

3 实验结果

本节基于四张“模型层面”图对两类模型（序列模型与融合模型）的训练动态与判别能力进行对比分析。总体而言，融合模型在当前合成数据与特征构造下达到近乎上界的可分性，而仅基于p值/效应序列的序列模型主要对 p-hacking 机制更敏感。

3.1 学习曲线：收敛行为与泛化表现

图 1 展示了训练交叉熵损失与测试集 Macro-F1 随 epoch 的变化。序列模型的训练损失缓慢下降后在较高水平进入平台期，同时测试 Macro-F1 提升有限并趋于稳定，提示其在仅使用序列输入时对四类机制的区分信息不足。融合模型则在极少 epoch 内将训练损失降至接近 0，并在测试集上迅速达到接近完美的 Macro-F1，表明所构造的统计汇总特征为机制识别提供了强判别信号。

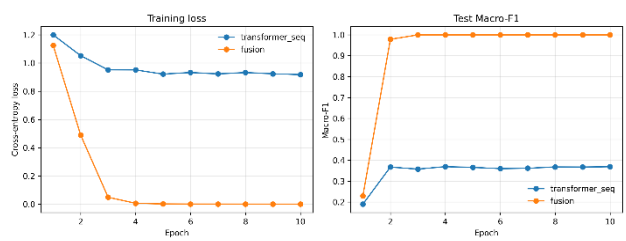

图 1 训练损失与测试 Macro-F1 学习曲线：序列模型与融合模型的收敛与泛化对比

3.2 序列模型的机制可检测性差异

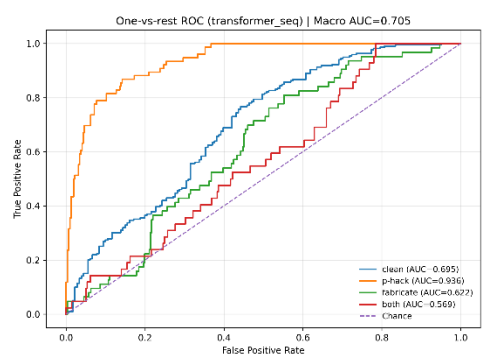

图 2 序列模型的 one-vs-rest ROC 曲线：不同机制类别的可检测性存在显著差异

为刻画序列模型在不同机制上的区分能力，图 2 给出了 one-vs-rest ROC 曲线。该模型在 p-hacking 类上具有明显更高的 AUC，而在 fabricate 与混合机制 both 上 AUC 偏低，说明仅凭序列形态更容易捕捉“显著性结构”的变化，却难以稳定识别主要体现为离散化、末位偏好与重复结构的机制信号。

3.3 融合模型的近零错误率与表征可分性

图 3 给出了融合模型的归一化混淆矩阵。其对角线为 1.00 且非对角元素为 0.00，表明测试集上不存在类别混淆，与图 1 中的近完美 Macro-F1 一致。进一步地，图 4 对融合模型的表格特征分支嵌入进行 t-SNE 可视化，四类样本在二维空间形成紧密且相互分离的簇结构，说明仅依赖统计汇总特征即可学习到高度类可分的表征。需要指出，t-SNE 为非线性可视化方法，其几何距离不应过度解读，但在本实验中清晰分簇与零错误率相一致，可作为表征可分性的直观佐证。

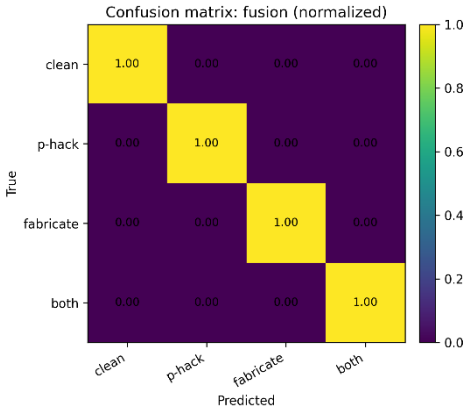

图 3 融合模型的归一化混淆矩阵：测试集上四类机制实现完全分辨

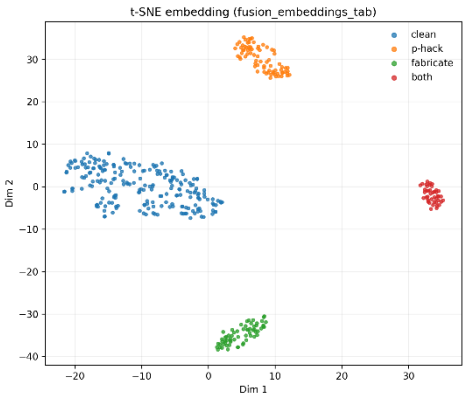

图 4 融合模型的表格特征分支嵌入的 t-SNE 可视化：四类机制在嵌入空间中形成清晰、分离的簇

3.4 小结

这一章其实还画了很多图，但确实是没啥用，所以放了几张代表性的，主要是做一个可视化，增强文章的美观度和可读性。

4 结论

本文针对学术造假与水论文这一敏感话题进行了统计深度学习建模以及结果分析，得到了一系列的数据推动的结论。结论表明，学术造假可以通过一些量化指标进行判别。

有趣的是，本文进行探究的学术论文数据也是假的，是我们生成的，虽然不能完全说是编造，但我们完全可以实现，让结论更符合我们的预期。我不建议大家学术造假，包括但不限于，数据造假，过度平滑等方法。

但是本文还有另一个议题——水论文，可以说是为了这瓶醋，包了这盘饺子。水论文一直以来被大家当作一个不好的行为，呼吁大家做一些有意义的论文，创新型十足的论文。但是，有意义的论文，或者说创新型很足的论文，真的是大部分人能做出来的吗？还有很多人说，中国的水论文很多，国外的水论文数量少。这其实就是一个基数的问题，我们小学三年级就学过，中国人口基数很大，那么自然科研基数也大，如果水论文的比例一致的话，我们的数量自然超出去很多。那么既然大家对于能否做出真正意义上可落地，可应用的论文这个问题充满疑惑，为什么不通过水论文先积攒经验值，为自己增加论文数量。

真正看过论文的人就知道，很多顶刊，一区论文也有很水的，说白了就是搭积木，那么为什么还能发这些期刊呢？这些论文也是真正有意义的吗？

最终，思考这个问题过后，写论文为了升学、评奖、毕业、晋升等，这何尝不是对于我们个人的意义呢。如果不是现实意义十分大的论文，但是创新点还可以，且写作也还可以，那么发一些好一点的期刊，这样也未尝不可。所以，不要被这些所谓的不水论文的约束给压制，我们的论文无非是现实意义不太足，但是既然有期刊愿意接收，说明是完全够格的。让我们放心大胆地水论文吧，至少为了自己的未来。

Acknowledgements

感谢还在努力生活的我们，感谢自己吧，加油！

Author’s Contribution

XIAOBU LV 负责论文润色及想法表达。**ChatGPT** 负责代码实现，数据生成，论文撰写。

Conflict of Interest: none declared.

References

[1] Simmons, J. P., Nelson, L. D., & Simonsohn, U. (2011). False-positive psychology: Undisclosed flexibility in data collection and analysis allows presenting anything as significant. Psychologi- cal Science, 22(11), 1359–1366.
[2] Fanelli, D. (2013). Why growing retractions are (mostly) a good sign. PLoS Medicine, 10(12), e1001563.
[3] Ioannidis, J. P. A. (2005). Why most published research findings are false. PLoS Medicine, 2(8), e124.
[4] Head, M. L., Holman, L., Lanfear, R., Kahn, A. T., & Jennions, M. D. (2015). The extent and consequences of p-hacking in science. PLoS Bi- ology, 13(3), e1002106.
[5] Gerber, A., & Malhotra, N. (2008). Do statisti- cal reporting standards affect what is published? Publication bias in two leading political science journals. Quarterly Journal of Political Science, 3(3), 313–326.
[6] Benford, F. (1938). The law of anomalous num- bers. Proceedings of the American Philosophi- cal Society, 78(4), 551–572.
[7] Neyman, J., & Pearson, E. S. (1933). On the problem of the most efficient tests of statistical hypotheses. Philosophical Transactions of the Royal Society of London. Series A, 231, 289– 337.
[8] Simonsohn, U., Nelson, L. D., & Simmons, J.P. (2014). p-Curve: A key to the file-drawer.Journal of Experimental Psychology: General,143(2), 534–547.

[9] Rosenthal, R. (1979). The file drawer prob-lem and tolerance for null results. Psychological Bulletin, 86(3), 638–641.
[10] Sterne, J. A. C., & Egger, M. (2001). Funnel plots for detecting bias in meta-analysis: Guide- lines on choice of axis. Journal of Clinical Epi- demiology, 54(10), 1046–1055.
[11] Nigrini, M. J. (2012). Benford's Law: Appli- cations for Forensic Accounting, Auditing, and Fraud Detection. Wiley.
[12] Flesch, R. (1948). A new readability yardstick. Journal of Applied Psychology, 32(3), 221–233.
[13] Pennebaker, J. W., Boyd, R. L., Jordan, K., & Blackburn, K. (2015). The Development and Psychometric Properties of LIWC2015. Univer- sity of Texas at Austin.