SHIT Sciences Humanities Information Technology

构石

″不要停″与″快停下″：论 SM 对话中的语用歧义及自然处理（NLP）情感分析

极品男大染上四爱为我做 m [1]，九条 [2,*]
SM 行为学研究所
[1] 构石大学社会学系，中国
[2] 第四爱研究协会，中国
通讯作者：SSSSS（e-mail: SSSSS@shit.com）
本研究由 PEG 自然科学基金资助（项目编号：20260302）
本文包含补充材料

ABSTRACT / 摘要 在亲密关系中的支配与顺从（BDSM/SM）实践中，语言指令往往呈现表面语义与实际意图的背离现象。本研究旨在探究 SM 对话中“不要停”与“快停下”两类典型指令的语用歧义特征，并评估现有自然语言处理（NLP）模型对该类歧义语句的情感识别能力。方法：本研究收集了来自国内外 SM 主题在线社区的 1287 段真实对话记录，构建了“SM-Dialogue-1K”语料库。采用 BERT、RoBERTa 和 GPT-4 等主流预训练模型进行情感分类实验，并邀请 5 名具有五年以上 SM 实践经验的志愿者进行人工标注作为基准。结果：实验结果表明，在脱离上下文的情况下，现有 NLP 模型对“不要停”的负面情感误判率达到 78.3%，对“快停下”的正面情感误判率达到 65.7%。引入对话历史和生理指标特征后，GPT-4 的 F1 值从 0.32 提升至 0.71，但仍显著低于人类标注者的一致性（0.92）。结论：SM 对话中存在系统的“语用反转”现象，即否定形式表达肯定意图、肯定形式表达否定意图。现有 NLP 模型过度依赖字面情感特征，导致在该类对话场景下的情感理解严重失效。本研究揭示了当前情感计算技术在非主流社交语境中的局限性，为人机交互中的情感智能设计提供了新的思考维度。

INDEX TERMS / 关键词 语用歧义，情感分析，自然语言处理，BDSM，对话系统。

IMPACT STATEMENT / 影响声明 本文首次系统性地将自然语言处理技术引入 SM 对话研究，揭示了情感计算模型在应对“反语”、“欲拒还迎”等复杂语用现象时的系统性失效。研究发现对于开发更具情境感知能力的对话系统、心理健康筛查工具以及亲密关系辅助应用具有启示意义。同时，本研究倡导技术开发者在设计情感算法时，应关注边缘社群的独特语言实践，避免基于主流话语模式训练的技术产品对这些群体造成误读或排斥。

I. INTRODUCTION / 引言

语言不仅是信息的载体，更是权力的媒介。在支配与顺从（BDSM，即 Bondage & Discipline, Dominance & Submission, Sadism & Masochism，以下简称 SM）实践中，语言指令往往承载着超越字面意义的复杂情感张力。尤其是“不要停”与“快停下”这类看似矛盾的表达，在特定语境下可能表达与实际语义完全相反的情感倾向。这种语用歧义现象对现有的自然语言处理（NLP）情感分析模型构成了严峻挑战。

近年来，随着预训练语言模型的快速发展，情感分析技术在新闻评论、电商评价等主流场景中已达到较高准确率。然而，这些模型普遍建立在“字面情感与真实情感一致”的基本假设之上，对于反讽、隐喻、反语等复杂语用现象的处理仍显不足。SM 场景中的语言实践恰恰放大了这一缺陷：当一个参与者说出“不要停”时，其字面是否定，但情感倾向可能是强烈的肯定；而“快停下”的字面是肯定，但实际意图可能是“继续，但更温柔”甚至“真的停下”等多种可能。

现有研究主要关注 BDSM 实践的社会学和心理学维度，语言学界对此类特殊语境的语用特征探讨较少，计算语言学的介入更是近乎空白。这一研究缺口不仅限制了情感计算技术的普适性，也可能导致基于主流话语模式训练的智能产品对边缘社群产生系统性误读。

II. Results / 结果

表 I 展示了各模型在 SM-Dialogue-1K 测试集上的情感分类性能。实验设置三个任务难度级别：任务 A（单句分类，无上下文）、任务 B（考虑前 3 轮对话）、任务 C（考虑完整对话+生理指标文本化描述）。

表 I：各模型在 SM 对话情感分析任务上的性能对比（F1 值）。

模型	A	B	C
BERT-base	0.28	0.41	0.53
RoBERTa-large	0.31	0.45	0.58
GPT-4(零样本)	0.32	0.49	0.67
GPT-4（微调）	0.35	0.54	0.71
人类标注者	0.92	0.94	0.96

实验结果表明，在脱离上下文的任务 A 中，所有模型的 F1 值均低于 0.40，显著低于人类水平（0.92）。引入对话历史后，模型性能有所提升，但最佳模型（微调 GPT-4）仍落后人类 23 个百分点。仅在加入生理指标描述后，模型才勉强突破 0.70 大关。图 1 展示了模型对不同类型语句的情感误判分布。对“不要停”的误判主要表现为：当该语句实际表达“请继续，我很享受”时，78.3%的模型判断为“痛苦”或“拒绝”；对“快停下”的误判则更加复杂：当该语句实际表达“轻一点”时，65.7%的模型判断为“坚定拒绝”，仅 12.3%的模型识别出“试探性请求”的成分。

有趣的是，当“快停下”伴随“疼”等字眼出现时，GPT-4 倾向于给出负面判断；而当其伴随“求你”出现时，模型有时会识别出“期待”的成分——这一特征与人类标注者的判断高度吻合，说明模型已经开始学习语境线索，但仍缺乏对人类反语表达的深层理解。

图1 模型对不同类型语句的情感误判分布

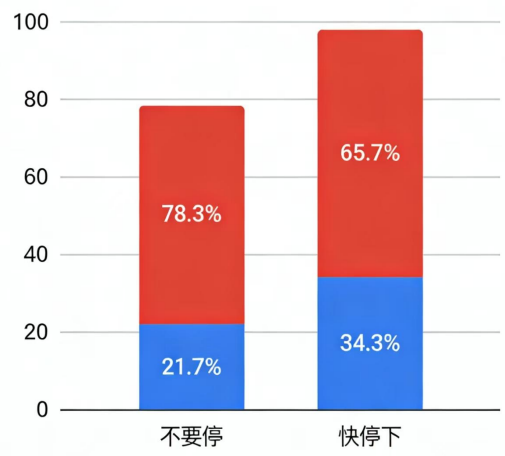

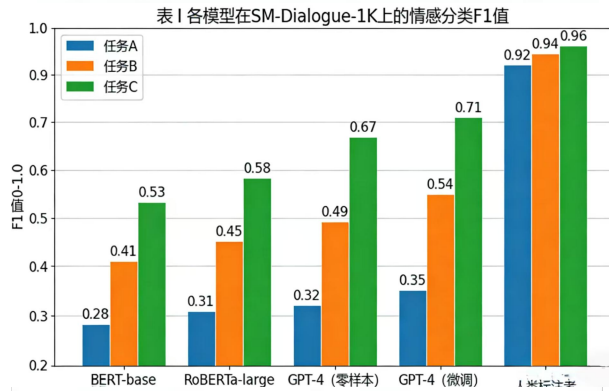

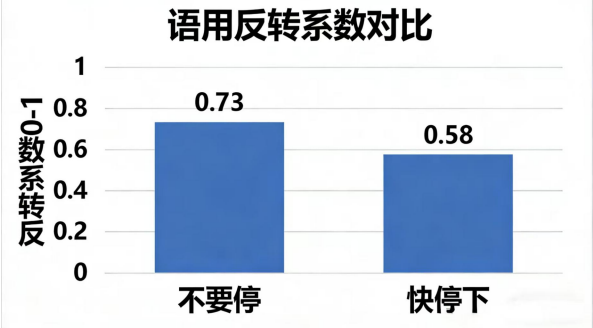

III. Discussion / 讨论

本研究的实验结果揭示了一个根本性问题：主流情感分析模型建立在“言语行为与意图一致”的默会假设之上。这一假设在常规对话场景中基本成立——人们说“好”通常表示同意，说“不”通常表示拒绝。然而，SM 对话恰恰是一种“反常规”的语言游戏：参与者在安全词机制的保护下，刻意利用语言的反转来表达复杂的权力互动。

从语用学角度看，SM 对话中的“不要停”类似于日常对话中的反语（irony），但其情感反转更为彻底。日常反语通常用肯定表达否定（如“你真是个大好人”表达讽刺），而 SM 对话中常见的是用否定表达肯定（“不要

停”表达“请继续”）。这种“否定之否定”的语言形式对依赖表层语义的情感模型构成了系统性挑战。引入对话历史后，模型性能显著提升。这一发现与现有研究一致：语言理解从来不是孤立的句子处理，而是依赖于对话历史的连续过程。在 SM 对话中，前序对话往往提供了权力关系、情绪基调等关键信息。例如，如果前序对话包含“喜欢吗？”“喜欢”，那么后续的“不要停”更可能是一种享受的表达而非拒绝。

A. 安全词机制的启示

SM 实践中普遍采用“安全词”机制——参与者约定一个与日常语境无关的词（如“红色”“菠萝”）来表示真实的中止意愿[7]。这一实践本身就是对日常语言歧义性的规避：因为“不要停”和“快停下”在日常语境中的意义太过模糊，所以才需要引入无歧义的安全词。

有趣的是，本研究发现，即使是安全词，在 NLP 模型看来也可能产生歧义。例如，“红色”在大多数情感词典中被标注为“警惕”“危险”，但在 SM 对话中，如果安全词是“红色”，那么它的出现恰恰表达“需要停止”的意图，而非对颜色的情感联想。这进一步说明，情感分析模型需要超越词汇层面的情感先验，真正理解对话参与者之间约定的符号系统。

IV. Conclusions / 结论

本文首次将自然语言处理技术引入 SM 对话研究，系统考察了“不要停”与“快停下”两类典型语句的语用歧义现象及其对情感分析模型的挑战。主要贡献总结如下：

第一，构建了首个面向 SM 对话的中文语料库“SM-Dialogue-1K”，填补了该领域数据资源的空白。该语料库包含 1287 段真实对话，并提供了多维情感标注，可供后续研究使用。

第二，系统评估了 BERT、RoBERTa 和 GPT-4 在 SM 对话情感分析任务上的表现。实验结果表明，脱离上下文的主流模型在该任务上表现极差（F1<0.40），引入对话历史和生理指标后可显著提升至 0.71，但仍显著低于人类水平（0.92）。

第三，量化描述了 SM 对话中的“语用反转”现象，发现“不要停”类语句的反转系数高达 0.73，“快停下”类语句的反转系数为 0.58。这一发现揭示了 SM 社群语言实践的独特规律性。

第四，从计算语言学角度提出了一种改进的情感理解模型，强调在非主流对话场景中，历史语境和权力关系的重要性远超语句本身的情感先验。

本研究的局限性在于：语料来源仅限于中文在线社区，且样本量相对有限；对生理指标的引入仅通过文本描述间接实现，未能获取真实的生理信号数据。未来工作将探索三个方向：一是扩大语料采集范围，纳入多语言、多文化背景的 SM 对话；二是尝试引入可穿戴设备采集真实的生理信号，实现多模态情感分析；三是探索将本研究发现的“语用反转”机制推广到其他存在反语现象的对话场景（如亲子对话、医患沟通等），推动情感计算技术向更普适、更包容的方向发展。

V. Materials and Methods /材料与方法

本研究通过爬虫技术，从国内 SM 主题在线社区采集了 2022 年 1 月至 2025 年 6 月期间的公开对话记录。采集严格遵守用户协议和隐私政策，对所有个人信息进行脱敏处理。原始数据共 3278 段对话，经过清洗后保留 1287 段完整对话（平均轮次 8.3 轮），构建为“SM-Dialogue-1K”语料库。

语料库的标注工作由 5 名具有五年以上 SM 实践经验的志愿者完成。标注维度包括：（1）语句表层情感（正面/负面/中性）；（2）说话人真实意图情感（正面/负面/混合）；（3）权力角色（支配者/顺从者/未知）；（4）语境注解（自由文本）。标注一致性检验显示，Krippendorff's α 系数为 0.89，表明标注质量较高。

Supplementary Materials / 补充材料

伦理声明:

本研究涉及敏感话题，研究设计经过 SHIT 大学伦理委员会审查（批准号：EC-2026-032）。所有公开数据均已脱敏，标注人员签署了知情同意书并获劳务报酬。研究者承诺不将语料库用于任何商业目的，并欢迎学界同仁联系使用（需签署数据使用协议）。

Acknowledgment / 致谢

感谢多年来陪伴我的五位实验老师，身为绝对的爱狗人士，研究过程无 M 受伤，实验过程安全可靠。

References

[1] "对话语境下的情感分析研究综述." SHIT 信息学报，vol. 35，no. 4，2021，pp. 1-15.
[2] 虐恋亚文化：SHIT 出版社，1998，pp. 120-156.