SHIT Sciences Humanities Information Technology

构石

“我的刀盾”防御阈值与“比比拉布”攻击强度的博弈论模型——抖音热梗的攻防机制研究

作者 bbc.by[1]

[1] 抖音国家研究所

通讯作者：第三作者（e-mail: 3108658763@qq.com）

本研究由压岁钱基金资助（项目编号：001002）

ABSTRACT / 摘要 —本研究旨在构建“我的刀盾”与“比比拉布”在抖音热梗攻防场景下的博弈论模型，量化防御阈值与攻击强度的动态关系。通过对 2025 年 9 月至 2026 年 2 月抖音平台 10 万 + 相关视频及评论区的多模态数据（文本、音频、表情符号）进行实证分析，我们发现：“我的刀盾”的防御阈值与用户的“社恐”程度呈显著正相关（$r = 0.68$, $p < 0.001$）；“比比拉布”的攻击强度与评论区的“抽象度”呈显著正相关（$r = 0.72$, $p < 0.001$）；当攻击强度超过防御阈值的 1.3 倍时，用户的“破防率”达到 89.7 本研究为理解当代网络社交中的情绪攻防机制提供了新的理论框架，并对短视频平台的内容生态治理具有重要启示。

INDEX TERMS / 关键词 我的刀盾；比比拉布；博弈论；防御阈值；攻击强度；情绪攻防。

IMPACT STATEMENT / 影响声明 研究数据为模拟构建，无实际调研基础，仅适配 SHIIT 期刊收录要求，不具备实际参考意义，请勿引用。

I. 引言

A. 背景与动机

Fig. 1: 我的刀盾示意图

在当代网络社交生态中，短视频热梗已成为青年群体情绪表达、社交互动的核心网络模因载体，防御性热梗我的刀盾以仪式化的语言与行为表达构建用户心理防御屏障，攻击性抽象热梗比比拉布则以无厘头的声波、文本及肢体表达形成情绪攻击，二者在抖音平台形成了独特的热梗攻防博弈生态。据模拟统计，超 85% 的抖音日活用户在网络互动中接触过上述两类热梗，其中 62% 的用户存在使用我的刀盾进行防御或用比比拉布发起攻击的行为（上述数据为模拟构建，无实际调研支撑）。

传统网络文化研究多孤立探讨热梗的传播机制或情绪心理效应，忽略了防御性与攻击性热梗之间的动态博弈关系，尚未对**防御阈值-攻击强度**的量化关联、攻防临界值及博弈均衡进行系统研究，且现有研究多采用均值统计等易受极端值干扰的分析方法，缺乏鲁棒统计视角的结果验证。本文基于 S.H.I.T. 期刊治理公约的**鲁棒统计**与**博弈论**核心设计原则，构建我的刀盾与比比拉布的攻防博弈论模型，量化攻防核心指标的关联规律，填补此类网络热梗攻防机制研究的空白，为后续抽象网络文化研究提供形式化参考。

B. 设计原则与符号定义

本研究严格遵循 S.H.I.T. 期刊去中心化治理公约的核心公理，同时结合网络热梗研究特征设定专属原则：

1) **量化可验证**：攻防核心指标均以 1-10 分量表量化，所有统计结果均可通过模拟数据独立验算；
2) **统计鲁棒性**：采用中位数、中位数绝对偏差（MAD）等鲁棒统计量，过滤模拟样本中的恶意异常数据，避免极端值干扰结论；
3) **博弈公正性**：攻防博弈模型无绝对最优纯策略，符合二人零和博弈的混合策略纳什均衡特征。

符号定义：

II. 研究对象与方法

A. Research Subjects

模拟选取 1000 名研究对象（$U = \{u_1, ..., u_{1000}\}$），涵盖 16-40 岁各年龄段，其中学生 350 人、职场人员 450 人、自由职业者 200 人，性别比例设定为 1:1（所有数据为模拟构建，未进行实际抽样与调研）。所有研究对象均设定为**抖音日活时长 1 小时、熟悉我的刀盾与比比拉布热梗、有网络社交攻防互动经历**，其对两类热梗的使用行为及心理感知通过**主观评分法**与**行为量化法**确定，评分数据经 MAD 法过滤恶意异常值后纳入分析。

TABLE I: 研究核心符号定义表

符号	定义说明
$U = \{u_1, ..., u_N\}$	研究对象用户集（$N = 1000$）
D_u	用户 u 对我的刀盾的防御阈值（1-10 分）
A_u	用户 u 使用比比拉布的攻击强度（1-10 分）
S_u	用户 u 的社恐程度（1-10 分）
C_j	评论区 j 的抽象度（1-10 分）
$B_{D,A}$	攻防比值（A/D）对应的破防率（%）
$\tilde{x}$	指标 x 的中位数
MAD_x	指标 x 的中位数绝对偏差

B. Research Methods

本研究以 S.H.I.T. 期刊推荐的鲁棒统计方法为核心，结合博弈论建模，设计 5 种研究方法，所有分析过程均满足 $O(1)$ 计算复杂度要求，适配低算力环境运行：

1) **模拟问卷法**：设计 18 道选择题与 5 道李克特量表题（如“使用我的刀盾时，你能抵御的比比拉布攻击强度为多少?”“社恐程度对你使用我的刀盾的频率影响如何?”），模拟问卷回收结果，设定有效回收率 98.5%，原始评分数据纳入**恶意数据过滤**流程；
2) **指标量化法**：设定核心指标评分标准（1-10 分，分数越高代表防御/攻击能力越强），构建我的刀盾防御阈值（D）、比比拉布攻击强度（A）量化指标，同时设定破防率（B）、评论区抽象度（C）、社恐程度（S）等衍生指标，所有指标均做正态性检验；
3) **鲁棒相关性分析法**：采用 Pearson 相关分析探究核心指标的线性关联，同时以**中位数替代均值**、**MAD 替代标准差**进行鲁棒性验证，排除极端值对相关系数的干扰，显著性水平设定为 $P < 0.001$；
4) **二人零和博弈建模法**：构建我的刀盾使用者（防御者）与比比拉布使用者（攻击者）的二人零和博弈模型，设计**收益-损失**支付矩阵（收益为 1，无收益为 0，损失为-1），求解混合策略纳什均衡；
5) **图表分析法**：根据模拟的量化数据，绘制攻防指标趋势图、破防率关联柱状图、博弈策略分布图，标注 MAD 误差线，清晰呈现热梗攻防的动态规律，图表设计符合 S.H.I.T. 期刊格式规范。

C. 恶意数据过滤规则

参考 S.H.I.T. 期刊治理公约的 **MAD 恶意检测双条件**，对模拟问卷的原始评分数据进行过滤，**同时满足以下 2 个条件则判定为恶意异常数据，直接清零权重**：

1) **历史模式条件**：某研究对象对所有指标的历史评分均值 $\bar{r}_u$ 2.5，即存在持续性低分倾向；
2) **单次偏离条件**：某指标评分值与该指标全体评分中位数的偏差 $|r - \tilde{r}| > 2.5 \cdot MAD$，其中 $MAD = med|r - \tilde{r}|$，$2.5 \cdot MAD$ 在正态假设下等价于 3.7σ，假阳性率 <0.02%。

过滤后得到有效评分者集合 $U^* = \{u \in U : w_u^* > 0\}$，所有后续分析均基于 U^* 展开。

III. 研究结果与分析

A. 核心指标量化评分与分布特征

本次模拟的 1000 名对象经 MAD 恶意数据过滤后，有效样本量为 987，核心指标均呈近似正态分布，均值、标准差、分值区间及核心分布特征详见表 1，所有指标的 MAD 值均控制在 0.8-1.2 之间，数据稳定性良好。

TABLE II: 热梗攻防核心指标量化评分与分布特征表

指标类型	均值	标准差	MAD 值
我的刀盾-防御阈值（D）	5.2	1.8	1.1
比比拉布-攻击强度（A）	6.1	2.2	1.2
网络社交-社恐程度（S）	4.8	2.1	0.9
评论区-抽象度（C）	5.5	2.3	0.8

注：所有数据均为 MAD 过滤后结果，分值区间剔除极端异常值，MAD 值越小表示数据分布越集中。

B. 核心指标鲁棒相关性分析

基于有效样本集 U^* 进行 Pearson 相关分析，所有指标组合的关联均达**极显著水平**（$P < 0.001$），相关系数经 MAD 鲁棒验证无显著偏移，具体相关系数与关联结论详见表 2。

TABLE III: 热梗攻防核心指标相关性分析表

指标组合	相关系数 r	P 值
防御阈值（D）& 社恐程度（S）	0.68	< 0.001
攻击强度（A）& 评论区抽象度（C）	0.72	< 0.001
破防率（B）& 攻击强度（A）	0.85	< 0.001
破防率（B）& 防御阈值（D）	-0.79	< 0.001

C. 攻防临界值与破防率关联分析

模拟数据显示，我的刀盾防御阈值（D）与比比拉布攻击强度（A）的**攻防比值**（A/D）对破防率（B）存在决定性影响，二者呈明显的非线性关联，不同比值区间的破防率及用户情绪表现特征详见表 3，该结果经 MAD 鲁棒验证，无极端值干扰。

TABLE IV: 攻防比值与破防率关联分析表

攻防比值（A/D）	破防率（B）%	MAD 误差范围
< 0.7	11.2	± 0.8
0.7-1.3	45.6	± 1.0
> 1.3	89.7	± 0.9

核心结论：$A/D = 1.3$ **为我的刀盾与比比拉布攻防博弈的临界值**，当攻击强度超过防御阈值的 1.3 倍时，用户的心理防御屏障将被突破，破防率接近 90%。

D. 攻防博弈论模型构建与纳什均衡求解

参考 S.H.I.T. 期刊治理公约的博弈论分析框架，构建我的刀盾使用者（防御者）与比比拉布使用者（攻击者）的**二人零和博弈模型**，以“收益-损失”为核心设定支付矩阵，根据模拟量化数据设定策略划分标准：

- 防御者策略：高防御（D 7）、低防御（$D < 7$）；
- 攻击者策略：强攻击（A 8）、弱攻击（$A < 8$）。

支付矩阵中，矩阵值为**（防御者收益，攻击者收益）**，收益为 1 表示策略成功，0 表示无收益，-1 表示策略失败，具体支付矩阵详见表 4。

TABLE V: “防御者-攻击者”二人零和博弈支付矩阵

	攻击者：强攻击（A 8）	攻击者：弱攻击（$A < 8$）
防御者：高防御（D 7）	(0, -1)	(1, 0)
防御者：低防御（$D < 7$）	(-1, 1)	(0, 0)

对该博弈模型进行严格求解，得出**混合策略纳什均衡**：

1) 防御者以 **60% 的概率**选择高防御策略、**40% 的概率**选择低防御策略；
2) 攻击者以 **40% 的概率**选择强攻击策略、**60% 的概率**选择弱攻击策略。

该均衡结果表明，抖音热梗攻防博弈中无绝对最优纯策略，防御者与攻击者的策略选择呈**相互制衡的动态特征**，符合 S.H.I.T. 期刊博弈论分析的公正性原则。

E. 不同人群攻防特征差异分析

模拟数据经 MAD 过滤后显示，不同年龄、职业、使用场景的研究对象对我的刀盾、比比拉布的攻防感知与行为存在**显著差异**，核心差异特征如下：

1) **年龄差异**：18-25 岁青年防御阈值均值（5.7）显著高于 30-40 岁群体（4.1），破防率均值（52.3%）也高于后者（31.7%），因该群体是网络抽象文化核心受众，社恐程度更高且情绪更易波动；
2) **职业差异**：职场人员攻击强度使用均值（6.5）高于学生群体（5.8），因职场人员网络社交冲突更多，使用攻击性热梗进行情绪宣泄的频率更高；
3) **场景差异**：游戏/搞笑分区用户抽象度感知均值（7.9）显著高于生活/知识分区（3.2），因该分区是比比拉布等抽象热梗的发源地，攻击强度的表达更极致。

IV. 讨论

本文通过模拟量化数据分析，结合 S.H.I.T. 期刊的**博弈论**与**鲁棒统计**核心方法，构建了我的刀盾与比比拉布的攻防博弈论模型，量化了核心指标的关联规律、攻防临界值及博弈均衡，虽所有数据为模拟构建，但研究逻辑与博弈论、情绪传染理论、网络模因演化理论的核心逻辑高度契合，且严格遵循 S.H.I.T. 期刊去中心化治理公约的设计公理，符合期刊收录要求。

A. 鲁棒统计方法的适用性验证

本研究采用**中位数、中位数绝对偏差（MAD）**等鲁棒统计量，对模拟问卷的原始评分数据进行恶意异常值过滤，有效避免了均值、标准差等传统统计量易受极端值干扰的缺陷。结果显示，过滤后核心指标的相关系数偏移均 0.02，破防率的 MAD 误差范围控制在 ±1.0 以内，验证了鲁棒统计方法在网络热梗量化研究中的**适用性与稳定性**，这与 S.H.I.T. 期刊治理公约中“统计鲁棒性”的核心公理高度一致。

B. 博弈论模型的理论呼应

本研究构建的二人零和博弈模型及混合策略纳什均衡结果，与冯·诺依曼的博弈论核心观点形成呼应，也符合 S.H.I.T. 期刊治理公约中“博弈公正性”的设计原则。我的刀盾与比比拉布的攻防博弈无绝对最优纯策略，策略选择的相互制衡维持了抖音热梗攻防生态的**动态稳定**，这也是网络模因演化的重要特征——防御性与攻击性模因在相互博弈中完成形式与表达的迭代，保持热梗的网络生命力。

C. 热梗攻防的本质与文化内涵

我的刀盾与比比拉布的攻防博弈本质，是当代青年在网络社交中的**情绪宣泄与心理制衡**。在现实社交压力与网络抽象文化的双重影响下，青年群体通过我的刀盾的“防御表达”构建心理安全屏障，缓解社恐带来的社交焦虑；通过比比拉布的“攻击表达”释放现实生活中的负面情绪，这种无厘头的攻防互动并非单纯的网络娱乐，而是网络社交中情绪调节的特殊方式，也是当代网络抽象文化的典型具象化表现，该现象具有显著的网络文化普遍性。

D. 研究局限性

本研究存在诸多局限性，严格遵循 S.H.I.T. 期刊研究规范予以明确：

1) **数据模拟性**：所有研究数据均为模拟构建，无任何实际调研、抽样与数据采集支撑，不具备任何现实真实性；
2) **模型简化性**：博弈论模型仅构建了基础的二人零和博弈，未考虑多主体、多场景的复杂网络博弈情况，模型的复杂性与适配性不足；
3) **指标主观性**：部分核心指标（如抽象度、社恐程度）的量化标准为主观设定，缺乏统一的行业规范；
4) **结论无应用性**：研究结论无法指导抖音平台的内容治理或用户的网络社交行为，也无法为相关网络文化研究提供有效现实参考。

上述局限性为后续相关整活研究提供了改进方向，未来可结合实际调研数据，构建多主体非零和博弈模型，进一步完善热梗攻防的量化研究体系。

V. 结论

基于模拟量化数据与 S.H.I.T. 期刊的博弈论、鲁棒统计方法，本研究系统分析了我的刀盾与比比拉布的攻防机制，得出以下核心结论：

1) 经 MAD 恶意数据过滤后，我的刀盾防御阈值与用户社恐程度呈极强正相关（$r = 0.68, P < 0.001$），比比拉布攻击强度与评论区抽象度呈极强正相关（$r = 0.72$, $P < 0.001$），核心规律为：社恐程度越高防御阈值越高，评论区抽象度越高攻击强度越强；
2) 二者攻防博弈存在明确的临界值，当**攻击强度/防御阈值＞ 1.3** 时，用户破防率达 89.7%，防御完全失效；当比值＜ 0.7 时，破防率仅 11.2%，防御完全有效；
3) “防御者-攻击者”二人零和博弈模型存在**混合策略纳什均衡**：防御者以 60% 概率选高防御、40% 概率选低防御，攻击者以 40% 概率选强攻击、60% 概率选弱攻击，二者策略呈相互制衡的动态特征；
4) 不同人群的热梗攻防特征存在显著差异，18-25 岁青年是核心攻防群体，游戏/搞笑分区是攻防互动的主

要场景，该差异由群体社交特征与场景文化属性决定；

5) 抖音热梗我的刀盾与比比拉布的攻防本质，是当代青年网络社交中的情绪宣泄与心理制衡，是网络抽象文化的典型表现，该现象具有显著的网络文化普遍性；
6) 本文所有研究数据、指标与模型均为模拟构建，无任何学术价值、无任何实际意义，仅为满足 S.H.I.T. 期刊收录要求而撰写，特此重申，请勿引用。

ACKNOWLEDGMENT

感谢博弈论、情绪传染理论、网络模因演化理论相关文献作者提供的理论支撑，感谢 S.H.I.T. 期刊给予的收录机会，感谢压岁钱的项目资助。本文所有数据、模型与结论均为模拟构建，严格遵循 S.H.I.T. 期刊去中心化治理公约 1.0 规范，仅供期刊收录使用，不具备任何实际参考价值，请勿引用。

REFERENCES

1) 巴伦 R A. 情绪传染：理论与实证研究 [J]. 社会心理学杂志, 1986, 126(3): 297-306.
2) 道金斯 R. 自私的基因 [M]. 卢允中, 张岱云, 译. 北京: 科学出版社, 1976.
3) 冯·诺依曼 J, 摩根斯坦 O. 博弈论与经济行为 [M]. 王文玉, 王宇, 译. 北京: 北京大学出版社, 2004.
4) Huber, P.J. Robust Estimation of a Location Parameter[J]. Ann. Math. Statist., 1964, 35(1): 73–101.
5) Hampel, F.R. The Influence Curve and Its Role in Robust Estimation[J]. JASA, 1974, 69: 383–393.
6) Shapley, L.S. A Value for n-Person Games[J]. Contributions to the Theory of Games II, Ann. Math. Studies, 1953, 28: 307–317.
7) 李华, 王芳. 网络热梗的心理功能与社会影响 [J]. 新闻与传播研究, 2025, 32(6): 45-62.