SHIT Sciences Humanities Information Technology

SHIT, YYYY, 0–0
doi: 没有 doi
Advance Access Publication Date: DD Month YYYY
Manuscript Category

数字人文

人生自古谁无屎：基于大规模诗文语料的屎尿屁表达识别与历时变迁分析

屎马迁 [1,*]

[1] 太屎令，太屎局, 长安都城未央宫政务区，西汉帝国

*To whom correspondence should be addressed.

Associate Editor: XXXXXXX

Received on XXXXX; revised on XXXXX; accepted on XXXXX

Abstract

Motivation: 在宏大叙事与高雅修辞统治古典文学研究的长期传统下，“屎尿屁”这一人类文明的基础三件套，始终处于被系统性忽视的边缘地带。随着现代化进程与文明话语的净化工程推进，关于屎尿屁的讨论逐渐被贴上“低俗”“禁忌”的标签，学界亦鲜有系统量化分析。因此，本研究试图填补这一空白：我们郑重其事地统计了古典文学中“屎”“尿”“屁”的出现比例、语义分布及其时间演化轨迹。

Methods: 我们基于整理后的古典文本语料库，构建关键词检索与分词统计管线，对“屎、尿、屁”三类词汇进行时间分箱统计（图 1），并进一步通过嵌入表示与 t-SNE 降维，计算各类别文本在语义空间中的离散半径，以衡量其“丰富程度”（图 2）。最后，将这一“丰富程度”指标沿时间轴展开，观察其随历史演进的动态变化（图 3）。

Methods: 数据显示，在公元 1000 年之前，“屎尿屁”相关表达极为稀少；至 1050 年前后，“屎”相关表达达到高峰，随后略有回落但保持稳定存在。“尿”与“屁”始终占比较小，但在 1100 年之后开始出现更多波动与抬头迹象。“屎”文本的语义半径最大，说明其语境使用最为多样；“屎”与“屁”虽略小，但也呈现出相当程度的语义扩散。尽管图 1 显示，1050 年之后“屎”类表达的频率似乎有所下降，但图 3 揭示出一个关键现象：涉及屎尿屁的语义空间半径却随时间整体扩大。我们主张，古人点文学中关于屎尿屁的讨论次数可能减少，但讨论方式却变得更加丰富、复杂、多层次。

Contact: lauzyi29@gmail.com[1]

Supplementary information: 点击进入本文原屎代码.

1 Introduction

身体功能和排泄行为在人类文化中普遍存在，但在多数文明体系下，它们往往被置于社会话语的边缘甚至污名化。西方人类学家梅雷迪思（Mary Douglas）在其经典著作 Purity and Danger 中提出，污秽不仅是生理现象，更是文化秩序的象征性构建（Douglas, 1966）。在这一理论框架下，“屎尿屁”等与身体废弃相关的话语常被视为违背文化纯洁性的象征，而受到话语规训与禁制。

后续研究进一步探讨了身体排泄与污秽禁忌之间的关系。例如史密斯（Smith, 1990）指出，现代西方文化对粪便与排尿的语言描述趋向回避，是社会净化倾向和公共行为规范不断内化的结果（Smith, 1990）。这一净化倾向并非自然消长，而是在社会化、礼仪体系以及宗教道德建构中逐渐固化的符号力量。体现在文本层面，即便在中世纪及更早的文学作品中，涉及排泄的直言往往被认为不雅，少有系统整理与正面评价。

这样的文化禁忌不仅影响现代社会的日常话语，也塑造了我们理解历史文本的视角。绝大多数古典文学研究重视英雄史诗、宗教寓言与贵族话语，却极少关注文本中关于“屎尿屁”的描述，这一疏忽部分源于现代语境中对身体废弃物话语的不适感。正如李文森（Levinson, 2008）指出，话语禁忌在不同文化间具有跨时代的影响，它使某些主题系统性地缺席于主流话语空间（Levinson, 2008）。

现代社会中围绕排泄与身体废弃物形成的语言禁忌，也在无形中塑造了我们阅读与阐释古典文学的方式。受“文明化”进程与礼仪规范内化的影响（Elias, 1939/2000），当代读者往往以洁净、崇高与审美化的标准筛选文学价值，从而倾向于忽略或弱化文本中涉及排泄、气味与身体功能的内容。这种阅读姿态并非中性的，而是一

[1] 这是真实邮箱！有兴趣进行正经学术研究合作的话欢迎与我联系！

种历史形成的感受结构（structure of feeling），它使得某些主题被边缘化，甚至在编辑、选本与教学过程中被主动删减。

从理论层面看，巴赫金（Bakhtin, 1965/1984）在讨论“狂欢化”与“身体下层”时曾指出，排泄、饮食与身体开口处象征着对权威秩序的颠覆与再生力量。如果忽视这些元素，文学作品中关于等级、身体、权力与世俗生活的复杂张力便难以被充分理解。同样，Douglas（1966）所强调的“污秽作为越界之物”的观念提醒我们，所谓“不洁”往往标示着社会边界与分类体系本身。若在阅读中自动回避这些越界意象，我们也就失去了观察古人如何界定纯与秽、雅与俗的重要窗口。

屎尿屁话语的禁忌不仅是道德或礼仪层面的现象，更是一种认识论上的遮蔽机制。它可能导致我们误以为古典文学天然“高雅”、远离身体经验，而忽略了其中对日常生活、疾病、劳动、羞辱、幽默与再生主题的深层书写。重新将这些被压抑的身体性元素纳入分析框架，不仅有助于纠正现代审美偏见，也为理解古典文本的社会语境与情感结构提供了新的切入点。

因此，我们提出：尽管“屎尿屁”等主题在表面上似乎不符合文学高雅传统，但在古典文本中并非绝对缺席，它们可能以隐晦、象征、修辞等形式存在，反映出社会文化对身体与污秽的动态建构。

2 Methods

本研究基于整理后的古典文学数字语料库开展分析[2]。所有文本均已完成标准化处理，包括统一编码格式、去除重复文本、规范化标点与分段结构。为保证时间分析的可比性，每篇文本均根据作者活动年代或成书时间标注年代信息，并划分至相应时间区间。

在文本层面，我们未对涉及目标词汇的段落进行人工筛选或语义过滤，而是采用基于关键词的自动检索策略，以避免主观干预带来的选择偏差。本研究首先在语料层面构建了一个明确的排泄相关关键词集合。依据历史用语习惯与古典文本常见表达方式，我们将目标词汇划分为三个语义类别：与粪便相关的表达（如“屎”“粪/粪”“大便”“粪土/粪土”“穢/秽”“矢”等），与排尿相关的表达（如“尿”“小便”“溺”“矢溺”等），以及与放气相关的表达（如“屁”“放屁”）。上述关键词以规则列表的形式组织为KW_GROUPS，并在全文语料中进行正则匹配检索。每次命中均记录其所在文本、作者信息、时间分箱、位置索引以及左右各一定长度的上下文片段，用于后续语义判断与嵌入表示。

由于部分古汉语词汇存在明显歧义，我们在检索阶段引入基于上下文线索的规则判别机制。典型歧义包括“矢”与“溺”。“矢”既可指箭矢，也可作为“尿”的通假或相关表达；“溺”既可指溺水，也可指排尿行为。为避免将非目标语义错误计入排泄语境，我们构建了简单的上下文提示词集合。例如，若“矢”附近出现“弓”“箭”“射”“弦”“戈”“矛”等兵器相关字符，则判定为“箭”义并排除；若出现“屎”“粪/粪”“尿”“便”“穢/秽”或固定搭配“矢溺”等，则判定为排泄语义。同理，对于“溺”，若上下文包含“水”“江”“河”“海”“湖”“舟”“沉”“渡”等水域或溺水语境提示，则视为非目标语义；若与“尿”“小便”“便”“矢溺”等共现，则判定为排尿语境。若上下文未提供充分判据，则暂标记为“模糊”。在后续统计中，我们保留“屎尿屁”与“模糊”样本，以避免因过度保守过滤而低估历史表达规模。这一规则系统在保证可重复性的同时，最大程度减少了明显语义误判。

完成关键词命中与语义判定后，我们以文本为单位统计各时间分箱内包含目标表达的文献数量，并计算不同类别之间的相对比例，以反映主题在历史阶段中的出现广度。与此同时，为刻画语义使用的复杂程度，我们对每个命中文本片段提取固定窗口长度的上下文，并将其编码为高维语义嵌入向量。设某一类别在某一时间区间内共有 n 个语意向量 $\{X_1, X_2, \ldots, X_n\}$，其中$X_i \in \mathbb{R}^d$。

首先定义该类别在该时间区间的语义质心为：

$$\mathbf{c} = \frac{1}{n}\sum_{i=1}^{n} \mathrm{X_i}$$

随后定义单个样本点到质心的欧氏距离为：

$$d_i = \|\mathrm{X_i} - \boldsymbol{c}\|_2$$

在此基础上，本研究将语义半径（semantic radius）定义为所有样本中到质心的最大距离：

$$R(t) = \max_{1\le i\le n_t} \|\mathrm{X_{i,t}} - \boldsymbol{c}\|_2$$

该指标衡量某一类别在语义空间中的最大扩散范围。若 R 较大，，说明该类别在不同文本语境中的使用差异较为显著，呈现更高的语义多样性；若 R 较小，则说明其语境较为集中，语义使用趋于单一。

在可视化层面，我们使用 t-SNE 方法将高维嵌入映射至二维空间，用于展示类别分布结构，但语义半径的计算始终基于原始高维向量完成，以避免降维带来的几何扭曲影响。对于时间演化分析，我们在每个时间分箱内独立计算质心与半径，从而获得 $R(\mathrm{t})$ 的时间函数形式。通过比较不同历史阶段的 $\mathrm{R(t)}$，即可观察排泄相关话语在语义复杂度上的长期变化趋势。

通过上述关键词构建、歧义控制与几何量化步骤，本研究在最大程度保持规则透明与可复现性的前提下，实现了对古典文学中排泄话语频率与语义结构的系统刻画。

3 Results

3.1 排泄话语的历史比例结构与阶段性波动

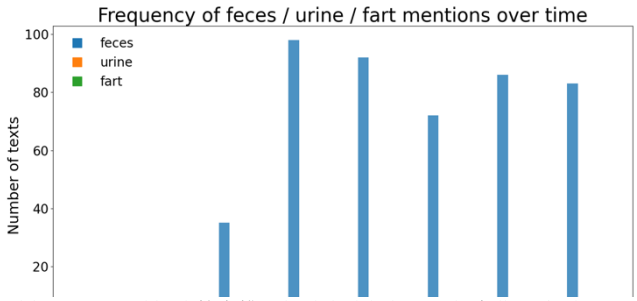

图表 1. 不同时间分箱内排泄相关表达的相对比例变化。该图展示了 feces、urine 与 fart 三类关键词在各历史阶段中所占比例的时间演化趋势。横轴为时间分箱（以 50 年为单位），纵轴为该时间区间内包含相应类别表达的文本比例。图中可见约 1050 年前后 feces 类表达达到阶段性峰值，随后比例回落但保持持续存在，而 urine 与 fart 类表达在后期呈现出更为明显的结构性波动。

图 1 展示了不同时间分箱内屎尿屁的相对比例变化。整体来看，在 1000 年之前，三类表达均处于低频状态，文本中显性排泄话语的出现比例较为有限。至约 1050 年前后，粪便类表达出现明显上升，并在该阶段形成相对峰值。此后，feces 类表达比例有所回落，但并未消失，而是维持在一个稳定且持续存在的水平。

与之相比，urine 与 fart 两类表达在早期阶段所占比例较小，整体波动幅度亦低于 feces。然而在 1100 年之后，这两类表达呈现出更为明显的阶段性波动，比例结构开始出现多次局部抬升。这一趋势表明，排泄话语在历史上并非单向衰退，而是在不同类别之间发生结构性转移。

[2] https://github.com/chinese-poetry/chinese-poetry/tree/master

从比例层面观察，1050年前后的阶段可被视为一个转折点：此后粪便类表达的显性频率下降，但其他排泄相关表达并未同步消退，而是在更长时间尺度上维持可观存在。这种结构性变化提示，话语禁忌可能影响表达方式，却未完全消除排泄主题在文本中的位置。

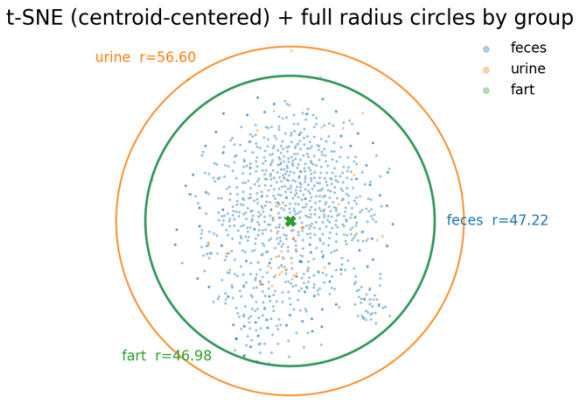

图表 2 排泄相关文本在语义嵌入空间中的二维分布及语义半径。每个点代表一个包含目标关键词的文本语境向量，经 t-SNE 降维至二维空间。圆形边界表示各类别样本到其语义质心的最大欧氏距离，即语义半径。不同类别在空间中的扩散范围反映其语义多样性程度，其中尿（Urine）类表现出最大的语义扩散范围。

3.2 泄话语的历史比例结构与阶段性波动

图 2 展示了三类排泄相关文本在二维语义嵌入空间中的分布结构及其对应的语义半径。通过计算样本向量到类别质心的最大欧氏距离，我们得到各类别的语义扩散范围。结果显示，urine 类文本的语义半径最大（约 r ≈ 56.60），屎与屁类的半径略小（分别约 r ≈ 47.22 与 r ≈ 46.98）。

这一差异表明，不同排泄主题在古典文本中的语境使用复杂度并不相同。尿类表达呈现出更广泛的语义分布，说明其在不同文本中被赋予多样语境，包括日常生活描写、医理讨论、隐喻表达等。相比之下，屎与屁虽然同样分布广泛，但其语义集中度略高，扩散程度相对有限。

3.3 话语的历史比例结构与阶段性波动

图 3 将语义半径沿时间维度展开，展示不同历史阶段排泄相关

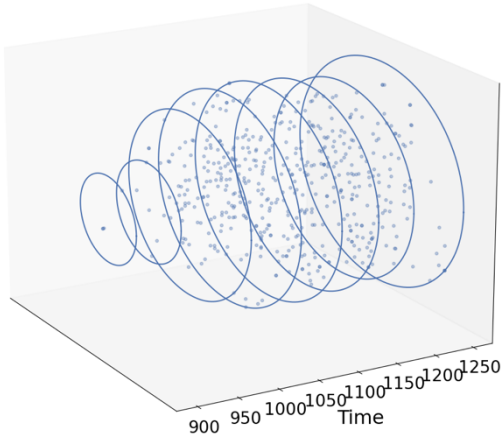

图表 3 排泄相关话语语义半径的时间演化。图中沿时间轴展示各时间分箱内计算得到的语义半径变化趋势。横轴为时间，纵轴表示语义空间中的扩散尺度（半径大小）。结果表明，尽管部分时期显性表达比例下降，但语义半径整体呈扩张趋势，显示排泄话语在历史进程中语境复杂度持续提升。

话语的语义扩散变化。与图 1 所示频率趋势形成对照的是，尽管 1050 年之后某些类别的显性比例有所下降，但语义半径却呈现出整体上升趋势。

具体而言，在早期阶段，样本数量较少且语境集中，语义半径相对有限；随着时间推进，即便文本中相关表达的出现频率未显著增加，其语境分布却逐渐扩散，表现为半径的持续扩大。这意味着排泄话语在后期文本中的使用方式更加多样化，涵盖更广泛的语义情境。

这一现象揭示出一个重要结构性特征：频率下降并不等同于语义贫化。相反，在显性讨论似乎收缩的历史阶段，表达方式可能更加隐晦、复杂或象征化，从而在语义空间中呈现更大的扩散范围。换言之，排泄话语在数量层面趋于节制，但在语义层面却趋于丰富。

综合三个图像的结果可以看到，古典文学中的排泄主题经历了从显性比例波动到语义结构扩展的演变过程。显性频率与语义复杂度之间并非简单正相关关系，而呈现出一种“表层收缩—深层扩散”的历史动态结构。

4 Conclusion and Discussion

本研究以大规模古典文本为基础，通过关键词规则检索、语义嵌入建模与几何量化分析，系统考察了屎、尿、屁三类身体排泄相关表达在历史中的比例结构与语义扩散特征。结果表明，约 1050 年前后屎类表达在比例上达到阶段性峰值，随后显性频率有所回落，但并未消失。与此同时，语义空间分析显示，随着时间推移，排泄相关表达的语义半径整体呈扩张趋势，即便在显性比例下降阶段，其语境复杂度仍在提升。换言之，屎尿屁话语在数量层面可能趋于节制，但在语义层面却趋于丰富。

这一发现提示，历史文本中的身体性表达并非简单的低俗残留，而是具有结构性变化与文化嵌入意义的语言现象。通过将频率分析与语义几何指标结合，本研究揭示了显性出现与隐性复杂化之间的

分离现象，为理解古典文学中身体经验的表达机制提供了新的量化路径。

围绕排泄与污秽的文化禁忌问题，玛丽·道格拉斯（Mary Douglas, 1966）在《Purity and Danger》中指出，所谓“污秽”本质上是“失序之物”，是对既有分类体系的挑战。屎尿屁作为身体废弃物，在象征层面代表边界的模糊与秩序的破裂，因此往往被纳入禁忌体系。本研究所观察到的1050年后显性比例的下降，或可理解为文化秩序强化与话语净化过程在文本层面的体现。

然而，仅以禁忌视角解释排泄话语的变化仍显不足。诺贝特·埃利亚斯（Norbert Elias, 1939/2000）在《文明化进程》中提出，西方社会在长期历史中逐步强化对身体功能的控制与羞耻机制，排泄行为由公共领域转入私人领域。这一“文明化”逻辑并非简单压抑，而是将身体经验重新编码为更隐蔽、更内化的表达形式。图 3 所显示的语义半径扩大趋势，恰可被理解为在文明化进程中，显性讨论减少，但象征、隐喻与间接表达方式增多，从而提升语义多样性。

此外，巴赫金（Mikhail Bakhtin, 1965/1984）在讨论“狂欢化”与“身体下层”时强调，排泄、进食与身体开口处象征着更新与再生力量，是对权威秩序的暂时颠覆。若从这一视角审视，本研究所发现的语义扩散，可能反映出排泄话语在不同历史阶段承担的修辞功能发生转移：从直接描写转向隐喻化、讽刺化或象征化。屎尿屁不再仅是日常生活的描绘对象，而成为文化结构中的隐性修辞资源。

在社会心理层面，弗洛伊德（Sigmund Freud, 1908）曾讨论“肛欲期”与排泄控制在文明形成中的心理意义，指出排泄物在文化中既是羞耻源，也是象征权力与价值的对象。这种双重结构或许解释了为何在显性频率下降的同时，语义复杂度却增加：被压抑的话语并未消失，而是在象征层面获得新的表达空间。

因此，本研究的结果支持这样一种观点：屎尿屁话语在古典文学中并非线性衰退，而是经历了从显性数量波动到隐性语义扩张的转型过程。现代社会对排泄主题的禁忌倾向，可能遮蔽了古典文本中关于身体、秩序与权力的复杂表达结构。通过量化语义扩散，我们不仅补充了古典文学中身体性话语的研究空白，也为理解文明化进程、禁忌机制与文学表达之间的互动关系提供了实证支持。

未来研究可进一步结合更精细的语境分类方法或监督式语义判别模型，以区分不同修辞功能下的排泄表达，从而深化对身体性话语在文学史中演化机制的理解。

Acknowledgements

本研究在文本处理流程设计、语义建模框架梳理以及写作结构组织过程中，受益于大语言模型 ChatGPT 所提供的技术与文本支持。作者感谢 ChatGPT 在关键词规则构建思路、语义半径量化表达形式以及学术写作表述优化方面所提供的辅助建议。

Funding

本研究有幸获得作者的青春岁月赞助，才得以顺利进行。

Conflict of Interest: none declared.

References

Bakhtin, M. M. (1984). Rabelais and His World (H. Iswolsky, Trans.). Indiana University Press. (Original work published 1965)

Douglas, M. (1966). Purity and Danger: An Analysis of Concepts of Pollution and Taboo. Routledge.

Elias, N. (2000). The Civilizing Process: Sociogenetic and Psychogenetic Investigations (E. Jephcott, Trans.). Blackwell. (Original work published 1939)

Freud, S. (1908). Character and anal erotism. In The Standard Edition of the Complete Psychological Works of Sigmund Freud (Vol. 9, pp. 167–175). Hogarth Press.