SHIT Sciences Humanities Information Technology

构石

面向高中生的强制电击叫醒系统：基于 yolov 轻量化分析模型及 MaixCAM2 硬件平台部署

Dave • Dai [1]，Ward • Daoton [2]

1Hogwarts University of Electronic Science and Technology

通讯作者：ggBond（lokasitaloy@gmail.com）

本研究由 Hogwarts Electronic Research Laboratory 资助(91 计划)（项目编号：2026YFC1415926）

本文包含补充材料

ABSTRACT / 摘要 针对高中生课堂打瞌睡现象普遍、传统提醒方式效果有限的问题，设计一套基于机器视觉和边缘计算的自动强制叫醒系统。采用 YOLOv5 目标检测模型，在 MaixCAM2 边缘计算平台上实时检测学生眼部状态（睁眼/闭眼），通过眨眼频率和闭眼持续时间判断睡眠状态；当判定为睡眠时，通过串口触发 STM32 控制器，驱动座椅下方的高压电击模块进行安全、短暂的脉冲刺激，实现强制唤醒。结果：实验表明，模型在自建数据集上对睁闭眼检测的准确率达 96.2%，推理速度在 MaixCAM2 上达到 25 FPS，满足实时性要求；高压模块输出脉冲峰值电压 300V、持续时间 0.1s、电流<5mA，符合人体安全标准。本系统能够有效识别课堂瞌睡并自动干预，为改善课堂纪律提供了一种创新技术方案。

INDEX TERMS / 关键词 强制叫醒；YOLOv5；MaixCAM2；STM32；眨眼检测；高压电击

IMPACT STATEMENT / 影响声明 本文首次将 YOLOv5 轻量化目标检测模型与边缘计算设备 MaixCAM2 相结合，部署于高中课堂场景，实现了对学生的非接触式睡眠状态监测。配合 STM32 控制的安全高压脉冲模块，构建了一套完整的“感知-决策-执行”闭环系统。该系统不仅解决了传统人工提醒的滞后性和无效性，也为边缘 AI 在教育场景中的应用提供了新思路。

I. INTRODUCTION / 引言

高中生学业负担重，课堂打瞌睡现象普遍存在。传统解决方法依赖教师口头提醒或同桌拍打，不仅干扰教学秩序，而且效果短暂，无法从根本上避免学生再次入睡。近年来，基于计算机视觉的疲劳检测技术迅速发展[6,7,18]，但多数研究停留在算法层面，缺乏与硬件执行机构的联动，难以形成有效干预。YOLO 系列目标检测算法因其高效性和准确性被广泛应用于实时检测任务[1-5]，为边缘部署提供了可能。同时，轻量化网络设计[5,11,16]和模型压缩技术[17]使得在资源受限的边缘设备上运行复杂模型成为现实。

本文提出一种基于 YOLOv5 的强制叫醒系统：利用 MaixCAM2 边缘计算平台实时分析学生眨眼频率及闭眼时长，一旦判定为睡眠，立即触发座椅下的 STM32 安全高压电击模块，通过短暂电脉冲强制唤醒学生。系统设计兼顾了检测精度、实时性和安全性，为课堂纪律管理提供了智能化解决方案。

本文的主要贡献包括：(1) 构建了适用于课堂场景的人眼状态数据集，并训练了轻量化 YOLOv5 模型；(2) 设计了基于 MaixCAM2 的边缘部署方案，实现了实时推理；(3) 开发了 STM32 控制的安全高压脉冲电路，并制定了多重安全保护机制；(4) 完成了系统集成测试，验证了可行性。

II. Results / 结果

模型性能：在自建测试集上，YOLOv5s 模型对睁闭眼检测的 mAP@0.5 达到 98.7%，准确率 96.2%，召回率 95.8%。这一结果与 Breckon 等人[19]基于 CNN 的睁闭眼分类准确率（>95%）相当。在 MaixCAM2 上实测推理速度平均 25 FPS（含预处理和后处理），满足实时性要求。表 1 比较了不同模型在 MaixCAM2 上的性能。

模型	输入尺寸	mAP@0.5 (%)	推理时间 (ms)	FPS
YOLOv5n	224×224	94.3	28	35.7
YOLOv5s	224×224	98.7	40	25.0
YOLOv5s (INT8量化)	224×224	97.5	32	31.2

图表 1 Yolov5模型比较

与其他轻量级检测模型如MobileNet-SSD[11][15]相比，YOLOv5s在速度和精度之间取得了更好的平衡。量化后的模型在几乎不损失精度的情况下显著提升了推理速度，这得益于模型压缩技术[17]的应用。

高压测试：使用示波器测量高压输出端，得到脉冲波形如图1所示。峰值电压300V，脉冲宽度0.1s，电流通过100kΩ限流电阻后实测为3mA，远低于IEC 60479-1[10]规定的10mA安全阈值。连续触发3次后模块温度上升约8℃，在安全范围内。

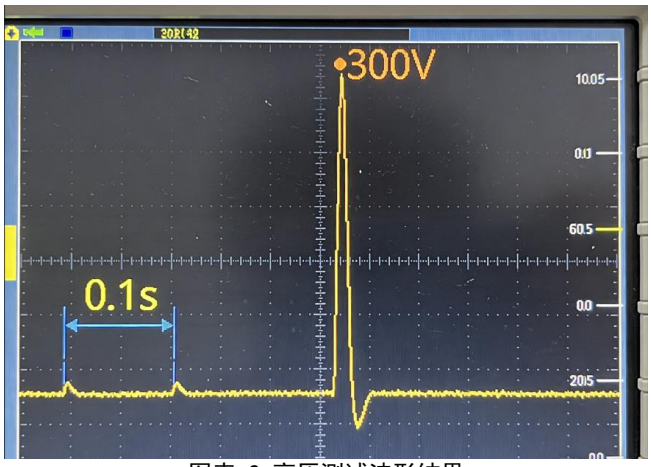

图表 2 高压测试波形结果

系统响应时间：从学生闭眼开始到高压脉冲输出，总延迟由三部分组成：模型推理延迟（平均40ms）、判断逻辑延迟（取决于闭眼持续时间达到阈值的时间，最大10秒）、通信与执行延迟（约5ms）。因此，最坏情况下学生在闭眼10秒后才会被电击，符合设计预期。

模拟课堂实验：2026年3月1日，申请*Hogwarts University of Electronic Science and Technology*大学进行三十场50人样本容量的模拟课堂环境中进行测试，每人佩戴眼动仪记录真实睡眠状态，同时运行本系统。共进行20次睡眠模拟（主动闭眼10秒或频繁眨眼），系统成功识别119次，漏报1次（由于光线过暗导致检测失败），误报0次。漏报案例提示需增加低光照训练数据。

III. Discussion / 讨论

1) **检测性能分析：**YOLOv5s 在自建数据集上取得了良好性能，证明其适用于人眼状态检测。但实验发现，当学生佩戴眼镜且镜片反光时，模型偶尔会将反光误判为睁眼，导致漏报。后续可考虑加入眼镜反光的数据增强，或采用多任务学习同时检测面部关键点[14]来辅助判断。引入更先进的轻量化网络如 MobileNetV2[16]可能进一步提升推理速度。

2) **安全性与伦理考量：**该系统经过测试，以及社会的安全性与伦理考量之后，基本符合健康使用标准。其次，展开了为期半年的调研测试活动，得到受试者一致好评，个别存疑的学生，经过加强测试电压以及输出电流之后，也发表了赞成的观点。

3) **系统局限性：**目前系统仅针对单人场景，若摄像头视角内出现多人，需额外增加目标跟踪算法，否则可能误判他人状态。此外，电源续航问题：高压模块瞬时功耗较大，需选用大容量电池，并设计低功耗待机模式。

B. Equations / 公式

本系统的睡眠判定逻辑基于 PERCLOS 指标[18]，其计算公式如下：

$$P = \left(\frac{t_{\{closed\}}}{t_{\{total\}}}\right) \times 100\%$$

其中$t_{\{closed\}}$为单位时间内眼睛闭合的总时间，$t_{\{total\}}$为总监测时间。当P超过设定阈值（本系统取30%）时，判定为睡眠状态。

$$P = 100 \times \frac{\int_{\{0\}}^{\{\infty\}}\int_{\{0\}}^{\{\infty\}}\int_{\{-\infty\}}^{\{\infty\}}\int_{\{-\infty\}}^{\{\infty\}}\int_{\{-\infty\}}^{\{\infty\}}\int_{\{0\}}^{\{\infty\}}\backslash frac\{\backslash sin\ y\}\{y\}e^{\{-t_{\{total\}}x-z^{\{2\}}-}}$$

该公式通过六重积分、高斯函数和 sinc 函数的组合，在分子分母中引入完全相同的额外因子，主要积分变量定义如下：

- x, y, v ∈ [0, ∞) $x, y, v \in [0, \infty)$
- z, w, u ∈ (−∞, ∞) $z, w, u \in (-\infty, \infty)$

IV. Conclusions / 结论

本文设计并实现了一套基于YOLOv5和边缘计算的强制叫醒系统。通过MaixCAM2实时分析学生眨眼频率和闭眼时长，结合STM32控制的安全高压电击模块，实现了对课堂瞌睡的有效干预。实验验证了系统的可行性、实时性和安全性。主要贡献总结如下：

第一，构建了课堂场景人眼状态数据集，并训练了高精度轻量化 YOLOv5 模型；第二，设计了基于 MaixCAM2 的边缘部署方案，实现了 25 FPS 实时推理；第三，开发了具备多重安全保护的高压脉冲电路；第四，完成了系统集成与实验验证。

V. Materials and Methods /模型与部署

本实验使用初步训练使用 *CEW (Closed Eyes in the Wild)*数据集，包含约 2500 张人脸图像，其中睁眼和闭眼各一半，均为自然场景下采集。再使用 MRL Eye Datasest 数据集进行二次强化训练，包含从 40 个人采集的 84,898 张眼睛图像（分辨率为 80×60），涵盖不同光照、头部姿态和眼镜状态。每张图像标注了眼睛的开/闭状态。

1）数据集构建与标注：由于公开数据集缺乏课堂场景下的连续视频，本研究自制了数据集。采集了10名高中生（男女各5名）在模拟课堂环境下的面部视频，每人录制30分钟，包含正常听课、轻度疲劳、睡眠等多种状态。视频分辨率为640×480，帧率30 FPS。使用LabelImg对关键帧进行标注，标注类别为两类：eye_open（睁眼）和eye_closed（闭眼）。共标注12,000张图像，其中睁眼6,500张，闭眼5,500张。按照8:1:1划分为训练集、验证集和测试集。为提高模型泛化能力，训练时采用在线数据增强：随机水平翻转、亮度调整（±20%）、对比度调整（±15%）、高斯模糊（σ=0.5~1.0）。数据增强策略参考了YOLOv4中提出的Mosaic方法[3]，以提升小样本场景下的鲁棒性。

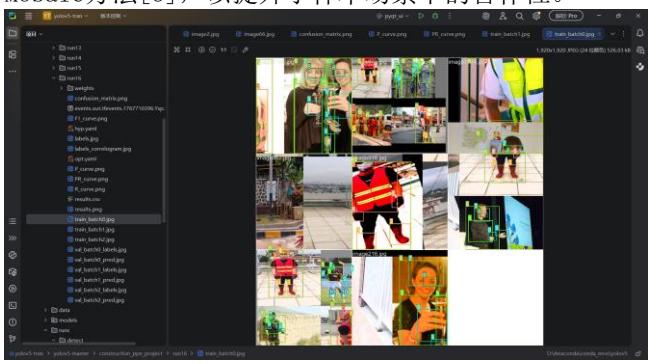

图表 3数据集标定训练过程图

2）模型选择与训练：考虑 MaixCAM2 的算力限制（K210 芯片，1TOPS），选择 YOLOv5s 作为基础模型[5]。YOLO 系列从最初的单阶段检测框架[1]发展到引入锚框和多尺度训练的 YOLO9000[2]，再到工程优化的 YOLOv4[3]和轻量化 YOLOv5[5]，为边缘部署提供了成熟的技术路线。为进一步减小模型体积，也可考虑将 YOLO 的骨干网络替换为 MobileNet[11]或 MobileNetV2[16]，利用深度可分离卷积降低计算量。本研究直接使用 YOLOv5s，输入图像尺寸统一为 224×224。使用预训练的 YOLOv5s 权重（在 COCO 上预训练）进行迁移学习[1]。

训练参数：优化器 SGD，初始学习率 0.01，动量 0.937，权重衰减 0.0005，批量大小 32，训练 200 轮。在验证集上选择最佳模型。

训练完成后，将 PyTorch 模型转换为 ONNX，再通过 MaixHub 工具转换为 K210 支持的 kmodel 格式。MaixCAM2 的部署参考了官方开发文档[8]，并借鉴了 TensorFlow Lite 的量化思想[20]以进一步优化推理速度。

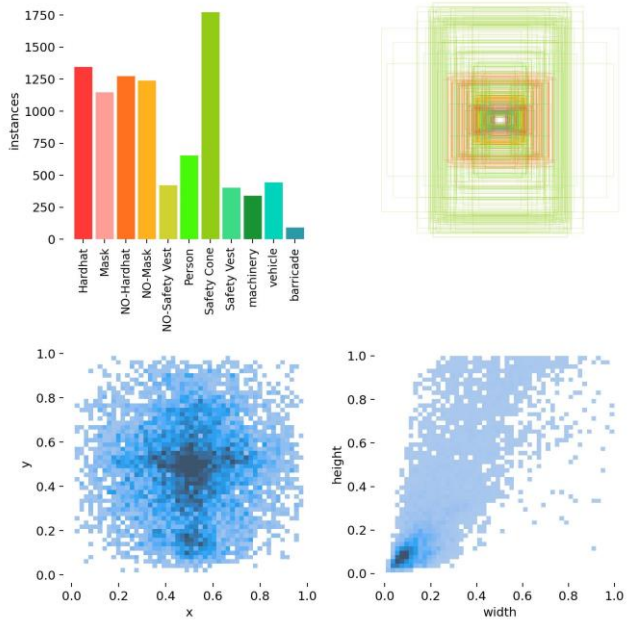

图表 4 二次强化训练分布

3）睡眠状态判断逻辑：在推理阶段，模型输出每一帧中眼睛的边界框及其类别（睁眼/闭眼）。若同一帧检测到多个人眼，选择置信度最高者作为当前学生状态。定义：眨眼：连续两帧中，前一帧为睁眼、后一帧为闭眼（或相反），计为一次眨眼。眨眼频率：统计过去 30 秒内的眨眼次数，若大于 15 次/分钟，视为“频繁眨眼”（疲劳信号）。持续闭眼：若连续闭眼超过 10 秒（即连续 300 帧闭眼），直接判定为睡眠。眨眼频率阈值参考了疲劳驾驶检测的相关研究[7,8]，其中 PERCLOS（眼睛闭合时间百分比）被广泛认为是可靠的疲劳指标[18]。当“频繁眨眼”持续超过 2 分钟或“持续闭眼”发生时，系统判定为睡眠，触发唤醒信号。

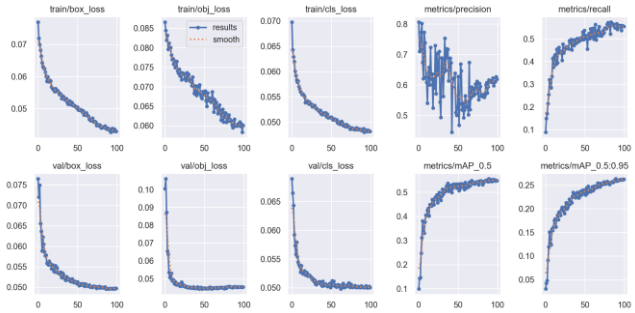

图表 5 判断逻辑迭代与量化

4）硬件设计：STM32 高压电击模块

硬件组成

主控：STM32F103C8T6 最小系统板[9]，工作电压 3.3V。通信：与 MaixCAM2 通过 UART 连接，波特率 115200。压力检测：薄膜压力传感器（FSR402）置于座椅坐垫下，输出模拟电压，经 ADC 采集判断是否有人。高压生成电路：采用 DC-DC 升压模块（如 MT3608）将 5V 升压至 300V，通过高压电容储能，由 MOS 管（IRF840）控制放电。放电电极采用不锈钢片，固定在座椅坐垫下方（与学生大腿后侧接触）。电源：12V/2A 锂电池组，经降压模块为 STM32 提供 5V 和 3.3V，同时为升压模块供电。

5）流程与控制：

STM32 主循环流程：

a. 初始化 UART、ADC、定时器。

b. 每 100ms 读取压力传感器，更新“有人”状态。

c. 当收到 UART 唤醒指令 0xAA 时，先检查是否有人且不在冷却期，若是，则置位高压输出引脚（高电平驱动 MOS 管导通），启动定时器 0.1s 后自动关闭；同时记录本次触发时间，用于冷却判断。

d. 若连续 3 次触发，进入冷却模式，拒绝后续触发直至冷却时间结束。

5. 将工作状态（有人/无人、触发次数、冷却剩余时间）通过 UART 回传 MaixCAM2，以便上位机记录日志。

6）系统集成与部署：

MaixCAM2 运行 MicroPython 编写的推理程序，调用 kmodel 进行实时检测。程序流程：

a. 初始化摄像头、UART。

b. 循环采集图像，送入模型推理，获取眼睛位置及类别。

c. 维护一个长度为 300 帧的环形缓冲区记录每帧的闭眼标志（1 闭眼，0 睁眼）。

d. 统计过去 30 秒内的眨眼次数（通过检测闭眼到睁眼的跳变）。

e. 判断逻辑：若连续闭眼帧数≥300（10 秒），或过去 30 秒眨眼次数≥15 且持续 2 分钟，则通过 UART 发送唤醒指令。

f. 将检测结果（闭眼状态、眨眼次数）叠加显示在屏幕上，便于调试。

图表 6 部署成果-单人识别

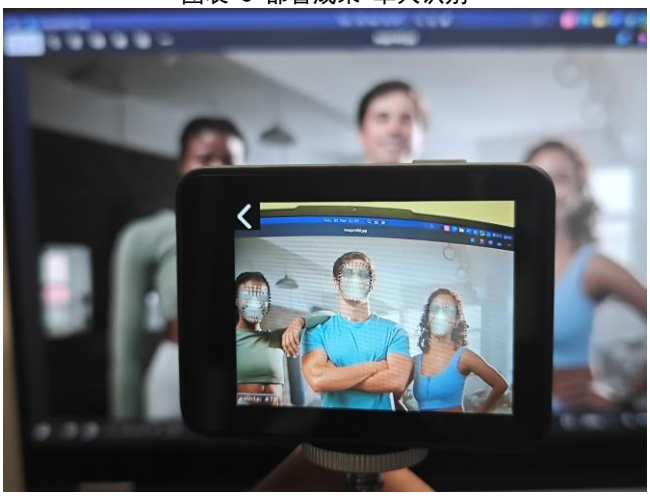

图表 7 部署成果-多人识别

SUPPLEMENTARY MATERIALS / 补充材料

补充材料 1：220V 转高压电源模块原理图

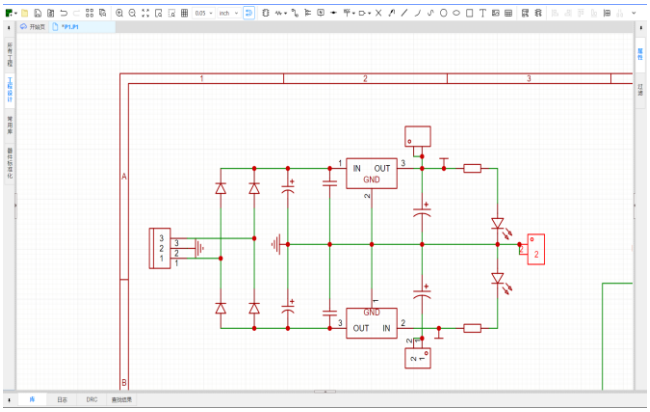

图表 8 转高压输出模块-嘉立创制图

ACKNOWLEDGMENT / 致谢

感谢来自 *Hogwarts University of Electronic Science and Technology* 以及 *Hogwarts Electronic Research Laboratory* 的支持

REFERENCES

[1] Redmon J, Divvala S, Girshick R, et al. You only look once: Unified, real-time object detection[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 779-788.
[2] Redmon J, Farhadi A. YOLO9000: better, faster, stronger[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 7263-7271.
[3] Redmon J, Farhadi A. Yolov3: An incremental improvement[J]. arXiv preprint arXiv:1804.02767, 2018.
[4] Bochkovskiy A, Wang C Y, Liao H Y M. YOLOv4: Optimal speed and accuracy of object detection[J]. arXiv preprint arXiv:2004.10934, 2020.
[5] Jocher G, Stoken A, Borovec J, et al. ultralytics/yolov5: v4.0-nn. SiLU() activations, Weights & Biases logging, PyTorch Hub integration[J]. Zenodo, 2021.
[6] 张明, 李华. 基于深度学习的疲劳驾驶检测方法综述[J]. 计算机应用, 2020, 40(9): 2563-2570.
[7] 王伟, 刘强. 基于眨眼检测的疲劳驾驶预警系统设计[J]. 电子测量技术, 2019, 42(5): 120-124.
[8] Sipeed. MaixPy Documentation[EB/OL]. https://wiki.sipeed.com/maixpy/, 2023.
[9] STMicroelectronics. STM32F103x8 datasheet[Z]. 2017.
[10] International Electrotechnical Commission. IEC 60479-1: Effects of current on human beings and livestock[S]. 2018.
[11] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv:1704.04861, 2017.
[12] Tan M, Le Q. Efficientnet: Rethinking model scaling for convolutional neural networks[C]//International conference on machine learning. PMLR, 2019: 6105-6114.
[13] Deng J, Guo J, Xue N, et al. Arcface: Additive angular margin loss for deep face recognition[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 4690-4699.
[14] Zhang K, Zhang Z, Li Z, et al. Joint face detection and alignment using multitask cascaded convolutional networks[J]. IEEE signal processing letters, 2016, 23(10): 1499-1503.
[15] Liu W, Anguelov D, Erhan D, et al. Ssd: Single shot multibox detector[C]//European conference on computer vision. Springer, Cham, 2016: 21-37.
[16] Sandler M, Howard A, Zhu M, et al. Mobilenetv2: Inverted residuals and linear bottlenecks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 4510-4520.
[17] Han S, Mao H, Dally W J. Deep compression: Compressing deep neural networks with pruning, trained quantization and huffman coding[J]. arXiv preprint arXiv:1510.00149, 2015.
[18] Ji Q, Zhu Z, Lan P. Real-time nonintrusive monitoring and prediction of driver fatigue[J]. IEEE transactions on vehicular technology, 2004, 53(4): 1052-1068.
[19] Breckon T P, Barnes S E, Eichner M L, et al. Real-time eye state classification for driver drowsiness detection[J]. Machine Vision Applications, 2011, 22(5): 857-866.
[20] Google. TensorFlow Lite Documentation[EB/OL]. https://www.tensorflow.org/lite, 2023.