SHIT Sciences Humanities Information Technology

Open Access
Governance Proposal
Received 20th February 2026,
Accepted 26th February 2026

S.H.I.T. 治理公约 1.0：基于博弈论与鲁棒统计的学术去中心化自治框架

Dr. Jacob · 阿波[1,*]

[1]Institute of Romantic Operations Research & Emotional Analytics, Northwestern University

[*] Jacoblian@u.northwestern.edu

本文为 S.H.I.T. 期刊设计一套去中心化的学术治理公约。**模块一**基于 Shapley 值建立贡献度量化模型，以可加分解实现 $O(1)$ 计算，配合指数衰减与平方根压缩将话语权绑定于持续的学术输出而非身份地位。**模块二**提出 S.H.I.T. 分数算法，以对数阅读量（20%）、加权中位数评分（65%）与争议校正（15%）为核心，稿件达到动态 Top 10% 百分位后触发三人审稿；审稿人拥有受约束的一票否决权；格式修订通道不重置已有社区数据。**模块三**设计三层递进举报协议（5 人审核、10 人隐藏），辅以基于中位数绝对偏差（MAD）的恶意评分检测与降权机制。**模块四**构建声誉代币激励闭环与三级弹性降级方案，保证低算力环境下系统可持续运行。所有机制均给出数学模型与公正性论证，不依赖 AI 决策。

Abstract: We propose a decentralized governance covenant for the S.H.I.T. Journal comprising four modules: (1) Shapley-value contribution metrics with exponential decay; (2) a robust S.H.I.T. Score with dynamic percentile thresholds, three-reviewer protocol, and format-revision channels; (3) a tiered conflict-resolution mechanism with MAD-based malicious rating detection; (4) a reputation-token incentive framework with elastic degradation. All mechanisms are mathematically specified and human-governed.

Keywords: 去中心化治理; 博弈论; 鲁棒统计; 学术评价; Shapley 值; 社区自治; 声誉系统; 争议检测

1 引言

1.1 背景与动机

传统学术出版以 ``编辑部 + 匿名审稿'' 的双重代理结构实现质量控制。该结构有效运行了数十年，但也积累了三个系统性缺陷。其一，**激励不相容**：审稿人无偿劳动，导致审稿质量参差不齐且周期漫长。其二，**权力集中**：编辑部的接稿与拒稿决策构成不可审计的黑箱。其三，**身份偏见**：来自高声望机构的投稿在评审中系统性地获得更宽容对待。

S.H.I.T. 期刊的社会实验提出一个根本问题：能否用透明的数学规则替代中心化的编辑权力？本文尝试给出一个完整的技术方案。

1.2 设计原则

公理 1.1 (质量主权)**.** 话语权的唯一来源是可验证的学术输出质量——发表质量、审稿质量、评分深度——而非身份、资历或社交关系。

公理 1.2 (透明可审计)**.** 所有评价规则与阈值均为确定性公式，任何成员可独立验算。

公理 1.3 (统计鲁棒)**.** 系统对恶意行为（刷分、恶意差评、灌水）须具备数学意义上的抵抗力，而非依赖事后人工干预。

公理 1.4 (最小管理员)**.** 管理员仅在算法触发时被动介入，不主动行使编辑权力。

1.3 符号

$\mathcal{U} = \{u_1, \ldots, u_N\}$：用户集。$\mathcal{P} = \{p_1, \ldots, p_M\}$：稿件集。$r_{uj} \in [1, 5]$：用户 u 对稿件 p_j 的评分。$\mathcal{R}_j$：稿件 p_j 的评分者集合。V_j：稿件 p_j 的阅读量。$\Phi_u(t)$：时刻 t 用户 u 的声誉值。

2 模块一：贡献度量化

2.1 目的

本模块解决 ``谁的评价应当更有份量'' 这一核心问题。传统体系隐式地以职称、机构等身份指标回答，这既不透明也不公正。本模块要求：**权重必须完全由可观测的行为数据推导**，且推导过程对所有人透明。

2.2 行为空间

定义 2.1 (行为向量)**.** 用户 u 在时间窗 $\mathcal{T}_k$ 内的行为：

$$\mathbf{a}_u^{(k)} = \left(n_u^{\text{pub}},\ n_u^{\text{rev}},\ \bar{q}_u^{\text{rev}},\ n_u^{\text{rate}},\ \bar{d}_u^{\text{rate}}\right) \tag{1}$$

分别为：发表篇数、审稿篇数、审稿质量均分（由被审作者与社区反评确定）、评分次数、评分深度均值（以评语字数衡量）。

选择这五个维度的理由：n_u^{pub} 衡量知识创造；$n_u^{\text{rev}}\bar{q}_u^{\text{rev}}$ 同时衡量审稿数量与质量，避免 ``只求数量、敷衍了事''；$n_u^{\text{rate}}\bar{d}_u^{\text{rate}}$ 对评分行为做同样处理。五个维度覆盖了平台上全部有价值的学术行为。

2.3 *Shapley* 值与可加分解

定义 2.2 (价值函数)**.**

$$v(S) = \sum_{j:\text{author}(p_j)\in S} \text{Score}(p_j) + \lambda_r \sum_{u\in S} n_u^{\text{rev}}\bar{q}_u^{\text{rev}} + \lambda_e \sum_{u\in S} n_u^{\text{rate}}\bar{d}_u^{\text{rate}} \tag{2}$$

其中 $\lambda_r = 1.5$，$\lambda_e = 0.3$。$\lambda_r > \lambda_e$ 反映审稿的劳动强度与责任高于普通评分。

Shapley 值是合作博弈中唯一满足效率性、对称性、虚拟玩家和可加性四条公理的分配方案 [1]。由于 v 具有可加结构，每位用户的 Shapley 值可精确分解为：

$$\phi_u = \underbrace{\sum_{j:\text{author}(p_j)=u} \text{Score}(p_j)}_{\text{创作}} + \underbrace{\lambda_r\, n_u^{\text{rev}}\bar{q}_u^{\text{rev}}}_{\text{审稿}} + \underbrace{\lambda_e\, n_u^{\text{rate}}\bar{d}_u^{\text{rate}}}_{\text{评分}} \tag{3}$$

这一分解至关重要：它使计算复杂度从 $O(2^N)$ 降至 $O(1)$（对单个用户），使系统可在任意规模的社区中实时运行。

2.4 时间衰减

为防止 ``一劳永逸''——早期贡献者长期不活跃仍占据高话语权——引入指数衰减：

定义 2.3 (衰减声誉)**.**

$$\Phi_u(t) = \sum_{k=1}^{t} e^{-\lambda_d(t-k)}\,\phi_u^{(k)}, \quad \lambda_d = 0.1/\text{月} \tag{4}$$

$\lambda_d = 0.1$ 对应半衰期约 7 个月，在 ``尊重历史贡献'' 与 ``鼓励持续活跃'' 之间取得平衡。

命题 2.1 (有界性)**.** $\Phi_u(t) \le \max_k \phi_u^{(k)}/(1-e^{-\lambda_d})$，声誉有上界，不会无限膨胀。

2.5 话语权映射

定义 2.4 (权重)**.**

$$w_u = \frac{\Phi_u^{\alpha}}{\sum_{v\in\mathcal{U}} \Phi_v^{\alpha}}, \quad \alpha = 0.5 \tag{5}$$

$\alpha = 0.5$（平方根压缩）的作用：若用户 A 声誉是 B 的 4 倍，A 的权重仅为 B 的 2 倍。这抑制了头部集中，保护中等贡献者的话语权。

定理 2.2 (公正性)**.** 话语权满足：*(i)* 零贡献 $\Rightarrow$ 零权重；*(ii)* 等贡献 $\Rightarrow$ 等权重（*Shapley* 对称性）；*(iii)* 权重随贡献单调递增但边际递减（$x^{0.5}$ 凹性）。

新人冷启动： 新用户 $\Phi_u(0) = 0$。前 5 次评分以基础权重 $w_0 = 1/N$ 参与，第 6 次起切换为声誉权重。新用户提交稿件不受限制。

3 模块二：见刊判定

3.1 目的与流程

本模块回答 ``一篇稿件何时从预印本转为正式发表''。核心设计理念：**社区评价做初筛，审稿人做终审**。社区负责广泛的质量信号采集，审稿人负责专业判断。两者缺一不可但职责分明。

稿件生命周期：提交 $\rightarrow$ 发酵池（接受社区阅读与评分）$\rightarrow$S.H.I.T. 分数达到动态阈值时触发审稿人评审 $\rightarrow$ 满足全部条件后见刊。

3.2 *S.H.I.T.* 分数

定义 3.1 (S.H.I.T. 分数)**.**

$$\boxed{\text{Score}(p_j) = 0.20\cdot R(p_j) + 0.65\cdot E(p_j) - 0.15\cdot C(p_j)} \tag{6}$$

权重分配的理由：评分（65%）占主导，因为它是质量的最直接信号；阅读量（20%）提供曝光度补充，但不应主导（否则标题党占优）；争议（15%）作为扣分项，惩罚存在实质性低分聚集的稿件。

3.2.1 阅读量分 $R(p_j)$

$$R(p_j) = \frac{\ln(1+V_j)}{\max_{p\in\mathcal{P}_{\text{active}}} \ln(1+V_p)}, \quad R\in[0,1] \tag{7}$$

使用对数变换的原因：原始阅读量分布通常严重右偏。对数变换将 1000 次与 100 次阅读的差距从 10:1 压缩至约 1.4:1，给小众优质稿件公平的曝光信用。

3.2.2 评分分 $E(p_j)$

定义 3.2 (加权中位数评分)**.**

$$E(p_j) = \frac{1}{5}\,\text{WeightedMedian}\big(\{r_{uj}\}_{u\in\mathcal{R}_j^*},\ \{w_u^*\}_{u\in\mathcal{R}_j^*}\big) \tag{8}$$

为什么用中位数而非均值？ 均值对极端值高度敏感：10 人评分中 1 人给 1 星即可将均值拉低 0.4 分。中位数的崩溃点为 50%——即使 49% 的评分者恶意操纵，中位数仍反映多数人的真实判断。加权中位数进一步将权重绑定于声誉。

计算方法：将评分按大小排序，逐步累加对应权重，取累积权重首次 ≥ 0.5 时的评分值。

3.2.3 恶意评分检测与降权

在计算 E 和 C 之前，需先过滤恶意评分。

定义 3.3 (恶意判定——双条件触发)**.** 用户 u 对稿件 p_j 的评分被标记为疑似恶意，当且仅当**同时**满足：

条件一（历史模式）：$\bar{r}_u \le 2.5$，即该用户历史平均给分低于 2.5。

条件二（单次偏离）：$|r_{uj} - \tilde{r}_j| > 2.5\cdot\text{MAD}_j$，其中 $\tilde{r}_j$ 为该稿件全体评分的中位数，$\text{MAD}_j = \text{med}_{u\in\mathcal{R}_j}|r_{uj}-\tilde{r}_j|$。

双条件设计的理由： 仅看条件一会误伤评价严格但诚实的用户；仅看条件二会误伤对个别差稿给出合理低分的正常用户。两者同时满足才构成 ``持续性恶意低评'' 的证据。

为什么用 MAD? 标准差本身受离群值影响——一个恶意 1 星拉大 σ，反而使该 1 星看起来 ``不那么异常''。MAD 的崩溃点为 50%，不受少数极端值干扰 [3,4]。$k = 2.5$ 在正态假设下等价于 $\approx 3.7\sigma$，假阳性率 $< 0.02\%$。

定义 3.4 (降权规则)**.**

$$w_u^* = \begin{cases} 0 & \bar{r}_u \le 2.0 \text{ 且 } r_{uj} = 1 \\ 0.1 \cdot w_u & 2.0 < \bar{r}_u \le 2.5 \\ w_u & \text{其他} \end{cases} \tag{9}$$

有效评分者集合 $\mathcal{R}_j^* = \{u \in \mathcal{R}_j : w_u^* > 0\}$。

分级降权的理由：$\bar{r}_u \le 2.0$ 且给 1 星是极端恶意的强信号，直接清零；$\bar{r}_u \in (2.0, 2.5]$ 可能是严格用户也可能是温和恶意，保留 10% 权重作为 ``疑罪从轻''；正常用户不受影响。

3.2.4 争议系数 $C(p_j)$

在过滤后的 $\mathcal{R}_j^*$ 上计算：

定义 3.5 (争议系数)**.**

$$C(p_j) = \frac{\mathrm{MAD}_j^*}{\tilde{r}_j^* + 0.1} \cdot \min\Big(1,\ \frac{f_j^{\text{low}}}{0.3}\Big) \tag{10}$$

其中 f_j^{low} 为有效评分者中给 ≤ 2 分的比例。右侧截断项确保：只有当 >30% 的有效评分者给出低分时，争议才产生显著罚分。单纯的 ``4 分 vs5 分'' 学术分歧不会被惩罚。

3.3 动态阈值与审稿触发

定义 3.6 (晋升阈值)**.**

$$\theta(t) = \mathrm{Percentile}_{90}\big(\{\mathrm{Score}(p) : p \in \mathcal{P}_{\text{active}}(t)\}\big) \tag{11}$$

$\mathrm{Score}(p_j) \ge \theta(t)$ 时自动触发审稿人评审。

为什么用动态百分位而非固定分数线？ 固定阈值（如 ≥ 4.0）在社区初期可能无稿达标，在成熟期可能大量过关。动态 Top 10% 保证：(a) 任何时期恰有约 10% 的稿件获得审稿机会，维持 ``见刊'' 的稀缺性；(b) 社区质量提升时阈值自动升高。

3.4 审稿人评审协议

协议 3.1 (三人评审制)**.**
1. 人数与选拔。每篇分配 $K = 3$ 名审稿人。两人易出现 1:1 僵局，四人以上的边际信息增益不足以补偿协调成本。审稿人从声誉排名前 25% 的活跃用户中随机抽取，需满足：(a) 非该稿作者；(b) 与作者无共同发表；(c) 30 天内未审过同一作者。
2. 评审维度。每位审稿人独立给出：学术质量分 $Q_{uj}^{\text{acad}} \in [1, 5]$；格式合规 $Q_{uj}^{\text{fmt}} \in \{0, 1\}$；总体推荐（接受/小修/格式修订后重提交/拒绝）；文字报告（≥200 字）。
3. 一票否决权。任一审稿人可行使否决，但须附 ≥50 字的明确理由，说明具体的学术问题或违规事项。否决触发后，另两名审稿人独立复核：若二者均认为否决不合理，否决被推翻（2:1 多数原则）。
4. 综合评审分。$Q_j = \frac{1}{3}\sum_{k=1}^{3} Q_{u_k j}^{\text{acad}}$，等权平均。

否决权设 50 字下限的理由： 否决是对一篇稿件的最强否定，必须给出可供复核的具体依据。50 字足以阐明一个核心问题（如 ``第 3 节的证明存在循环论证，定理 2 的条件未验证充分性''），同时不构成过高的表达门槛。

审稿人综合占比的限制： 审稿人以 ``通过/不通过''（$Q_j \ge 3.0$）的形式参与见刊判定，而非以连续分数覆盖 S.H.I.T. 分数。社区评分决定 ``谁有资格接受审稿''，审稿人确认 ``确实值得发表''。

3.5 见刊四条件

定义 3.7 (见刊判定)**.** 稿件 p_j 获已见刊状态当且仅当同时满足：

(G1)	$\mathrm{Score}(p_j) \ge \theta(t)$	(社区门槛)
(G2)	$Q_j \ge 3.0$	(审稿人门槛)
(G3)	无未被推翻的否决	(否决检查)
(G4)	$\sum_{k=1}^{3} Q_{u_k j}^{\text{fmt}} \ge 2$	(格式合规)

3.6 格式修订通道

协议 3.2 (格式修订)**.** 当稿件通过 (G1)(G2)(G3) 但不满足 (G4) 时：
1. 审稿人给出格式修改要求。
2. 作者通过系统重新提交通道上传修订版。
3. **重新提交不重置该稿件的阅读量、评分与 S.H.I.T. 分数**。仅更新文档内容。
4. 标记不合规的审稿人中 ≥1 人复核。合规后直接见刊。
5. 30 天未提交修订则回退发酵池，保留全部数据。

不重置数据的理由：格式问题不影响学术质量判断。社区评分反映的是内容价值，不应因排版修正而归零。

3.7 抗操纵性

定理 3.1 (抗操纵性)**.** 设恶意占比 $\le 40\%$ 且全部给 *1* 星，则：*(a)* $E(p_j)$ 偏移 $= 0$（恶意者清零后不影响中位数）；*(b)* 争议罚分增量 ≤ 0.15；*(c)* 总 *Score* 偏移 ≤ 0.0225。

证明. (a) $\bar{r}_u \le 2.0$ 且 $r_{uj} = 1$ 时 $w_u^* = 0$。(b) $C \le 1$ 乘 $w_C = 0.15$。(c) 仅 C 项变化。□

4 模块三：冲突解决

4.1 目的

本模块处理人身攻击、敏感内容与恶意灌水。设计难点在于：学术批评（即使措辞激烈）必须被保护，而人身攻击必须被清除。本模块的方案是**不预设内容标准，而用举报人数作为社区共识的代理指标**，由管理员做最终裁决。

4.2 三层举报协议

定义 4.1 (三层递进)**.** 设 $F(t)$ 为某条内容截至 t 的独立举报人数。

第一层（$F < 5$）：记录但不行动。原因：少数人的举报不应触发限制，否则举报机制本身会成为打压异见的工具。

第二层（$5 \le F < 10$）：内容自动转入管理员审核队列，标记 “待审” 但仍可见。管理员在 72 小时内完成审核。

第三层（$F \ge 10$）：内容自动隐藏，仅管理员可见。管理员裁决三选一：恢复展示（无违规）；确认删除并惩罚发布者；要求修改后重新展示（部分违规）。

阈值选择的依据： $N = 100$ 社区中，若举报为独立随机事件、单人恶意举报率 $q = 0.03$，则 $P(F \ge 5) < 0.015$，$P(F \ge 10) < 10^{-5}$。两个阈值在灵敏度与误报率之间取得合理平衡。

4.3 管理员约束

管理员仅在第二、三层被触发时介入，**不得主动删改内容**。每次裁决记录公开，社区可发起**申诉投票**（≥20 人发起，简单多数通过即推翻裁决）。

4.4 灌水检测

定义 4.2 (灌水标记（满足任一即触发）).

$$\text{(W1)}\ \ n_u^{\text{comm}}(\Delta t) > \mu_c + 3\sigma_c \qquad \text{(频率异常)}$$

$$\text{(W2)}\ \ \text{平均长度} < 20\text{字} \ \wedge\ n_u^{\text{comm}} > 10 \qquad \text{(低质高频)}$$

$$\text{(W3)}\ \ \text{重复率} > 0.5 \qquad \text{(大量重复)}$$

(W1) 基于 3σ 原则，正常行为超过此阈值的概率 <0.3%。(W2) 捕捉 ``大量发送无实质内容短消息''。(W3) 中重复率为用户评论与自身历史评论 Jaccard 相似度 > 0.8 的比例。被标记用户自动降频：每小时评论上限 3 条，持续 7 天。

5 模块四：资源配置

5.1 目的

去中心化系统面临的最大长期风险不是恶意攻击，而是**参与不足**。本模块通过代币激励解决 ``公地悲剧''，通过弹性降级解决 ``资源枯竭''。

5.2 嗅探积分（*SHIT Token*）

定义 5.1 (铸造与销毁).

$$\text{见刊论文：}\ +50\ \text{ST} \qquad \text{完成审稿：}\ +20\ \text{ST} \tag{12}$$

$$\text{有效评分（}\geq\text{50 字）：}\ +3\ \text{ST} \qquad \text{有效举报：}\ +5\ \text{ST} \tag{13}$$

$$\text{确认恶意行为：}\ -30\ \text{ST} \tag{14}$$

数值逻辑：见刊论文（+50）最高，是社区核心价值输出；审稿（+20）次之，反映劳动强度；评分/举报较低但非零，确保日常维护有激励。代币不可交易，纯粹反映学术贡献。用途包括审稿人资格门槛、社区投票权、初始曝光优先级、荣誉徽章。

命题 5.1 (供需平衡). 月见刊 P 篇，月铸造 $\approx 140P$ *ST*，月销毁 $\approx 1.5N$ *ST*。$N = 1000, P = 20$ 时 $2800 \gg 1500$，系统可持续。

5.3 三级弹性降级

L1（正常）：全模块实时运行。**L2（节能，负载 >70%）：**Shapley 值每日批量；争议系数每 6 小时；MAD 阈值放宽至 $k = 3.0$。**L3（生存，负载 >90%）：**暂停自动计算，分数冻结，审稿暂停，举报纯人工。恢复后批量重算。

L1 下单次评分触发的计算量 $O(|\mathcal{R}_j| \log |\mathcal{R}_j| + |\mathcal{P}_{\text{active}}|)$。$|\mathcal{R}_j| \leq 200$、$|\mathcal{P}_{\text{active}}| \leq 5000$ 时 $< 1\,\text{ms}$，可在低配服务器运行。

6 系统流程与极端场景

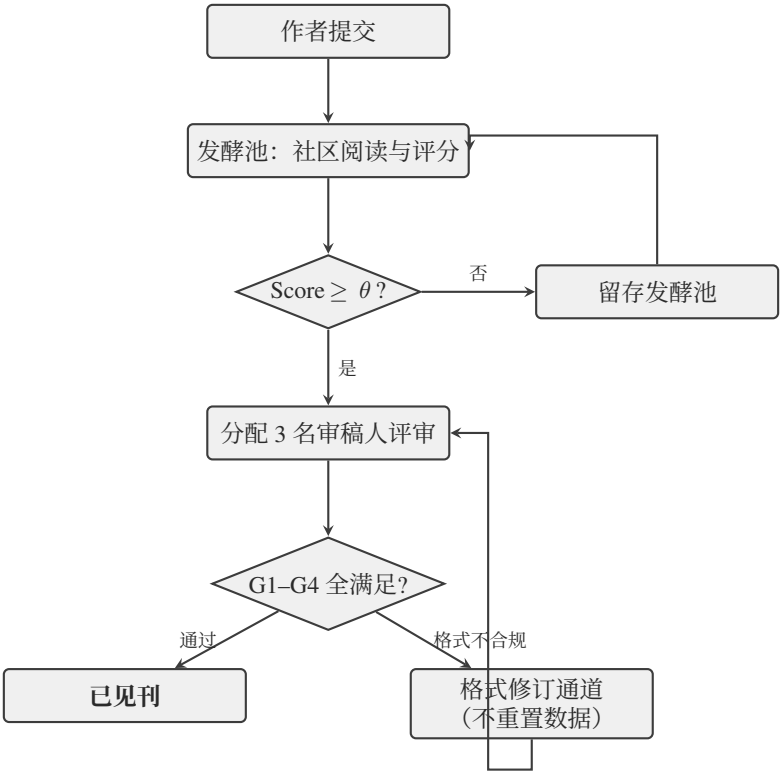

Figure 1: 稿件生命周期流程图。

串谋刷高分：m 人联合给某稿 5 星。加权中位数在串谋者 <50% 有效评分者时不受影响；新号声誉低，权重极小；高声誉者串谋需牺牲长期积累，成本远超收益。

审稿人合谋否决：审稿人从前 25% 中随机抽取，合谋需预知分配；利益回避规则排除关联；否决理由公开，低质否决损害自身声誉；被否决稿可重新入池。

举报武器化：5 人阈值使少数人无法触发审核；管理员裁决公开可追责；申诉投票可推翻不当裁决。

7 参数总表

Table 1: 核心参数。均可由社区投票调整。

参数	值	说明
λ_r，λ_e	1.5, 0.3	审稿/评分贡献权重
λ_d	0.1/月	声誉半衰期 ≈7 月
α	0.5	话语权压缩指数
w_R，w_E，w_C	.20, .65, .15	Score 权重
阈值	Top 10%	动态百分位
K	3	审稿人数
$Q_{\min}$	3.0	审稿通过线
否决字数	≥50	最低理由字数
$\bar{r}_{\text{th}}$	2.5 / 2.0	软/硬恶意阈值
k (MAD)	2.5	$\approx 3.7\sigma$
η	0.1	软降权系数
F_1，F_2	5, 10	审核/隐藏触发
奖励	50/20/3/5 ST	见刊/审/评/举报
惩罚	−30 ST	确认恶意
L2/L3	70%/90%	降级触发负载

8 结论

本文为 S.H.I.T. 期刊设计了一套完整的去中心化治理公约。

第一，**贡献度量的可计算公正性**。Shapley 值的可加分解使计算从 $O(2^N)$ 降至 $O(1)$，指数衰减阻止历史积累的固化，平方根压缩抑制头部集中。话语权完全由行为数据推导，不接受身份输入。

第二，**见刊判定的双层筛选**。S.H.I.T. 分数基于鲁棒统计量（加权中位数、MAD 检测），对恶意操纵具有数学证明的抵抗力。动态百分位阈值自适应社区规模。三人审稿制提供专业判断，否决权受约束以防滥用。格式修订通道尊重已有社区评价。

第三，**可持续的自治生态**。代币激励将公共品维护内化为个人收益，三层举报将管理员限定为被动角色，弹性降级保证极端条件下系统存活。

让规则透明，让数学公正，让社区自治。

参考文献

[1] Shapley, L.S. A Value for n-Person Games. *Contributions to the Theory of Games II*, Ann. Math. Studies **28**, Princeton, **1953**, 307--317.

[2] Myerson, R.B. *Game Theory: Analysis of Conflict*. Harvard Univ. Press, **1991**.

[3] Huber, P.J. Robust Estimation of a Location Parameter. *Ann. Math. Statist.* **1964**, *35*(1), 73--101.

[4] Hampel, F.R. The Influence Curve and Its Role in Robust Estimation. *JASA* **1974**, *69*, 383--393.

[5] Ostrom, E. *Governing the Commons*. Cambridge Univ. Press, **1990**.

[6] Roth, A.E. The Shapley Value as a von Neumann--Morgenstern Utility. *Econometrica* **1977**, *45*(3), 657--664.

[7] Buterin, V.; Hitzig, Z.; Weyl, E.G. A Flexible Design for Funding Public Goods. *Manag. Sci.* **2019**, *65*(11), 5171--5187.

[8] Rousseeuw, P.J.; Croux, C. Alternatives to the Median Absolute Deviation. *JASA* **1993**, *88*, 1273--1283.