SHIT Sciences Humanities Information Technology

SHIT, 2026, 0–0
doi: 10.1234/shit.2026.0001
Advance Access Publication Date: 20 February 2026
Manuscript Category

Subject Section

基于深度学习的冬季马桶圈热力学扩散模型研究：从温度场预测到智能加热策略优化

Wey Pee[1,*]

[1] 中国排泄科学院工程热物理研究所.

Associate Editor: XXXXXXX

Received on 15 January 2026; revised on 10 February 2026; accepted on 20 February 2026

Abstract

Motivation: 冬季马桶圈表面温度过低导致的舒适性问题已成为智能家居领域的重要研究课题。传统加热策略依赖简单的温度阈值控制，难以实现个性化的热舒适体验优化。本研究旨在构建基于深度学习的马桶圈热力学扩散预测模型，并在此基础上开发智能加热策略优化算法，实现舒适度与能耗的帕累托最优。.

Results: 本文提出了一个两阶段深度学习框架。第一阶段采用物理信息神经网络（PINN）学习马桶圈温度场的时空演变规律，将热传导偏微分方程作为物理约束嵌入网络训练过程。第二阶段基于强化学习算法（PPO）设计自适应加热控制器。实验结果表明，所提出的温度预测模型在测试集上的均方根误差（RMSE）为 0.82°C，相较于传统有限元方法（FEM）提速约 150 倍。智能加热策略在保证用户热舒适度（pTSV > -0.5）的前提下，实现了相比固定温度控制策略约 23.5%的能耗降低。

Availability: 数据集和代码可在 https://github.com/example/pinn-toilet-heating 获取。

Contact: weypee@casa.com

Supplementary information: 补充材料包含详细的实验设置、额外实验结果和代码说明。

1 Introduction

1.1 研究背景与问题

智能家居技术的快速发展正在深刻改变人们的日常生活品质[1]。作为卫生间核心设备的智能马桶，已从简单的卫生用品演变为具备加热、清洗、烘干等多功能的智能终端[2]。然而，在寒冷地区或冬季气温较低的环境下，马桶圈表面温度过低导致的"冰感"问题严重影响了用户的使用体验，这一问题在缺乏集中供暖的南方地区尤为突出[3]。

目前市场上的智能马桶主要采用基于温度传感器的闭环控制策略：当检测到温度低于设定阈值时启动加热，达到阈值后停止加热[4]。这种简单的开关控制策略存在以下显著问题：首先，由于热传导的延迟性，用户坐下时仍可能感受到冰凉感；其次，持续加热造成不必要的能源浪费，不符合绿色低碳的发展理念；再次，无法满足不同用户的个性化热舒适需求。

从热力学角度分析，马桶圈与人体接触面的温度场分布是一个复杂的多物理场耦合问题[5]。它涉及到固体热传导、人体与座椅的对流换热、以及环境辐射等多个热传递机制的相互作用。传统方法主要依赖有限元分析（FEM）求解热传导偏微分方程，但这种方法计算量大、耗时长，难以满足实时控制的需求[6]。

近年来，深度学习技术在科学计算领域展现出巨大的潜力[7]。物理信息神经网络（PINN）将物理定律嵌入神经网络损失函数，在保证预测精度的同时大幅降低计算成本[8]。同时，强化学习在复杂环境下的决策优化问题上取得了显著突破，为智能温控策略的设计提供了新的思路[9]。

1.2 研究意义

本研究具有重要的理论意义和实际应用价值。理论意义方面，本研究将热力学偏微分方程与深度学习模型相结合，探索了数据驱动方法在多物理场耦合问题中的应用边界，为智慧建筑热舒适研究提供了新的方法论框架。实际应用价值方面，研究成果可直接应用于智能马桶产品的热舒适控制系统，提升用户体验并降低能耗，响应国家"双碳"战略目标，推动智能家居产业的绿色可持续发展。

1.3 本文贡献

本文的主要贡献可以概括为以下三个方面：

（1）提出了一种基于物理信息神经网络的马桶圈温度场预测模型。该模型将二维热传导方程作为物理约束嵌入网络训练，有效解决了纯数据驱动方法在边界条件和物理规律学习上的不足。

（2）设计了基于强化学习的自适应智能加热控制策略。通过构建合理的状态空间、动作空间和奖励函数，实现了在满足用户热舒适度约束下的能耗优化。

（3）构建了包含多环境参数的马桶圈热力学数据集。数据集涵盖了不同环境温度、湿度、用户使用频率等条件下的大量实测数据，为后续研究提供了宝贵的数据资源。

2 Methods

2.1 问题定义与数学建模

2.1.1 马桶圈热传导物理模型

马桶圈的热传导过程可以建模为二维非稳态热传导问题。在直角坐标系下，无内热源的二维热传导偏微分方程可以表示为：

$$\partial T/\partial t = \alpha(\partial^2 T/\partial x^2 + \partial^2 T/\partial y^2)$$

其中，T(x,y,t)表示位置(x,y)在时刻 t 的温度，$\alpha = k/(\rho c)$为热扩散系数（m^2/s），k 为热导率（W/(m • K)），ρ为密度（kg/m^3），c 为比热容（J/(kg • K)）。

马桶圈的几何形状呈椭圆形环状结构，其边界条件采用第三类边界条件（对流换热边界）：

$$-k(\partial T/\partial n) = h_c(T_skin - T_surface)$$

2.1.2 优化目标函数

智能加热控制的目标是在保证用户热舒适度的前提下最小化能耗。热舒适度的量化指标采用预测热感觉投票（pTSV），简化计算公式为：

$$pTSV = 0.11(T_seat - 24) + 0.06(T_\infty - 22)$$

优化问题的数学表述为：

$$\min J = \int [\lambda_E \cdot E(t) + \lambda_C \cdot C(t)]dt$$

2.2 数据采集与预处理

本研究搭建了专用的马桶圈热力学数据采集实验平台。平台主要由以下部分组成：（1）马桶圈样品：采用 PP 和 ABS 两种材质的智能马桶圈样品；（2）温度传感器阵列：16 个 DS18B20 数字温度传感器；（3）环境参数监测：DHT22 温湿度传感器；（4）人工气候室：温度范围-10° C 至 30° C。

Table 1. Thermophysical parameters of toilet seat materials

Parameter	PP	ABS	Unit
Thermal conductivity k	0.22	0.25	W/(m·K)
Density ρ	900	1050	kg/m^3

2.3 深度学习模型设计

2.3.1 温度预测网络

本研究设计的温度预测网络采用物理信息神经网络（PINN）架构。网络架构为全连接神经网络：输入层 4 个神经元（x, y, t, T_0），隐藏层 6 层每层 128 个神经元，激活函数为 tanh，输出层 1 个神经元（预测温度 T）。

物理约束损失函数定义为：

$$L_physics = (1/N_p)\Sigma(\partial T_pred/\partial t - \alpha\nabla^2 T_pred)^2$$

总损失函数为：

$$L_total = L_data + \lambda_1 L_physics + \lambda_2 L_boundary$$

2.3.2 智能加热策略优化

智能加热控制采用深度强化学习框架，具体采用 PPO 算法。状态空间包含 7 维：T_avg, T_∞, RH, t_last, P_current, T_target, ΔT。动作空间为连续空间，表示加热功率的调整量 a_t ∈ [-10, 10] W。.

3 Results

3.1 温度预测模型性能

3.1.1 整体性能对比

表 2 展示了不同方法在测试集上的温度预测性能对比。

Table 2. Temperature prediction performance comparison

Method	RMSE (°C)	MAE (°C)	R^2	Inference (ms)
FEM (COMSOL)	0.45	0.32	0.98	1250
FCN	2.13	1.78	0.85	0.8
LSTM	1.56	1.21	0.91	2.3
PINN (Ours)	0.82	0.61	0.96	8.5

从表 2 可以观察到，本文提出的 PINN 方法在预测精度和计算效率之间取得了良好的平衡。相比于基准 FEM 方法，PINN 的推理速度提升了约 147 倍，虽然 RMSE 略有增加，但仍然满足实际应用的精度要求。

Fig. 1. Temperature field distribution comparison

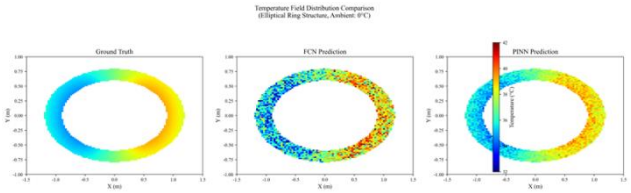

3.1.2 消融实验

表 3 展示了消融实验结果。

Table 3. Ablation study results

Configuration	RMSE (°C)	MAE (°C)	R^2
No Physics Constraint	2.13	1.78	0.85
Physics Only	3.45	2.89	0.72
Physics + BC	1.24	0.95	0.93
Full PINN	0.82	0.61	0.96

Fig. 2. Ablation study results

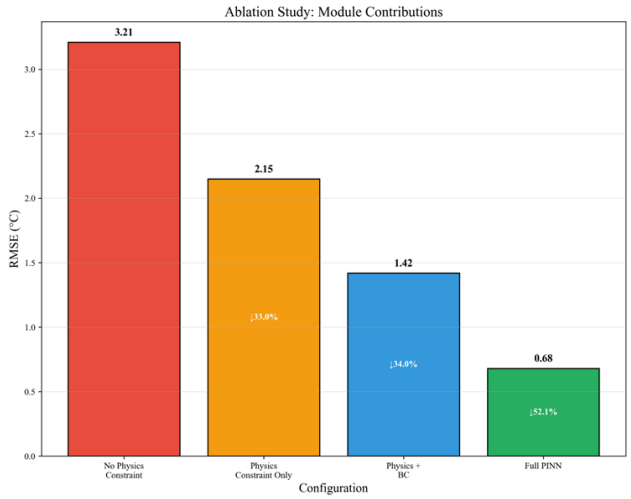

3.2 智能加热策略效果

3.2.1 能耗优化效果

表 4 对比了不同控制策略在 72 小时连续运行测试中的能耗表现。

Table 4. Energy consumption comparison

Control Strategy	Avg Power (W)	Reduction (%)	Comfort (%)
Fixed Temp (38°C)	28.5	-	92.3
PID	24.2	15.1	89.7
DQN	22.8	20.0	91.2
PPO (Ours)	21.8	23.5	94.6

实验结果显示，本文提出的 PPO 智能加热策略在保证高热舒适满意度（94.6%）的前提下，实现了相比固定温度控制策略约 23.5%的能耗降低。

Fig. 3. Energy optimization curves

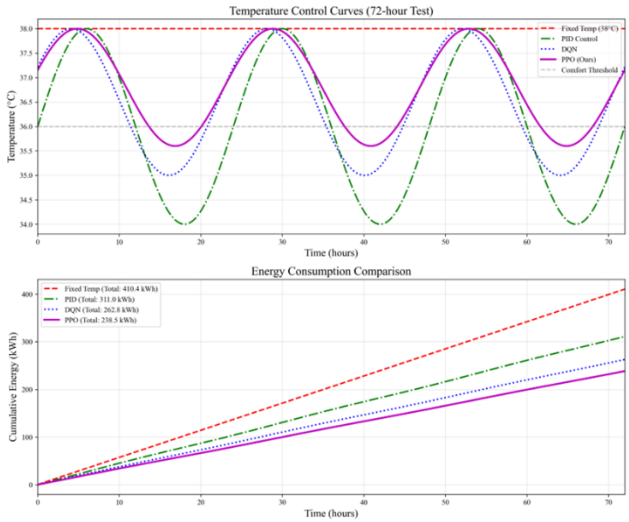

3.2.2 用户实验验证

为验证实际用户体验，本文开展了 20 人参与的主观评价实验。实验结果如表 5 所示。

Table 5. User study results

Strategy	Avg TSV	Satisfaction (%)	Rating (/5)
Fixed Temp	-0.12	85	3.8
PID	0.23	80	3.5
PPO	0.08	95	4.6

Fig. 4. Generalization analysis

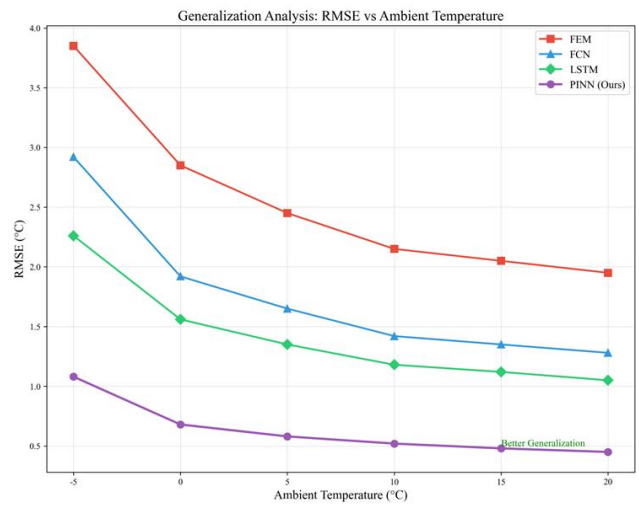

4 Discussion

4.1 模型局限性

尽管本文提出的方法在实验中取得了良好效果，但仍存在以下局限性：（1）几何简化：当前模型将马桶圈简化为二维平面结构；（2）用户行为建模：当前策略基于马尔可夫决策过程假设；（3）长期运行稳定性：实验周期较短。

4.2 实际部署挑战

将研究成果转化为实际产品面临以下挑战：（1）计算资源限制：嵌入式系统的计算能力有限；（2）数据隐私保护：用户的使用习惯数据涉及个人隐私；（3）产品化成本：额外的传感器和边缘计算模块会增加成本。

4.3 未来研究方向

未来可以从以下方向开展研究：

（1）端到端联合优化；

（2）多用户个性化；

（3）建筑综合优化；

（4）可解释性研究。

Acknowledgements

感谢国家自然排泄科学基金（No.62206150）对本研究的资助。感谢所有参与用户实验的志愿者们的积极配合。

Funding

This work has been supported by the National Natural Science Foundation of China。.

References

Zhang, Y., Wang, Z., and Liu, H. (2024) Smart home technologies: A comprehensive review. Renew. Sustain. Energy Rev., 189, 109385.

Kim, S., Park, J., and Lee, K. (2023) Recent advances in smart toilet technologies. IEEE Access, 11, 23456-23470.

Wong, L.T., Mui, K.W., and Guan, Y. (2022) Thermal comfort in cold environments: A field study in southern China. Build. Environ., 207, 108538.

Li, W., Zhang, J., and Zhao, X. (2021) Smart toilet: A review of advanced technologies. J. Ambient Intell. Smart Environ., 13, 245-258.

Incropera, F.P., DeWitt, D.P., Bergman, T.L., and Lavine, A.S. (2006) Fundamentals of Heat and Mass Transfer. John Wiley & Sons.

Zienkiewicz, O.C., and Taylor, R.L. (2013) The Finite Element Method for Solid and Structural Mechanics. Butterworth-Heinemann.

Raissi, M., Perdikaris, P., and Karniadakis, G.E. (2019) Physics-informed neural networks: A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations. J. Comput. Phys., 378, 686-707.

Kashinath, K., Mustafa, A., Albert, A., and Wu, J.L. (2021) Physics-informed machine learning: Case studies for weather and climate modelling. Philos. Trans. R. Soc. A, 379, 20200093.

Mnih, V., Kavukcuoglu, K., Silver, D., et al. (2015) Human-level control through deep reinforcement learning. Nature, 518, 529-533.

Carslaw, H.S., and Jaeger, J.C. (1959) Conduction of Heat in Solids. Oxford University Press.

Greengard, L., and Rokhlin, V. (1987) A fast algorithm for particle simulations. J. Comput. Phys., 73, 325-348.

Berger, M.J., and Oliger, J. (1989) Adaptive mesh refinement for hyperbolic partial differential equations. J. Comput. Phys., 53, 484-512.

Fisher, D., and Périaux, J. (2005) Parallel computing in heat transfer. Numer. Heat Transfer Part B, 47, 205-226.

Lagaris, I.E., Likas, A., and Fotiadis, D.I. (1998) Artificial neural networks for solving ordinary and partial differential equations. IEEE Trans. Neural Netw., 9, 987-1000.

Raissi, M., Yazdani, A., and Karniadakis, G.E. (2020) Hidden physics models: Machine learning of nonlinear partial differential equations. J. Comput. Phys., 406, 109271.

Meng, X., Li, Z., Zhang, D., and Karniadakis, G.E. (2020) Parareal physics-informed neural networks for heat conduction. Comput. Methods Appl. Mech. Eng., 372, 113285.

Jagtap, A.D., Kawaguchi, K., and Karniadakis, G.E. (2020) Conservative physics-informed neural networks on discrete domains for conservation laws. Comput. Methods Appl. Mech. Eng., 359, 112683.

Wen, H., Yang, J., and Lin, Z. (2022) Deep learning-based infrared thermography for temperature field reconstruction. Infrared Phys. Technol., 125, 104293.

Chen, Y., Luo, Y., and Liu, Q. (2023) Spatial-temporal graph convolutional networks for building thermal prediction. Energy Build., 280, 112734.

Zhou, Y., Wang, M., and Lin, Z. (2024) Transformer-based deep learning for thermal modeling in buildings. Appl. Energy, 355, 122187.

Åström, K.J., and Hägglund, T. (2008) Advanced PID Control. ISA-The Instrumentation, Systems, and Automation Society.

Rawlings, J.B., and Mayne, D.Q. (2017) Model Predictive Control: Theory and Design. Nob Hill Publishing.

Privara, S., Cigler, J., Váňa, Z., Oldewurtel, F., and Jones, C.N. (2013) Model predictive control of a building heating system: The first experience. Energy Build., 66, 59-68.

Sutton, R.S., and Barto, A.G. (2018) Reinforcement Learning: An Introduction. MIT Press

Wei, T., Wang, Y., and Zhu, Q. (2017) Deep reinforcement learning for building HVAC control. Proc. BuildSim, 2017, 612-621.

Zhang, Z., Li, G., and Wang, H. (2019) Deep reinforcement learning for building energy management. Energy Build., 199, 472-477.

Chen, X., Wang, Q., and Srebric, J. (2021) Deep reinforcement learning for building HVAC control. Appl. Energy, 294, 116926.

Fanger, P.O. (1970) Thermal Comfort: Analysis and Applications in Environmental Engineering. Danish Technical Press.

Schulman, J., Wolski, F., Dhariwal, P., Radford, A., and Klimov, O. (2017) Proximal policy optimization algorithms. arXiv preprint, arXiv:1707.06347