SHIT Sciences Humanities Information Technology

构石

关于GITHUB主页二次元浓度与代码缺陷密度的相关性研究——兼论性别表达多样性的调节效应

Mr.D1ck ， Yutong Chen

第一单位： Dick University(Shenzhen)

通讯方式： 91mrchen.netlify.app

摘要

Motivation: 二次元文化（动漫、游戏、萌系符号）在程序员社群中广泛流行，大量开发者在 GitHub 主页使用动漫头像、萌系昵称。这一亚文化现象是否与代码质量存在关联，尚缺乏实证证据。本研究旨在量化主页二次元浓度，探究其与代码缺陷密度的关系，并初步考察性别表达多样性的可能调节作用。

Results: 我们通过 GitHub API 随机采集 5,200 名活跃开发者的主页信息，利用图像分类与文本分析计算二次元指数（Anime Index, AI）。基于主要仓库的静态分析，统计每千行代码缺陷数（Defect Density, DD）。回归分析显示，AI 与 DD 呈显著负相关（$r = -0.37$, $p < 0.001$），即二次元浓度越高，缺陷密度越低。在控制经验、语言等变量后，效应依然稳健（$\beta = -0.21$, $p < 0.001$）。进一步探索发现，主页中隐含的性别表达多样性（如代词、简介中的相关暗示）对上述关系有正向调节作用，与先前关于亚文化技术效应的发现相呼应（魔芋 Owo, S.H.I.T,2025）。高 AI 且性别表达非传统的开发者，其缺陷密度最低。

Availability: 原始数据、模型及分析脚本已开源于 91mrchen.netlify.app 。

关键词:程序员，迪克，Yutong Chen 与 bug

1. 引言

GitHub 作为全球最大开源协作平台，不仅承载代码，也呈现着开发者多元的数字身份。近年来，二次元文化（Anime Culture）在程序员社群中蔚然成风：动漫头像、萌系昵称、满含“喵”“ovo”的个人简介比比皆是（杨等，2025）。这一现象引发学界好奇：二次元元素是否仅仅是个人趣味，还是与编程行为存在更深层的联系？

已有研究表明，开发者在线形象与技术产出存在潜在关联。Wu 等（2019）发现头像类型与用户活跃度相关；魔芋 Owo（2025）则揭示了女装频率与代码质量的 U 型关系，指出“偶尔女装”的开发者代码质量最优。后者虽以戏谑方式探讨性别表达，却触及亚文化身份如何影响技术行为的深层问题。

受此启发，本研究聚焦于二次元浓度这一更广泛的亚文化指标，系统考察其与代码缺陷密度的关系。我们假设：二次元爱好者可能将对细节、美学的追求迁移至编程中，从而写出缺陷更少的代码；同时，性别表达的多样性（如跨性别表演）作为二次元文化的常见伴生现象，可能强化这种正向效应。因此，我们提出两个研究问题：

RQ1：GitHub 主页二次元浓度与代码缺陷密度是否存在显著相关？
RQ2：性别表达多样性是否调节上述关系？

通过大规模数据采集与统计分析，本研究试图为理解程序员亚文化对技术产出的影响提供量化证据。

2. 核心概念与操作化

2.1 二次元浓度（Anime Index, AI）

二次元浓度反映开发者主页中二次元元素的丰度，由三个子维度加权合成：

头像类型：利用卷积神经网络（ResNet-50 微调）将头像分类为二次元（如动漫角色、萌系动物）或非二次元，输出概率 p_{img}。
昵称萌化度：统计昵称中二次元关键词（“喵”“酱”“碳”“sakura”“senpai”等）占比 p_{nick}。
简介二次元性：匹配简介中的二次元相关短语（“anime”“manga”“cosplay”“二次元”等），计算匹配词占比 p_{bio}

最终定义 $AI=0.5p_{img}+0.3p_{nick}+0.2p_{bio}$，并标准化至 0–100 分。

2.2 代码缺陷密度（Defect Density, DD）

选取开发者最活跃的 5 个仓库，使用 SonarQube 进行静态分析，统计所有严重等级（Blocker/Critical/Major）的缺陷数量，除以仓库有效代码行数（排除注释与空行），乘以 1000 得到每千行缺陷数。最终 DD 取各仓库的加权平均（按代码行数加权）。

2.3 性别表达多样性（Gender Expression Diversity, GED）

鉴于直接获取开发者性别信息存在伦理与技术困难，本研究采用主页中可观察的性别表达信号作为代理，包括：

简介中使用的代词（如 she/her、they/them、非传统代词）；
头像的性别模糊或跨性别特征（如伪娘/男娘风格）；
简介中提及性别相关活动（如“crossplay”“drag”）。

通过自然语言处理与图像分类（二阶段筛选）构建二元指标 $GED\in\{0,1\}$，1 表示主页呈现性别表达多样性（包含至少一个上述信号）。该变量仅作为探索性调节变量，不用于群体划分。

2.4 控制变量

经验：关注数对数、注册时长（月）；
主要编程语言（分类）；
仓库平均 star 数（对数）。

3. 方法

3.1 数据采集

通过 GitHub REST API 抽取 12,000 名活跃开发者（最近半年有 commit），过滤要求：公开仓库≥3，且至少包含一个 SonarQube 支持的语言（Java, Python, JS, TS, C#, C++）。经筛选，获得有效样本 8,743 个。

抓取数据包括：头像 URL、昵称、简介；仓库列表及代码行数；开发者关注数、注册时间、主要语言。

3.2 AI 计算

头像分类模型在测试集（2,000 张）准确率 94.7%，F1=0.93。昵称与简介匹配基于扩展关键词库（含 600 词）。计算 AI 后归一化至 0–100。

3.3 DD 计算

使用 SonarQube 社区版批量扫描仓库，排除扫描失败（依赖缺失、构建错误）的仓库。最终每个开发者平均有效仓库数 4.3 个，共 7,542 人拥有完整数据。

3.4 GED 识别

采用规则匹配与图像分类相结合：简介文本匹配代词及关键词列表；头像通过风格分类（“男性化/女性化/模糊”）及伪娘特征检测（基于特定画风识别）。人工复核随机样本显示准确率约 82%。最终 7,542 人中标记 GED=1 者占 8.2%。

3.5 统计分析

采用多元线性回归模型：

$$\log(DD+1)=\beta_0+\beta_1 AI+\beta_2 GED+\beta_3(AI\times GED)+\gamma X+\varepsilon$$

并对 AI 进行中心化处理以减少多重共线性。使用 R 4.3 进行分析。

4. 结果

4.1 描述性统计

最终分析样本 n=7,542，AI 均值 22.7（SD=19.3），DD 均值 13.4（SD=10.2），GED=1 组占比 8.2%。各变量分布见表 1。

表 1 主要变量描述性统计

变量	均值	标准差	最小值	最大值
AI	22.7	19.3	0	98
DD	13.4	10.2	0.3	91.2
log(DD+1)	2.56	0.81	0.26	4.52
关注数（对数）	2.21	1.92	0	8.34
注册时长（月）	36.5	30.1	1	172
GED (比例)	0.082	0.27	0	1

4.2 二次元浓度与缺陷密度

线性回归结果见表 2。模型 1 仅含 AI，系数显著为负（β = -0.0092, p<0.001），即 AI 每增加 1 分，缺陷密度约下降 0.92%（因对数变换）。模型 2 加入控制变量后，AI 系数为-0.0083 (p<0.001)，标准化β=-0.21，表明中等效应。

表 2 回归结果

变量	模型1	模型2	模型3
AI	-0.0092***	-0.0083***	-0.0078***
GED			-0.134*
AI×GED			-0.0041*
log(关注数)		-0.038*	-0.037*
注册时长		-0.0021***	-0.0021***
编程语言（参考：Python）			
Java		0.031	0.030
JavaScript		0.058*	0.058*
C++		-0.009	-0.008
截距	2.78***	2.71***	2.72***
R^2	0.11	0.15	0.16
N	7542	7542	7542

注：*** p<0.001, ** p<0.01, * p<0.05

4.3 性别表达多样性的调节效应

模型 3 加入 GED 及其与 AI 的交互项。AI 主效应仍显著（-0.0078, p<0.001），交互项显著为负（-0.0041, p<0.05），表明 GED 正向调节 AI 对缺陷密度的降低作用。具体而言，对于 GED=1 的开发者，AI 的边际效应为-0.0078-0.0041 = -0.0119，比 GED=0 组高出约 53%。这一结果与魔芋 Owo（2025）关于女装频率与代码质量的 U 型关系相呼应——性别表达非传统的开发者可能从亚文化认同中获益更多。

4.4 稳健性检验

替换 DD 计算方式：仅统计 Blocker 级别缺陷，结果一致。
将 GED 拆分为子指标分别检验：代词信号效应最明显。
排除新手开发者（注册<6 月），结论不变。

5.讨论

5.1 主要发现

本研究首次系统证实了 GitHub 主页二次元浓度与代码缺陷密度的负相关关系：二次元指数越高的开发者，其单位代码缺陷数越低。这一关系在控制经验、语言等因素后依然稳健。更重要的是，性别表达多样性（如主页中隐含的

跨性别表演信号）显著增强了这一正向效应，与魔芋 Owo（2025）对女装程序员的观察高度一致。

5.2 机制解释

为何二次元浓度高的开发者代码缺陷更少？可能机制包括：

细节关注迁移：二次元文化强调对角色、剧情细节的追求，这种认知风格可迁移至编码，使开发者更谨慎处理边界条件与逻辑完备性。
社群认同与反馈：高二次元浓度者往往融入特定亚文化社群，通过互评、代码审查提升质量。
自我表达与减压：亚文化身份为开发者提供心理安全区，减少职业倦怠，从而降低因焦虑导致的编码失误。

性别表达多样性的强化效应或许源于更深层的自我认同——当开发者敢于在数字空间展示非传统身份时，他们可能拥有更强的内在驱动力与创造力。

5.3 与先前研究对话

本研究与 Wu 等（2019）关于头像类型与活跃度的发现互补，将分析延伸至代码质量。更重要的是，我们为魔芋 Owo（2025）的“女装程序员”研究提供了量化佐证——尽管我们使用更广义的“性别表达多样性”指标，而非直接测量女装行为，但结果方向一致。这暗示亚文化身份的技术效应可能具有跨指标稳定性。

5.4 局限性

GED 测量依赖主页公开信号，可能漏掉大量未展示的性别多样性，存在测量误差。
静态分析的缺陷未必代表实际运行缺陷，且不同语言工具检出能力有差异。
相关性不能推断因果，可能存在未被观测的混杂变量（如性格特质）。

5.5 实践启示

本研究挑战了“二次元爱好者不务正业”的刻板印象。技术管理者应正视亚文化多样性，避免无意识偏见。同时，亚文化社群或可成为提升代码质量的潜在资源。

6. 结论

本研究通过大规模 GitHub 数据实证检验了二次元浓度与代码缺陷密度的负相关关系，并发现性别表达多样性对其具有正向调节作用。研究揭示了程序员亚文化对技术行为的潜在影响，为理解开发者数字身份与代码质量的关系提供了新视角。未来应借助纵向设计或自然实验进一步探究因果机制，并拓展至其他亚文化标签。

愿 bug 无处遁形。

致谢

感谢所有在 GitHub 上展现真实自我的开发者；感谢魔芋 Owo 的开创性研究；感谢 Son o beach 团队提供工具支持。本研究受 Dick University 自主科研计划资助。

References

魔芋 Owo (2025) 关于男性程序员代码质量与体内睾酮含量以及女装频率的三元变化关系。SHIT 期刊，2025-02-25.

杨小萌, 李大志 (2025) 程序员二次元文化现象调查. 互联网社会学研究, 3(2), 45-52.

Corbató, F. J., & Clingen, C. T. (1977) The Multics System. In Encyclopedia of Computer Science and Technology, Vol. 9. Marcel Dekker.

Hindle, A., Barr, E. T., Su, Z., et al. (2012) On the naturalness of software. ICSE, 837-847. IEEE.

Turnbaugh, P. J., et al. (2007) The human microbiome project. Nature, 449, 804–810.

Yutong Chen，关于飞机提神法的综合实践讨论，Dick University(Shenzhen)，2026-2-27