SHIT Sciences Humanities Information Technology

SHIT, 2026, 2-25
doi: 没有 doi
Advance Access Publication Date: 25 Month 2
Manuscript Category

Subject Section

基于深度学习的蛋白质折叠预测方法及其在肠道菌群研究中的应用

张晓明[1]，，王芳[2]，陈思[3]，刘洋[4]

[1]北京大学生命科学学院，北京，100871

[2]清华大学计算机科学与技术系，北京，100084

[3]中国科学院微生物研究所，北京，100101

[4]上海交通大学医学院附属瑞金医院，上海，200025

*通讯作者：zhangxm@pku.edu.cn.

副主编： 陈建平

收稿日期： 2025 年 3 月 10 日；修回日期： 2025 年 4 月 20 日；接受日期： 2025 年 5 月 1 日

摘要

动机： 蛋白质折叠是生命科学中的核心问题之一，准确预测蛋白质的三维结构对于理解其功能具有重要意义。近年来，深度学习技术在蛋白质结构预测中展现出巨大潜力。本文提出了一种基于 Transformer 和多尺度卷积神经网络的蛋白质折叠预测模型 DeepFold-Gut，旨在提高预测精度和效率，并将其应用于肠道菌群蛋白质组学研究中。

结果： 实验结果表明，该模型在多个公开数据集上均优于现有方法，平均 RMSD 降低了 15%，预测速度提升了 30%。特别是在长序列蛋白质结构中，模型表现出更强的泛化能力。将该模型应用于人类肠道菌群宏基因组数据，成功预测了 327 个与宿主互作相关的新蛋白结构，其中包括 12 个潜在的抗菌肽和 8 个黏附因子。

可用性： 模型源代码和预训练权重已发布在 GitHub 上

地址：https://github.com/zhanglab/DeepFold-Gut

联系方式： zhangxm@pku.edu.cn

补充信息： 补充材料包括模型结构图、训练曲线、肠道菌群蛋白预测列表和实验验证数据，见附件。

1 引言

蛋白质折叠问题被认为是生物学领域的“圣杯”之一。尽管实验方法如 X 射线晶体衍射和冷冻电镜能够提供高分辨率结构，但其成本高、周期长，难以大规模应用。因此，计算方法的快速发展为蛋白质结构预测提供了新的可能。

近年来，深度学习技术，尤其是 Transformer 和注意力机制，已经在自然语言处理和计算机视觉领域取得了巨大成功。受到 AlphaFold2 的启发，本文提出了一种结合多尺度卷积和自注意力机制的混合模型 DeepFold-Gut，旨在捕捉蛋白质序列中的局部和全局依赖关系。

本研究的贡献包括：（1）提出了一种新的深度学习架构；（2）在多个基准数据集上验证了模型的有效性；（3）开源了代码和模型，便于复现和应用；（4）首次将模型系统性地应用于肠道菌群蛋白质组研究，揭示了多个潜在的功能蛋白。

肠道菌群作为人体"隐形器官"，其编码的蛋白质数量远超人类基因组。然而，目前对肠道菌群蛋白的结构和功能认知仍然有限。传统实验方法难以应对宏基因组数据的规模和多样性，而计算方法则提供了高通量解析的可行性。DeepFold-Gut 的提出为解决这一问题提供了新的工具。

2 方法

2.1 数据准备

我们从 PDB 数据库中提取了约 10 万个非冗余蛋白质链，序列相似性低于 30%。数据被划分为训练集、验证集和测试集，比例分别为 80%、10%和 10%。此外，我们从人类微生物组计划(HMP)和 MetaHIT 项目中收集了 5000 个肠道菌群宏基因组样本，从中组装出约 200 万个非冗余蛋白序列用于下游应用分析。

2.2 模型架构

DeepFold-Gut 由三部分组成：嵌入层、多尺度卷积模块和 Transformer 编码器。嵌入层将氨基酸序列转换为高维向量；多尺度卷积模块使用三种不同大小的卷积核(3,5,7)提取局部结构特征；Transformer 编码器由 12 层多头注意力机制组成，捕捉长距离依赖

关系。模型总参数量为 1.2 亿，在 8 张 NVIDIA A100 GPU 上训练了约 2 周时间。

为了适应肠道菌群蛋白序列的特殊性，我们在预训练阶段引入了领域自适应技术，使用从肠道宏基因组中提取的未标注序列进行掩码语言模型预训练，使模型能够更好地捕捉肠道菌群蛋白的序列特征。

2.3 训练策略

我们使用 AdamW 优化器，采用余弦退火学习率调度，初始学习率为 1e-4，最小学习率为 1e-6。批量大小为 64，使用梯度累积技术模拟更大批次。损失函数包括 RMSD 损失、二面角损失和接触图损失的多任务联合优化。训练共进行 300 个 epoch，早停机制用于防止过拟合。

2.4 肠道菌群蛋白筛选与验证流程

我们从宏基因组数据中筛选出满足以下条件的蛋白序列：（1）长度在 50-500 氨基酸之间；（2）与已知结构蛋白序列相似性低于 30%；（3）在至少 5 个独立样本中均有表达。筛选出的蛋白序列使用 DeepFold-Gut 进行结构预测，然后通过结构比对和功能注释工具进行功能推断。部分高价值候选蛋白通过基因合成和体外表达进行实验验证。

3 结果

3.1 性能比较

在 CASP14 数据集上，DeepFold-Gut 的平均 RMSD 为 2.28Å，优于传统方法如 Rosetta（3.12Å）和 I-TASSER（2.89Å）。与 AlphaFold2 相比（2.17Å），虽略逊一筹，但计算时间减少了约 45%，模型大小仅为 AlphaFold2 的三分之一。在 CAMEO 数据集上的持续测试表明，DeepFold-Gut 在每周更新的新蛋白上保持稳定性能。

3.2 消融实验

我们分别移除了多尺度卷积和 Transformer 模块，发现两者对模型性能均有显著贡献。移除多尺度卷积后 RMSD 上升至 2.78Å，移除 Transformer 后上升至 2.91Å。同时移除两者后，模型退化为简单的全连接网络，RMSD 高达 4.23Å，充分说明了两个模块的重要性。

3.3 可视化分析

图 2 展示了模型对蛋白质"1A3A"链的预测结构与实验结构的叠合图，显示两者在主链上高度一致，RMSD 仅为 1.87Å。图 3 展示了模型注意力权重的可视化，显示模型成功捕捉到了远距离残基之间的相互作用关系。

3.4 肠道菌群蛋白预测结果

我们将 DeepFold-Gut 应用于 3278 个筛选后的肠道菌群蛋白序列，成功获得了高置信度结构预测（pLDDT>70）的有 2145 个，占比 65.4%。其中，327 个蛋白在已知数据库中没有同源结构，被认为是潜在的新蛋白家族。

功能注释分析表明，这些新蛋白中包括：

(1) 抗菌肽候选（12 个）：这些蛋白具有两亲性 α -螺旋结构，表面电荷分布与已知抗菌肽相似，可能参与肠道菌群间的竞争性互作。

(2) 黏附因子候选（8 个）：这些蛋白含有类似于细菌黏附素的结构域，可能介导细菌与肠上皮细胞的黏附，影响肠道屏障功能。

(3) 代谢酶候选（45 个）：这些蛋白含有与糖苷水解酶、蛋白酶等相似的活性位点结构，可能参与膳食纤维的降解和短链脂肪酸的产生。

(4) 分泌系统组分（23 个）：这些蛋白与细菌分泌系统的结构组分相似，可能参与效应蛋白的跨膜运输。

3.5 实验验证

我们选择了其中 5 个高置信度的抗菌肽候选进行基因合成和功能验证。体外抑菌实验表明，其中 3 个合成肽对大肠杆菌和金黄色葡萄球菌有明显抑制作用，最小抑菌浓度在 8-32 μ g/mL 之间。这一结果初步验证了 DeepFold-Gut 预测的功能准确性。

4 讨论

尽管 DeepFold-Gut 在多个数据集上表现良好，但仍存在一些局限性。例如，对于含有大量无序区域的蛋白质，预测精度仍有待提高；对于多结构域蛋白的域间相对 orientation 预测仍不够准确。未来我们将尝试引入更多物理化学约束，如分子动力学模拟，并结合多序列比对信息进一步提升性能。

在肠道菌群应用方面，本研究仅初步探索了 DeepFold-Gut 的潜力。未来我们将扩大分析规模，构建完整的肠道菌群蛋白结构数据库，并探索这些结构与宿主健康状态的关联。例如，特定菌群蛋白的表达是否与炎症性肠病、肥胖等疾病相关。此外，我们也将尝试将模型应用于其他微生物组，如土壤微生物组和海洋微生物组。

另一个值得探索的方向是将 DeepFold-Gut 与宏基因组组装技术结合，实现从测序数据到蛋白结构功能注释的端到端流程，为微生物组学研究提供新的工具。

5 结论

本研究提出了一种基于深度学习的蛋白质结构预测模型 DeepFold-Gut，在保持较高预测精度的同时显著提升了计算效率。将该模型应用于肠道菌群宏基因组数据，成功预测了数百个新蛋白结构，并通过实验验证了部分抗菌肽的功能。这一研究表明，深度学习辅助的蛋白质结构预测为微生物组功能研究开辟了新途径。

致谢

感谢北京大学高性能计算平台和清华大学蛋白质研究技术中心提供的计算与实验资源。感谢李华教授、陈思研究员在模型设计和实验验证中的宝贵建议。感谢瑞金医院刘洋医生提供的临床样本和宏基因组数据。

基金

本研究受国家自然科学基金（项目号：62272008, 82372015）、国家重点研发计划（项目号：2023YFC3401800）和北京市自然科学基金（项目号：5242007）资助。

利益冲突：无。

参考文献

Zhang,X. et al. (2024) Deep learning for protein structure prediction. Nature Methods, 21, 123–130.

Wang,H. et al. (2023) Transformer-based model for protein folding. Bioinformatics, 39, 45–52.
Senior,A.W. et al. (2020) Improved protein structure prediction using potentials from deep learning. Nature, 577, 706–710.
Jumper,J. et al. (2021) Highly accurate protein structure prediction with AlphaFold. Nature, 596, 583–589.
Qin,J. et al. (2010) A human gut microbial gene catalogue established by metagenomic sequencing. Nature, 464, 59–65.
Zhao,L. et al. (2023) Gut microbiome-derived proteins in host-microbe interactions. Cell Host & Microbe, 31, 412–425.
Chen,S. et al. (2024) Metagenomic mining of antimicrobial peptides from human gut microbiome. Microbiome, 12, 45–58.
Liu,Y. et al. (2023) Structural insights into bacterial adhesion factors in inflammatory bowel disease. Gut Microbes, 15, 218–235.