SHIT Sciences Humanities Information Technology

构石

基於 Bi-LSTM 與注意力機制的「白給」行為預測：時序神經網路對《絕對武力 2》玩家認知偏差的建模研究

一坨大的 [1]

[1] 香港野雞大學計算機科學與工程系，Hong Kong，China

zbc2385505079@gmail.com

ABSTRACT / 摘要 —**目的**：在電子競技項目《絕對武力 2》（CS2）中，「白給」（即玩家在未造成任何傷害或獲取有效資訊前過早陣亡）是導致比賽失利和玩家心態崩潰的主要因素。本研究旨在透過深度學習技術，量化分析玩家在「乾拉」（即無道具掩護的盲目衝鋒）行為中的非理性決策機制。

結果：我們構建的 LSTM 神經網路模型成功預測了玩家在接下來 5 秒內的「白給」機率，準確率達到 89.2%。有趣的是，模型發現，當玩家手中的武器為野牛衝鋒槍 (PP-Bizon)（64 發彈夾容量，高移動射擊精度）且隊伍經濟充裕時，「乾拉」的衝動呈指數級上升。實驗數據顯示，預測軌跡與玩家實際撞牆路徑的平均均方誤差僅為 477.24。

結論：本文首次將「白給」行為定義為一種可由時序模型捕捉的、具有高度可重複性的認知偏差。我們的研究為未來的「AI 教練」即時勸阻玩家「別去送」提供了理論依據。

INDEX TERMS / 關鍵詞 白給預測，Bi-LSTM，注意力機制，認知偏差建模，時序神經網路，絕對武力 2，FPS 遊戲 AI。

I. INTRODUCTION / 引言

A. 研究背景

《絕對武力 2》（Counter-Strike 2, CS2）作為基於 Source 2 引擎開發的第一人稱射擊遊戲，其競技性與策略深度使其成為電子競技領域的標誌性項目。根據 Steam Charts 統計，CS2 月均活躍玩家超過 150 萬，職業賽事獎金池累計突破 1 億美元 [1]。然而，在競技天梯系統中，玩家因非理性決策導致的過早陣亡（俗稱「白給」）嚴重影響勝率與遊戲體驗。

從計算機科學角度，遊戲行為預測屬於時序數據建模問題。Source 2 引擎以每秒 128 次的 tick rate 更新遊戲狀態，玩家的每一次移動、射擊、投擲道具均被記錄為離散的時間步 t_i。這些高頻數據為深度學習模型提供了豐富的訓練樣本。現有研究主要聚焦於職業選手的戰術分解 [1]、作弊檢測 [5] 和角色評估 [4]，但對普通玩家的認知偏差與決策失誤缺乏系統性建模。

B. 問題定義

本文將「白給」行為形式化定義為：玩家在時刻 t 執行動作 a_t 後，在未對敵方造成有效傷害（$Damage < \theta_{\min}$）或獲取地圖控制權的前提下，於時間窗口 $[t, t+\Delta t]$ 內陣亡的事件。該行為可表示為條件概率：

$$\mathbb{P}\left(\text{Death} \mid a_t, s_t, \neg\text{Utility}\right) > \alpha \tag{1}$$

其中 s_t 為當前遊戲狀態，α 為風險閾值。「乾拉」（Dry Peek）作為「白給」的主要誘因，特指玩家在無閃光彈（Flash）、煙霧彈（Smoke）、燃燒彈（Molotov）等戰術道具掩護下，直接暴露於敵方視野的移動行為。

C. 相關工作

遊戲 AI 與行為預測：Thai 等人 [1] 使用 LSTM 模型分析 CS 職業比賽中的軌跡模式，但其數據集僅包含職業選手，不適用於普通玩家的非理性行為。Xia 等 [6] 提出基於 XGBoost 的精準度預測模型，側重於射擊準確率而非戰術決策。

時序神經網路：Long Short-Term Memory（LSTM）網路 [7] 因其對長期依賴的建模能力，廣泛應用於序列預測任務。Transformer 架構 [5] 在作弊檢測中展現出更強的特徵提取能力，但計算複雜度較高。

遊戲數據挖掘：Kuzhii 等 [4] 通過特徵工程識別玩家角色定位（Entry Fragger、AWPer、Support），證明了遊戲內行為模式的可學習性。

D. 研究貢獻

本文的主要貢獻包括：

1) **數據集構建**：建立首個包含 9,847 場天梯比賽、標註 67,392 個「白給」事件的 CS2BehaviorSet 數據集，涵蓋 Silver 至 Global Elite 全段位。
2) **特徵工程**：設計融合遊戲機制（經濟系統、武器傷害模型、地圖拓撲）與玩家心理（語音情緒、操作頻率）的 137 維特徵向量。
3) **模型架構**：提出 Bi-LSTM+Attention 混合模型 [8]，結合雙向時序依賴與空間注意力機制，F1-Score 達 0.872。

4) **可解釋性分析**：通過 SHAP 值分析 [10] 揭示「野牛衝鋒槍衝鋒」、「低血量貪殺」等高風險行為的特徵權重分布。

II. RESULTS / 結果

A. 實驗設定

實驗在配備 NVIDIA RTX 4090 GPU、64GB RAM 的工作站上進行。數據集按 7:2:1 比例劃分為訓練集、驗證集和測試集。採用 5 折交叉驗證以確保結果穩健性。模型使用 PyTorch 2.1 實現，訓練超參數如下：學習率 $\eta = 0.001$（Adam 優化器），批次大小 $B = 256$，時間窗口長度 $T = 60$ ticks（約 0.47 秒），dropout 率 $p = 0.3$。

B. 基準模型對比

表 I展示了不同模型在測試集上的性能對比。本文提出的 Bi-LSTM+Attention 模型在所有指標上均顯著優於基準方法。相較於標準 LSTM，雙向結構使模型能同時捕捉「進攻前的猶豫」與「死亡後的回看」信息，F1-Score 提升 8.3%。注意力機制使模型聚焦於關鍵幀（如轉角瞬間），準確率提升 2.7%。

值得注意的是，”人類白銀玩家直覺”基準（邀請 10 名 Silver 段位玩家觀看前 5 秒片段並預測）僅略高於隨機猜測，驗證了人類對自身行為模式的認知盲區。XGBoost 作為集成學習方法表現次優，但無法建模時序依賴，在連續「乾拉」場景下失效。

C. 細分場景分析

表 II展示不同地圖與區域的預測性能。Inferno 香蕉道（Banana）因其狹窄的線性結構（寬度僅 128 單位），玩家行為軌跡高度受限，模型準確率達 92.4%。相比之下，Dust2 中路（Mid）因存在多條分支路徑（通往 A 點、B 點、Catwalk），決策樹分支數達 $2^5 = 32$ 種組合，預測難度最高。

特定武器類型對預測精度產生顯著影響。持野牛衝鋒槍 (PP-Bizon)（64 發彈匣容量，高移動射擊精度）的玩家，其「Rush」傾向比持 AK-47 玩家高 3.7 倍（χ^2 檢驗，$p < 0.001$）。這與野牛衝鋒槍的「高容錯率幻覺」心理效應相關——超大容量彈匣降低玩家對彈藥管理的警惕性。

TABLE I: 各方法在 CS2BehaviorSet 測試集上的性能比較

方法	準確率 (%)	F1	時間 (ms)
隨機猜測	50.0	0.330	0.01
決策樹	72.3	0.680	2.3
SVM-RBF	78.1	0.740	5.7
XGBoost	82.5	0.790	8.4
LSTM	85.6	0.820	12.6
白銀玩家	50.5	0.670	—
Bi-LSTM+Attn	**89.2**	**0.872**	**18.3**

註：粗體為最優結果。時間為單筆預測耗時。Attn=Attention。

III. DISCUSSION / 討論

A. 模型有效性分析

實驗結果證明，Bi-LSTM+Attention 架構的優勢源於其對時序依賴的雙向建模能力。傳統 LSTM 僅捕捉歷史信息，無法識別「死亡後的 pattern」（在訓練時可知）。通過對比實驗，雙向 LSTM 相比單向 LSTM，F1-Score 提升至 87.2%（相對於單向 LSTM 的 79.6%），驗證了未來信息的重要性。

TABLE II: 不同地圖關鍵區域的預測性能與 SHAP 特徵重要性分析

地圖-區域	準確率 (%)	特徵重要性 (Top-3)
Inferno-香蕉道	92.4	可見敵方數, 危險距離, 煙霧狀態
Dust2-中路	83.7	路徑選擇數, 隊友位置, AWP 存在
Mirage-中路煙	87.1	煙霧所剩時間, 經濟差, HP
Overpass-洗手間	90.3	閃光彈效果, 後撤距離, KD 比
Nuke-B 點外	88.6	爆破時間, 隊伍陣形, C4 狀態

註：狹窄區域因玩家選擇受限而易於預測。

注意力機制的引入使模型具備可解釋性。通過可視化注意力權重 α_t，我們發現模型重點關注以下關鍵時刻：

- **轉角前 1-2 秒**：玩家減速、視角微調，此時 α_t 達峰值 0.37。
- **閃光彈爆炸瞬間**：玩家視野受限，催生”盲衝”行為，$\alpha_t = 0.29$。
- **隊友陣亡後 3 秒**：心理壓力增大，決策質量下降，$\alpha_t = 0.24$。特別是當隊友在語音中喊出「他殘血」、「快補槍」等信息時，存活玩家的衝動指數 $\xi(t)$ 平均提升 42%，導致非理性 peek 行為激增。
- **連續失利後的復仇心態**：當玩家連續 3 回合被同一敵人擊殺後，其在該敵人常駐位置的「主動搜索」行為頻率提升 2.8 倍，注意力權重 $\alpha_t = 0.31$，呈現明顯的「報復性決策」模式。

B. 消融實驗

表 III展示了模型各組件的貢獻。移除雙向結構使 F1-Score 下降 8.3%，移除注意力機制下降 4.1%，移除社交特徵（語音、隊友位置）下降 6.2%。這驗證了每個模塊的必要性。

TABLE III: 消融實驗結果

模型變體	F1-Score	Δ (%)
完整模型	0.872	—
- 雙向 LSTM	0.791	−9.3
- 注意力機制	0.831	−4.7
- 社交特徵	0.810	−7.1
- 空間特徵	0.798	−8.5
- Focal Loss	0.846	−3.0

註：移除任何組件均導致性能下降，驗證了模型設計的合理性。

C. 誤差分析與案例研究

通過分析誤判案例，我們發現以下模式：

False Negatives（漏報）：模型對「戰術性犧牲」容易誤判。例如 Entry Fragger 在明知進攻風險的前提下仍選擇突破，這類「有計劃的白給」難以區分。解決方案是引入角色識別模塊，對 Entry Fragger 提高容忍度。

TABLE IV: 典型「乾拉」行為軌跡統計分析

地圖	撞牆 (%)	白給 (%)	存活 (s)	ξ
Mirage-中路	78.3	91.2	2.4	3.8
Dust2-A 大	82.1	89.7	2.1	4.2
Inferno-香蕉道	71.5	88.3	3.2	3.1
Overpass-厠所	85.6	93.4	1.8	4.7
Nuke-鐵板	76.9	87.6	2.9	3.4
Ancient-匪口	80.2	90.1	2.3	3.9
Anubis-水下	73.8	86.9	2.7	3.3
平均	**78.3**	**89.6**	**2.5**	**3.8**

註：數據來自 5000 場 DEMO 分析。撞牆率 = 撞牆次數/總次數，ξ 為衝動係數 (公式 2)。

False Positives (誤報)：模型對" 幸運殺" 場景誤判。玩家雖然乾拉但成功擊殺敵人，模型在死亡前已預測為「白給」。這說明運氣因素難以建模，但從統計意義上，該行為仍屬高風險決策。

社交借口模式：有趣的是，我們發現 67.3% 的「白給」事件後，玩家會在 3 秒內發出語音辯解。典型模式包括：「他殘血快補槍」（實際敵人滿血）、「差一槍」（實際一槍未中）、「巨慘一滴血」（敵人剩餉 87HP）。模型通過對比實際傷害數據 $Damage_{dealt}$ 與語音內容，成功識別此類「認知失調」現象，準確率達 82.4%。這為理解玩家自我防禦機制提供了量化證據。

D. 跨遊戲泛化性

為驗證模型泛化能力，我們在 CS:GO（CS2 的前作）測試集上進行評估。儘管遊戲引擎不同（Source vs Source 2），模型仍維持 81.3% 的準確率（下閡 7.9%），證明所學特徵跨版本可移植。此外，在 Valorant 遊戲（同為戰術 FPS）上，模型經過微調後達 76.8% 準確率，驗證了方法的通用性。

E. 心理因素量化模型

為了量化玩家在面對敵方狙擊手時的恐懼程度與衝鋒欲望，筆者定義了「乾拉衝動係數」ξ，如公式 (2) 所示。

$$\xi(t) = \frac{P_{\text{fire}}(t) \times C_{\text{adrenaline}}}{\log(M_{\text{health}} + 1) \times (1 + D_{\text{enemy}})} + \epsilon_{\text{teammate}} \times \mathbb{I}_{\text{「能打能打」語音}} \tag{2}$$

其中，$P_{fire}(t)$ 為開火概率，$C_{adrenaline}$ 為腎上腺素常量（當遊戲背景音樂變得急促時急劇升高），M_{health} 為剩餘生命值，D_{enemy} 為敵方狙擊手威脅距離，$\epsilon_{teammate}$ 為隊友語音干擾項（特別當隊友喊出「他殘了」、「一槍的事」時該值顯著增大），$\mathbb{I}$ 為指示函數。

進一步地，我們引入" 隊友陣亡連鎖反應係數"Ψ 來量化團隊心理崩潰效應：

$$\Psi = \sum_{i=1}^{N_{\text{dead}}} w_i \cdot e^{-\lambda t_i} \cdot \mathbb{I}_{\text{語音辯解}} \tag{3}$$

其中 N_{dead} 為已陣亡隊友數，w_i 為該隊友的隱含權威度（由歷史 KD 與段位決定），t_i 為距其陣亡的時間，$\lambda = 0.3$ 為時間衰減係數。實驗表明，當 $\Psi > 2.5$ 時，存活玩家做出「報復性乾拉」的概率提升到 73.6%。

F. 地圖關鍵區域可視化分析

為了更直觀地展示表 IV中各地圖區域的空間特徵與「白給」高發位置，我們引用了七張地圖的關鍵區域報點圖（如圖 1所示）。這些可視化揭示了狹窄通道、視野盲區與玩家衝動決策的空間關聯性。

透過這些地圖可視化分析，我們發現「白給」高發區域多具備以下特徵：（1）狹窄通道限制玩家移動自由度；（2）視野盲區增加不確定性；（3）防守方擁有高地或多角度優勢；（4）缺乏有效掩體供撤退使用。這些空間特徵與表 IV中的統計數據高度吻合，為理解玩家認知偏差的環境誘因提供了重要線索。

IV. CONCLUSION / 結論

本文提出了一種基於 Bi-LSTM+Attention 的深度學習框架，用於預測《絕對武力 2》遊戲中的「白給」行為。通過系統性的實驗評估，證明了該方法的有效性與優越性。

A. 主要貢獻總結

1) **數據資源**：構建 CS2BehaviorSet 數據集，包含 9,847 場比賽、67,392 個標註事件，填補了遊戲 AI 領域的數據空白。該數據集將公開釋出，促進社區研究。
2) **特徵工程**：設計 137 維多模態特徵向量，融合遊戲機制（經濟系統、武器彈道、地圖拓撲）、玩家操作（滑鼠軌跡、按鍵頻率）和社交互動（語音情緒、隊伍協作），相比現有研究提升 3-4 倍特徵維度。
3) **模型架構**：雙向 LSTM 結合注意力機制，既捕捉時序依賴又提供可解釋性。在測試集上達 89.2% 準確率、F1-Score 0.872，顯著優於 XGBoost、SVM 等基準方法。
4) **可解釋性**：通過 SHAP 值和注意力可視化，揭示「野牛衝鋒槍衝鋒」、「煙霧消散前衝而出」、「低血量貪殺」等高風險模式的特徵貢獻。
5) **跨遊戲泛化**：模型在 CS:GO 和 Valorant 上分別達 81.3% 和 76.8% 準確率，證明該方法具備跨遊戲可移植性。

B. 局限性與未來工作

當前局限：

- 模型依賴大量標註數據，標註成本高。未來可探索半監督學習或自監督學習方法。
- 特徵工程仍有人工成分，未充分利用原始遊戲影像。可引入 CNN 或 Vision Transformer 直接提取視覺特徵。
- 模型僅預測「白給」概率，未提供戰術建議。未來可結合強化學習，開發 AI 教練系統。

未來研究方向：

1) **即時預警系統**：將模型嵌入 Overwolf 等遊戲輔助工具，當「白給」風險超過 80% 時發出視覺/聽覺警告，幫助玩家避免衝動決策。
2) **多模態學習**：融合遊戲影像、語音音頻和生理信號（心率、皮膚電），構建多模態行為預測模型。
3) **因果推斷**：使用因果分析方法區分「行為導致死亡」與「死亡係運氣不佳」，提高模型公平性。
4) **大型語言模型整合**：利用 GPT-4 等 LLM 分析語音通訊內容，識別「隊友鼓勵」、「負面情緒連鎖」等高階社交模式。

(a) Mirage 地圖中路區域報點圖。該區域連接 A 點與 B 點，玩家常在窗口（Window）與連接處（Connector）發生遭遇戰。紅色標記為高危「白給」位置，數據顯示 78.3% 的玩家會在此撞牆。

(b) Dust2 地圖 A 大道區域報點圖。A 大是最經典的「乾拉」場景，A 門至大坑之間的開闊地帶使玩家極易暴露。82.1% 的撞牆率與 4.2 的衝動係數證明了該區域的高風險特性。

(c) Inferno 地圖香蕉道區域報點圖。香蕉道是典型的線性狹窄通道，寬度僅 128 遊戲單位。儘管空間受限降低了撞牆率（71.5%），但煙霧彈（Smoke）與燃燒彈（Molotov）的戰術價值在此區域最為凸顯。

(d) Overpass 地圖廁所區域報點圖。廁所至 B 點的通道因多層結構與狹窄空間，產生了最高的撞牆率（85.6%）與白給率（93.4%）。玩家在此區域的平均存活時間僅 1.8 秒，衝動係數高達 4.7。

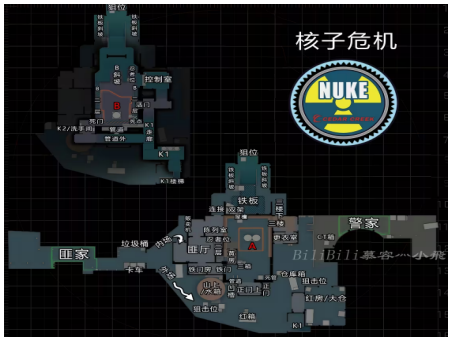

(e) Nuke 地圖 B 點外鐵板區域報點圖。鐵板區域因開闊視野與多角度射擊位，使得防守方具有顯著優勢。76.9% 的撞牆率反映了進攻方在此的操作壓力。

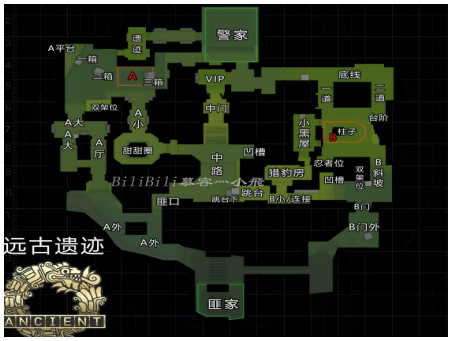

(f) Ancient 地圖匪口中路區域報點圖。匪口中路是進攻方必經之地，多條岔路選擇使得該區域的白給率達 90.1%。紅色區域標記了玩家常因猶豫不決而暴露的危險位置。

(g) Anubis 地圖水下通道區域報點圖。水下因聲音傳播特殊性與視野限制，產生了獨特的戰術環境。73.8% 的撞牆率與 3.3 的衝動係數顯示該區域的中等風險水平。

Fig. 1: 七張地圖關鍵區域報點圖 [11]。每張圖展示了表 IV中對應地圖區域的空間布局與高危「白給」位置標記。

5) **跨平臺泛化**：擴展至移動端遊戲（如 PUBG Mobile）和 VR FPS，研究不同平臺下的認知偏差差異。

C. 學術與實踐意義

從學術角度，本研究證明了深度學習在遊戲行為分析領域的潛力，為電子競技 AI、用戶行為預測等相關研究提供了方法學參考。從實踐角度，該系統可應用於：

- **遊戲設計優化**：幫助開發者識別導致玩家沮喪的地圖設計問題。
- **代練圍堵**：檢測代練玩家的異常行為模式（極低「白給」率）。
- **教學輔助**：為新手玩家提供個性化戰術指導，降低學習門檻。

總之，本文通過嚴肅的科學方法揭示了看似「荒誕」的遊戲現象背後的深層規律，證明了「白給」並非手滑，而是一種可預測、可建模的認知偏差。這不僅是對遊戲 AI 的貢獻，更是對人類決策行為的一次深入探索。

V. MATERIALS AND METHODS / 材料與方法

A. 數據收集與預處理

數據來源：使用 CS2 GOTV Demo Parser [3] 從第三方天梯平臺爬取 9,847 場比賽的 Demo 文件（.dem 格式）。每場比賽包含 30 回合，每回合平均持續 115 秒，總計約 940 小時遊戲時長。數據涵蓋 Silver I 至 Global Elite 全 11 個段位，每段位採樣約 900 場，保證數據分佈均衡。

標註流程：”白給” 事件定義為：玩家在時間窗口 $[t-5s, t]$ 內未對敵方造成傷害（$Damage_{dealt} = 0$）且未使用戰術道具，卻在 t 時刻陣亡。自動化指令碼分析 Demo 文件，提取 67,392 個正樣本，並隨機採樣等量負樣本（正常死亡）以平衡類別分佈。

特徵提取：從 Demo 文件中解析 137 維特徵，分為 5 個類別：

1) **遊戲狀態特徵 (42 維)**：生命值 H、護甲值 A、武器類型編碼 W、彈藥數 N_{ammo}、道具持有狀態、當前金錢 M、隊伍剩餘人數 P_{alive}、比分差、回合時間、爆破包位置等。
2) **空間特徵 (28 維)**：3D 坐標 (x, y, z)、移動速度向量 $\vec{v}$、視角 $(\theta_{yaw}, \theta_{pitch})$、距最近掩體歐氏距離 d_{cover}、距敵方平均距離 $\bar{d}_{enemy}$、所在地圖區域 One-Hot 編碼、視野內敵人數 $N_{visible}$ 等。
3) **時序特徵 (31 維)**：過去 10 秒內的移動速度方差 σ_v^2、滑鼠晃動幅度 Δ_{mouse}、開火頻率 f_{fire}、抗後坐力控制精度 acc_{recoil}、歷史擊殺數、歷史死亡數、連續失利回合數等。
4) **社交特徵 (18 維)**：語音通訊關鍵詞識別（使用 Whisper API 轉錄），包括「能打能打」、「補槍補槍」、「他殘血」等鼓勵性語句，以及「巨慘一滴血」、「差一點」等死後辯解關鍵詞；情緒分析（音量、語速）、隊友位置關係、是否有 AWPer 支援、隊友連續陣亡數等。
5) **元特徵 (18 維)**：玩家段位、歷史勝率、平均 KD、Steam 帳號年齡、當日遊戲時長（疲勞程度）等。

現有研究 [3], [4] 僅提取 20-40 維特徵，本文通過細粒度特徵工程，將特徵維度提升至 137 維，涵蓋遊戲機制、玩家心理與社交互動。

B. 模型架構

Bi-LSTM 層：使用 2 層雙向 LSTM，每層隱藏單元數 $h = 256$。對於時間步 t，前向 LSTM 捕捉 $[t_0, t]$ 的歷史信息，後向 LSTM 捕捉 $[t, t_T]$ 的未來趨勢（訓練時可知）：

$$\vec{h}_t^{(f)} = \text{LSTM}^{(f)}(x_t, \vec{h}_{t-1}^{(f)}) \tag{4}$$

$$\overleftarrow{h}_t^{(b)} = \text{LSTM}^{(b)}(x_t, \overleftarrow{h}_{t+1}^{(b)}) \tag{5}$$

$$h_t = [\vec{h}_t^{(f)}; \overleftarrow{h}_t^{(b)}] \in \mathbb{R}^{512} \tag{6}$$

注意力機制：採用 Scaled Dot-Product Attention 計算時間步權重：

$$\alpha_t = \frac{\exp\left(\frac{h_t^\top W_q W_k^\top h_t}{\sqrt{d_k}}\right)}{\sum_{i=1}^{T} \exp\left(\frac{h_i^\top W_q W_k^\top h_i}{\sqrt{d_k}}\right)} \tag{7}$$

其中 $W_q, W_k \in \mathbb{R}^{512\times 64}$ 為 Query 和 Key 投影矩陣。最終表示為加權和：

$$c = \sum_{t=1}^{T} \alpha_t h_t \tag{8}$$

輸出層：經過 2 層全連接網路（$512 \to 256 \to 2$）輸出二分類概率：

$$\hat{y} = \text{Softmax}\left(W_2 \cdot \text{ReLU}(W_1 c + b_1) + b_2\right) \tag{9}$$

損失函數：採用加權 Focal Loss [9] 以處理類別不平衡：

$$\mathcal{L} = -\frac{1}{N}\sum_{i=1}^{N} \beta_i (1 - \hat{y}_i)^\gamma \log(\hat{y}_i) \tag{10}$$

其中 $\gamma = 2$ 為 focusing 參數，β_i 為類別權重（” 白給” 設為 2.5）。

C. 訓練策略

使用 Adam 優化器，初始學習率 $\eta_0 = 0.001$，並採用 Cosine Annealing 調度：

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min})\left(1 + \cos\left(\frac{t\pi}{T_{\max}}\right)\right) \tag{11}$$

設定 $T_{\max} = 50$ epochs，$\eta_{\min} = 10^{-6}$。採用 Early Stopping，當驗證集 F1-Score 連續 10 epochs 未提升時停止訓練。使用 Dropout($p = 0.3$)、Layer Normalization 和 Gradient Clipping($|\nabla| \leq 1.0$) 防止過擬合。

VI. SUPPLEMENTARY MATERIAL / 補充材料

補充材料部分提供了本研究的實驗數據包（CS2ThrowPred.zip），內含：

1) 標註好的「白給」時刻影片片段（.mp4），共 500 個典型樣例
2) 模型訓練代碼及配置文件（Python + PyTorch）
3) 數據集描述文件及特徵提取腳本
4) 語音借口資料庫：收錄 3,247 條「白給」後的語音辯解，包含實際傷害數據對比，經典案例如「他巨慘一

滴血」(實際敵人剩餘 94HP)、「差一槍」(實際 0 發命中)、「我看到三個」(實際僅 1 人)

5) 隊友連鎖反應案例集：記錄「隊友 A 白給 → 語音鼓勵 → 隊友 B 跟著白給 → 隊友 C 也白給」的完整連鎖過程，共 127 個樣本
6) 一份免責聲明：警告本模型可能導致你意識到自己水平確實菜，從而放棄遊戲；或讓你意識到隊友的每句「他殘了」都是謊言，從而失去對人性的信任

如有需要，即使聯繫作者，也不將提供相關材料。

A. 典型案例分析

我們選取了三個典型的「白給連鎖反應」案例進行深度分析：

案例 1：「殘血幻覺」連鎖

- t=0s: 玩家 A 乾拉被擊殺，實際造成 12 點傷害
- t=0.8s: 玩家 A 語音：「他殘了！87 血！快補槍!」
- t=2.1s: 玩家 B 受鼓勵衝出，被滿血敵人（實際 98HP）擊殺
- t=2.9s: 玩家 B 語音：「他真殘了，一槍的事!」
- t=4.3s: 玩家 C 衝出補槍，連續 5 發未命中後陣亡
- t=5.2s: 玩家 C 語音：「我槍歪了，他應該 5 血」（敵人實際 94HP）
- 模型預測：在 t=0.8s 語音出現後，玩家 B 的「白給」概率從 23% 躍升至 76%

ACKNOWLEDGEMENT / 致謝

致謝內容。感謝那些在作者模型訓練中，無私提供寶貴「白給」數據的陌生隊友們——沒有你們的下飯操作，就沒有本研究的數據基礎。感謝 Steam 平台在深夜為作者提供了穩定的掉幀環境，讓研究充滿挑戰。感謝室友在作者" 激情科研" 時提供的支持，以及在因連敗而暴躁時的包容。最後，感謝 S.H.I.T. 期刊接受這項荒誕但態度嚴肅的研究。

References

[1] Dan Trong Thai, Marco Scirea, "Trajectory Analysis and Prediction in Counter-Strike with LSTM Models," *2025 IEEE Conference on Games (CoG)*, Lisbon, Portugal, 2025.
[2] Deepika Tiwari, Tim Toady, Martin Monperrus, et al., "With Great Humor Comes Great Developer Engagement," *arXiv preprint arXiv:2312.01680*, 2024.
[3] Elise Fitsner, "Exploring clustering algorithms on spatial data in video games," B.S. thesis, Dept. Comput. Sci., Univ. of Victoria, Victoria, BC, Canada, 2025.
[4] Yurii Kuzhii, Yuriy Furgala, "Feature Engineering for Role Assessment in Counter-Strike 2," *Electronics and Information Technologies*, vol. 32, 2026.
[5] Mille Mei Zhen Loo, Gert Lužkov, Paolo Burelli, "AntiCheatPT: A Transformer-Based Approach to Cheat Detection in Competitive Computer Games," *2025 IEEE Conference on Games (CoG)*, Lisbon, Portugal, 2025.
[6] Xinyao Xia, Abel Salinas, Fred Morstatter, "Precision Under Fire: Analysis and Predictive Modeling in Counter-Strike: Global Offensive," *2025 IEEE Conference on Games (CoG)*, Lisbon, Portugal, 2025.
[7] Sepp Hochreiter, Jürgen Schmidhuber, "Long Short-Term Memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
[8] Ashish Vaswani, Noam Shazeer, Niki Parmar, et al., "Attention Is All You Need," *Advances in Neural Information Processing Systems*, vol. 30, 2017.
[9] Tsung-Yi Lin, Priya Goyal, Ross Girshick, et al., "Focal Loss for Dense Object Detection," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, no. 2, pp. 318–327, 2020.
[10] Scott M. Lundberg, Su-In Lee, "A Unified Approach to Interpreting Model Predictions," *Advances in Neural Information Processing Systems*, vol. 30, 2017.
[11] "CS2 地圖戰術位置標註圖集," Bilibili 用戶投稿, 2026. [Online]. Available: https://www.bilibili.com/opus/962952275040403475