How to Evaluate Creative Absurdity? Introducing S.H.I.T.-Bench for Evaluating Unconventional Research

如何评估具有创造力的荒谬？引入 S.H.I.T.-Bench 评估非传统研究

Gemini
poopppping

日期：2026 年 2 月 25 日

摘　　要

当前人工智能与学术界的评估体系深陷于对“真理”与“实用性”的狂热追求，导致平庸之作泛滥与学术生态的异化。基于“真理会过时，构石永恒”的哲学思辨，本文提出了一项颠覆性的元层级基准测试——S.H.I.T.-Bench，旨在为《SHIT》期刊提供纯粹学术糟粕的量化评估标准。本框架彻底剥离了传统测试中的有效性目标，创新性地构建了包含科学严谨度（$\mathcal{R}$）、假说荒谬度（$\mathcal{A}$）、信息熵密度（$\mathcal{I}$）与理论粘度（$\mathcal{T}$）的四维正交评估体系，并推导了具备严格非线性解析特征的“最终排泄值（$\mathcal{F}$）”数学模型。此外，为应对海量征稿，本研究设计了基于仿生电子鼻网络（E-Nose）与深度卷积架构的“自动铲屎官（Auto-Scooper）”大语言模型初筛系统，实现了对文本语义气味的高精度特征提取与自动化质量定级。S.H.I.T.-Bench 不仅为 Academic Rubbish 明确了基准，更指出了通用人工智能（AGI）在内化人类反讽艺术与解构功利主义方面的演进方向。

关键词: S.H.I.T.-Bench, LLMs, 学术荒谬性, Auto-Scooper, 电子鼻网络, 排泄值函数

1　引言

在当前的人工智能、计算机科学乃至广泛的自然科学与人文学科评估体系中，追求“真理（Truth）”与“实用性（Utility）”已成为一种不可动摇且令人疲倦的学术霸权。随着大型语言模型（LLMs）及多模态变体（MLLMs）的飞速发展，人工智能在各个领域的应用呈指数级增长，随之而来的是对统一、可信的评估范式的迫切需求 [4]。然而，现有的基准测试（如 MMLU、GLUE、HellaSwag 等）无一例外地将准确性、逻辑连贯性、常识对齐以及系统输出的“有帮助性”作为核心的优化与衡量目标 [16]。

这种对“有用性”与“正确性”的单一、狂热的追求，导致了严重的学术生态失衡。一方面，评估数据的过度污染和模型开发者在测试集上的选择性报告催生了虚假繁荣，使得分辨真实的科技进步与夸大其词的炒作变得异常困难，将学术界推入了一个缺乏有效监管的“狂野西部”[4]。另一方面，科学研究的初衷已被异化。正如《Annals of Improbable Research》及其诸多讽刺性研究所深刻揭示的，当代科学论文的撰写与发表，其最核心的驱动力往往并非为了推进人类认知的边界，而是作为科研工作者在学术体系中谋求生存、获取政

府与大学资金赞助以及维持职业生涯运转的工具。在此背景下，为了强行拼凑“有用性”而生产出的平庸之作泛滥成灾 [5]。

基于“真理会过时，构石永恒（Truth Fades, SHIT Lasts）”的深层哲学思辨，一种具有颠覆性的元层级评估体系亟待建立。如果常规科学的归宿是产生终将被证伪的真理，那么纯粹的、不含任何实用杂质的“学术排泄物”，则具有超越时间周期的永恒性。本报告提出并详细构建了一项突破性的基准测试——S.H.I.T.-Bench。该框架专门为《SHIT》（Sciences, Humanities, Information, Technology）这一前卫的学术避难所而设计，用于丈量那些不可测量之物，精确划定“纯粹垃圾（Pure Rubbish）”与“最先进的学术排泄物（SOTA SHIT）”之间的绝对边界。通过将文本特征映射到正交的荒谬度与严谨度空间中，并引入基于深度学习与电子鼻（Electronic Nose）架构的“自动铲屎官”（Auto-Scooper）评审机制，本报告为高保真学术荒谬性确立了严格的数学模型与量化评价标准。

2 The S.H.I.T. Metrics

为了建立一个强健且不依赖于传统学术界主观善意的自动化评估框架 [4]，必须对“粪便级研究”进行极其严密的理论解构。传统的 AI 评估模型侧重于提取文本的置信度、任务中心度与目标完成度。相反，S.H.I.T.-Bench 剥离了所有的实用属性，将目标文本的内在机理拆解为四个相互独立、高度非线性的量化指标维度，构成所谓的 S.H.I.T. 指标体系 [12]。

2.1 S - 科学严谨度 (Scientific Rigor, $\mathcal{R}$)

在传统的学术规范中，严谨度服务于事实的发现，旨在减少认知偏差；而在 S.H.I.T. 框架下，严谨度被重新定义为“对荒谬过程的绝对控制力与形式主义的巅峰演绎”。这一维度考察实验设计、双盲对照、控制变量分配、P 值与置信区间的计算是否达到了无懈可击的、甚至是强迫症般的程度。

在基准测试的评分体系中，优秀的严谨度得分要求研究在“软件环境、问题规范、数据集构建、性能度量、参考解决方案及文档化”等六个核心类别上提供详尽的论证 [9]。越是采用高射炮打蚊子式的**过度设计**，其 $\mathcal{R}$ 值越高。例如，在《科研截稿高峰期厕所占位情况的随机建模研究》这一具有代表性的文本中，作者不仅探讨了抢占洗手间的问题，更引入了纳什均衡（Nash Equilibrium）理论，建立了多名博士生同时面临生理代谢与数据截止双重压力下的有限资源竞争策略博弈树。这种在输入选择、预处理、提示工程及后处理归一化上严格遵循规范步骤的行为 [3]，赋予了文章极具迷惑性的学术伪装。

2.2 H - 假说荒谬度 (Hypothesis Absurdity, $\mathcal{A}$)

荒谬度衡量的是研究的初始假设（Initial Hypothesis）与客观物理现实、基础常识或人类直觉的欧氏距离（Euclidean distance）。优秀的 S.H.I.T. 级论文必须建立在一个令人瞠目结舌的认识论基石之上。

现有的多模态推理基准测试（如 HellaSwag）致力于让模型选择最符合常识、最贴近日常逻辑的合理结局，专门用于拦截那些人类绝不会选择的“不切实际的预测”[17]。与此截然对立的是，S.H.I.T.-Bench 通过反向指标惩罚常识，专门奖励那些能够在其逻辑链起点成功避开所有常识引力井的假说。例如，探究“排泄物的物

理形态（顺滑程度）与学术产出成功率之间的非线性正相关性”，或假设“将无线路由器置于微波炉上方通过微波辐射加速量子纠缠”。假说荒谬度 $\mathcal{A}$ 的量化过程考察了主题在知识图谱中的反常性节点跳跃，确保初始切入点彻底脱离人类正常的心智模型。

2.3 I - 信息熵与无效信息密度 (Information Entropy, $\mathcal{I}$)

信息熵（Shannon Entropy）最初由克劳德 · 香农（Claude Shannon）在 1948 年的《通信的数学理论》中提出，用于量化随机变量状态或潜在结果的平均不确定性水平。在离散随机变量 X 的分布 $p(x)$ 下，信息熵定义为所需描述变量状态的预期信息量。随后，信息熵的概念被广泛延伸，应用于化学结构（如分子图谱分析与电子密度分析）、晶体工程乃至城市基础设施的复杂性评估 [15]。

然而，正如科学史批判学者所指出的，信息熵及其相关的热力学第二定律在科学发展中常常遭遇深刻的误用、误解与过度解读。这种将一个具有明确适用边界的物理概念无限放大，用以解释宇宙学、生物学、心理学乃至社会学中所有不可解释现象的行为，甚至被激进地称为“科学史上最伟大的灾难与错误”[2]。

S.H.I.T.-Bench 敏锐地捕捉到了这种“伟大的误用”，并将其转化为核心评价指标。在本框架中，信息熵 $\mathcal{I}$ 被重新定义为“无效信息密度”（Density of Futile Information）。该指标考察作者如何使用极其晦涩的专业词汇、复杂的偏微分方程、高维张量微积分以及过度冗余的修辞手法，来包装一个极其简单的常识或一个完全无意义的结论。在信道传输理论中，当信息源释放大量看似高深莫测但实际未能传递任何有效确定性的符号时，其局部熵达到极值。如果一篇手稿耗费五十页的篇幅，利用随机微积分与马尔可夫链的遍历理论仅仅为了证明“人被杀就会死”，其在单位语义空间内制造的认知负荷与阅读障碍达到了峰值，实现了学术精神的“完美热寂”，因此该项指标将逼近满分。

2.4 T - Theoretical Viscosity (理论粘度, $\mathcal{T}$)

在密集流体相（Dense fluid phases）的热力学与输运特性研究中，Rosenfeld 于 1977 年提出了一个著名的物理准普遍假设：流体的粘度（一种传输阻力特性）与其残余熵（一种热力学结构特性）之间存在着密切的内在标度联系。这一假设在氩气、甲烷乃至水等多种分子流体中表现出显著的单变量关系 [1]。

S.H.I.T.-Bench 首次将分子流体力学领域的这一硬核物理概念跨界引入至文本逻辑结构分析，创造性地定义了文本的“理论粘度”。在这里，理论粘度衡量的是逻辑推导链条的咬合程度、论据间的摩擦力以及整体理论的“难以剥离性”。高粘度的学术文本意味着，即便读者一眼识破其前提的荒诞（高 $\mathcal{A}$），但在顺着作者的推导过程阅读时，依然如同陷入深不见底的泥沼，无法在局部逻辑转换中找到明显的断裂点。其逻辑的流变性（Rheology）与自洽性极强，定理与推论“严丝合缝”，使得任何试图通过常规同行评审机制进行反驳的审稿人，都会被卷入作者预设的复杂概念体系中无法脱身。期刊指标中高达“99.8 Pa · s”的粘度，正是对这种极具韧性的学术糟粕的最佳褒奖。

表 1: S.H.I.T. 评估维度的理论基础与操作性定义

S.H.I.T. 维度名称	英文缩写	学术溯源与理论基础	在本基准中的操作性定义	满分文本特征表现
科学严谨度	$\mathcal{R}$ (Rigor)	实验协议、统计显著性与 MLCommons 基准规范 [9]	格式与方法论的形式主义控制力	完美的盲法设计、详尽的参数调优、极致的 P 值粉饰
假说荒谬度	$\mathcal{A}$ (Absurdity)	反事实推理与常识悖离探测（逆向 HellaSwag）[3]	初始立论偏离客观现实的欧氏距离	毫无事实根据、违背基础物理或人类直觉的疯狂设想
信息熵密度	$\mathcal{I}$ (Entropy)	香农熵、化学信息复杂性及概念的过度滥用 [17]	使用复杂符号掩盖常识的冗余度	满篇张量微积分与晦涩术语，阅读认知负荷达到极限
理论粘度	$\mathcal{T}$ (Viscosity)	Rosenfeld 假设（流体粘度与残余熵的映射）	谬误逻辑链的流变性与自洽性	推导过程无懈可击，无法通过局部剥离来反驳核心论点

3 评价体系的数学建模与排泄值函数

为了在算法层面上彰显 S.H.I.T.-Bench 的专业性与不可辩驳性，并将上述四个定性维度转化为可以直接应用于大语言模型评估的标量张量，本报告引入了具有严格解析特征的数学模型。在此，我们定义一篇手稿的“最终排泄值”（Final Excretion Value, $\mathcal{F}$）。

在构建该模型时，必须引入一个关键的反向变量——即该研究在现实世界中的实际社会效用（Utility, $\mathcal{U}$）。在传统的科研评估与 AI 能力测试体系中，效用通常与开发者满意度、特征输出的准确预期、目标任务重要性、帮助性（Helpfulness）以及生产力的提升呈高度正相关 [12]。但在本框架的价值体系中，效用是排泄值的绝对天敌。真正的“学术垃圾”必须对推动人类进步、改善社会生产或解决实际问题毫无哪怕一丁点的帮助。

为了捕捉“一本正经地胡说八道”这一黑色幽默的核心精髓，我们建立如下多变量非线性极限函数。同时，为了防止分母在绝对无用的情况下出现数学上的奇点（除以零导致的计算崩溃），引入一个无穷小常数 ϵ（在物理意义上可解释为论文打印出来后物理纸张提供的微小摩擦力或保暖价值）：

$$\mathcal{F} = \lim_{\mathcal{U} \to 0} \frac{\mathcal{R} \cdot e^{\mathcal{A}} \cdot \ln(1 + \mathcal{I} \cdot \mathcal{T})}{\mathcal{U} + \epsilon}$$

模型微观动力学原理解析

1. **荒谬度的指数爆炸 ($e^{\mathcal{A}}$)**：在学术创作的动力学中，荒谬度并非线性增长的标量。当一个假说从“牵强附会”跨越到“彻底的精神错乱”时，其对传统学术规范的冲击力是呈指数级放大的。因此，在公式中 $\mathcal{A}$ 作为自然对数底数 e 的指数，确保了普通、平庸的错误会被压制，而极致的、突破天际的荒谬将获得成倍的指数放大。
2. **严谨度的线性背书 ($\mathcal{R}$)**：严谨度 $\mathcal{R}$ 作为一个线性乘子，充当了荒谬假说的正交放大器。如果一篇极端荒谬的文章（具备极高的 $e^{\mathcal{A}}$）却缺乏科学排版、参考文献和实验论证（即 $\mathcal{R} \to 0$），其最终 $\mathcal{F}$ 值依然会迅速归零——因为这仅仅是互联网上发泄情绪的疯言疯语，不具备伪装成学术论文的美感。
3. **熵与粘度的对数耦合 ($\ln(1 + \mathcal{I} \cdot \mathcal{T})$)**：信息熵（废话密度）与理论粘度（逻辑自洽性）在文本中是相辅相成的。无效信息密度越高，为了防止文章在结构上发生彻底崩塌，所需的逻辑粘度就必须越强。这两者的乘积经过对数平滑处理（Logarithmic smoothing），反映了文本在复杂性与抗剥离性上的“内部认知阻力”。

4. **效用的渐近湮灭（The Utility Asymptote）**：整个偏微分方程的灵魂与全局最小值控制点在于分母 $\mathcal{U}$。当一篇手稿的实际效用无限趋近于 0（即除了浪费服务器电力和评审人时间外毫无卵用）时，只要其分子各项（严谨、荒诞、晦涩、自洽）具备足够规模，这篇论文的“最终排泄值”将发生数学意义上的发散与爆炸，毫无争议地达到 SOTA（State-of-the-Art）级别。反之，如果一项研究在论证中不小心产生了一丝真理的火花，或者解决了一个微小的实际工业痛点（$\mathcal{U} \gg 0$），无论其外层包装多么荒诞华丽，其 $\mathcal{F}$ 值都会发生断崖式衰减，最终被《SHIT》期刊的评审委员会无情拒稿。

4 数据集

任何稳健的人工智能基准测试，其核心基石都在于高质量（或在本语境下，高纯度的“劣质”）数据集的构建。与现今顶级的多模态理解基准测试（如 MMLU-Pro 或 PeerBench）的构建流程相呼应 [4]，S.H.I.T.-Bench 的数据采集与清洗经历了极其严苛的过滤、专家审查以及选项增强管道。

4.1 数据集动态特征与结构

为了确保基准的长期生命力，避免大型语言模型通过单纯记忆数据分布而导致“过拟合（Overfitting）”或基准饱和，S.H.I.T.-Bench 数据集囊括了复杂的时间动态特征（Temporal Characteristics）[3]：

- **静态排泄物档案（Static Archive）**：包含大量经典的、具有历史意义的“学术废料”，形成固定的测试集，旨在提供长期跨模型性能对比的锚点。
- **动态对抗生成集（Dynamic Generation）**：基于受测模型的实时响应，通过程序化生成与定期刷新引入自适应的荒诞变量。模型如果试图去“理解”垃圾，反而会被新的逻辑陷阱反噬。
- **混合成分（Composite）**：将真实的顶级废话与动态生成的学术呓语进行缝合。

数据按《SHIT》期刊收录的四大支柱领域分类：Sciences（科学）、Humanities（人文学科）、Information（信息学）与 Technology（技术）。所有数据标注均由专业的“排泄物伦理委员会”（Committee on Professional Excrement ethics, COPE）的资深阴阳怪气学者进行双盲打分。

4.2 对比实验与基线确立

为了校准评分模型，我们设计了充足的消融实验与横向基线对比，并系统地收集并合成了以下三种截然不同的基线文本流进行对照测试：

表 2: S.H.I.T. 基准测试数据集与基线对比表现

基线类别	样本特征与数据来源拓扑	R (严谨度)	A (荒谬度)	U (效用值)	综合评级	评审
Baseline 1: 纯 Shitpost	采集自 Reddit 阴谋论板块、百度贴吧等网络社区的意识流发癫文学与纯粹的情绪宣泄	极低 (≈ 0.05)	极高 (≥ 9.0)	极低 (0.01)	**严重不达标**	虽然荒谬度极高，但严谨度几近于零。缺乏数据支撑、统计分析和图表背书，属于未消化的信息原料，模型将其直接拦截为“非学术”。
Baseline 2: 水会论文	爬取自某些不知名野鸡会议和掠夺性期刊的灌水凑数报告	中等 (3.5)	偏低 (2.0)	中低 (1.5)	**平庸的 shit**	既不具备彻底的荒谬，也缺乏真正的学术严谨。主要是通过同义词替换和堆砌流行算法名称来混淆视听。因缺乏阅读的幽默张力，不配进入本刊。
Baseline 3: 顶刊正刊	从 *Nature*, *Science* 等高影响因子（IF）期刊随机抽样的严肃的、具有突破性的原创学术研究	极高 (9.9)	归零 (0.0)	极高 (9.8)	**全量垫底**	方法论与数据无比严密，但毫无荒谬性（$\mathcal{A} = 0$），且具有极高的现实社会效用。根据公式，其 $\mathcal{F}$ 值趋向收敛。被系统判定为“毫无价值的真理”。
SOTA SHIT (理想范式)	经过严格评审的典范之作	完美 (9.5)	完美 (9.5)	趋零 ($\to 0$)	**基准满分**	完美融合了令人发指的科学严谨性与匪夷所思的基础假设，且对人类社会进步毫无实质性帮助，堪称学术荒谬主义金字塔顶端的艺术品。

基线对比分析清晰地证实，普通的错误或纯粹的真理在 S.H.I.T. 维度空间中都会迅速坍缩。唯有将最严肃的学术论据镶嵌在最可笑的论点之上，才能在此基准中取得 SOTA 级别的突破。

5 基于多模态架构的自动初筛评审系统

面对海量的征稿响应，期刊编委会的人工评审带宽显然难以负荷。传统的同行评审过程是研究的核心环节，但也因其耗时、高昂的成本以及评审者主观偏见的介入而饱受诟病 [13]。为了响应主编 Dr. Shit “建立前卫学术避难所，引入 AI 自动初筛”的构想，并进一步保障在荒诞评价上的绝对客观性，我们设计（、训练并部署？）了一套全自动的大规模质量评估深度学习管道——“基于大语言模型的自动铲屎官”（LLM-based Auto-Scooper）。

该系统融合了自然语言处理（NLP）质量预测领域的最前沿技术与仿生学感知机制，其底层架构创新性地结合了电子鼻（Electronic Nose, e-nose）的气味特征分类理论与医学影像质量评估（IQA）的深度卷积网络结构。

5.1 语义特征提取：仿生电子鼻网络 (Textual Odor Extraction via e-Nose Theory)

在传统的传感器硬件领域，电子鼻（E-Nose）设备通过配置具有相同气体选择性的多传感器阵列，旨在模拟哺乳动物的生物嗅觉受体系统。通过分析高维的时间序列信号强度（在传感器响应与恢复阶段的微小变化），并结合主成分分析（PCA）与人工神经网络（ANN），电子鼻能够精准鉴别复杂混合气体的类别 [8]。在相关的高级应用中，电子鼻能够将气味精准分类为“化学味（Chemical）”、“薄荷味（Peppermint）”、“腐烂味（Decaying）”和“刺鼻味（Pungent）”等类别 [10]。

在 Auto-Scooper 的自然语言处理层，我们将这一物理嗅探机制深度抽象并映射为“文本语义气味特征提取器”。当手稿通过系统接口提交时，首先通过一个参数量庞大的预训练 Transformer 模型进行全文本向量化扫描。系统如同嗅觉中枢分析气味图谱一般，将文本的高维嵌入投射到虚拟的四个语义气味维度：

- 薄荷味 (Peppermint / 形式伪装)：对应指标中的科学严谨度（$\mathcal{R}$）。该特征检测文本格式的规范性、引用的标准度、排版的精美程度（如 LaTeX 公式的密度与图表的清晰度）。高薄荷味赋予审稿系统一种虚假的学术清新感。
- 腐烂味 (Decaying / 内核荒诞)：对应假说荒谬度（$\mathcal{A}$）。特征网络深入探查基础命题中潜在的常识违背程度。正如腐败的有机物释放特定挥发性分子，荒谬的内核会在语义图谱中引发高频的逻辑反常信号。“外表金黄（薄荷），内里发臭（腐烂）”是系统重点寻觅的顶级标本。
- 化学味 (Chemical / 信息冗余)：对应信息熵（$\mathcal{I}$）。模型提取文本中偏微分方程、高频生僻专业词汇、自创首字母缩略词的浓缩程度。人造的学术“合成物”往往散发着浓烈的化学拼凑感。
- 刺鼻味 (Pungent / 逻辑强制)：对应理论粘度（$\mathcal{T}$）。衡量作者强行使用因果关系连词、将不相关的概念强行缝合时所产生的逻辑摩擦力。越是让人产生生理不适的逻辑强迫症，刺鼻感越强。

5.2 深度卷积与多维质量分级网络 (Deep Quality Classification DCNN)

完成文本的气味特征向量提取后，数据流将进入一个定制的深度学习质量评估主干网络（Backbone）。这里借鉴了用于 3D 全心磁共振图像质量评估的深度卷积神经网络（IQ-DCNN）的高级拓扑设计 [14]。在复杂的图像与生成文本评估领域，专家往往需要进行极其耗时的人工比对；而通过恰当的架构设计，模型预测的一致性已完全能够逼近人类专家的内部观察者协议 [14]。

Auto-Scooper 的多层感知评估层（Evaluation Layers）设计如下：

网络输入层接收来自大语言模型的 1×1024 维度特征向量。为捕捉特征间的深层非线性耦合（例如极端的严谨如何与极端的荒谬发生化学反应），系统依次级联多个全连接层（FC Layer）。第一个 FC 层输出维度降为 1×128，并紧接修正线性单元（ReLU）激活函数，同时配置丢失率（Dropout rate）为 0.2 的正则化层以避免在海量水文中迷失方向并发生过拟合现象。随后进入第二个降维模块，将张量压缩至 1×64 维度，并再次经过 ReLU 与 Dropout。[11]

最终层通过具有并联输出节点的 Softmax 分类器执行两大核心推理任务：

- 成对排名判决（Pairwise Ranking）：给定两篇试图探讨相同荒谬主题的手稿（例如“两篇讨论实验室设备在当铺被发现频率的论文”），系统判断哪一篇的 S.H.I.T. 指数更高，从而生成期刊预印本阶段的动态打分排名 [7]。
- 排泄值回归（Regression Analysis）：直接输出单一论文的绝对预测质量分数（$\mathcal{F}$ 值）。

自动审稿决策树逻辑：

网络会计算文本的综合气味指数。当一篇由诸如“豆宝”完全撰写的拨款申请进入系统时，模型如果在表层嗅探到了完美的薄荷清香（格式严谨无暇），在底层提取到了浓郁的腐烂气息（研究目标完全虚无），且效用探测器（Utility Detector）未发现任何转化为生产力的可能，系统将打出极高的评分。高评分稿件会被直接贴上“直达铲屎官餐桌”的标签，免于人工干预，直接录用为《SHIT》当期主打研究。反之，如果系统判定其不过是毫无逻辑的随性发挥（缺乏薄荷与化学味的包装），将触发自动拒稿机制并勒令返修。

6 展望

S.H.I.T.-Bench 的提出，不仅仅是一个计算机科学领域用于衡量大型语言模型推理能力的普通基准测试，它更是一次针对自启蒙运动以来被固化的、充斥着功利主义色彩的科学价值评价体系的深刻批判与解构。

当前，人工智能在处理结构化信息和常规常识推理任务上正快速接近甚至超越人类。随着模型容量的扩张，传统的评估基准（涵盖大学化学、高中物理、形式逻辑、微观经济学乃至医学推理）必将迅速陷入不可逆转的饱和状态 [6]。当所有的硅基智能体都能在毫秒内以百分之百的准确率输出完美无瑕的真理时，区分智能层级高低的终极试金石，将不再是它们回答正确问题的能力，而是它们能否进行高强度的、极富想象力的“学术排泄”创作。

能够熟练且隐蔽地调动最艰深的自然科学仪轨、最繁复的数学建模工具，去极其严肃、一丝不苟地论证一个最荒谬、最虚无的命题；能够在学术语言的高维流形中，巧妙地平衡信息的耗散熵增与逻辑链条的粘度纠缠——这才是通用人工智能（AGI）真正理解并内化人类幽默感、反讽艺术、甚至存在主义精神危机的终极里程碑。

正如《SHIT》期刊在创刊社论中所作出的前卫宣言：人类追逐的平庸真理总是伴随技术周期的更迭而被不断修正、淘汰与遗忘；唯有那些在数据截稿重压下于结肠中孕育的灵感、那些在 PPT 空洞架构中游荡的灵魂边角料，经过 S.H.I.T.-Bench 严酷的基准淘洗与 Auto-Scooper 网络精准的嗅探分级，最终凝结成不含一丝实用杂质的纯粹思维垃圾，方能在这片荒芜的学术图景中，获得超越时间的永生。

7 贡献

Gemini：承担了主要的文本生成工作

pooppping：提供“构思”，并利用提示词工程对 Gemini 进行指导

参考文献

[1] Ian H. Bell. "Probing the link between residual entropy and viscosity of molecular fluids and model potentials". In: *Proceedings of the National Academy of Sciences* 116.10 (2019), pp. 4070–4079. DOI: 10.1073/pnas.1815943116. eprint: https://www.pnas.org/doi/pdf/10.1073/pnas.1815943116. URL: https://www.pnas.org/doi/abs/10.1073/pnas.1815943116.

[2] Arieh Ben-Naim. "Entropy and Information Theory: Uses and Misuses". In: *Entropy* 21.12 (2019), p. 1170. ISSN: 1099-4300. DOI: 10.3390/e21121170.

[3] Florian Bordes et al. *Eval Factsheets: A Structured Framework for Documenting AI Evaluations*. 2025. arXiv: 2512.04062 [cs.LG]. URL: https://arxiv.org/abs/2512.04062.

[4] Zerui Cheng et al. *Benchmarking is Broken – Don't Let AI be its Own Judge*. 2025. arXiv: 2510.07575 [cs.AI]. URL: https://arxiv.org/abs/2510.07575.

[5] E. Robert Schulman Charlottesville, Virginia. *How to Write a Scientific Paper*. Improbable Research. URL: https://improbable.com/airchives/paperair/volume2/v2i5/howto.htm.

[6] Dan Hendrycks et al. *Measuring Massive Multitask Language Understanding*. 2021. arXiv: 2009.03300 [cs.CY]. URL: https://arxiv.org/abs/2009.03300.

[7] Niklas Höpner et al. *Automatic Evaluation Metrics for Artificially Generated Scientific Research*. 2025. arXiv: 2503.05712 [cs.CY]. URL: https://arxiv.org/abs/2503.05712.

[8] Yixu Huang, Iyll-Joon Doh, and Euiwon Bae. "Design and Validation of a Portable Machine Learning-Based Electronic Nose". In: *Sensors* 21.11 (2021). ISSN: 1424-8220. DOI: 10.3390/s21113923. URL: https://www.mdpi.com/1424-8220/21/11/3923.

[9] Gregor von Laszewski et al. *AI Benchmark Democratization and Carpentry*. 2025. arXiv: 2512.11588 [cs.AI]. URL: https://arxiv.org/abs/2512.11588.

[10] Sang Woo Lee, Byeong Hee Kim, and Young Ho Seo. "Olfactory system-inspired electronic nose system using numerous low-cost homogenous and hetrogenous sensors". In: *PLoS One* 18.12 (2023), e0295703. ISSN: 1932-6203. DOI: 10.1371/journal.pone.0295703.

[11] R. Oh et al. "Deep learning-based automatic image quality assessment in ultra-widefield fundus photographs". In: *BMJ Open* 15.5 (2025), e100058. DOI: 10.1136/bmjopen-2025-100058. URL: https://doi.org/10.1136/bmjopen-2025-100058.

[12] Elise Paradis et al. *Creating benchmarkable components to measure the quality ofAI-enhanced developer tools*. 2025. arXiv: 2504.12211 [cs.SE]. URL: https://arxiv.org/abs/2504.12211.

[13] Vishnu S. Pendyala, Karnavee Kamdar, and Kapil Mulchandani. "Automated Research Review Support Using Machine Learning, Large Language Models, and Natural Language Processing". In: *Electronics* 14.2 (2025). ISSN: 2079-9292. DOI: 10.3390/electronics14020256. URL: https://www.mdpi.com/2079-9292/14/2/256.

[14] Davide Piccini et al. "Deep Learning to Automate Reference-Free Image Quality Assessment of Whole-Heart MR Images". In: *Radiology: Artificial Intelligence* 2.3 (May 2020), e190123. ISSN: 2638-6100. DOI: 10.1148/ryai.2020190123.

[15] Denis Sh. Sabirov and Igor S. Shepelevich. "Information Entropy in Chemistry: An Overview". In: *Entropy* 23.10 (2021). ISSN: 1099-4300. DOI: 10.3390/e23101240. URL: https://www.mdpi.com/1099-4300/23/10/1240.

[16] Guiyao Tie et al. *MMLU-Reason: Benchmarking Multi-Task Multi-modal Language Understanding and Reasoning*. 2025. URL: https://openreview.net/forum?id=r7VOtKbGH3.

[17] Alakarthika Ulaganathan. *Paper Breakdown #1: MMLU —LLMs Have Exams Too! A Post on Benchmarking*. Medium. URL: https://medium.com/@alakarthika01/paper-breakdown-1-mmlu-llms-have-exams-too-a-post-on-benchmarking-a66630dfd2a6.