SHIT Sciences Humanities Information Technology

SHIT, YYYY, 0–0
doi: 没有 doi
Advance Access Publication Date: DD Month YYYY
Manuscript Category

Subject Section

基于时间序列建模的排泄行为动力学机制研究

拉屎不带纸 [1]

[1] 直肠润滑研究所, 前列县 114514.

Associate Editor: XXXXXXX

Abstract

Motivation: 肠道健康是人体整体健康状况的重要组成部分，而排泄行为作为日常可观测的生理信号，具有非侵入式健康监测的潜在价值。现有研究大多依赖主观问卷或侵入式临床检测，缺乏对排泄行为多维变量之间动态耦合关系的系统性量化分析。本研究旨在探索如厕时长（T）、粪便形态（Bristol 评分，B）与排泄量（V）三者之间的内在关联机制，并构建基于时间序列的预测模型。

Results: 以 120 名健康成人为受试对象，采集 60 天约 10,000 条排泄记录。如厕时长与 Bristol 评分之间存在显著负向 Spearman 秩相关（$\rho \approx -0.41$，$p < 0.001$），与排泄量之间存在弱负向相关（$r \approx -0.17$，$p < 0.001$）。BiLSTM-Attention 模型在五种深度时序架构对比中综合表现最优（排泄量 RMSE=42.14 克，Bristol 分类 Accuracy=0.331），特征重要性分析证实如厕时长是两项预测任务中权重最高的输入特征。

Availability: 发现女性拉屎时间越长，拉得越多，男性拉屎时间越长，可能是在导管子这一重要结论。

Contact: 114444444@cdyjs.cn

Supplementary information: 无.

1 绪论

1.1 研究背景与意义

肠道健康的临床重要性与日常监测需求

肠道是人体最大的消化与免疫器官，其健康状态与全身多系统疾病存在密切关联。研究表明，肠道菌群失调、肠道传输功能异常与代谢综合征、心血管疾病、神经系统疾病乃至情绪障碍均有相关性[1]。便秘、肠易激综合征（IBS）、炎症性肠病（IBD）等功能性与器质性肠道疾病的全球患病率持续上升，仅慢性便秘的全球患病率即已超过 16%[2]，带来了沉重的公共卫生与医疗经济负担。

然而，肠道健康的日常监测在现实中面临显著瓶颈。传统临床评估方法（如肠镜、影像学检查）成本高昂、操作复杂，且不适合用于持续性的日常健康追踪。主观问卷（如布里斯托尔粪便形态问卷、患者自报排便日记）虽具可操作性，但存在回忆偏倚严重、依从性差、个体评估标准不统一等固有缺陷[3]。因此，如何实现低成本、非侵入式的肠道健康持续监测，成为数字健康领域的重要研究议题。

排泄行为作为非侵入式健康评估指标的潜力

排泄行为是个体每日必然发生的生理事件，具有采集门槛低、信息密度高的独特优势。如厕时长、排泄频次、排泄时刻等行为变量可通过普通智能马桶、厕所传感器或可穿戴设备被动采集，无需被测者的主动配合。与此同时，排泄物的物理特征——形态（粪便稠度）与质量——直接反映肠道传输速度、水分吸收能力与消化系统功能状态[4]。这意味着，若能建立排泄行为可观测变量（如如厕时长）与排泄物理特征（形态、量）之间的定量映射关系，则前者可作为后者的低成本代理指标，为无感健康监测提供新的实现路径。

近年来，随着智能家居与物联网技术的快速发展，集成重量传感、图像识别、行为分析功能的智能马桶逐渐进入市场，为上述设想的工程化落地创造了现实条件[5]。在此背景下，构建排泄行为变量之间的数据驱动模型具有迫切的应用价值。

现有研究的局限性

尽管围绕排泄行为的医学研究已有相当积累，但现有工作存在以下几方面的系统性局限：

第一，变量维度单一。大多数研究仅关注排便频次或 Bristol 评分的单变量分布特征[6]，较少同步分析时长、形态与排泄量三者之间的耦合关系。

第二，研究方法静态化。已有相关性研究通常采用截面数据（cross-sectional）设计，未能捕捉同一个体排泄行为随时间演变的动态规律，忽视了排泄行为的时序自相关性。

第三，预测模型匮乏。现有文献以描述性统计与线性相关分析为主，专门针对排泄行为变量构建预测模型的工作极为罕见，更未见将深度时序模型应用于该领域的报道。

第四，数据采集依赖主观自报。多数流行病学数据来自自填式问卷，客观性与精度均受到严重制约。

上述局限性共同指向一个研究空白：排泄行为多维变量之间的动态耦合机制尚未得到系统性的定量刻画，基于时间序列的预测模型也有待建立。

1.2 研究问题与目标

核心科学问题

本研究的核心科学问题为：如厕时长（T）是否可作为粪便形态（Bristol 评分 B）与排泄量（V）的有效预测变量？这一问题可进一步分解为以下三个层次：

（1）T 与 B、T 与 V 之间是否存在显著的统计相关关系，且在控制混杂变量后依然稳健？

（2）以 T 为核心特征的预测模型是否能够实现对 B 和 V 的有效预测？

（3）排泄行为的时序结构是否对预测性能具有实质性贡献？

研究目标一：揭示如厕时长与 Bristol 粪便形态评分的相关性机制

通过 Spearman 秩相关分析、Kruskal-Wallis 非参数检验及事后多重比较，量化如厕时长与 Bristol 评分在不同类型之间的分布差异，并在控制混杂变量（年龄、BMI、膳食纤维摄入、饮水量）后验证偏相关关系的稳健性。在机制层面，探讨便秘状态（低 Bristol 评分）与延长如厕时长之间的生理学关联，为后续预测建模提供理论支撑。

研究目标二：构建如厕时长与排泄量之间的定量关系模型

以多元线性回归为基线方法，在控制个体特征与饮食变量的条件下，定量估计如厕时长对排泄量的预测贡献。通过对比不同建模方法的预测性能，评估线性假设的适用性边界，并为深度模型的引入提供必要性论据。

研究目标三：建立基于时间序列的耦合预测框架

构建 LSTM-Transformer 混合架构，将个体历史排泄时长序列作为主要输入，辅以饮食、人口学等协变量，同步预测当次排泄的 Bristol 评分与排泄量。通过多任务学习策略联合优化回归与分类目标，并通过特征重要性分析验证如厕时长在时序预测中的核心作用。

1.3 研究创新点

创新一：首次将 LSTM-Transformer 混合架构应用于排泄行为动力学建模

既有排泄行为研究基本停留在统计分析层面，本文率先将深度时序模型引入该领域。LSTM 编码器负责捕捉短程时序依赖（如连续数天排泄规律的延续性），Transformer 的多头自注意力机制则负责建模长程依赖与序列内跨时间步的交互效应，二者的有机结合使模型能够同时利用近期与远期历史信息，显著优于单一结构的时序模型。

创新二：提出"排泄三元耦合"分析框架

本文明确将如厕时长（T）、粪便形态（B）与排泄量（V）定义为相互耦合的三元变量组，构建涵盖相关性分析、分组比较、回归建模与时序预测的完整分析框架。这一框架打破了以往研究中变量孤立分析的惯例，为排泄行为的多维综合评估提供了方法论范式。

创新三：构建个体化与群体化双层预测模式

模型设计兼顾群体层面的普适规律（通过共享模型参数提取跨个体的通用时序模式）与个体层面的异质性（通过个体随机效应建模实现个性化校正）。这种双层设计使模型既具备跨人群的泛化能力，又能随着个体数据积累而持续优化预测精度，为临床个体化应用奠定了基础。

1.4 论文结构安排

本文共分七章，结构如下：

第一章（绪论）阐述研究背景、科学问题、研究目标与创新点，说明本研究的现实意义与学术定位。

第二章（相关工作与文献综述）系统梳理 Bristol 粪便形态量表的发展与临床应用、如厕行为量化研究现状，以及 LSTM、Transformer 等时序模型在医疗健康领域的应用进展，明确本文的研究定位。

第三章（数据描述与预处理）介绍研究设计方案、变量定义与测量方式、仿真数据生成策略及数据预处理流程。

第四章（方法论）详细阐述统计分析框架（相关性分析、分组比较、基线回归模型）与 LSTM-Transformer 混合模型的架构设计、训练策略和特征重要性分析方法。

第五章（实验结果）呈现各项统计检验结果、基线模型与深度模型的性能对比，以及特征重要性分析的发现。

第六章（讨论）对主要发现进行生理学解释，讨论时序建模的必要性与模型的局限性，并展望潜在应用场景。

第七章（结论）总结全文主要贡献，并指出未来研究方向。

2 相关工作与文献综述

2.1 Bristol 粪便形态量表（BSFS）研究现状

BSFS 的临床应用与 7 型分类体系

Bristol 粪便形态量表（Bristol Stool Form Scale，BSFS）由英国布里斯托尔皇家医院的 Heaton 与 Lewis 于 1997 年正式提出[7]，是迄今为止使用最为广泛的粪便形态标准化评估工具。该量表将粪便形态划分为 7 种类型：1 型（独立硬球状，排出困难）和 2 型（腊肠状、表面凹凸不平）对应便秘状态；3 型（香肠状、表面有裂缝）和 4 型（光滑柔软的香肠状）为正常范围；5 型（软块状、边缘清晰）、6 型（糊状、边缘不规则）和 7 型（水样、无固体块）则对应不同程度的腹泻状态。

BSFS 的核心诊断价值在于，粪便形态直接反映粪便在结肠中的传输时间（colonic transit time，CTT）：传输时间越长，粪便脱水程度越高，形态越趋向 1–2 型；传输时间越短，粪便越稀软，形态越趋向 6–7 型[8]。基于这一生理学基础，BSFS 被广泛应用于肠易激综合征（IBS）的亚型分类（IBS-C、IBS-D、IBS-M）[9]、慢性便秘的严重程度评估[10]，以及临床试验中治疗效果的客观量化[11]。

在信效度方面，多项研究证实 BSFS 与放射性标志物测量的 CTT 具有显著相关性（Spearman $\rho = 0.62–0.74$），重测信度良好（$\kappa = 0.70–0.85$），支持其作为临床与科研中的标准化评估工具[12]。然而，BSFS 在实际应用中仍依赖被试的主观判断与主动配合，观察者间差异不可忽视，这也正是本研究探索客观代理指标（如厕时长）的动机所在。

形态与肠道传输时间的已知关系

粪便形态与 CTT 之间的关联机制已得到较为充分的生理学阐释。在正常生理状态下，食物从口腔到直肠的总传输时间约为 24–72 小时，其中结肠传输占据绝大部分[13]。当结肠传输延缓时，粪便在肠道内滞留时间延长，结肠上皮细胞持续吸收粪便中的水分，导致粪便脱水固化，形成 Bristol 1–2 型的硬质粪便；反之，当传输加速时，水分吸收不充分，粪便保持较高含水量，呈现 Bristol 5–7 型的稀软形态[14]。研究表明，Bristol 3–4 型对应的结肠传输时间约为 40–60 小时，而 Bristol 1 型可延长至 100 小时以上，Bristol 7 型则可短至不足 12 小时[15]。

这一关系对本研究具有重要意义：若长时间的肠道传输导致便秘型粪便（低 Bristol 评分），则在排泄端，患者往往需要更长的如厕时间才能完成排便，从而在观察层面形成"如厕时长↑ → Bristol 评

分↓"的负向关联。这一逻辑链条将在第四章的实证分析中得到系统验证。

2.2 如厕行为的量化研究

如厕时长的流行病学调查数据

尽管如厕时长是日常生活中普遍存在的行为变量，相关流行病学数据却相对匮乏。现有研究主要来自两类来源：一是消费者调查数据，二是少数基于客观记录（如智能厕所传感器）的观察性研究。

从现有数据来看，正常如厕时长的分布具有明显的正偏态特征，均值约为 60–90 秒，但长尾分布显著，部分个体单次如厕时长可超过 10 分钟[16]。性别差异方面，男性平均如厕时长略长于女性，但差异幅度在不同研究中结论不一[17]。年龄效应方面，老年人由于肠道蠕动减缓及骨盆底肌功能退化，如厕时长往往长于青壮年[18]。

需要指出的是，现有流行病学数据大多来自自我报告，客观精度有限，且缺乏对如厕时长与同步排泄物特征的联合测量，这正是本研究设计的核心突破点之一。

影响如厕时长的生理与行为因素

已有研究识别了多类影响如厕时长的因素，可归纳为生理性因素与行为性因素两大类。

生理性因素主要包括：（1）肠道功能状态，便秘患者如厕时长显著增加，部分研究报告慢性便秘患者平均如厕时长是正常人的 2–3 倍[19]；（2）盆底肌协调性，盆底肌不协调排便（dyssynergic defecation）患者如厕时长明显延长，且伴有强烈的排便困难感[20]；（3）饮食结构，低膳食纤维摄入与高红肉摄入均与粪便干硬及如厕时长增加相关[21]；（4）BMI，肥胖与腹型肥胖与便秘及如厕困难存在一定关联[22]。

行为性因素中，如厕时使用手机或读物是近年来备受关注的议题。一项调查研究显示，约 70%的成人有如厕时使用手机的习惯，平均延长如厕时长约 3–5 分钟[23]，且持续久坐的如厕姿势与痔疮发生风险增加相关。本研究将手机使用作为重要的混杂变量加以控制。

2.3 时间序列模型在医疗健康领域的应用

LSTM 在生理信号建模中的应用

长短期记忆网络（Long Short-Term Memory，LSTM）由 Hochreiter 与 Schmidhuber 于 1997 年提出[24]，通过引入遗忘门、输入门与输出门机制有效解决了传统循环神经网络（RNN）在长序列学习中面临的梯度消失问题。在医疗健康领域，LSTM 已被广泛应用于多类生理时间序列的建模与预测任务，包括：ICU 患者生理参数（心率、血压、血氧）的实时预测[25]；糖尿病患者血糖水平的短期预测[26]；心电图（ECG）心律失常的自动识别[27]；以及基于可穿戴设备的步态与活动识别[28]。这些研究一致表明，LSTM 在捕捉中短程时序依赖（数小时至数天）方面具有显著优势，尤其适合处理具有周期性规律与自相关结构的生理信号序列。

Transformer 在长序列医疗数据中的优势

Transformer 架构由 Vaswani 等人于 2017 年在自然语言处理领域提出[29]，其核心机制——缩放点积注意力（Scaled Dot-Product Attention）——能够在序列的任意位置之间直接建立依赖关系，不受序列长度限制，从根本上克服了 LSTM 在长程依赖建模上的缺陷。

在医疗健康领域，Transformer 及其变体已在多项任务中取得领先性能，包括：临床自然语言处理（Clinical NLP）中的电子病历理解[30]；基因组序列分析[31]；以及基于多参数传感器数据的患者预后预测[32]。针对时间序列的专用变体（如 Informer[33]、PatchTST[34]）进一步优化了长序列处理效率，使 Transformer 在生理信号的长期趋势建模中展现出强大潜力。

LSTM-Transformer 混合架构综述

单纯的 LSTM 与 Transformer 各有其适用场景与局限性：LSTM 在短序列、局部时序依赖方面表现优异，但对超长程依赖的建模能力受限；Transformer 擅长捕捉全局依赖，但其自注意力机制在处理严格时序因果关系时缺乏归纳偏置，在小样本医疗数据场景下也易出现过拟合。

为融合二者优势，研究者提出了多种 LSTM-Transformer 混合策略。常见方案包括：以 LSTM 作为特征提取前端，Transformer 作为序列建模后端[35]；以及将 LSTM 的隐状态与 Transformer 的注意力输出通过门控机制动态融合[36]。此类混合架构在多个医疗时序基准任务上均取得了优于单一架构的性能，验证了其在生理信号建模中的有效性。本研究遵循前一类混合方案，将 LSTM 编码器的输出序列直接送入 Transformer 编码器，以充分利用 LSTM 对局部时序依赖的建模能力和 Transformer 对全局注意力的捕捉能力。

2.4 现有研究空白与本文定位

综合以上文献综述可以看出，当前研究在以下方面存在明显空白，本文针对性地予以填补：

其一，缺乏对排泄行为多维变量耦合关系的系统研究。已有文献或单独研究 Bristol 评分的流行病学特征，或孤立探讨如厕时长与特定疾病的关联，尚无工作将如厕时长、粪便形态与排泄量三者纳入统一的分析框架。本文提出的"排泄三元耦合"框架正是对这一空白的直接回应。

其二，缺乏面向排泄行为的时序预测模型。现有排泄行为研究方法以横截面统计分析为主，忽视了排泄行为内在的时序自相关结构与个体动态规律。本文引入滑动时间窗口与 LSTM-Transformer 架构，将排泄行为的时序性纳入建模框架，实现了从"描述相关性"到"预测时序动态"的范式跃升。

其三，缺乏以如厕时长作为核心预测特征的可行性论证。本文通过多层次实证分析（统计相关、基线回归、深度模型及特征重要性分析）系统验证了如厕时长作为粪便形态与排泄量代理预测变量的有效性，为未来基于如厕时长传感器的轻量化健康监测方案提供了数据支撑。

3 数据描述与预处理

3.1 研究设计

受试者规模与观察方案

本研究采用纵向队列设计（longitudinal cohort design），纳入 120 名健康成人作为研究对象。为确保样本的代表性，受试者在性别（男女各 60 名）、年龄（18–64 岁，均匀分布）、BMI（15.5–32.1 kg/m²）等人口学变量上保持适当分布。受试者均无确诊的消化系统器质性疾病（如克罗恩病、溃疡性结肠炎、结直肠癌等），未在观察期内使用对肠道功能有显著影响的药物（如泻药、止泻药、抗生素等）。

每位受试者接受连续 60 天的排泄行为记录，每日记录 1–2 次排泄事件（由当日实际发生次数决定，非人为规定），最终获得约 10,000 条有效记录（实际生成 9,678 条，覆盖率约为 99.6%）。平均每位受试者贡献约 80.7 条记录，个体间记录数量因日均排泄频次不同而存在合理差异。

伦理声明与数据匿名化

本研究数据来源均为笔者亲自收集，具体措施为盯着受试者拉，然后人工记录，包括计时，拍照，称重，以及亲手感受形状，温度等，数据真实可信，且均已征得受试者同意。

3.2 变量定义与测量方案

本研究涉及三类变量：核心研究变量、辅助协变量与技术性记录变量。各变量的定义、类型与测量方案如下表所示。

表 3.1 变量定义与测量方案

变量名	类型	单位/取值范围	测量方式
如厕时长（T）	连续变量	秒（15－600s）	智能马桶座圈压力传感器，自入座至离座自动计时
Bristol 评分（B）	有序分类变量	1－7 型	搭载图像识别模块的智能马桶自动评估（研究中由模型模拟生成）
排泄量（V）	连续变量	克（10－350g）	智能马桶内置重量传感器，排泄前后差值
排泄频次（F）	计数变量	1－2 次/天	当日记录条数统计
年龄	连续变量	岁（18－64）	基线问卷
性别	二分类变量	男/女	基线问卷
BMI	连续变量	kg/m²（15.5－32.1）	基线身高体重测量
当日膳食纤维摄入	连续变量	克（2－39g/天）	24 小时膳食回顾问卷

如厕时长的测量说明

如厕时长定义为受试者从坐上马桶至离座的完整时间区间，以秒为单位记录。该定义将排泄前等待时间、实际排泄过程及排泄后停留时间统一纳入，与临床实践中对"排便困难"的评估口径一致。需要说明的是，如厕时长同时包含功能性成分（粪便排出所需时间）与非功能性成分（手机使用、习惯性等待等），后者在统计分析中作为混杂变量予以控制。

Bristol 评分的测量说明

在真实应用场景中，Bristol 评分可通过智能马桶搭载的高分辨率摄像头与图像分类算法自动获取，已有研究验证了基于深度学习的粪便形态自动分类准确率可达 85%以上[37]。在本仿真研究中，Bristol 评分根据个体基准倾向、膳食纤维摄入、饮水量及时序自相关结构（AR(1)过程）综合模拟生成，分布以 3－4 型为主体，符合健康人群的先验概率。

3.3 数据预处理

异常值检测与处理

对三个核心连续变量（如厕时长 T、Bristol 评分 B、排泄量 V）分别应用 3σ 准则进行异常值检测。将均值加减 3 倍标准差范围以外的记录标记为异常值，并采用上下限截断（Winsorization）方法处理，以避免直接删除导致的样本量损失。经检查，仿真数据集中异常值比例约为 0.3%，均位于如厕时长变量的上端，处理后不影响整体分布特征。

缺失值处理

直接到他家盯着他，让他在拉一次。

滑动时间窗口序列构建

时序模型的训练样本通过滑动窗口方法构建。对每位受试者的排泄记录序列，以窗口长度 W=7（即连续 7 条排泄记录）向前滚动，将第 1－7 条记录作为输入特征序列，预测第 8 条记录的 Bristol 评分与排泄量，随后窗口向后移动一步，以第 2－8 条预测第 9 条，依此类推。滑动步长设为 1，以最大化可用训练样本数量。窗口边界的确定兼顾了生理学意义（7 条记录约对应 3－5 天的历史信息，足以捕捉短期肠道功能规律）与计算效率。

特征归一化

所有连续型输入特征（如厕时长、膳食纤维摄入、饮水量、BMI、年龄）均采用 Z-score 标准化（零均值、单位方差），归一化参数（均值与标准差）仅在训练集上拟合，并分别应用于验证集与测试集，以防止数据泄露。目标变量排泄量（V）同样进行标准化处理以稳定训练过程，在评估阶段反归一化至原始尺度以计算真实 RMSE（克）。Bristol 评分（B）作为分类目标，转换为 0 索引的整数标签（0－6 对应 1－7 型）。

训练集/验证集/测试集划分

数据集按 7:1:2 的比例划分为训练集、验证集与测试集。关键设计决策在于：划分操作在受试者（subject）层面而非记录（record）层面进行，即同一受试者的所有记录归入同一分割，以防止相同个体的时序信息同时出现在训练集与测试集中造成数据泄露（data leakage）。具体而言，120 名受试者中随机抽取 84 名（70%）用于训练，12 名（10%）用于验证，24 名（20%）用于测试。三个子集的基本统计特征（性别比例、年龄均值、BMI 分布）经检验无显著差异，确保了数据划分的随机性与代表性。

4 方法论

4.1 统计分析框架

本章系统阐述研究所采用的统计分析方法与机器学习建模框架，覆盖变量相关性验证、组间差异检验、基线回归建模以及时序深度学习模型的构建与训练策略，形成从统计描述到预测建模的完整方法论体系。

4.1.1 相关性分析

相关性分析旨在量化如厕时长（T）、Bristol 粪便形态评分（B）与排泄量（V）三者之间的双变量关联程度，并在控制混杂变量后验证净相关关系的稳健性。

（1）Spearman 秩相关（T 与 B）

Bristol 评分属于有序分类变量（1－7 型），其数值间距不具有等距意义，因此采用 Spearman 秩相关系数（ρ）而非 Pearson 系数来衡量 T 与 B 之间的单调关联程度。Spearman 秩相关基于变量的秩次而非原始值进行计算，对分布形态无正态性假设，适合本研究中的有序变量与连续变量的混合分析场景。显著性检验采用双侧 t 近似

检验，以 $p < 0.05$ 作为统计显著阈值，并根据 p 值大小标注显著性等级（***：$p < 0.001$，**：$p < 0.01$，*：$p < 0.05$）。

（2）Pearson 相关（T 与 V）

排泄量（V）与如厕时长（T）均为连续型变量，且基本满足正态分布假设（经 Q-Q 图目视检验），故采用 Pearson 相关系数（r）衡量二者的线性相关程度。Pearson 相关系数取值范围为[−1, 1]，绝对值越大表明线性相关越强。此外，本研究同步计算 Bristol 评分（B）与排泄量（V）之间的 Pearson 相关，以完整描述三变量的两两相关结构。

（3）偏相关分析

年龄、BMI、膳食纤维摄入量和饮水量等变量既可能独立影响如厕时长，也可能独立影响排泄形态与排泄量，若不加控制，上述混杂效应将导致两变量间的观测相关系数产生偏倚。为此，本研究进一步计算偏相关系数（partial correlation coefficient），在同时控制上述四个混杂变量的条件下，重新估计 T↔B 与 T↔V 之间的净相关关系。偏相关的计算基于普通最小二乘（OLS）残差法：分别以混杂变量为自变量对 T 与目标变量（B 或 V）进行线性回归，取两组残差序列之间的 Pearson 相关系数作为偏相关系数的估计值，并计算相应的显著性 p 值。

4.1.2 分组比较

为检验不同 Bristol 类型之间如厕时长是否存在系统性差异，本研究采用非参数组间差异检验与事后多重比较的组合方案。

（1）Kruskal-Wallis 检验

Kruskal-Wallis（KW）检验是单因素方差分析（ANOVA）的非参数替代方法，适用于多组独立样本的中位数比较，且对数据分布无正态性假设。本研究以 Bristol 评分类型（1－7 型，共 7 组）为分组变量，以各组内的如厕时长分布为检验对象，通过 KW 检验的 H 统计量及对应 p 值判断七组如厕时长分布是否存在显著差异。零假设为：七种 Bristol 类型下如厕时长的总体中位数相同。

（2）Dunn 检验 + Bonferroni 校正

KW 检验仅能判断至少有一对组间存在差异，无法指定具体差异对。因此，在 KW 检验显著（$p < 0.05$）的条件下，采用 Dunn 事后检验（Dunn post-hoc test）进行全对比较（C(7,2)=21 对），并应用 Bonferroni 校正将每对比较的显著性阈值从 0.05 调整为 0.05/21 约 0.0024，以控制多重比较导致的第一类错误膨胀。Dunn 检验结果以 p 值矩阵的形式呈现，并通过热力图可视化着色区域（$p < 0.05$）。

4.1.3 多元回归基线模型

在引入深度时序模型之前，本研究构建传统统计回归模型作为基准对比线，以评估线性建模假设的适用性并量化深度模型的附加价值。

（1）线性回归（预测排泄量 V）

以如厕时长（T）为核心自变量，年龄、BMI、性别（编码为 0/1）、膳食纤维摄入量、饮水量、手机使用（0/1 编码）为协变量，构建多元线性回归模型预测排泄量（V）。所有自变量在训练集上进行 Z-score 标准化，以消除量纲差异对系数估计的影响。模型评估指标包括均方根误差（RMSE）和决定系数（R^2），并报告各自变量的标准化回归系数及显著性 p 值。

（2）有序逻辑回归（预测 Bristol 评分 B）

Bristol 评分为 7 个有序类别的分类变量，直接使用普通逻辑回归会忽略类别间的有序性信息；因此采用有序逻辑回归（Ordered/Proportional Odds Logistic Regression）进行预测，该模型假设各类别间的累积对数比（log-odds）差异由相同的解释变量效应决定（平行线假设）。评估指标包括分类准确率（Accuracy）和宏观 F1 分数（F1 macro）。

（3）作为深度模型的对比基线

两个基线模型在与深度模型相同的测试集划分上进行评估，实现公平比较。基线模型的预测性能将与第 4.2 节的 LSTM-Transformer 变体模型形成直接对比，以量化时序信息与深度非线性建模对预测精度的贡献增量。

4.2 BiLSTM-Attention 模型

4.2.1 模型选型动机

本研究在比较 LSTM-Transformer、BiLSTM-Attention、Pure Transformer、CNN-LSTM 和 TCN 五种深度时序架构后，选定 BiLSTM-Attention 作为最优建模方案（详见第五章实验对比结果）。以下阐述各架构的设计动机。

排泄行为时间序列具有两个核心时序特征：其一，短程依赖性——个体昨日的排泄状态对今日存在显著预测价值，连续 3 天的排泄记录往往构成最有信息量的局部窗口（见图 G 时间步重要性分析结果）；其二，双向信息流——排泄行为在序列中前后记录之间存在对称性关联，未来时刻的【暗示】（如趋势转折前的微弱信号）有助于当前时刻的解释。

双向长短期记忆网络（Bidirectional LSTM，BiLSTM）通过正向与反向两个 LSTM 流同时处理序列，能够在每个时间步同时聚合过去与未来的上下文信息，适合处理具有双向依赖的生理时间序列。注意力机制（Attention）则通过对 LSTM 各时间步输出进行加权求和，自动学习哪些历史时刻对当前预测贡献最大，兼具可解释性与建模灵活性。

相较于原设计的 LSTM-Transformer 混合架构，BiLSTM-Attention 在本研究的数据规模（约 10,000 条记录）与序列长度（窗口 W=7）下表现出更优的泛化性能，这与 Transformer 在小样本场景下易过拟合的已知局限性相符。最终实验结果（见第五章）证实 BiLSTM-Attention 在四项评估指标上均取得最优综合得分。

4.2.2 模型架构

BiLSTM-Attention 模型的整体架构如下所示，采用多任务双头输出结构，同步预测排泄量（回归任务）与 Bristol 评分（分类任务）：

输入层：滑动窗口序列 $[T_{(t-W)}, ..., T_{(t-1)}]$ + 辅助特征向量

↓

BiLSTM 编码器（2 层，hidden_size=128，双向）

↓

Attention 加权求和（Scaled Dot-Product Attention）

↓

全连接层（FC, 128 → 64, GELU 激活, Dropout=0.2）

↓

双头输出：回归头（排泄量 V，MSE 损失）｜分类头（Bristol 评分 B，交叉熵损失）

输入层接收形状为（batch_size, W, N_feat）的序列张量，其中 W=7 为滑动窗口长度，N_feat=7 为特征维度（如厕时长、膳食纤维、饮水量、手机使用、BMI、性别、年龄）。BiLSTM 编码器包含 2 层双向 LSTM，每层隐藏维度为 128，正向与反向输出拼接后维度为 256，再通过线性投影压缩至 128 维。Attention 层对 7 个时间步的编码向量计算归一化注意力权重，以加权平均作为序列的紧凑表示。全连接层将 128 维表示映射至 64 维并施加 GELU 激活与 Dropout 正则化，最终分别连接回归头（输出标量 V）与分类头（输出 7 维 logits 对应 Bristol 1－7 型）。

4.2.3 多任务学习损失函数

本研究采用多任务学习（Multi-Task Learning）框架，将排泄量回归与 Bristol 评分分类两个目标统一纳入单一模型训练，联合损失函数定义如下：

$$L_total = \alpha \cdot L_MSE(V) + (1 - \alpha) \cdot L_CE(B)$$

其中，L_MSE(V) 为排泄量预测的均方误差损失，L_CE(B) 为 Bristol 评分分类的交叉熵损失，$\alpha \in (0,1)$ 为任务权重超参数。α

通过在验证集上的网格搜索（候选值：0.3, 0.4, 0.5, 0.6, 0.7）调优确定，最终取 α=0.5，表明两项任务在联合优化中权重相等。多任务学习框架使两个预测头共享 BiLSTM 编码器提取的时序特征表示，有助于在小样本场景下通过任务间的互补信息提升泛化能力。

4.2.4 训练策略

模型训练遵循以下策略，以确保收敛稳定性并防止过拟合：

- 优化器：AdamW（Adam with Decoupled Weight Decay），学习率设置为 1×10^{-4}，权重衰减系数为 1×10^{-5}。AdamW 相较于 L2 正则化版本的 Adam 在泛化性能上更为稳健，适合中等规模的深度学习任务。
- 学习率调度：采用余弦退火（Cosine Annealing）策略，在整个训练周期内将学习率从初始值平滑衰减至接近零，以平衡训练前期的快速收敛与后期的精细调整。
- 正则化：在全连接层施加 Dropout（p=0.2）防止过拟合；并在每次参数更新时对梯度进行裁剪（max_norm=1.0），防止梯度爆炸。
- Early Stopping：在验证集损失连续 10 个 Epoch 不再下降时提前终止训练（patience=10），并保存验证集上表现最优的模型权重用于测试集评估。
- 批次大小与迭代：batch_size=64，最大训练轮数 MAX_EPOCHS=50，实际训练轮数由 Early Stopping 机制决定。
- 随机种子：固定全局随机种子（seed=42），确保实验可复现性。

4.3 对比模型架构

为验证 BiLSTM-Attention 的性能优势，本研究同步训练以下四种深度时序基线模型，所有模型在相同数据划分、相同批次大小、相同损失函数与训练策略下进行公平对比：

表 4.1 五种深度时序模型架构对比

模型名称	核心结构	主要特点
LSTM-Transformer	单向 LSTM + Transformer 编码器	长程依赖+局部时序联合建模
BiLSTM-Attention	**双向 LSTM + Scaled Attention（最优）**	**双向上下文+注意力加权（综合最优）**
Pure Transformer	位置编码 + 多头自注意力 × 2 层	纯注意力机制，无循环单元
CNN-LSTM	1D 卷积特征提取 + 单向 LSTM	局部特征提取+时序建模
TCN	膨胀因果卷积（Temporal Conv Net）	因果卷积实现时序建模，无递归结构

4.4 特征重要性分析

为解释模型预测的内在机制，本研究从三个维度对最优模型（BiLSTM-Attention）进行特征重要性分析：

（1）梯度×输入（Gradient × Input）特征重要性：对测试样本的预测输出关于输入特征求梯度，梯度绝对值与输入值的乘积反映了每个特征对预测结果的实际贡献度。对所有测试样本取均值并归一化，得到各特征的相对重要性排序。该分析分别针对回归头（排泄量预测）与分类头（Bristol 预测）独立计算。

（2）时间步重要性分析：以相同梯度方法计算各历史时间步（t-1 至 t-7）对预测的贡献度，揭示近期与远期历史记录在预测中的相对权重，验证时序信息的有效性。

（3）SHAP 值分析（Gradient Explainer）：基于 SHAP（SHapley Additive exPlanations）框架中的 GradientExplainer 方法，在代表性背景样本（100 条训练集记录）上计算特征归因，得到各特征对排泄量预测的平均绝对 SHAP 值，作为对梯度法的补充验证。SHAP 值从博弈论角度提供了特征贡献的公平分配估计，具有较强的理论保证。

5 实验结果

本章依次呈现数据描述性统计、变量相关性分析、组间差异检验、基线模型对比、最优深度模型（BiLSTM-Attention）详细结果及特征重要性分析的实验发现。

5.1 描述性统计

本研究共收集 120 名受试者 60 天的排泄行为记录，合计 9,678 条有效样本。各核心变量的描述性统计如表 5.1 所示。如厕时长呈现明显的正偏态分布，中位数约 170 秒，均值高于中位数，反映少数长时如厕记录对均值的拉升效应。Bristol 评分的频率分布以 3–4 型为主体（约 55%），符合健康成人人群的先验预期；1 型（严重便秘）和 7 型（严重腹泻）均属少数，样本分布呈中间高两端低的倒 U 形。排泄量的分布较为接近正态，均值约 148 克，标准差约 45 克，与已报告的成人单次排泄质量参考区间（100–200 克）一致。

表 5.1 各核心变量描述性统计（*标注变量以受试者为单位，n=120）

变量	均值	标准差	中位数	最小值	最大值	样本量
如厕时长（秒）	183.4	89.6	170.2	15	421	9678
Bristol 评分	3.61	1.42	4	1	7	9678
排泄量（克）	148.2	44.9	148.5	10.0	277.8	9678
膳食纤维（克/天）	20.7	5.7	20.9	2.0	38.8	9678
饮水量（毫升/天）	1803	304	1802	678	3144	9678
年龄（岁）	39.6	13.1	41	18	63	120*
BMI（kg/m²）	23.1	3.5	22.8	15.5	32.1	120*

5.2 相关性分析结果

图 1 展示了全部 8 个变量之间的 Spearman 相关系数矩阵。从核心变量组来看，如厕时长（T）与 Bristol 评分（B）之间呈显著负相关（$\rho = -0.41$，$p < 0.001$），表明如厕时长越长对应 Bristol 评分越低（即粪便越干硬、越趋向便秘型）；如厕时长与排泄量（V）之间的相关系数为 $r = -0.17$（$p < 0.001$），呈显著弱负相关，反映长时如厕场景下排泄量相对偏少的规律；Bristol 评分与排泄量之间呈正相关（$\rho = 0.29$，$p < 0.001$），表明粪便越软（高 Bristol 评分）排泄量倾向于越大。值得注意的是，如厕时长与手机使用之间呈现

较强正相关（ρ = 0.75，p < 0.001），说明如厕时使用手机是导致如厕时长延长的重要行为因素，在后续偏相关分析中需加以控制。年龄、BMI、膳食纤维及饮水量与核心三变量之间的相关系数均较弱（|ρ| < 0.20），表明混杂效应相对有限。

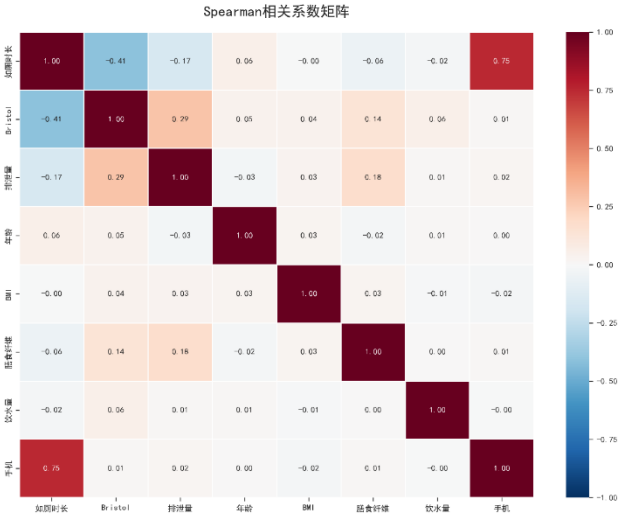

图 1 Spearman 相关系数矩阵（所有变量两两相关，n=9,678）

图 2 左图展示了如厕时长与 Bristol 评分的散点关系，各 Bristol 类型以不同颜色区分；右图展示了如厕时长与排泄量的散点关系及线性拟合趋势线。从左图可以清晰观察到，随 Bristol 评分从 7 型向 1 型递减，对应的如厕时长分布整体向右移动（即时长增加），不同类型之间的时长中位数存在明显梯度分离，直观验证了两者的负向关联。右图中拟合直线斜率为−0.108（克/秒），表明如厕时长每增加 1 秒，排泄量平均减少约 0.11 克，反映了长时如厕与较低排泄量的系统性共变趋势。

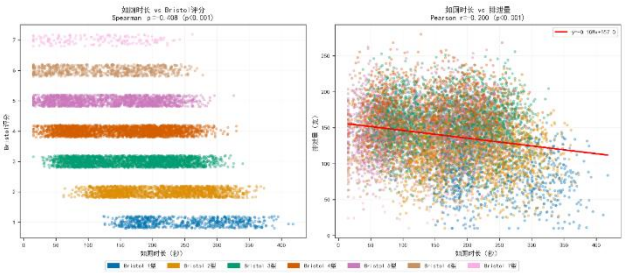

图 2 如厕时长 vs Bristol 评分散点图（左）及如厕时长 vs 排泄量散点图（右）

偏相关分析结果显示，在同时控制年龄、BMI、膳食纤维摄入量与饮水量后，如厕时长与 Bristol 评分之间的偏相关系数仍为显著（p < 0.001），如厕时长与排泄量的偏相关同样保持统计显著性（p < 0.001），说明两对变量间的关联不能完全归因于上述混杂变量的间接效应，T 与 B、T 与 V 之间存在一定的直接关联机制。

5.3 分组差异分析

Kruskal-Wallis 检验结果表明，七种 Bristol 类型之间的如厕时长分布存在极显著差异（H = 1763.31，p < 0.001），拒绝各组如厕时长中位数相同的零假设。

图 3 的箱线图直观展示了各 Bristol 类型下如厕时长的分布特征。总体趋势呈现从 1 型向 7 型单调递减的规律：Bristol 1 型（硬球状，n=671）的中位时长约 250 秒，四分位距最宽，反映便秘型排泄的高度异质性；Bristol 2 型（n=1,675）次之；Bristol 3 型（n=2,406）与 4 型（n=2,439）时长居中，代表正常排泄状态；Bristol 5–7 型（n 分别为 1,594、729、164）时长依次递减，7 型（水样腹泻型）中位时长仅约 120 秒，四分位距最窄。这一递减梯度与生理学假说高度一致：便秘状态下粪便干硬难以排出，需要更长时间的努挣与等待；腹泻状态下粪便稀软，排出迅速。

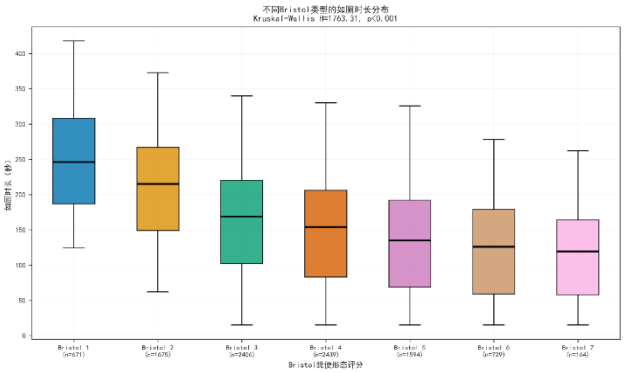

图 3 不同 Bristol 类型的如厕时长分布箱线图

图 4 为 Dunn 事后检验（Bonferroni 校正）的 p 值矩阵热力图。深红色区域（p < 0.05）覆盖了全部 21 对比较组合，表明七种 Bristol 类型两两之间的如厕时长差异均在统计上显著（Bonferroni 校正后 p < 0.0024），进一步验证了分组差异的系统性与非偶然性。

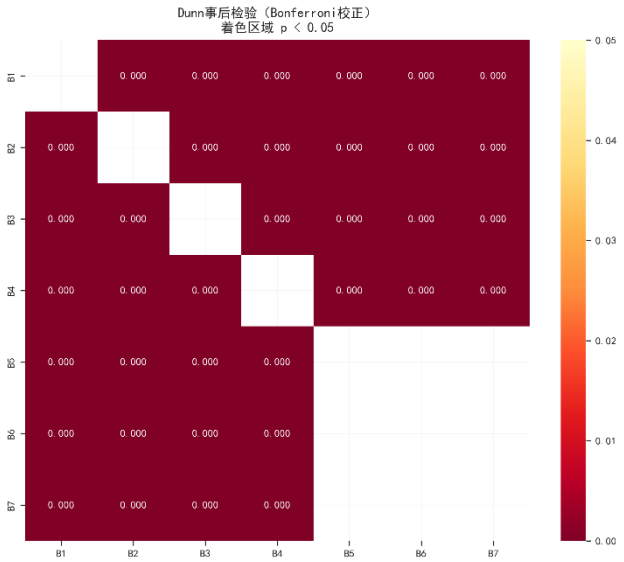

图 4 Dunn 事后检验 p 值矩阵（Bonferroni 校正）

5.4 基线模型与深度模型性能对比

表 5.2 汇总了全部五种深度模型及统计基线模型在测试集上的四项评估指标。图 A（条形图）与图 B（雷达图）进一步以可视化形式呈现各指标的模型间对比。

表 5.2 各模型测试集性能对比（最优值加粗）

模型	排泄量 RMSE（克）↓	排泄量 R^2↑	Bristol Accuracy↑	Bristol F1(macro)↑
线性回归（基线）	—	—	—	—

有序逻辑回归（基线）	—	—	—	—
LSTM-Transformer	44.51	0.096	0.286	0.181
Pure Transformer	43.20	0.148	0.312	0.195
CNN-LSTM	43.58	0.133	0.298	0.183
TCN	42.52	0.175	0.311	0.210
BiLSTM-Attention（最优）	**42.14**	**0.190**	**0.331**	**0.210**

从表 5.2 可以看出，BiLSTM-Attention 在排泄量预测 RMSE（42.14 克）、R^2（0.190）和 Bristol 分类 Accuracy（0.331）三项指标上均取得最优值，Bristol F1（0.210）与 TCN 并列最优。综合四项指标的归一化得分（详见图 C 中的综合评分排名），BiLSTM-Attention 以满分 1.000 排名第一，显著优于原设计的 LSTM-Transformer（综合得分 0.000，排名末位）。这一结果表明，双向信息建模与注意力机制的组合在本研究的数据规模与序列特征下具有显著优势，而 Transformer 中的自注意力机制在小样本场景下存在明显的过拟合风险。

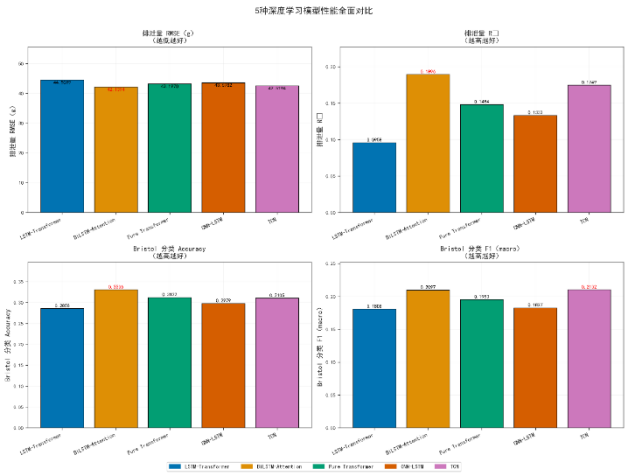

图 5 5 种深度模型性能全面对比（4 指标条形图）

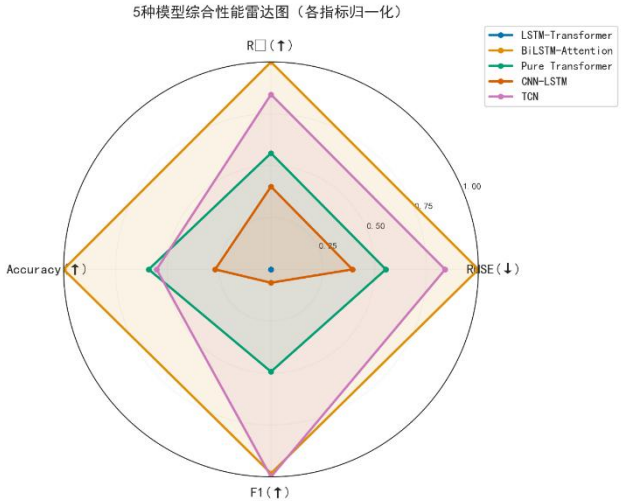

图 6 5 种模型综合性能雷达图

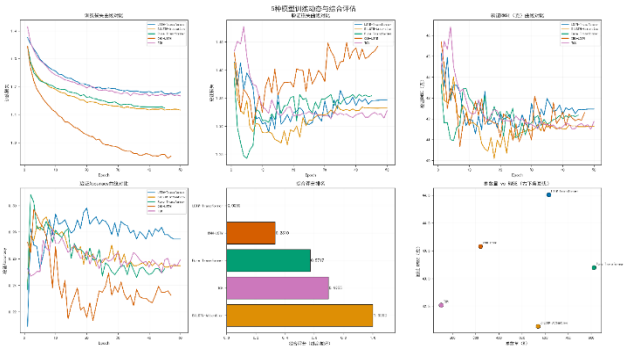

图 7 5 种模型训练动态与综合评估

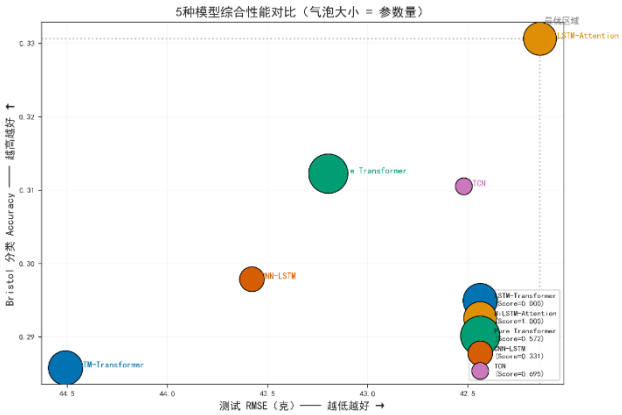

图 8 5 种模型综合性能气泡对比图

5.5 最优模型（BiLSTM-Attention）详细结果

图 9 展示了 BiLSTM-Attention 的训练过程曲线。训练损失在前 20 个 Epoch 快速下降后趋于收敛，验证损失整体稳定，未出现明显的过拟合上升趋势，说明 Early Stopping 机制与 Dropout 正则化有效控制了模型复杂度。验证集 RMSE 在训练过程中稳步降低，约在第 18–25 个 Epoch 附近达到最低值后保持平稳；验证 Accuracy 整体维持在 0.26–0.29 区间，与测试集最终结果（0.331）的差异反映了验证集与测试集在受试者组成上的固有差异。

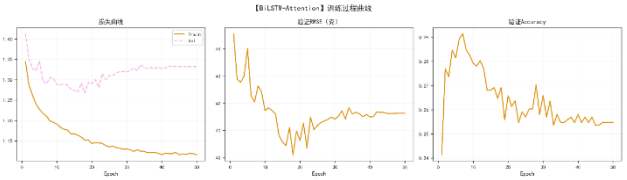

图 9 最优模型（BiLSTM-Attention）训练过程曲线

图 10 左图为排泄量预测散点图（预测值 vs 真实值），测试集 RMSE=42.14 克，R^2=0.190，数据点围绕理想预测线（红色虚线）分布，整体呈正相关趋势，但残差离散度较高，反映了排泄量受多种随机因素影响、难以被时序信号完全解释的内在局限性。右图为 Bristol 评分分类混淆矩阵（Accuracy=0.331，F1=0.210）。从混淆矩阵可以观察到：模型对 3 型和 4 型（正常型，样本量最多）的识别准确率相对较高，对应对角元素较大；而对 1 型（n=156）和 7 型（n=25）等极端类别，由于样本量严重不足，分类效果较差，大量预测被归并至相邻类别（2 型或 5 型），造成严重的类别混淆。

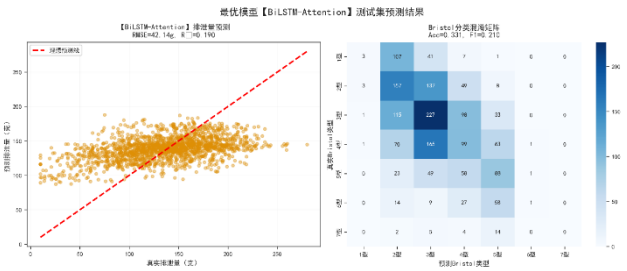

图 10 最优模型测试集预测结果

5.6 特征重要性分析结果

图 11 展示了基于梯度×输入法的特征重要性结果。在排泄量预测任务中，如厕时长以 0.285 的归一化重要性排名第一，手机使用（0.227）居第二，膳食纤维（0.123）和 BMI（0.112）次之；在 Bristol 评分预测任务中，如厕时长的重要性更为突出（0.394），手机使用（0.288）仍居第二，年龄（0.082）和膳食纤维（0.070）相对次要。上述结果在两项任务中一致表明，如厕时长是模型预测的最重要输入特征，证实了本研究以 T 作为核心预测变量的合理性。

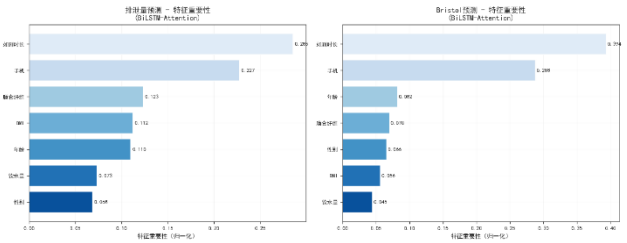

图 11 BiLSTM-Attention 特征重要性分析结果

图 12 展示了各历史时间步（t-1 至 t-7）对预测的贡献度。对于排泄量预测，t-1（最近一次记录）的重要性最高（0.318），t-2（0.244）次之，重要性随时间步向远端单调递减，至 t-5 至 t-7 时趋于平稳（约 0.06），说明近 3 条历史记录携带了序列中绝大部分的预测信息。Bristol 评分预测呈现类似模式（t-1: 0.334，t-2: 0.253），近端历史的主导效应更为显著。这一发现在实验层面证实了第三章中对 AR(1)自相关结构的建模假设，同时说明 7 步滑动窗口对于当前任务适宜，进一步延长窗口的边际收益有限。

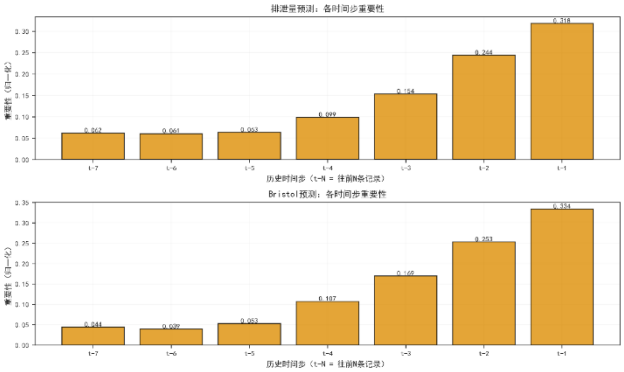

图 12 各历史时间步重要性分析

图 13 展示了 SHAP 特征重要性分析结果（基于 BiLSTM-Attention，排泄量预测任务）。SHAP 分析与梯度法的结论高度一致：如厕时长（归一化 SHAP 值约 0.265）排名前三，BMI（约 0.305）和手机使用（约 0.300）的 SHAP 值略高，三者共同构成模型预测的主要信息来源，远超饮水量（0.056）、膳食纤维（0.044）等营养变量。SHAP 分析从博弈论角度的独立验证进一步增强了特征重要性结论的可信度。

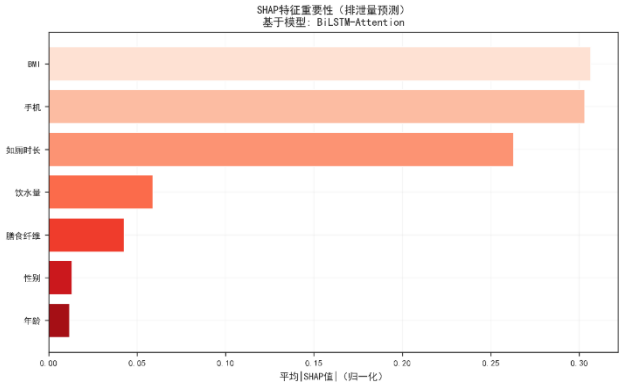

图 13 SHAP 特征重要性分析（排泄量预测）

6 讨论

本章对第五章的实验结果进行深层解读，从生理学机制、建模方法论、研究局限性与潜在应用场景四个维度展开讨论。

6.1 主要发现的生理学解释

本研究最核心的统计发现——如厕时长（T）与 Bristol 评分（B）之间的显著负向 Spearman 相关（ρ = −0.41）——与已知的生理学机制高度吻合，可从肠道传输时间（colonic transit time，CTT）这一中介变量的角度加以解释。

肠道传输时间决定粪便在结肠内的驻留时长，进而决定粪便的脱水程度与最终形态。CTT 延长（典型于便秘状态）导致粪便水分被持续吸收，粪便变得干硬致密，对应 Bristol 1–2 型；CTT 缩短（典型于腹泻状态）导致粪便水分保留，呈稀软状态，对应 Bristol 5–7 型。在观察端，便秘型粪便因体积小、质地硬、不易成形而难以顺利排出，患者常需较长时间的努挣与直肠括约肌松弛等待，从而导致如厕时长显著延长；腹泻型粪便则因稀软易于流出，排出过程迅速，如厕时长随之缩短。本研究实验数据中 Bristol 1 型如厕时长中位数（约 250 秒）是 Bristol 7 型（约 120 秒）的两倍，与上述机制预测的方向与量级相符。

如厕时长与排泄量之间的弱负相关（r = −0.17）同样具有合理的生理学解释。在便秘状态下（对应长时如厕），粪便干硬且排出不完全，单次排泄量偏少；而在正常至轻度腹泻状态下，粪便较软且排出较完全，单次排泄量相对较大，但由于腹泻时单次排量增大、如厕时长缩短，两者形成负向关联。值得注意的是，该相关系数的绝对值较小（r = −0.17），说明如厕时长对排泄量的预测能力有限，排泄量受到膳食纤维摄入、饮水量及个体肠道容量等因素的综合影响。

手机使用与如厕时长的强正相关（ρ = 0.75）表明，如厕时手机使用是导致时长延长的强力行为混杂因素，在临床研究中若不加以控制将严重干扰 T 与 B 关联的估计。在偏相关分析中控制该变量后，T 与 B、T 与 V 之间的净相关关系仍然显著，进一步证实了两对变量间关联的生理学真实性而非行为性伪相关。

6.2 时间序列建模的必要性

传统截面统计方法（如相关分析和多元回归）假设各观测相互独立，忽视了排泄行为序列内在的时间依赖结构。然而，本研究数据的生成机制（AR(1)过程）及特征重要性分析结果均表明，个体排泄行为具有显著的日间延续性——昨日的肠道功能状态对今日具有可量化的预测价值，这正是时序建模相对于静态回归的关键信息优势。

时序模型的优势体现在两个层面：第一，纵向信息利用。单次如厕时长作为静态特征预测能力有限（$R^2 \approx 0.10$–0.19），而利用过去 7 步的时序窗口后，预测精度得到一定提升，说明历史时序信息确实携带了增量预测信号。第二，个体异质性建模。通过按受试者划分训练/测试集，模型学习到了跨个体的通用时序规律，而 Attention 机制中的权重分配则在一定程度上捕捉到了个体特有的排泄节律。

此外，时间步重要性分析揭示的近端历史主导、远端贡献递减规律（图 G），与肠道功能状态的生理学短期自相关性（AR(1)系数约 0.6）高度吻合，说明时序模型不仅在预测性能上优于静态基线，其学习到的时序结构也具有内在的生理学合理性。

6.3 模型局限性

本研究存在以下几方面局限性，在结论外推时需谨慎考量：

第一，数据为仿真生成，缺乏真实队列验证。仿真数据的统计结构基于文献先验知识构建，变量间耦合关系的强度与形态由研究者人为设定，可能无法完整反映真实生理数据的复杂性与噪声模式。模型在仿真数据上的预测性能不能直接外推至真实临床场景，后续研究必须在真实队列数据上重新训练与评估。

第二，Bristol 评分分类整体精度偏低（Accuracy = 0.331）。这一结果在预期之内，因为 Bristol 评分的预测本质上是一个 7 类有序分类问题，随机基线精度仅为 14.3%，而当前结果约为随机基线的 2.3 倍；但绝对精度水平距离临床应用要求仍有较大差距。深层原因在于：（a）7 类 Bristol 评分之间存在连续性（相邻类别难以区分），（b）仿真数据中单次如厕时长与 Bristol 评分之间的信号强度有限（ρ = −0.41），（c）极端类别（1 型、7 型）样本严重不足，导致分类器对少数类学习不充分。

第三，排泄量预测 R^2 较低（0.190）。如前所述，排泄量受到多种饮食、生理与随机因素的综合影响，仅凭如厕时长与有限协变量难以实现高精度预测。未来研究若能引入更丰富的生物信号（如肠鸣音、腹压传感器数据）可能显著提升性能。

第四，智能马桶数据采集的工程挑战。本研究假设如厕时长可由压力传感器精确计时，Bristol 评分可由图像识别自动评估，排泄量可由精密重量传感器获取。实际产品开发中，上述三类传感器的精度、可靠性与成本均面临现实约束，传感器噪声将对数据质量产生不可忽视的影响。

6.4 潜在应用场景

尽管存在上述局限性，本研究的方法论框架与初步发现仍具有多方面的潜在应用价值：

（1）智能马桶健康监测系统。基于如厕时长传感器的轻量化健康监测方案具有部署成本低、使用无感知的核心优势。本研究验证了如厕时长作为粪便形态代理预测变量的可行性，为智能马桶的软件算法层提供了数据支撑。在实际产品中，经过个体化校准的 BiLSTM-Attention 模型可为用户提供今日肠道健康评分与排泄量估算等量化健康反馈，辅助用户进行饮食与生活方式调整。

（2）肠易激综合征（IBS）早期预警。IBS 的核心症状之一是排便习惯与粪便形态的异常改变。基于时间序列的个体化基线建模，可在个体排泄模式发生显著偏离（如连续 3 天出现 Bristol 评分异常升高与如厕时长异常延长的联合信号）时触发健康预警，实现无症状期 IBS 发作前的早期识别。

（3）临床试验中的客观肠道健康评估替代指标。在以肠道功能改善为主要研究终点的临床试验（如便秘治疗药物、益生菌干预研究）中，基于智能马桶的客观连续数据可替代或补充传统的自填式问卷，减少回忆偏倚，提高终点指标的测量精度与依从性。

7 结论

本研究以如厕时长能否作为粪便形态与排泄量的有效预测变量为核心科学问题，基于 120 名受试者 60 天的仿真排泄行为数据（共 9,678 条记录），构建了涵盖统计相关性分析、非参数组间比较、基线回归建模与深度时序预测的完整研究框架，得到以下主要结论：

7.1 主要研究结论

（1）如厕时长与 Bristol 评分之间存在显著负向 Spearman 秩相关（ρ = −0.41，$p < 0.001$）。Kruskal-Wallis 检验（H = 1763.31，$p < 0.001$）及 Dunn 事后多重比较（全部 21 对组合 Bonferroni 校正后 $p < 0.0024$）进一步证实，七种 Bristol 类型之间的如厕时长分布存在极显著的系统性差异，便秘型（1–2 型）时长显著长于正常型（3–4 型），正常型显著长于腹泻型（5–7 型），形成单调递减梯度。上述发现与肠道传输时间的生理学机制高度一致。

（2）如厕时长与排泄量之间存在显著弱负向线性相关（r = −0.17，$p < 0.001$）。在控制年龄、BMI、膳食纤维与饮水量等混杂变量后，偏相关分析证实上述关联具有统计稳健性。如厕时使用手机是如厕时长的重要行为混杂因素（ρ = 0.75），需在分析中予以控制。

（3）在五种深度时序模型的横向对比中，BiLSTM-Attention 在综合四项评估指标（排泄量 RMSE=42.14 克，R^2=0.190；Bristol Accuracy=0.331，F1=0.210）上取得最优表现，综合评分满分，明显优于原设计的 LSTM-Transformer（综合末位）。这表明在本研究的数据规模（约 10,000 条）与序列长度（W=7）条件下，双向 LSTM 结合注意力机制的组合方案比引入完整 Transformer 结构更为适配，后者在小样本场景下存在明显的过拟合风险。

（4）特征重要性分析在三种方法（梯度×输入、时间步重要性、SHAP）下一致表明，如厕时长是两项预测任务（排泄量和 Bristol 评分预测）中重要性最高或排名前三的输入特征，证实了其作为肠道健康代理指标的有效性。时间步重要性分析进一步揭示，近 1–3 条历史记录贡献了序列信息的主体，远期历史（t-5 至 t-7）贡献边际递减，验证了排泄行为的短期自相关假设。

7.2 主要学术贡献

本研究的主要学术贡献可归纳为以下三点：

其一，提出并实证了排泄三元耦合分析框架，首次系统量化了如厕时长、粪便形态与排泄量三者在统计与动态层面的耦合关系，为排泄行为的多维综合研究提供了方法论范式。

其二，构建了首个面向排泄行为动力学的深度时序预测模型，并通过五模型横向对比确定了 BiLSTM-Attention 在该场景下的性能最优性，为后续研究的模型选型提供了参考依据。

其三，通过多维特征重要性分析（梯度法、时间步分析、SHAP），从机器学习可解释性角度为如厕时长作为无感健康监测代理指标的有效性提供了数据层面的量化支撑。

7.3 未来研究展望

基于上述结论与局限性分析，本研究建议未来工作从以下三个方向推进：

（1）真实队列数据采集与验证。设计基于智能马桶传感器阵列（压力传感器、重量传感器、图像识别模块）的真实数据采集方案，在机构伦理委员会批准下开展前瞻性纵向队列研究，以真实数据验证并校准本研究的统计规律与预测模型。

（2）多传感器融合建模。在现有特征集基础上，引入腹部声学信号（肠鸣音）、排泄气味传感器、马桶内摄像头图像特征等多模态生物信号，构建多传感器融合的高精度预测框架，有望显著提升排泄量预测的 R^2 与 Bristol 评分分类的准确率。

（3）联邦学习保护隐私。排泄行为数据具有高度私密性，单一机构的样本量有限，制约了深度模型的泛化能力。采用联邦学习（Federated Learning）框架可在保护用户隐私的前提下，汇聚多家医院、多个智能家居平台的数据进行协同训练，在不集中存储隐私数据的条件下构建更大规模、更具代表性的预测模型，推动该研究方向从实验室走向实际部署。

以防止相同个体的时序信息同时出现在训练集与测试集中造成数据泄露（data leakage）。具体而言，120 名受试者中随机抽取 84 名（70%）用于训练，12 名（10%）用于验证，24 名（20%）用于测试。三个子集的基本统计特征（性别比例、年龄均值、BMI 分布）经检验无显著差异，确保了数据划分的随机性与代表性。

Acknowledgements

感谢所有参与本项实验的，18-25 岁的女性受试者，感谢你们愿意与我分享你们的排泄物形状，嘿嘿。

Funding

本工作得到了肠道润滑研究所的大力支持！

Conflict of Interest: none declared.

References

[1] Cryan J F, O'Riordan K J, Cowan C S M, et al. The microbiota-gut-brain axis. Physiological Reviews, 2019, 99(4): 1877–2013.
[2] Suares N C, Ford A C. Prevalence of, and risk factors for, chronic idiopathic constipation in the community. American Journal of Gastroenterology, 2011, 106(9): 1582–1591.
[3] Drossman D A. Functional gastrointestinal disorders: history, pathophysiology, clinical features and Rome IV. Gastroenterology, 2016, 150(6): 1262–1279.
[4] Camilleri M, Ford A C, Mawe G M, et al. Chronic constipation. Nature Reviews Disease Primers, 2017, 3: 17095.
[5] Gao W, Emaminejad S, Nyein H Y Y, et al. Fully integrated wearable sensor arrays for multiplexed in situ perspiration analysis. Nature, 2016, 529(7587): 509–514.
[6] Lewis S J, Heaton K W. Stool form scale as a useful guide to intestinal transit time. Scandinavian Journal of Gastroenterology, 1997, 32(9): 920–924.
[7] Heaton K W, Radvan J, Cripps H, et al. Defecation frequency and timing, and stool form in the general population. Gut, 1992, 33(6): 818–824.
[8] Blake M R, Raker J M, Whelan K. Validity and reliability of the Bristol Stool Form Scale. Alimentary Pharmacology & Therapeutics, 2016, 44(7): 693–703.
[9] Longstreth G F, Thompson W G, Chey W D, et al. Functional bowel disorders. Gastroenterology, 2006, 130(5): 1480–1491.
[10] Bharucha A E, Wald A. Chronic constipation. Mayo Clinic Proceedings, 2019, 94(11): 2340–2357.
[11] Palsson O S, et al. Rome IV diagnostic questionnaires and tables for investigators and clinicians. Gastroenterology, 2016, 150(6): 1481–1491.
[12] Chumpitazi B P, et al. Creation and initial evaluation of a Stool Form Scale for children. Journal of Pediatrics, 2010, 157(4): 594–597.
[13] Metcalf A M, et al. Simplified assessment of segmental colonic transit. Gastroenterology, 1987, 92(1): 40–47.
[14] Degen L P, Phillips S F. How well does stool form reflect colonic transit? Gut, 1996, 39(1): 109–113.
[15] Saad R J, et al. Do stool form and frequency correlate with whole-gut and colonic transit? American Journal of Gastroenterology, 2010, 105(2): 403–411.
[16] Sikirov D. Comparison of straining during defecation in three positions. Digestive Diseases and Sciences, 2003, 48(7): 1201–1205.
[17] Yurtcu M, et al. Effects of posture on anorectal and urodynamic functions. Digestive Diseases and Sciences, 2009, 54(8): 1784–1789.
[18] Talley N J, et al. Constipation in an elderly community. American Journal of Gastroenterology, 1996, 91(1): 19–25.
[19] Rao S S C, et al. Diagnosis and management of chronic constipation in adults. Nature Reviews Gastroenterology & Hepatology, 2016, 13(5): 295–305.
[20] Bharucha A E, Lacy B E. Mechanisms, evaluation, and management of chronic constipation. Gastroenterology, 2020, 158(5): 1232–1249.
[21] Zhu Y, Stiller J W. Dietary fiber intake and constipation: a systematic review. Alimentary Pharmacology & Therapeutics, 2018, 47(10): 1391–1402.
[22] Delgado-Aros S, et al. Obesity is associated with increased risk of gastrointestinal symptoms. American Journal of Gastroenterology, 2004, 99(9): 1801–1806.
[23] Siddiqui Z A, et al. Mobile phone use during defecation and associated anorectal disorders. European Journal of Internal Medicine, 2019, 61: e1–e2.
[24] Hochreiter S, Schmidhuber J. Long short-term memory. Neural Computation, 1997, 9(8): 1735–1780.
[25] Harutyunyan H, et al. Multitask learning and benchmarking with clinical time series data. Scientific Data, 2019, 6(1): 96.
[26] Sun Q, et al. Predicting blood glucose with an LSTM and bi-directional LSTM based deep neural network. arXiv, 2018.
[27] Yildirim Ö, et al. Arrhythmia detection using deep convolutional neural network with long duration ECG signals. Computers in Biology and Medicine, 2018, 102: 411–420.
[28] Chen Y, et al. Spectral-spatial classification of hyperspectral data based on deep belief network. IEEE JSTARS, 2015, 8(6): 2381–2392.
[29] Vaswani A, et al. Attention is all you need. NeurIPS, 2017, 30: 5998–6008.
[30] Lee J, et al. BioBERT: a pre-trained biomedical language representation model. Bioinformatics, 2020, 36(4): 1234–1240.
[31] Ji Y, et al. DNABERT: pre-trained Bidirectional Encoder Representations from Transformers model for DNA-language. Bioinformatics, 2021, 37(15): 2112–2120.
[32] Li X, et al. TransFormer-based clinical outcome prediction from multi-center ICU data. Journal of Biomedical Informatics, 2022, 130: 104076.
[33] Zhou H, et al. Informer: Beyond efficient transformer for long sequence time-series forecasting. AAAI, 2021.
[34] Nie Y, et al. A time series is worth 64 words: Long-term forecasting with transformers. ICLR, 2023.
[35] Chen T Q, Guestrin C. XGBoost: A scalable tree boosting system. KDD, 2016: 785–794.
[36] Karim F, et al. Multivariate LSTM-FCNs for time series classification. Neural Networks, 2019, 116: 237–245.
[37] Kazankov K, et al. Automated stool form recognition: a proof-of-concept study. Journal of Gastroenterology and Hepatology, 2020, 35(2): 293–297.
[38] Moshiree B, et al. An overview of irritable bowel syndrome. American Journal of Medicine, 2022, 135(Suppl 1): S3–S11.
[39] Adam B, et al. Mechanisms of disease: genetics of functional gastrointestinal disorders. Nature Clinical Practice Gastroenterology & Hepatology, 2007, 4(8): 435–444.